

Cássio Silva Takarada

**Complexidade estatística dos pesos como
indicador de overfitting independente do
conjunto de validação**

Ribeirão Preto

2026

Cássio Silva Takarada

Complexidade estatística dos pesos como indicador de overfitting independente do conjunto de validação

Projeto de pesquisa apresentado ao Programa de Pós-Graduação em Computação Aplicada da Faculdade de Filosofia, Ciências e Letras de Ribeirão Preto da Universidade de São Paulo.

Universidade de São Paulo
Faculdade de Filosofia, Ciências e Letras de Ribeirão Preto
Departamento de Computação e Matemática

Orientador: Prof. Dr. Luiz Otávio Murta Junior

Ribeirão Preto
2026

Resumo

O diagnóstico de *overfitting* em redes neurais profundas depende hoje, integralmente, de um conjunto de validação rotulado, representativo e suficientemente grande — condição frequentemente inviável em imagens médicas, onde a anotação é cara e exige especialista. Este projeto investiga se medidas de complexidade estatística calculadas *exclusivamente sobre os pesos* da camada densa de uma rede, sem acesso a rótulo algum, fornecem ao desenvolvedor uma leitura do estado do treinamento independente da validação. São consideradas a complexidade LMC, a entropia amostral unidimensional (SampEn) e a entropia amostral bidimensional (SampEn2D), acompanhadas ao longo das épocas de treino. Resultados preliminares com a rede ResNet-18 sobre o repositório MedNIST, em oito pares de execuções com e sem corrupção controlada de rótulos, indicam que a SampEn2D da camada densa inflete, em média, $7,5 \pm 0,9$ épocas antes da degradação da acurácia de validação, com razão de amplitude de 5,7 vezes entre execuções com e sem memorização ($p = 0,00016$), enquanto a complexidade LMC não discrimina as duas condições ($p = 0,33$). Pretende-se consolidar esses achados, caracterizar os limites de generalização entre arquiteturas e entregar um monitor acoplável a qualquer laço de treinamento em PyTorch. **Palavras-chave:** complexidade estatística; entropia amostral; *overfitting*; aprendizado profundo; imagens médicas.

Sumário

Sumário	3
1 PROPOSTA	5
1.1 Contextualização e Motivação	5
1.2 Problema de Pesquisa	5
1.3 Hipótese	6
1.4 Objetivos	6
1.4.1 Objetivo Geral	6
1.4.2 Objetivos Específicos	6
1.5 Justificativa: o ponto de vista do desenvolvedor	7
1.5.1 A dependência atual dos dados rotulados	7
1.5.2 O que muda com um indicador calculado sobre os pesos	7
1.5.3 Casos de uso concretos	7
1.5.4 Entrega prática	8
1.6 Visão Geral da Metodologia	8
1.7 Contribuição Esperada	8
2 CONTEÚDO TEÓRICO	9
2.1 Complexidade Estatística	9
2.1.1 Entropia de Shannon e a insuficiência da desordem	9
2.1.2 Complexidade LMC	9
2.2 Entropia Amostral	10
2.2.1 Formulação unidimensional	10
2.2.2 Extensão bidimensional	10
2.2.3 Entropia multiescala	11
2.3 A Camada Densa como Objeto de Medida	11
2.3.1 Por que a camada densa	11
2.3.2 O caminho e a ordem de achatamento	11
2.4 Definição Operacional de <i>Overfitting</i>	12
2.5 Síntese	12
3 ESTADO DA ARTE	14
3.1 Memorização e Generalização em Redes Profundas	14
3.2 Métricas de Generalização a partir dos Pesos	15
3.3 Medidas de Complexidade Aplicadas a Redes Neurais	15
3.4 Critérios de Parada	16

3.5	Síntese e Posicionamento da Proposta	16
4	RESULTADOS PRELIMINARES	17
4.1	Protocolo Experimental	17
4.2	Discriminação entre Memorização e Aprendizado	17
4.3	Antecedência em Relação à Degradação da Validação	18
4.4	Efeito do Nível de Corrupção	19
4.5	Generalização entre Arquiteturas: um Limite Identificado	19
4.6	Escolha da Âncora	20
4.7	Limitações dos Resultados Atuais	20
	REFERÊNCIAS	21

1 Proposta

1.1 Contextualização e Motivação

O aprendizado profundo consolidou-se como abordagem dominante em tarefas de classificação e segmentação de imagens médicas. Esse sucesso, contudo, apoia-se em uma premissa que a prática clínica raramente satisfaz: a disponibilidade de grandes conjuntos de dados anotados. Em imagens médicas, a anotação exige um especialista, é onerosa e lenta, e frequentemente esbarra em restrições éticas e de privacidade que limitam o compartilhamento entre instituições.

Essa escassez tem uma consequência metodológica pouco discutida. O procedimento padrão para decidir quando interromper o treinamento — o *early stopping* — monitora o erro em um conjunto de validação separado e interrompe o ajuste quando esse erro deixa de diminuir (PRECHELT, 1998). O procedimento é sólido, mas transfere para o conjunto de validação toda a responsabilidade pelo diagnóstico: se ele é pequeno, desbalanceado ou pouco representativo, a estimativa do momento de parada torna-se ruidosa, e o desenvolvedor não dispõe de nenhum sinal alternativo para confrontá-la. Em outras palavras, justamente no regime de poucos dados — aquele em que o *overfitting* é mais provável — o instrumento de medida é o menos confiável.

Há, entretanto, uma fonte de informação sobre o estado do treinamento que permanece pouco explorada e que não depende de rótulo algum: os próprios pesos da rede. A memorização de exemplos deixa marcas na distribuição de valores dos parâmetros, e trabalhos consolidados mostram que redes profundas são capazes de ajustar rótulos completamente aleatórios (ZHANG et al., 2017), memorizando-os por um regime de aprendizado distinto daquele em que extraem padrões generalizáveis (ARPIT et al., 2017). Se esses dois regimes deixam assinaturas distinguíveis na estrutura dos pesos, então medidas de complexidade estatística aplicadas a esses pesos podem, em princípio, sinalizar a transição entre eles sem consultar nenhum dado rotulado.

1.2 Problema de Pesquisa

É possível detectar o início do *overfitting* de uma rede neural profunda a partir exclusivamente da complexidade estatística de seus pesos, sem recorrer a um conjunto de validação rotulado?

1.3 Hipótese

A hipótese central deste trabalho é a de que a transição do regime de aprendizado generalizante para o regime de memorização produz uma mudança mensurável na irregularidade estrutural dos pesos da camada densa, e que essa mudança *antecede* a degradação observável no conjunto de validação.

Operacionalmente, espera-se que, em execuções nas quais o *overfitting* é induzido de forma controlada, ao menos um dos indicadores considerados apresente inflexão em uma época anterior àquela em que a acurácia de validação começa a cair de modo sustentado, e que essa inflexão não ocorra — ou ocorra de forma substancialmente atenuada — em execuções de controle sem indução. A hipótese é falsificável: caso a inflexão ocorra simultaneamente ou posteriormente à degradação da validação, ou caso ocorra com a mesma intensidade nas execuções de controle, o indicador não tem valor como aviso antecipado e isso deve ser reportado como tal.

1.4 Objetivos

1.4.1 Objetivo Geral

Avaliar a complexidade estatística dos pesos de redes neurais profundas como indicador de *overfitting* independente do conjunto de validação, entregando ao desenvolvedor um instrumento de diagnóstico acoplável ao laço de treinamento.

1.4.2 Objetivos Específicos

1. Implementar, em um módulo único e validado numericamente, a complexidade LMC, a entropia amostral unidimensional (SampEn) e a entropia amostral bidimensional (SampEn2D), estabelecendo-o como fonte única de cálculo para todo o trabalho.
2. Formalizar a leitura dos pesos da camada densa como objeto de medida, fixando a ordem de achatamento da matriz de pesos e justificando-a experimentalmente.
3. Definir operacionalmente o início do *overfitting* e construir um protocolo de indução controlada por corrupção de rótulos, com execuções de controle pareadas.
4. Implementar um monitor que calcule os indicadores a cada época durante o treinamento e emita um estado do aprendizado em tempo real.
5. Quantificar a antecendência de cada indicador em relação à degradação da validação, com múltiplas sementes e teste de significância.
6. Caracterizar os limites do indicador quanto ao nível de corrupção e quanto à arquitetura da rede, reportando explicitamente os regimes em que ele falha.

1.5 Justificativa: o ponto de vista do desenvolvedor

A justificativa deste trabalho é deliberadamente formulada do ponto de vista de quem treina a rede, e não apenas do ponto de vista teórico.

1.5.1 A dependência atual dos dados rotulados

Para saber se uma rede aprendeu ou apenas memorizou, o desenvolvedor depende hoje inteiramente dos dados. É preciso construir conjuntos de treino, validação e teste que sejam bem particionados, corretamente rotulados e representativos da população de interesse. Cada um desses requisitos custa tempo e dinheiro, e em imagens médicas frequentemente esbarra na indisponibilidade de especialistas para anotação. O diagnóstico do treinamento é, portanto, uma função do orçamento de anotação — não uma propriedade que se possa ler diretamente do modelo.

1.5.2 O que muda com um indicador calculado sobre os pesos

Os indicadores investigados neste trabalho são calculados exclusivamente a partir dos pesos da rede. Não consomem imagem, não consomem rótulo e não dependem de nenhuma partição. Se forem capazes de sinalizar a transição para o regime de memorização, o desenvolvedor passa a dispor de uma segunda leitura do treinamento, obtida por um caminho independente daquele do conjunto de validação. As duas leituras podem então ser confrontadas: quando concordam, a decisão de parada ganha confiança; quando discordam, há indício de que a validação não é representativa.

1.5.3 Casos de uso concretos

1. **Decidir quando parar.** Um aviso emitido antes da degradação observável na validação amplia a janela de decisão do desenvolvedor, em vez de constatar a perda depois de consumada.
2. **Economizar computação.** Detectar que a rede deixou de aprender evita épocas de treinamento que não trarão ganho, com impacto direto em custo de GPU.
3. **Comparar arquiteturas sem ampliar a anotação.** Como a medida não consome dados rotulados, a comparação entre arquiteturas candidatas não exige a ampliação do conjunto de validação.
4. **Diagnosticar com validação pequena.** Em cenários nos quais o conjunto de validação é pequeno demais para ser confiável, um indicador independente oferece evidência adicional — exatamente o cenário típico em imagens médicas.

1.5.4 Entrega prática

A contribuição não se esgota na constatação empírica. Entrega-se um monitor implementado em PyTorch, acoplável ao laço de treinamento de terceiros, que calcula os indicadores a cada época e devolve um estado do aprendizado. O custo computacional é baixo, pois a medida incide apenas sobre a camada densa.

1.6 Visão Geral da Metodologia

O trabalho experimental organiza-se em torno da comparação pareada entre execuções com e sem *overfitting* induzido. A indução é feita por corrupção controlada de uma fração dos rótulos do conjunto de treino, procedimento que força a rede a memorizar exemplos inconsistentes (ZHANG et al., 2017). Cada execução com corrupção possui uma execução de controle correspondente, idêntica em arquitetura, partição e semente de inicialização, diferindo apenas pela presença da corrupção — de modo que a semente que governa o ruído é separada daquela que governa a partição e a inicialização.

Durante o treinamento, um monitor calcula a cada época a LMC, a SampEn e a SampEn2D sobre os pesos da camada densa. Ao final, compara-se a época em que cada indicador inflete com a época em que a acurácia de validação passa a cair de forma sustentada, definida como âncora. A diferença entre as duas é a antecedência, positiva quando o indicador avisa antes. A significância é avaliada por teste não paramétrico entre os grupos com e sem corrupção, escolhido pelo tamanho reduzido das amostras.

O detalhamento reprodutível — repositório de imagens, arquiteturas, hiperparâmetros, partição congelada e critério de inflexão — constitui o capítulo de metodologia do documento final.

1.7 Contribuição Esperada

Espera-se contribuir em três frentes. Do ponto de vista científico, caracterizar empiricamente se e quando medidas de complexidade estatística sobre pesos antecipam o *overfitting*, incluindo a delimitação honesta dos regimes em que não o fazem. Do ponto de vista metodológico, formalizar a leitura dos pesos de uma camada densa como objeto de medida de complexidade, questão até aqui tratada de modo implícito na literatura. Do ponto de vista prático, disponibilizar um monitor documentado e testado, utilizável por terceiros independentemente deste trabalho.

2 Conteúdo Teórico

Este capítulo reúne os conceitos necessários para acompanhar as escolhas metodológicas e a leitura dos resultados. A Seção 2.1 apresenta a noção de complexidade estatística e a formulação LMC. A Seção 2.2 define a entropia amostral e sua extensão bidimensional. A Seção 2.3 justifica a escolha da camada densa como objeto de medida e formaliza a leitura de seus pesos como sequência. A Seção 2.4 fixa a definição operacional de *overfitting* adotada.

2.1 Complexidade Estatística

2.1.1 Entropia de Shannon e a insuficiência da desordem

Dada uma variável discreta com distribuição de probabilidade $P = \{p_1, \dots, p_N\}$, a entropia de Shannon (SHANNON, 1948) é

$$H(P) = - \sum_{i=1}^N p_i \ln p_i. \quad (2.1)$$

A entropia mede desordem: é nula quando toda a probabilidade concentra-se em um único estado e máxima, igual a $\ln N$, quando a distribuição é uniforme. Por isso, isoladamente, ela não serve como medida de complexidade. Um cristal perfeito tem entropia mínima e um gás ideal tem entropia máxima, mas nenhum dos dois é estruturalmente complexo: o primeiro é totalmente previsível, o segundo totalmente aleatório. A complexidade que interessa está entre os dois extremos.

2.1.2 Complexidade LMC

López-Ruiz, Mancini e Calbet (1995) resolvem esse problema introduzindo um segundo termo, o desequilíbrio, que mede a distância quadrática da distribuição observada em relação à distribuição uniforme $P_e = \{1/N, \dots, 1/N\}$:

$$D(P) = \sum_{i=1}^N \left(p_i - \frac{1}{N} \right)^2. \quad (2.2)$$

A complexidade LMC é o produto dos dois termos, com a entropia normalizada pelo seu valor máximo:

$$C_{\text{LMC}}(P) = \frac{H(P)}{\ln N} \cdot D(P). \quad (2.3)$$

O produto na Equação 2.3 anula-se nos dois extremos e é máximo em distribuições intermediárias. No cristal, $H \rightarrow 0$ e o primeiro fator zera; no gás ideal, $P \rightarrow P_e$ e o

desequilíbrio zero. Uma discussão das propriedades e das limitações dessa formulação, incluindo variantes baseadas na divergência de Jensen-Shannon, encontra-se em Lamberti et al. (2004) e Rosso et al. (2010).

Duas propriedades são relevantes para este trabalho. A primeira é que C_{LMC} depende apenas do histograma dos valores, sendo portanto *invariante a qualquer permutação* da sequência analisada. A segunda, consequência da primeira, é que a LMC não pode captar nenhuma informação posicional: se a memorização se manifestar na organização espacial dos pesos e não na distribuição de seus valores, a LMC será cega a ela.

2.2 Entropia Amostral

2.2.1 Formulação unidimensional

A entropia amostral (RICHTMAN; MOORMAN, 2000) quantifica a irregularidade de uma sequência medindo com que frequência padrões semelhantes permanecem semelhantes quando estendidos por uma amostra. Ela corrige o viés de autocomparação presente na entropia aproximada de Pincus (1991).

Seja a série $\{u(1), \dots, u(L)\}$ e os vetores de janela $\mathbf{x}_m(i) = \{u(i), \dots, u(i + m - 1)\}$. Sejam B o número de pares de janelas de comprimento m cuja distância de Chebyshev é inferior à tolerância r , e A o número correspondente para janelas de comprimento $m + 1$. Define-se

$$\text{SampEn}(m, r, L) = -\ln \frac{A}{B}. \quad (2.4)$$

O parâmetro m é o comprimento do padrão comparado e r é a tolerância de similaridade, usualmente expressa como fração do desvio-padrão da série. Valores elevados de SampEn indicam baixa previsibilidade. A escolha de m e r não é neutra e afeta a estabilidade da estimativa, especialmente em séries curtas (YENTES et al., 2013); por isso este trabalho reporta a sensibilidade dos resultados a esses parâmetros.

Diferentemente da LMC, a entropia amostral *não* é invariante à ordem, pois compara janelas consecutivas. Essa é precisamente a propriedade que a torna complementar à LMC neste trabalho.

2.2.2 Extensão bidimensional

A entropia amostral bidimensional (SILVA et al., 2016) generaliza a Equação 2.4 substituindo as janelas unidimensionais por sub-matrizes $m \times m$ deslizantes sobre uma matriz, com a mesma lógica de contagem de pares similares. Preserva-se assim a vizinhança nas duas direções, em vez de destruí-la pelo achatamento. Sua formulação e validação em textura de imagens são discutidas em Silva et al. (2014) e Silva e Junior (2012).

Para este trabalho a SampEn2D é particularmente pertinente, pois a matriz de pesos de uma camada densa é um objeto naturalmente bidimensional — cada linha corresponde a um neurônio de saída e cada coluna a uma característica de entrada — e reduzi-la a um vetor descarta uma das duas estruturas.

2.2.3 Entropia multiescala

A entropia multiescala (COSTA; GOLDBERGER; PENG, 2002; COSTA; GOLDBERGER; PENG, 2005) aplica a entropia amostral a versões da série granuladas em escalas crescentes, obtidas pela média de blocos consecutivos não sobrepostos. O perfil resultante distingue sinais cuja irregularidade se mantém através das escalas daqueles em que ela se concentra na escala fina. Está implementada neste trabalho e prevista como extensão.

2.3 A Camada Densa como Objeto de Medida

2.3.1 Por que a camada densa

Em uma rede convolucional de classificação, as camadas convolucionais produzem uma representação da imagem e a camada densa final converte essa representação em pontuações por classe. É nela que a decisão é efetivamente tomada, e é nela que a associação entre representação e rótulo precisa ser armazenada. Se a rede memoriza pares imagem–rótulo inconsistentes, é razoável esperar que essa associação se inscreva de forma mais direta nos pesos dessa camada. A escolha tem ainda a vantagem prática de manter o custo do monitoramento baixo: na ResNet-18 aplicada a seis classes, a matriz de pesos tem forma 6×512 , totalizando 3072 parâmetros.

2.3.2 O caminho e a ordem de achatamento

Considere-se uma camada densa com M entradas $x_1, \dots, x_M$ e N neurônios $n_1, \dots, n_N$. A matriz de pesos é $W \in \mathbb{R}^{N \times M}$, e o elemento w_{ji} é o peso do *caminho* $x_i \rightarrow n_j$. Essa é exatamente a convenção do PyTorch, em que o atributo de pesos de uma camada linear tem forma $[N, M]$.

Como a entropia amostral unidimensional depende da ordem, é necessário fixar o percurso pelo qual a matriz é lida como sequência. Duas ordens são naturais. Na ordem *por neurônio*, percorrem-se todos os pesos que chegam a cada neurônio antes de passar ao seguinte:

$$v_n = (w_{11}, w_{12}, \dots, w_{1M}, w_{21}, \dots, w_{2M}, \dots, w_{NM}). \quad (2.5)$$

Na ordem *por entrada*, percorrem-se todos os pesos que partem de cada entrada:

$$v_x = (w_{11}, w_{21}, \dots, w_{N1}, w_{12}, \dots, w_{N2}, \dots). \quad (2.6)$$

As duas leituras não são equivalentes e medem coisas distintas: a Equação 2.5 avalia a regularidade *dentro do campo receptivo de cada neurônio*, enquanto a Equação 2.6 avalia a regularidade *da distribuição de uma mesma entrada entre os neurônios*. Adota-se a ordem por neurônio como convenção padrão, e a comparação entre as duas é reportada como ablação. Para a complexidade LMC a distinção é irrelevante, pela invariância discutida na Seção 2.1.

Por coerência com a noção de caminho, o vetor de viés é excluído da análise: o viés é um deslocamento aditivo do neurônio, não a ligação entre uma entrada e um neurônio. Quando há mais de uma camada densa, cada uma é analisada separadamente, sem concatenação.

2.4 Definição Operacional de *Overfitting*

Para que a antecedência de um indicador seja mensurável, é preciso uma definição de *overfitting* que produza um número de época, e não apenas uma descrição qualitativa. Adota-se a seguinte construção.

Seja $\text{val_loss}(e)$ a perda no conjunto de validação na época e . A melhor época é $e^* = \arg \min_e \text{val_loss}(e)$. O início do *overfitting* é a primeira época $e^{of} > e^*$ tal que $\text{val_loss}(e) > \text{val_loss}(e^*) + \delta$ de forma sustentada por um número pré-fixado de épocas consecutivas. Toda análise dos indicadores restringe-se às épocas $e \leq e^{of}$; as posteriores permanecem registradas e são exibidas nas figuras em região sombreada, mas não sustentam nenhuma conclusão.

Como referência temporal para o cálculo da antecedência utiliza-se uma âncora definida sobre a acurácia de validação — a época em que ela passa a cair de forma sustentada. A opção pela acurácia, e não pela perda, decorre de uma observação empírica relatada no Capítulo 4: em repositórios que saturam rapidamente, a perda de validação começa a subir muito cedo, mesmo em execuções sem memorização, o que a torna uma âncora pouco discriminativa.

A partição dos dados segue a separação em três conjuntos disjuntos. O conjunto de treino é o único que participa da retropropagação; o de validação é observado a cada época e nunca entra no gradiente; o de teste é consultado uma única vez, ao final, na época selecionada.

2.5 Síntese

Os conceitos aqui reunidos sustentam a proposta em três pontos. A complexidade LMC oferece uma leitura da distribuição de valores dos pesos, insensível à posição. A entropia amostral, uni e bidimensional, oferece uma leitura sensível à organização — e, no caso

bidimensional, preserva a estrutura de linhas e colunas da matriz de pesos. A formalização do caminho e da ordem de achatamento torna explícita uma escolha que, de outro modo, permaneceria arbitrária e não reprodutível.

3 Estado da Arte

Este capítulo discute os trabalhos que se aproximam do problema formulado no Capítulo 1. O critério de seleção foi a existência de alguma tentativa de caracterizar o estado de generalização de uma rede sem depender integralmente de um conjunto de teste rotulado, ou de caracterizar a transição entre aprendizado e memorização. A Seção 3.1 revisa o que se sabe sobre memorização em redes profundas. A Seção 3.2 discute métricas de generalização calculadas sobre os pesos. A Seção 3.3 trata da aplicação de medidas de complexidade a redes neurais. A Seção 3.4 revisa critérios de parada. A Seção 3.5 sintetiza e posiciona a proposta.

3.1 Memorização e Generalização em Redes Profundas

Zhang et al. (2017) demonstraram experimentalmente que redes convolucionais de grande porte ajustam perfeitamente rótulos atribuídos ao acaso, e que esse comportamento persiste mesmo sob regularização explícita. O resultado é qualitativamente importante para este trabalho por duas razões: estabelece que a capacidade de memorização não é um acidente, mas uma propriedade das arquiteturas usuais, e fornece o protocolo experimental — corrupção controlada de rótulos — que permite induzir memorização de forma reprodutível. A limitação, do ponto de vista aqui adotado, é que o diagnóstico continua dependendo da comparação entre desempenho de treino e de teste.

Arpit et al. (2017) refinam esse quadro ao mostrar que memorização e aprendizado de padrões não ocorrem simultaneamente: redes tendem a aprender primeiro as regularidades simples e só depois memorizam os exemplos ruidosos. A existência de dois regimes sucessivos, e não de um processo homogêneo, é o pressuposto que torna plausível a hipótese deste projeto — se há transição, pode haver assinatura da transição. Os autores, contudo, caracterizam os regimes por meio de métricas que dependem dos dados, e não da estrutura dos pesos.

Power et al. (2022) descrevem o fenômeno de *grokking*, em que a generalização ocorre muito depois do ajuste completo do treino, às vezes após longo período de estagnação da validação. O fenômeno é relevante aqui porque constitui um contraexemplo aos critérios ingênuos de parada antecipada: uma interrupção baseada apenas na estagnação da validação eliminaria justamente o regime em que a generalização acabaria emergindo. Um indicador que leia o estado interno da rede, e não apenas seu desempenho externo, é potencialmente capaz de distinguir estagnação de reorganização — questão que este trabalho deixa registrada como hipótese derivada, ainda não testada.

3.2 Métricas de Generalização a partir dos Pesos

Bartlett, Foster e Telgarsky (2017) propõem limites de generalização baseados em normas espectrais e margens, estabelecendo que propriedades geométricas dos pesos se relacionam com a capacidade de generalizar. Dziugaite e Roy (2017) obtêm, por via PAC-Bayesiana, limites não vacuosos para redes sobreparametrizadas. Ambos representam avanços substantivos, mas produzem limites válidos para um estado da rede, tipicamente o final do treinamento, e não uma leitura acompanhável ao longo das épocas.

Jiang et al. (2020) conduzem o estudo empírico mais sistemático dessa família, avaliando um grande conjunto de medidas candidatas quanto à sua correlação causal com a lacuna de generalização. A conclusão é cautelosa: muitas medidas teoricamente motivadas correlacionam-se mal com a generalização observada, e medidas baseadas em otimização desempenham-se melhor do que as baseadas em norma. Esse resultado impõe a este trabalho uma exigência metodológica clara — não basta exibir correlação entre indicador e *overfitting* em uma execução; é preciso demonstrar discriminação entre execuções com e sem memorização, com controles pareados.

Martin, Peng e Mahoney (2021) mostram que propriedades de cauda pesada do espectro das matrizes de pesos permitem prever tendências de qualidade de modelos sem acesso aos dados de treino ou de teste. Este é o trabalho mais próximo do objetivo aqui perseguido, e convém explicitar a diferença: a abordagem é *spectral*, apoiando-se nos autovalores das matrizes, ao passo que a abordagem deste projeto é *informação-teórica*, apoiando-se na distribuição de valores e na organização espacial dos pesos. Além disso, o alvo em Martin, Peng e Mahoney (2021) é comparar modelos já treinados, enquanto aqui o alvo é acompanhar a trajetória temporal de um único treinamento.

3.3 Medidas de Complexidade Aplicadas a Redes Neurais

A aplicação de medidas de entropia e complexidade ao estudo de redes neurais é mais recente e menos consolidada. Advani, Saxe e Sompolsky (2020) analisam a dinâmica do aprendizado em regime de alta dimensionalidade, caracterizando fases distintas do treinamento. Delgado-Bonal e Marshak (2019) revisam o uso de medidas de entropia em séries temporais e sistematizam a escolha de parâmetros, questão diretamente relevante para a estabilidade das estimativas aqui empregadas.

O que a revisão da literatura não localizou foi trabalho que acompanhe, época a época, medidas de complexidade estatística calculadas sobre os pesos de uma camada específica com o propósito explícito de emitir um aviso antecipado de *overfitting*, com controles pareados e quantificação da antecendência. Essa é a lacuna que o projeto endereça.

3.4 Critérios de Parada

Prechelt (1998) sistematizou os critérios automáticos de parada antecipada baseados em validação cruzada, avaliando empiricamente catorze critérios quanto a eficiência e eficácia. O trabalho permanece a referência metodológica da prática corrente e explicita seu próprio pressuposto: a decisão de parada é uma função do erro medido em dados separados. É exatamente esse pressuposto que este projeto procura relaxar, não substituindo o critério clássico, mas oferecendo uma segunda leitura obtida por caminho independente.

3.5 Síntese e Posicionamento da Proposta

Tabela 1 – Comparação dos trabalhos discutidos quanto à dependência de dados rotulados e à natureza temporal da leitura.

Trabalho	Objeto da medida	Precisa de rótulo	Leitura temporal	Avisa antes?
Prechelt (1998)	Erro de validação	Sim	Sim	Não
Zhang et al. (2017)	Desempenho	Sim	Não	Não
Arpit et al. (2017)	Desempenho	Sim	Sim	Não
Bartlett, Foster e Telgarsky (2017)	Norma espectral	Não	Não	Não
Dziugaite e Roy (2017)	Limite PAC-Bayes	Sim	Não	Não
Jiang et al. (2020)	Diversas	Sim	Não	Não
Martin, Peng e Mahoney (2021)	Espectro dos pesos	Não	Não	Não
Este trabalho	Complexidade dos pesos	Não	Sim	Sim

Fonte: Elaborado pelo autor.

A Tabela 1 organiza os trabalhos segundo dois eixos. O primeiro é a dependência de dados rotulados: apenas Bartlett, Foster e Telgarsky (2017) e Martin, Peng e Mahoney (2021) dispensam-nos, e ambos o fazem por via espectral. O segundo é a natureza temporal da leitura: das abordagens que dispensam rótulos, nenhuma foi concebida para acompanhar a trajetória do treinamento época a época.

A proposta deste trabalho situa-se na interseção ainda vazia desses dois eixos, e diferencia-se da literatura existente em três aspectos: (i) a medida é informação-teórica, incidindo sobre a distribuição de valores e sobre a organização espacial dos pesos, e não sobre seu espectro; (ii) a leitura é temporal, produzindo uma trajetória e não um escalar ao final do treino; e (iii) a validação é feita por controles pareados com indução explícita de memorização, em resposta direta à advertência metodológica de Jiang et al. (2020) quanto a correlações espúrias.

4 Resultados Preliminares

Este capítulo reporta os resultados já obtidos, suficientes para sustentar a viabilidade da proposta e, igualmente, para delimitar os regimes em que o indicador não se sustenta. Todos os números foram recalculados a partir dos registros por época das execuções, e não reproduzidos de análises anteriores.

4.1 Protocolo Experimental

Os experimentos utilizam o repositório MedNIST, com a arquitetura ResNet-18 (HE et al., 2016) e, para o teste de generalização entre arquiteturas, a DenseNet-121. A partição em treino, validação e teste é congelada e reutilizada entre execuções, de modo que a comparação entre elas não seja contaminada por variação de amostragem.

A memorização é induzida pela corrupção de uma fração dos rótulos do conjunto de treino, seguindo o protocolo de Zhang et al. (2017). Cada execução com corrupção possui uma execução de controle pareada, idêntica em tudo exceto pela ausência de corrupção. A semente que governa a corrupção é independente daquela que governa a partição e a inicialização — distinção necessária, pois, se ambas fossem a mesma, repetir o experimento com semente diferente reproduziria exatamente os mesmos rótulos errados e mediria sensibilidade à inicialização, não replicação.

O conjunto principal de resultados compreende oito execuções com corrupção de 30% dos rótulos e oito execuções de controle, todas com ResNet-18.

4.2 Discriminação entre Memorização e Aprendizado

A Tabela 2 apresenta a amplitude de variação de cada indicador ao longo do treinamento, comparada entre os dois grupos. A razão entre as médias é o que importa: um indicador que varia muito nas duas condições não informa nada sobre a memorização.

Tabela 2 – Amplitude de variação dos indicadores em execuções com corrupção de rótulos e em controles pareados ($n = 8$ por grupo). Valores como média $\pm$ desvio-padrão amostral; p obtido por teste de Mann-Whitney bilateral.

Indicador	Com corrupção	Controle	Razão	p
LMC	$1,219 \pm 0,055$	$1,153 \pm 0,130$	1,06	0,33
SampEn 1D	$0,205 \pm 0,018$	$0,056 \pm 0,009$	3,64	0,00016
SampEn2D	$0,340 \pm 0,061$	$0,060 \pm 0,008$	5,71	0,00016

Fonte: Elaborado pelo autor.

O resultado é assimétrico e merece ser lido com atenção. A complexidade LMC **não discrimina** as duas condições: a razão de 1,06 é compatível com ausência de efeito e o teste não rejeita a hipótese nula ($p = 0,33$). Como discutido na Seção 2.1, a LMC é invariante a permutações e lê apenas o histograma dos valores dos pesos; a interpretação mais econômica desse achado é que a memorização reorganiza os pesos sem alterar substancialmente a distribuição de seus valores.

As duas variantes de entropia amostral discriminam, e a bidimensional discrimina melhor. O valor $p = 0,00016$ é o menor alcançável pelo teste com $n = 8$ por grupo e corresponde à separação completa entre os grupos.

4.3 Antecedência em Relação à Degradação da Validação

A antecedência é a diferença, em épocas, entre a inflexão do indicador e a âncora definida sobre a acurácia de validação. A Tabela 3 reporta os valores obtidos.

Tabela 3 – Antecedência dos indicadores em relação à queda sustentada da acurácia de validação, em épocas, nas oito execuções com corrupção.

Indicador	Média $\pm$ desvio	IC 95 %	Discrimina?
SampEn2D	7,50 $\pm$ 0,93	[6,73; 8,27]	Sim
SampEn 1D	3,62 $\pm$ 1,06	[2,74; 4,51]	Sim
LMC	3,00 $\pm$ 1,85	[1,45; 4,55]	Não

Fonte: Elaborado pelo autor.

Registre-se que a antecedência da LMC não deve ser interpretada como resultado positivo: como a Tabela 2 mostra que o indicador não distingue as duas condições, a época de sua inflexão não constitui aviso de coisa alguma. A antecedência só é informativa para indicadores que discriminam.

A separação temporal da SampEn2D é limpa. Nas oito execuções com corrupção, o indicador inflete nas épocas $\{7, 7, 7, 7, 7, 7, 8, 9\}$; nos controles em que chega a inflectir, isso ocorre entre as épocas 13 e 31, e em duas das oito execuções de controle não há inflexão alguma dentro do horizonte de treinamento. Não há sobreposição entre as duas distribuições.




Figura 1 – Trajetória dos três indicadores e da validação em execução com corrupção de 30 % dos rótulos. A região sombreada corresponde às épocas posteriores ao início do *overfitting*, excluídas das conclusões.

Fonte: Elaborado pelo autor.

4.4 Efeito do Nível de Corrupção

Variou-se a fração de rótulos corrompidos em 15 %, 30 % e 50 %, com três sementes por nível. O resultado é instrutivo e não era o esperado.

A época em que o monitor emite o alerta é praticamente invariante ao nível de corrupção — médias de 10,0, 9,3 e 10,0 épocas para os três níveis, sem diferença estatisticamente detectável ($F = 1,00$; $p = 0,42$). O que se move é a âncora, isto é, o momento em que a degradação se torna visível na validação, que chega progressivamente mais cedo com mais corrupção ($F = 30,2$; $p = 0,0007$).

A consequência prática é que a antecedência encolhe à medida que a corrupção aumenta: aproximadamente 7,7 épocas a 15 %, 5,3 a 30 % e 3,0 a 50 %. A leitura que se propõe é que o indicador marca o *início* da memorização, cujo momento depende pouco da quantidade de rótulos errados, enquanto a validação mede o *sintoma*, que se manifesta tanto mais cedo quanto maior a corrupção. Trata-se de interpretação plausível, ainda não demonstrada, e que o trabalho pretende investigar.

4.5 Generalização entre Arquiteturas: um Limite Identificado

O experimento foi repetido com DenseNet-121, em três execuções com corrupção e três controles. Os resultados são parcialmente favoráveis e devem ser reportados com precisão.

A antecedência é preservada e de fato ampliada: a SampEn2D inflete 20, 21 e 17 épocas antes da âncora nas três execuções. Contudo, o poder de discriminação por amplitude **cai substancialmente**: a razão entre execuções com corrupção e controles é de 2,8 vezes, contra 5,71 na ResNet-18, e as demais medidas deixam de discriminar (1,3 para a SampEn 1D e 1,2 para a LMC). Com três execuções por grupo, não há poder estatístico para afirmar significância.

A conclusão honesta é que o achado central foi verificado em uma segunda arquitetura quanto à antecedência, mas não quanto à magnitude do contraste. Se isso decorre do tamanho da camada densa, da dinâmica de otimização própria da DenseNet ou simplesmente do número reduzido de execuções, é questão em aberto e consta entre os objetivos específicos deste projeto.

4.6 Escolha da Âncora

Um resultado metodológico merece registro. A primeira versão do monitor ancorava o diagnóstico na perda de validação. Nessa configuração, o monitor acusava *overfitting* em dez de dez execuções, incluindo todos os controles, sinalizando o estado em cerca de metade das épocas mesmo quando não havia corrupção alguma. A causa é que o MedNIST satura muito cedo, e a perda de validação começa a subir logo após a primeira época mesmo em treinamentos saudáveis.

Reancorando o diagnóstico na acurácia de validação, o comportamento tornou-se o esperado: oito de oito execuções com corrupção sinalizadas, nenhum falso positivo entre os oito controles. O episódio ilustra que a definição operacional de *overfitting* não é detalhe de implementação, mas condição de validade do resultado.

4.7 Limitações dos Resultados Atuais

1. Os experimentos restringem-se a um único repositório de imagens, que é reconhecidamente fácil e satura rapidamente. A extensão a repositórios mais difíceis é necessária.
2. A memorização é induzida artificialmente. Resta demonstrar que o indicador se comporta do mesmo modo diante de *overfitting* espontâneo, por escassez de dados e não por corrupção de rótulos.
3. O contraste em DenseNet-121 é fraco e baseado em três execuções por grupo.
4. Os limiares do monitor foram calibrados em um subconjunto das execuções e verificados nas demais; ainda assim, a possibilidade de ajuste excessivo do critério aos próprios dados exige validação em condições inteiramente novas.

Referências

- ADVANI, M. S.; SAXE, A. M.; SOMPOLINSKY, H. High-dimensional dynamics of generalization error in neural networks. **Neural Networks**, v. 132, p. 428–446, 2020.
- ARPIT, D. et al. A closer look at memorization in deep networks. In: **Proceedings of the 34th International Conference on Machine Learning (ICML)**. [S.l.: s.n.], 2017. p. 233–242.
- BARTLETT, P. L.; FOSTER, D. J.; TELGARSKY, M. Spectrally-normalized margin bounds for neural networks. In: **Advances in Neural Information Processing Systems (NeurIPS)**. [S.l.: s.n.], 2017. v. 30.
- COSTA, M.; GOLDBERGER, A. L.; PENG, C.-K. Multiscale entropy analysis of complex physiologic time series. **Physical Review Letters**, v. 89, n. 6, p. 068102, 2002.
- COSTA, M.; GOLDBERGER, A. L.; PENG, C.-K. Multiscale entropy analysis of biological signals. **Physical Review E**, v. 71, n. 2, p. 021906, 2005.
- DELGADO-BONAL, A.; MARSHAK, A. Approximate entropy and sample entropy: A comprehensive tutorial. **Entropy**, v. 21, n. 6, p. 541, 2019.
- DZIUGAITE, G. K.; ROY, D. M. Computing nonvacuous generalization bounds for deep (stochastic) neural networks with many more parameters than training data. In: **Proceedings of the 33rd Conference on Uncertainty in Artificial Intelligence (UAI)**. [S.l.: s.n.], 2017.
- HE, K. et al. Deep residual learning for image recognition. p. 770–778, 2016.
- JIANG, Y. et al. Fantastic generalization measures and where to find them. In: **International Conference on Learning Representations (ICLR)**. [S.l.: s.n.], 2020.
- LAMBERTI, P. W. et al. Intensive entropic non-triviality measure. **Physica A: Statistical Mechanics and its Applications**, v. 334, n. 1–2, p. 119–131, 2004.
- LÓPEZ-RUIZ, R.; MANCINI, H. L.; CALBET, X. A statistical measure of complexity. **Physics Letters A**, v. 209, n. 5–6, p. 321–326, 1995.
- MARTIN, C. H.; PENG, T.; MAHONEY, M. W. Predicting trends in the quality of state-of-the-art neural networks without access to training or testing data. **Nature Communications**, v. 12, n. 1, p. 4122, 2021.
- PINCUS, S. M. Approximate entropy as a measure of system complexity. **Proceedings of the National Academy of Sciences**, v. 88, n. 6, p. 2297–2301, 1991.
- POWER, A. et al. **Grokking: generalization beyond overfitting on small algorithmic datasets**. 2022. ArXiv:2201.02177.
- PRECHELT, L. Automatic early stopping using cross validation: quantifying the criteria. **Neural Networks**, v. 11, n. 4, p. 761–767, 1998.

- RICHMAN, J. S.; MOORMAN, J. R. Physiological time-series analysis using approximate entropy and sample entropy. **American Journal of Physiology – Heart and Circulatory Physiology**, v. 278, n. 6, p. H2039–H2049, 2000.
- ROSSO, O. A. et al. Generalized statistical complexity measure. **International Journal of Bifurcation and Chaos**, v. 20, n. 3, p. 775–785, 2010.
- SHANNON, C. E. A mathematical theory of communication. **Bell System Technical Journal**, v. 27, n. 3, p. 379–423, 1948.
- SILVA, L. E. V. et al. Two-dimensional sample entropy analysis of rat sural nerve aging. In: **Proceedings of the 36th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)**. [S.l.: s.n.], 2014. p. 3345–3348.
- SILVA, L. E. V. et al. Two-dimensional sample entropy: assessing image texture through irregularity. **Biomedical Physics & Engineering Express**, v. 2, n. 4, p. 045002, 2016.
- SILVA, L. E. V.; JUNIOR, L. O. M. Evaluation of physiologic complexity in time series using generalized sample entropy and surrogate data analysis. **Chaos: An Interdisciplinary Journal of Nonlinear Science**, v. 22, n. 4, p. 043105, 2012.
- YENTES, J. M. et al. The appropriate use of approximate entropy and sample entropy with short data sets. **Annals of Biomedical Engineering**, v. 41, n. 2, p. 349–365, 2013.
- ZHANG, C. et al. Understanding deep learning requires rethinking generalization. In: **International Conference on Learning Representations (ICLR)**. [S.l.: s.n.], 2017.