Cássio Silva Takarada

Comportamento da complexidade estatística dos pesos da camada densa durante o treinamento de redes neurais convolucionais em imagens médicas

Ribeirão Preto
2026

Cássio Silva Takarada

Comportamento da complexidade estatística dos pesos da camada densa durante o treinamento de redes neurais convolucionais em imagens médicas

Projeto de pesquisa apresentado ao Programa de Pós-Graduação em Computação Aplicada da Faculdade de Filosofia, Ciências e Letras de Ribeirão Preto da Universidade de São Paulo.

Universidade de São Paulo
Faculdade de Filosofia, Ciências e Letras de Ribeirão Preto
Departamento de Computação e Matemática

Orientador: Prof. Dr. Luiz Otávio Murta Junior

Ribeirão Preto
2026

Resumo

O treinamento de redes neurais profundas é acompanhado, na prática, quase exclusivamente por métricas que dependem de dados rotulados — perda e acurácia nos conjuntos de treino e de validação. Os próprios pesos da rede, que registram o que foi aprendido, raramente são tratados como objeto de medida. Este projeto descreve como duas medidas de complexidade estatística calculadas *exclusivamente sobre os pesos* da camada densa — a complexidade LMC e a entropia amostral (SampEn) — se comportam ao longo das épocas, em regimes de treinamento que diferem pela quantidade e pela qualidade das imagens de treino. Os experimentos usam a ResNet-18 sobre o repositório MedNIST e o PathMNIST, com um controle de oito sementes, subamostragem do treino a 10 %, 2 % e 1 % — com e sem igualar o número de passos de otimização ao do controle — e ruído branco e rosa somado às imagens de treino. Resultados preliminares mostram que, nos dois repositórios, a LMC final da subamostragem curta fica bem abaixo da do controle (entre 0,13 e 0,54 vezes; $p = 0{,}0016$). No MedNIST, essa diferença praticamente desaparece quando os passos de otimização são igualados; no PathMNIST, em que a rede memoriza o subconjunto reduzido, ela persiste em todas as estatísticas. O ruído nas imagens, nos níveis testados, não altera as duas medidas em nenhum dos repositórios, embora derrube o desempenho — no PathMNIST, a acurácia de teste cai de 0,88 para 0,48 com ruído rosa a $\sigma = 0{,}2$. O trabalho não propõe um detector: seu objetivo é caracterizar o comportamento dessas medidas e delimitar o que elas registram e o que não registram. **Palavras-chave**: complexidade estatística; entropia amostral; camada densa; aprendizado profundo; imagens médicas.

Sumário

Sumário **3**

1 PROPOSTA **5**
1.1 Contextualização e Motivação **5**
1.2 Problema de Pesquisa **5**
1.3 Hipótese **5**
1.4 Objetivos **6**
1.4.1 Objetivo Geral 6
1.4.2 Objetivos Específicos 6
1.5 Justificativa **6**
1.5.1 Os pesos como objeto de medida 7
1.5.2 Por que descrever antes de propor 7
1.6 Visão Geral da Metodologia **7**
1.7 Contribuição Esperada **8**

2 CONTEÚDO TEÓRICO **9**
2.1 Complexidade Estatística **9**
2.1.1 Entropia de Shannon e a insuficiência da desordem 9
2.1.2 Complexidade LMC 9
2.2 Entropia Amostral **10**
2.2.1 Formulação unidimensional 10
2.2.2 Entropia multiescala 10
2.3 A Camada Densa como Objeto de Medida **11**
2.3.1 Por que a camada densa 11
2.3.2 O caminho e a ordem de achatamento 11
2.4 Definições Usadas na Descrição do Treinamento **12**
2.5 Síntese **12**

3 ESTADO DA ARTE **13**
3.1 Memorização e Generalização em Redes Profundas **13**
3.2 Métricas de Generalização a partir dos Pesos **14**
3.3 Medidas de Complexidade Aplicadas a Redes Neurais **14**
3.4 Critérios de Parada **15**
3.5 Síntese e Posicionamento da Proposta **15**

4 RESULTADOS PRELIMINARES **16**

4.1 Protocolo Experimental 16
4.2 Comparação com o Controle 17
4.3 Subamostragem: o Efeito dos Passos de Otimização 18
4.4 Ruído nas Imagens: Desempenho Muda, Medidas Não 19
4.5 Outra Arquitetura: Controle com a DenseNet-121 19
4.6 Segundo Repositório: PathMNIST 20
4.7 Limitações dos Resultados Atuais 24

REFERÊNCIAS 25

1 Proposta

1.1 Contextualização e Motivação

O aprendizado profundo consolidou-se como abordagem dominante em tarefas de classificação e segmentação de imagens médicas. Esse sucesso, contudo, apoia-se em uma premissa que a prática clínica raramente satisfaz: a disponibilidade de grandes conjuntos de dados anotados. Em imagens médicas, a anotação exige um especialista, é onerosa e lenta, e frequentemente esbarra em restrições éticas e de privacidade que limitam o compartilhamento entre instituições.

Essa escassez tem uma consequência metodológica pouco discutida. O acompanhamento do treinamento — inclusive a decisão de quando interrompê-lo, o *early stopping* (PRECHELT, 1998) — é feito quase exclusivamente por métricas calculadas sobre dados rotulados: perda e acurácia nos conjuntos de treino e de validação. Toda a leitura do processo passa, portanto, pelos dados, e é tão confiável quanto eles. Justamente no regime de poucos dados, em que o *overfitting* é mais provável, essa leitura é a menos estável.

Há, entretanto, uma fonte de informação sobre o treinamento que permanece pouco explorada e que não depende de rótulo algum: os próprios pesos da rede. É neles que fica registrado o que a rede aprendeu, e trabalhos consolidados mostram que o modo como uma rede ajusta os dados de treino — extraindo regularidades ou decorando exemplos — varia com o regime de treinamento (ZHANG et al., 2017; ARPIT et al., 2017). Medidas de complexidade estatística, desenvolvidas para caracterizar sinais e sistemas físicos, oferecem uma forma de resumir a estrutura desses pesos em números acompanháveis época a época. O que essas medidas registram ao longo do treinamento, e em que condições, ainda não foi descrito de forma sistemática.

1.2 Problema de Pesquisa

Como se comportam a complexidade LMC e a entropia amostral dos pesos da camada densa ao longo do treinamento de uma rede convolucional, e como esse comportamento muda quando se altera a quantidade e a qualidade das imagens de treino?

1.3 Hipótese

A hipótese de trabalho é a de que as duas medidas respondem ao regime de treinamento: em regimes que alteram de modo relevante o que a rede precisa ajustar — menos dados,

ou dados degradados — as trajetórias de LMC e de SampEn afastam-se das do controle de forma maior do que a variação entre sementes.

A hipótese é falsificável e é avaliada regime a regime. Para cada regime, compara-se o valor final e a amplitude de cada medida com os do controle, por teste não paramétrico entre sementes. Se a diferença não superar a variação entre sementes, a medida não registra aquele regime, e isso é reportado como resultado — não como falha a ser contornada. Também se verifica se uma diferença observada pode ser explicada por um fator mais simples do que o regime em si, como o número de passos de otimização.

1.4 Objetivos

1.4.1 Objetivo Geral

Descrever o comportamento da complexidade LMC e da entropia amostral dos pesos da camada densa durante o treinamento de redes neurais convolucionais em imagens médicas, sob diferentes regimes de quantidade e qualidade dos dados de treino.

1.4.2 Objetivos Específicos

1. Implementar, em um módulo único e validado numericamente, a complexidade LMC e a entropia amostral, estabelecendo-o como fonte única de cálculo para todo o trabalho.
2. Formalizar a leitura dos pesos da camada densa como objeto de medida, fixando a ordem de achatamento da matriz de pesos e justificando-a experimentalmente.
3. Registrar as duas medidas a cada época de treinamento, junto com as métricas convencionais de perda e acurácia.
4. Comparar com o controle os regimes de subamostragem do treino, com e sem igualar o número de passos de otimização, para separar o efeito da quantidade de dados do efeito do número de passos.
5. Comparar com o controle os regimes de ruído somado às imagens de treino, com diferentes espectros (branco e rosa) e intensidades.
6. Relacionar o comportamento das medidas ao desempenho por classe na validação, explicitando os casos em que o desempenho muda e as medidas não.

1.5 Justificativa

O público deste trabalho são pesquisadores que estudam o treinamento de redes neurais e a sua aplicação em imagens médicas. A mensagem central é que existem parâmetros,

calculados apenas sobre os pesos, que podem ser usados para *medir* o treinamento — e que vale caracterizar o que eles medem antes de propor qualquer uso prático para eles.

1.5.1 Os pesos como objeto de medida

As métricas convencionais descrevem o *desempenho* da rede sobre um conjunto de dados; não descrevem a rede em si. Duas redes com a mesma acurácia podem ter chegado a ela por caminhos diferentes, com pesos organizados de modo diferente. Medidas calculadas sobre os pesos não consomem imagem, não consomem rótulo e não dependem de partição, e por isso fornecem uma leitura do treinamento obtida por um caminho independente daquele das métricas usuais.

1.5.2 Por que descrever antes de propor

Uma medida só pode ser usada com segurança quando se sabe a que ela responde. Uma diferença entre regimes pode refletir o fenômeno de interesse ou um fator lateral — por exemplo, o número de atualizações dos pesos. Este trabalho adota deliberadamente um escopo descritivo: caracterizar como as medidas se comportam, separar os fatores que as movem e registrar os casos em que elas permanecem insensíveis. Esse mapa é pré-requisito para qualquer proposta posterior de uso.

1.6 Visão Geral da Metodologia

O trabalho experimental compara regimes de treinamento contra um controle comum. O controle usa todo o conjunto de treino, sem aumento de dados, por 60 épocas. Os regimes alteram um único aspecto por vez:

1. **Subamostragem curta**: 10 %, 2 % ou 1 % do treino, com um número fixo de épocas — e, portanto, muito menos passos de otimização que o controle.

2. **Subamostragem com passos igualados**: as mesmas frações, com o número de épocas aumentado até que o total de passos se iguale ao do controle (cerca de 22.140).

3. **Ruído nas imagens**: um campo de ruído é somado aos pixels das imagens de treino, com espectro branco (potência constante em frequência) ou rosa (potência proporcional a $1/f$), e desvio-padrão $\sigma \in \{0{,}05; 0{,}1; 0{,}2\}$. Os rótulos não são alterados.

Em todos os regimes apenas o treino é modificado; validação e teste permanecem intactos. O controle é repetido com uma segunda arquitetura, a DenseNet-121, para verificar se o comportamento observado depende da rede. Todo o desenho é aplicado a dois repositórios de imagens médicas — o MedNIST, com seis classes em tons de cinza, e o PathMNIST, com nove classes de histologia colorida —, para verificar se o comportamento

depende dos dados. A cada época calculam-se a LMC e a SampEn sobre os pesos da camada densa. Para cada execução resumem-se as trajetórias pelo valor final e pela amplitude relativa, e cada regime é comparado ao controle pelo teste de Mann-Whitney, escolhido pelo tamanho reduzido das amostras. O detalhamento reprodutível — repositório de imagens, arquitetura, hiperparâmetros e partição congelada — constitui o capítulo de metodologia do documento final.

1.7 Contribuição Esperada

Espera-se contribuir em três frentes. Do ponto de vista científico, descrever empiricamente como medidas de complexidade estatística dos pesos se comportam ao longo do treinamento e a que fatores respondem, incluindo a delimitação dos regimes que elas não registram. Do ponto de vista metodológico, formalizar a leitura dos pesos de uma camada densa como objeto de medida de complexidade, questão até aqui tratada de modo implícito na literatura, e mostrar a importância de controlar o número de passos de otimização ao comparar regimes. Do ponto de vista prático, disponibilizar o módulo de cálculo e o registro por época, documentados e testados, para uso por outros pesquisadores.

2 Conteúdo Teórico

Este capítulo reúne os conceitos necessários para acompanhar as escolhas metodológicas e a leitura dos resultados. A Seção 2.1 apresenta a noção de complexidade estatística e a formulação LMC. A Seção 2.2 define a entropia amostral. A Seção 2.3 justifica a escolha da camada densa como objeto de medida e formaliza a leitura de seus pesos como sequência. A Seção 2.4 fixa as definições usadas para descrever o treinamento.

2.1 Complexidade Estatística

2.1.1 Entropia de Shannon e a insuficiência da desordem

Dada uma variável discreta com distribuição de probabilidade $P = \{p_1, \ldots, p_N\}$, a entropia de Shannon (SHANNON, 1948) é

$$H(P) = -\sum_{i=1}^{N} p_i \ln p_i. \tag{2.1}$$

A entropia mede desordem: é nula quando toda a probabilidade concentra-se em um único estado e máxima, igual a $\ln N$, quando a distribuição é uniforme. Por isso, isoladamente, ela não serve como medida de complexidade. Um cristal perfeito tem entropia mínima e um gás ideal tem entropia máxima, mas nenhum dos dois é estruturalmente complexo: o primeiro é totalmente previsível, o segundo totalmente aleatório. A complexidade que interessa está entre os dois extremos.

2.1.2 Complexidade LMC

López-Ruiz, Mancini e Calbet (1995) resolvem esse problema introduzindo um segundo termo, o desequilíbrio, que mede a distância quadrática da distribuição observada em relação à distribuição uniforme $P_e = \{1/N, \ldots, 1/N\}$:

$$D(P) = \sum_{i=1}^{N} \left(p_i - \frac{1}{N} \right)^2. \tag{2.2}$$

A complexidade LMC é o produto dos dois termos, com a entropia normalizada pelo seu valor máximo:

$$C_{\mathrm{LMC}}(P) = \frac{H(P)}{\ln N} \cdot D(P). \tag{2.3}$$

O produto na Equação 2.3 anula-se nos dois extremos e é máximo em distribuições intermediárias. No cristal, $H \to 0$ e o primeiro fator zera; no gás ideal, $P \to P_e$ e o desequilíbrio zera. Uma discussão das propriedades e das limitações dessa formulação,

incluindo variantes baseadas na divergência de Jensen-Shannon, encontra-se em Lamberti et al. (2004) e Rosso et al. (2010).

Duas propriedades são relevantes para este trabalho. A primeira é que C_{LMC} depende apenas do histograma dos valores, sendo portanto *invariante a qualquer permutação* da sequência analisada. A segunda, consequência da primeira, é que a LMC não pode captar nenhuma informação posicional: se uma mudança no treinamento se manifestar na organização dos pesos e não na distribuição de seus valores, a LMC será cega a ela.

2.2 Entropia Amostral

2.2.1 Formulação unidimensional

A entropia amostral (RICHMAN; MOORMAN, 2000) quantifica a irregularidade de uma sequência medindo com que frequência padrões semelhantes permanecem semelhantes quando estendidos por uma amostra. Ela corrige o viés de autocomparação presente na entropia aproximada de Pincus (1991).

Seja a série $\{u(1), \ldots, u(L)\}$ e os vetores de janela $\mathbf{x}_m(i) = \{u(i), \ldots, u(i+m-1)\}$. Sejam B o número de pares de janelas de comprimento m cuja distância de Chebyshev é inferior à tolerância r, e A o número correspondente para janelas de comprimento $m+1$. Define-se

$$\mathrm{SampEn}(m, r, L) = -\ln \frac{A}{B}. \tag{2.4}$$

O parâmetro m é o comprimento do padrão comparado e r é a tolerância de similaridade, usualmente expressa como fração do desvio-padrão da série. Valores elevados de SampEn indicam baixa previsibilidade. A escolha de m e r não é neutra e afeta a estabilidade da estimativa, especialmente em séries curtas (YENTES et al., 2013); por isso os valores adotados são fixados antes das comparações e mantidos iguais em todos os regimes.

Diferentemente da LMC, a entropia amostral *não* é invariante à ordem, pois compara janelas consecutivas. Essa é precisamente a propriedade que a torna complementar à LMC neste trabalho.

2.2.2 Entropia multiescala

A entropia multiescala (COSTA; GOLDBERGER; PENG, 2002; COSTA; GOLDBERGER; PENG, 2005) aplica a entropia amostral a versões da série granuladas em escalas crescentes, obtidas pela média de blocos consecutivos não sobrepostos. O perfil resultante distingue sinais cuja irregularidade se mantém através das escalas daqueles em que ela se concentra na escala fina. Sua versão unidimensional está implementada neste trabalho e fica prevista como extensão.

2.3 A Camada Densa como Objeto de Medida

2.3.1 Por que a camada densa

Em uma rede convolucional de classificação, as camadas convolucionais produzem uma representação da imagem e a camada densa final converte essa representação em pontuações por classe. É nela que a decisão é efetivamente tomada, e é nela que a associação entre representação e rótulo precisa ser armazenada. É razoável esperar, portanto, que mudanças no que a rede precisa ajustar — menos exemplos, ou exemplos degradados — se inscrevam de forma direta nos pesos dessa camada. A escolha tem ainda a vantagem prática de manter o custo do monitoramento baixo: na ResNet-18 aplicada a seis classes, a matriz de pesos tem forma 6×512, totalizando 3072 parâmetros.

2.3.2 O caminho e a ordem de achatamento

Considere-se uma camada densa com M entradas $x_1, \ldots, x_M$ e N neurônios $n_1, \ldots, n_N$. A matriz de pesos é $W \in \mathbb{R}^{N \times M}$, e o elemento w_{ji} é o peso do *caminho* $x_i \to n_j$. Essa é exatamente a convenção do PyTorch, em que o atributo de pesos de uma camada linear tem forma $[N, M]$.

Como a entropia amostral unidimensional depende da ordem, é necessário fixar o percurso pelo qual a matriz é lida como sequência. Duas ordens são naturais. Na ordem *por neurônio*, percorrem-se todos os pesos que chegam a cada neurônio antes de passar ao seguinte:

$$v_n = (w_{11}, w_{12}, \ldots, w_{1M},\ w_{21}, \ldots, w_{2M},\ \ldots,\ w_{NM}). \tag{2.5}$$

Na ordem *por entrada*, percorrem-se todos os pesos que partem de cada entrada:

$$v_x = (w_{11}, w_{21}, \ldots, w_{N1},\ w_{12}, \ldots, w_{N2},\ \ldots). \tag{2.6}$$

As duas leituras não são equivalentes e medem coisas distintas: a Equação 2.5 avalia a regularidade *dentro do campo receptivo de cada neurônio*, enquanto a Equação 2.6 avalia a regularidade *da distribuição de uma mesma entrada entre os neurônios*. Adota-se a ordem por neurônio como convenção padrão, e a comparação entre as duas é reportada como ablação. Para a complexidade LMC a distinção é irrelevante, pela invariância discutida na Seção 2.1.

Por coerência com a noção de caminho, o vetor de viés é excluído da análise: o viés é um deslocamento aditivo do neurônio, não a ligação entre uma entrada e um neurônio. Quando há mais de uma camada densa, cada uma é analisada separadamente, sem concatenação.

2.4 Definições Usadas na Descrição do Treinamento

A partição dos dados segue a separação em três conjuntos disjuntos. O conjunto de treino é o único que participa da retropropagação; o de validação é observado a cada época e nunca entra no gradiente; o de teste é consultado uma única vez, ao final, na época selecionada.

Seja val_loss(e) a perda no conjunto de validação na época e. A melhor época é $e^* = \arg\min_e \text{val_loss}(e)$, e é nela que se avalia o teste. Diz-se que há *overfitting* quando o desempenho no treino supera de forma persistente o desempenho na validação; a lacuna entre a acurácia final de treino e a de validação é reportada para cada regime.

Como o trabalho compara regimes com números de exemplos muito diferentes, a época não é uma unidade de tempo comparável entre eles: uma época com 1 % dos dados corresponde a cerca de um centésimo das atualizações de uma época completa. Por isso as trajetórias também são descritas em *passos de otimização* — o número de atualizações dos pesos —, e os regimes de subamostragem são repetidos com o número de passos igualado ao do controle.

Para resumir uma trajetória $y(e)$ de uma medida usam-se duas estatísticas: o valor final, $y(e_{\text{fim}})$, e a amplitude relativa,

$$A = \frac{\max_e y(e) - \min_e y(e)}{|\overline{y}|}, \tag{2.7}$$

em que $\overline{y}$ é a média da trajetória. A normalização torna a amplitude comparável entre medidas que vivem em escalas distintas.

2.5 Síntese

Os conceitos aqui reunidos sustentam a proposta em três pontos. A complexidade LMC oferece uma leitura da distribuição de valores dos pesos, insensível à posição. A entropia amostral oferece uma leitura sensível à organização da sequência de pesos. A formalização do caminho e da ordem de achatamento torna explícita uma escolha que, de outro modo, permaneceria arbitrária e não reprodutível.

3 Estado da Arte

Este capítulo discute os trabalhos que se aproximam do problema formulado no Capítulo 1. O critério de seleção foi a existência de alguma tentativa de caracterizar o estado de generalização de uma rede sem depender integralmente de um conjunto de teste rotulado, ou de caracterizar a transição entre aprendizado e memorização. A Seção 3.1 revisa o que se sabe sobre memorização em redes profundas. A Seção 3.2 discute métricas de generalização calculadas sobre os pesos. A Seção 3.3 trata da aplicação de medidas de complexidade a redes neurais. A Seção 3.4 revisa critérios de parada. A Seção 3.5 sintetiza e posiciona a proposta.

3.1 Memorização e Generalização em Redes Profundas

Zhang et al. (2017) demonstraram experimentalmente que redes convolucionais de grande porte ajustam perfeitamente rótulos atribuídos ao acaso, e que esse comportamento persiste mesmo sob regularização explícita. O resultado é qualitativamente importante para este trabalho porque estabelece que a capacidade de memorização não é um acidente, mas uma propriedade das arquiteturas usuais: o modo como a rede ajusta os dados depende do regime de treinamento, e não apenas da arquitetura. A limitação, do ponto de vista aqui adotado, é que a caracterização continua dependendo da comparação entre desempenho de treino e de teste.

Arpit et al. (2017) refinam esse quadro ao mostrar que memorização e aprendizado de padrões não ocorrem simultaneamente: redes tendem a aprender primeiro as regularidades simples e só depois memorizam os exemplos ruidosos. A existência de dois regimes sucessivos, e não de um processo homogêneo, é o que motiva acompanhar os pesos época a época, e não apenas ao final do treinamento: se o processo tem fases, uma medida dos pesos pode registrá-las. Os autores, contudo, caracterizam os regimes por meio de métricas que dependem dos dados, e não da estrutura dos pesos.

Power et al. (2022) descrevem o fenômeno de *grokking*, em que a generalização ocorre muito depois do ajuste completo do treino, às vezes após longo período de estagnação da validação. O fenômeno é relevante aqui porque constitui um contraexemplo aos critérios ingênuos de parada antecipada: uma interrupção baseada apenas na estagnação da validação eliminaria justamente o regime em que a generalização acabaria emergindo. Uma medida que leia o estado interno da rede, e não apenas seu desempenho externo, pode em princípio distinguir estagnação de reorganização — questão que este trabalho deixa registrada, sem testá-la.

3.2 Métricas de Generalização a partir dos Pesos

Bartlett, Foster e Telgarsky (2017) propõem limites de generalização baseados em normas espectrais e margens, estabelecendo que propriedades geométricas dos pesos se relacionam com a capacidade de generalizar. Dziugaite e Roy (2017) obtêm, por via PAC-Bayesiana, limites não vacuosos para redes sobreparametrizadas. Ambos representam avanços substantivos, mas produzem limites válidos para um estado da rede, tipicamente o final do treinamento, e não uma leitura acompanhável ao longo das épocas.

Jiang et al. (2020) conduzem o estudo empírico mais sistemático dessa família, avaliando um grande conjunto de medidas candidatas quanto à sua correlação causal com a lacuna de generalização. A conclusão é cautelar: muitas medidas teoricamente motivadas correlacionam-se mal com a generalização observada, e medidas baseadas em otimização desempenham-se melhor do que as baseadas em norma. Esse resultado impõe a este trabalho uma exigência metodológica clara — não basta exibir correlação entre indicador e o regime de treinamento em uma execução; é preciso comparar múltiplas sementes contra um controle comum e verificar se a diferença não se explica por um fator mais simples.

Martin, Peng e Mahoney (2021) mostram que propriedades de cauda pesada do espectro das matrizes de pesos permitem prever tendências de qualidade de modelos sem acesso aos dados de treino ou de teste. Este é o trabalho mais próximo do objetivo aqui perseguido, e convém explicitar a diferença: a abordagem é *espectral*, apoiando-se nos autovalores das matrizes, ao passo que a abordagem deste projeto é *informação-teórica*, apoiando-se na distribuição de valores e na organização sequencial dos pesos. Além disso, o alvo em Martin, Peng e Mahoney (2021) é comparar modelos já treinados, enquanto aqui o alvo é acompanhar a trajetória temporal de um único treinamento.

3.3 Medidas de Complexidade Aplicadas a Redes Neurais

A aplicação de medidas de entropia e complexidade ao estudo de redes neurais é mais recente e menos consolidada. Advani, Saxe e Sompolinsky (2020) analisam a dinâmica do aprendizado em regime de alta dimensionalidade, caracterizando fases distintas do treinamento. Delgado-Bonal e Marshak (2019) revisam o uso de medidas de entropia em séries temporais e sistematizam a escolha de parâmetros, questão diretamente relevante para a estabilidade das estimativas aqui empregadas.

O que a revisão da literatura não localizou foi trabalho que acompanhe, época a época, medidas de complexidade estatística calculadas sobre os pesos de uma camada específica, descrevendo de forma sistemática como elas se comportam em regimes de treinamento distintos e a que fatores respondem. Essa é a lacuna que o projeto endereça.

3.4 Critérios de Parada

Prechelt (1998) sistematizou os critérios automáticos de parada antecipada baseados em validação cruzada, avaliando empiricamente catorze critérios quanto a eficiência e eficácia. O trabalho permanece a referência metodológica da prática corrente e explicita seu próprio pressuposto: a decisão de parada é uma função do erro medido em dados separados. É exatamente esse pressuposto que motiva este projeto a olhar para os pesos: não para substituir o critério clássico, mas para descrever uma segunda leitura do treinamento, obtida por caminho independente.

3.5 Síntese e Posicionamento da Proposta

Tabela 1 – Comparação dos trabalhos discutidos quanto à dependência de dados rotulados e à natureza temporal da leitura.

Trabalho	Objeto da medida	Precisa de rótulo	Leitura temporal
Prechelt (1998)	Erro de validação	Sim	Sim
Zhang et al. (2017)	Desempenho	Sim	Não
Arpit et al. (2017)	Desempenho	Sim	Sim
Bartlett, Foster e Telgarsky (2017)	Norma espectral	Não	Não
Dziugaite e Roy (2017)	Limite PAC-Bayes	Sim	Não
Jiang et al. (2020)	Diversas	Sim	Não
Martin, Peng e Mahoney (2021)	Espectro dos pesos	Não	Não
Este trabalho	Complexidade dos pesos	Não	Sim

Fonte: Elaborado pelo autor.

A Tabela 1 organiza os trabalhos segundo dois eixos. O primeiro é a dependência de dados rotulados: apenas Bartlett, Foster e Telgarsky (2017) e Martin, Peng e Mahoney (2021) dispensam-nos, e ambos o fazem por via espectral. O segundo é a natureza temporal da leitura: das abordagens que dispensam rótulos, nenhuma foi concebida para acompanhar a trajetória do treinamento época a época.

A proposta deste trabalho situa-se na interseção ainda vazia desses dois eixos, e diferencia-se da literatura existente em três aspectos: (i) a medida é informação-teórica, incidindo sobre a distribuição de valores e sobre a organização sequencial dos pesos, e não sobre seu espectro; (ii) a leitura é temporal, produzindo uma trajetória e não um escalar ao final do treino; e (iii) a comparação é feita contra um controle comum, com várias sementes por regime e com o número de passos de otimização controlado, em resposta direta à advertência metodológica de Jiang et al. (2020) quanto a correlações espúrias.

4 Resultados Preliminares

Este capítulo reporta os resultados já obtidos. Eles descrevem como a LMC e a SampEn da camada densa se comportam em cada regime e delimitam, com a mesma ênfase, os regimes que as medidas não registram. Todos os números foram recalculados a partir dos registros por época das execuções.

4.1 Protocolo Experimental

Os experimentos utilizam o repositório MedNIST, com seis classes e imagens redimensionadas para 64×64, e a arquitetura ResNet-18 (HE et al., 2016). A partição em treino, validação e teste (47.164, 5895 e 5895 imagens) é congelada e reutilizada entre execuções, de modo que a comparação entre elas não seja contaminada por variação de amostragem. Todas as execuções usam o otimizador AdamW com taxa de aprendizado 0,001, sem decaimento de pesos, lote de 128 imagens e sem aumento de dados. A LMC é calculada com 100 classes de histograma e a SampEn com $m = 2$ e $r = 0{,}2$ vezes o desvio-padrão da sequência, na ordem de achatamento por neurônio. Para verificar se o comportamento do controle depende da arquitetura, o controle é repetido com a DenseNet-121 (HUANG et al., 2017), cuja camada densa tem forma 6×1024 (6144 pesos), com a mesma configuração. As Seções 4.2 a 4.5 referem-se ao MedNIST; a Seção 4.6 repete os mesmos regimes num segundo repositório, o PathMNIST.

A Tabela 2 lista os regimes. O controle tem oito sementes; os demais regimes, cinco. A Figura 1 ilustra o ruído somado às imagens: o campo é gerado no domínio da frequência, filtrando ruído branco gaussiano por $1/f^{\beta/2}$, o que produz potência proporcional a $1/f^{\beta}$ — constante no ruído branco ($\beta = 0$) e proporcional a $1/f$ no rosa ($\beta = 1$). O campo é fixo para cada imagem e afeta apenas o treino.

Tabela 2 – Regimes de treinamento comparados com o controle.

Regime	O que muda	Imagens de treino	Épocas	Passos
Controle	—	47.164	60	22.140
Subamostragem 10 %	fração do treino	4717	60	2220
Subamostragem 2 %	fração do treino	944	200	1600
Subamostragem 1 %	fração do treino	471	200	800
Subamostragem 10 %, passos igualados	fração e épocas	4717	599	22.163
Subamostragem 2 %, passos igualados	fração e épocas	944	2768	22.144
Subamostragem 1 %, passos igualados	fração e épocas	471	5535	22.140
Ruído rosa ou branco, $\sigma \in \{0{,}05; 0{,}1; 0{,}2\}$	pixels do treino	47.164	60	22.140
Controle DenseNet-121 ($n = 5$)	arquitetura	47.164	60	22.140

Fonte: Elaborado pelo autor.

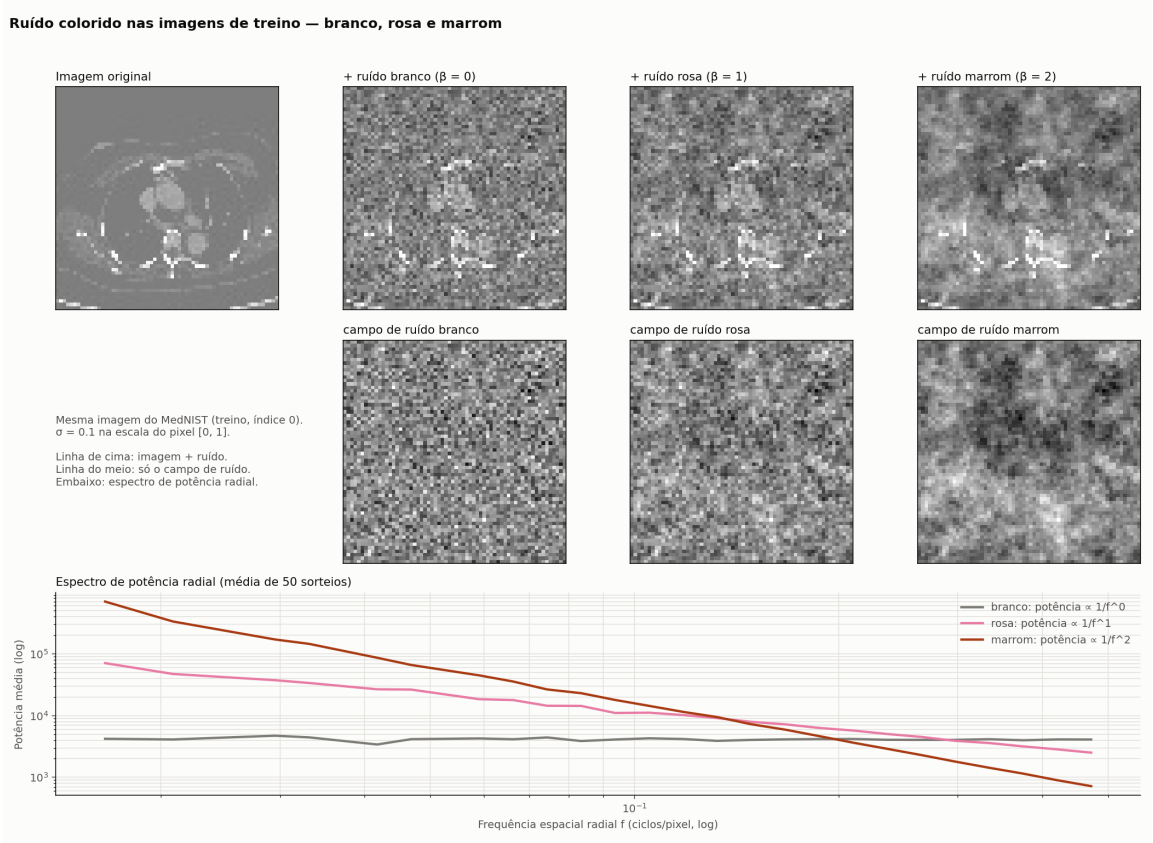


Figura 1 – Uma imagem de treino do MedNIST com ruído branco, rosa e marrom somado ($\sigma = 0{,}1$), o campo de ruído isolado e o espectro de potência radial de cada cor. Os experimentos usam o branco e o rosa; o marrom aparece apenas como referência.

Fonte: Elaborado pelo autor.

4.2 Comparação com o Controle

A Tabela 3 resume, para cada regime, a razão entre a média do regime e a média do controle no valor final e na amplitude relativa (Equação 2.7) de cada medida. No controle, a LMC final é 0,087 ± 0,016 e a SampEn final é 2,130 ± 0,028. Com cinco execuções contra oito, o menor valor-p alcançável pelo teste de Mann-Whitney é 0,0016, que corresponde à separação completa entre os grupos.

Tabela 3 – Razão entre a média de cada regime e a do controle, com o valor-p do teste de Mann-Whitney bilateral entre parênteses. Controle com $n = 8$; regimes com $n = 5$.

	LMC		SampEn	
Regime	Final	Amplitude	Final	Amplitude
Subamostragem 10 %	0,43 (0,0016)	0,90 (0,62)	1,03 (0,0031)	0,32 (0,0016)
Subamostragem 2 %	0,37 (0,0016)	1,07 (0,83)	1,03 (0,0031)	0,37 (0,0016)
Subamostragem 1 %	0,13 (0,0016)	0,57 (0,0016)	1,03 (0,0016)	0,19 (0,0016)
10 %, passos igualados	0,98 (0,35)	1,07 (0,28)	1,00 (0,72)	0,89 (0,94)
2 %, passos igualados	0,71 (0,011)	1,04 (0,72)	1,01 (0,28)	0,92 (0,28)
1 %, passos igualados	0,92 (0,72)	1,50 (0,0016)	1,00 (0,94)	1,08 (0,44)
Rosa, $\sigma = 0{,}05$	0,88 (0,22)	0,96 (0,94)	0,99 (0,093)	1,12 (0,44)
Rosa, $\sigma = 0{,}1$	0,94 (0,62)	1,00 (0,94)	1,00 (0,72)	1,06 (1,00)
Rosa, $\sigma = 0{,}2$	0,83 (0,13)	0,97 (0,72)	1,00 (0,94)	1,06 (0,83)
Branco, $\sigma = 0{,}05$	0,98 (0,83)	0,92 (0,62)	1,00 (0,72)	1,03 (0,72)
Branco, $\sigma = 0{,}1$	0,96 (0,52)	1,01 (0,94)	0,98 (0,065)	1,19 (0,045)
Branco, $\sigma = 0{,}2$	1,07 (0,94)	1,11 (0,94)	1,00 (0,83)	0,88 (0,35)

Fonte: Elaborado pelo autor.

4.3 Subamostragem: o Efeito dos Passos de Otimização

Na subamostragem curta, as duas medidas separam-se completamente do controle. A LMC final cai para 0,43, 0,37 e 0,13 vezes a do controle a 10 %, 2 % e 1 %, e a amplitude da SampEn cai para entre 0,19 e 0,37 vezes. A leitura imediata seria a de que as medidas registram a quantidade de dados.

Os regimes com passos igualados mostram que essa leitura é, em grande parte, equivocada. Quando o número de atualizações dos pesos é o mesmo do controle, a LMC final volta a 0,98, 0,71 e 0,92 vezes a do controle, e a SampEn deixa de diferir em qualquer das estatísticas. A maior parte da diferença observada na subamostragem curta acompanha, portanto, o número de passos de otimização: com poucos passos, os pesos simplesmente ainda não percorreram a trajetória que o controle percorre. Restam dois efeitos que sobrevivem ao controle dos passos — a LMC final a 2 % ($p = 0{,}011$) e a amplitude da LMC a 1 % (1,50 vezes, $p = 0{,}0016$) —, que são os candidatos a efeito próprio da quantidade de dados e serão examinados com mais sementes. Como mostra a Seção 4.6, essa conclusão não se transfere ao PathMNIST.

Do ponto de vista do desempenho, a subamostragem produz o regime esperado: a acurácia de treino chega a 1,000 em todas as execuções, enquanto a de validação fica entre 0,992 e 0,998, contra 0,9997 no controle. A lacuna é pequena porque o MedNIST é um repositório fácil, que satura cedo; mesmo com 1 % dos dados a rede generaliza bem.

4.4 Ruído nas Imagens: Desempenho Muda, Medidas Não

Nos seis regimes de ruído nas imagens, nenhuma das medidas difere do controle de forma consistente. O único valor-p abaixo de 0,05 — a amplitude da SampEn com ruído branco a $\sigma = 0{,}1$, 1,19 vezes, $p = 0{,}045$ — não se repete nos níveis vizinhos e é compatível com o número de comparações feitas, que não foi corrigido.

O desempenho, porém, muda. A Tabela 4 mostra o acerto da pior classe na validação ao final do treino. Com $\sigma = 0{,}2$, o ruído rosa leva o acerto da classe AbdomenCT a praticamente zero nas cinco sementes (0,0004, contra 1,000 no controle), e a acurácia de validação final cai para 0,838; o ruído branco de mesma intensidade leva essa classe a 0,73 em média, com grande variação entre sementes. As demais cinco classes permanecem acima de 0,99.

Tabela 4 – Acurácia de validação final e acerto da pior classe na validação, média entre sementes, ao final do treino.

Regime	Acurácia de validação	Pior classe	Acerto da pior classe
Controle	0,9997	CXR	0,999
Subamostragem 2 %, passos igualados	0,9930	Hand	0,979
Rosa, $\sigma = 0{,}1$	0,9982	AbdomenCT	0,991
Rosa, $\sigma = 0{,}2$	0,8379	AbdomenCT	0,0004
Branco, $\sigma = 0{,}1$	0,9996	CXR	0,999
Branco, $\sigma = 0{,}2$	0,9557	AbdomenCT	0,732

Fonte: Elaborado pelo autor.

Esse é um caso em que o desempenho da rede muda de forma drástica e as medidas calculadas sobre a camada densa não registram a mudança. Uma interpretação possível é que o ruído atua sobre a representação produzida pelas camadas convolucionais, e que a camada densa, ao receber essa representação, ajusta-se de modo estatisticamente semelhante ao do controle. Trata-se de hipótese ainda não testada. Registra-se o resultado como delimitação: a LMC e a SampEn da camada densa não são, nos níveis testados, sensíveis à degradação das imagens de treino.

4.5 Outra Arquitetura: Controle com a DenseNet-121

Com a DenseNet-121, o controle atinge a mesma acurácia de validação final da ResNet-18 (0,9997) e as medidas seguem a mesma direção: a LMC sobe ao longo do treino e a SampEn desce. A LMC final (0,101 contra 0,087) e a sua amplitude relativa não diferem das da ResNet-18 ($p = 0{,}52$ e $p = 0{,}62$). A SampEn final é menor (1,98 contra 2,13; $p = 0{,}0016$), e a sua amplitude relativa é cerca de duas vezes maior (0,124 contra 0,058; $p = 0{,}0016$). Como a camada densa da DenseNet-121 tem o dobro de pesos e outra largura

de entrada, essa diferença de nível não é atribuível só à arquitetura; o que se mantém entre as duas é o sentido das trajetórias.

4.6 Segundo Repositório: PathMNIST

Para verificar se os comportamentos descritos acima são próprios do MedNIST, os mesmos regimes foram repetidos no PathMNIST (YANG et al., 2023), na versão 64×64: imagens coloridas de tecido de cólon corado com hematoxilina e eosina, em nove classes. A partição oficial (89.996, 10.004 e 7180 imagens de treino, validação e teste) é usada sem alteração; o teste vem de outro hospital, o que torna a acurácia de teste sistematicamente menor que a de validação. Hiperparâmetros, sementes e estatísticas são os do MedNIST. A camada densa passa a ter 9×512 (4608) pesos na ResNet-18 e 9×1024 (9216) na DenseNet-121. O controle percorre 42.240 passos em 60 épocas; a subamostragem curta usa 9000, 1800 e 901 imagens por 60 épocas, e a versão com passos igualados, 595, 2816 e 5280 épocas. O ruído usa o mesmo campo bidimensional nos três canais de cor e os mesmos valores de σ; como o desvio-padrão médio dos pixels por imagem é menor no PathMNIST (0,146 contra 0,20), o mesmo σ representa ali uma perturbação relativamente mais forte.

Instabilidade da avaliação. No PathMNIST, a acurácia de validação oscila muito entre épocas consecutivas, mesmo com a perda de treino perto de zero: no controle, a maior queda de uma época para a seguinte é, em média, de 0,55, contra 0,05 no MedNIST. A oscilação aparece também ao avaliar o próprio conjunto de treino com a rede em modo de avaliação, o que aponta para as estatísticas acumuladas pelas camadas de normalização em lote, e não para o aprendizado em si. Por isso, no PathMNIST o desempenho é reportado na época de menor perda de validação — a mesma usada no teste —, e não na última. Para verificar se essa oscilação contamina as medidas, calculou-se, em cada execução de controle, a correlação de Spearman entre a variação absoluta da acurácia de validação e a variação absoluta de cada medida, época a época. As correlações médias ficam entre $-0{,}05$ e 0,10 nas duas arquiteturas: as medidas, calculadas sobre os pesos, não acompanham a oscilação, que afeta as ativações.

Desempenho. A Tabela 5 resume o desempenho. No controle, a acurácia de validação é 0,968 e a de teste, 0,884. Diferentemente do MedNIST, aqui os regimes degradam o desempenho de forma clara: a subamostragem a 1 % leva a acurácia de teste a 0,58, e o ruído rosa com $\sigma = 0{,}2$, a 0,48, com o acerto da classe de tecido adiposo caindo de 0,99 para 0,31. Nas versões com passos igualados, a rede memoriza o subconjunto: nas dez últimas épocas, a acurácia sobre o treino fica entre 0,990 e 0,997, e a de validação, entre 0,51 e 0,86. A 1 %, a melhor época de validação cai sempre dentro das 60 primeiras épocas, de modo que a versão curta e a com passos igualados coincidem nessa tabela.

Tabela 5 – PathMNIST: acurácia de validação e de teste na época de menor perda de validação e acerto da pior classe na validação, média entre sementes.

Regime	Validação	Teste	Pior classe	Acerto da pior classe
Controle	0,968	0,884	Estroma	0,934
Subamostragem 10 %	0,863	0,818	Estroma	0,670
Subamostragem 2 %	0,628	0,632	Mucosa normal	0,412
Subamostragem 1 %	0,564	0,580	Detritos	0,337
10 %, passos igualados	0,880	0,826	Estroma	0,685
2 %, passos igualados	0,661	0,670	Estroma	0,446
1 %, passos igualados	0,564	0,580	Detritos	0,337
Rosa, $\sigma = 0{,}05$	0,958	0,853	Detritos	0,918
Rosa, $\sigma = 0{,}1$	0,882	0,771	Estroma	0,642
Rosa, $\sigma = 0{,}2$	0,602	0,482	Adiposo	0,311
Branco, $\sigma = 0{,}05$	0,952	0,843	Estroma	0,885
Branco, $\sigma = 0{,}1$	0,916	0,798	Estroma	0,811
Branco, $\sigma = 0{,}2$	0,663	0,549	Muco	0,537
Controle DenseNet-121	0,983	0,903	Detritos	0,955

Fonte: Elaborado pelo autor.

Medidas. No controle do PathMNIST, a LMC final é $0{,}077 \pm 0{,}010$ e a SampEn final é $2{,}058 \pm 0{,}019$, com as mesmas direções do MedNIST: a LMC sobe e a SampEn desce ao longo do treino. A Figura 2 compara, regime a regime, a razão em relação ao controle nos dois repositórios, e a Tabela 6 traz os valores do PathMNIST.

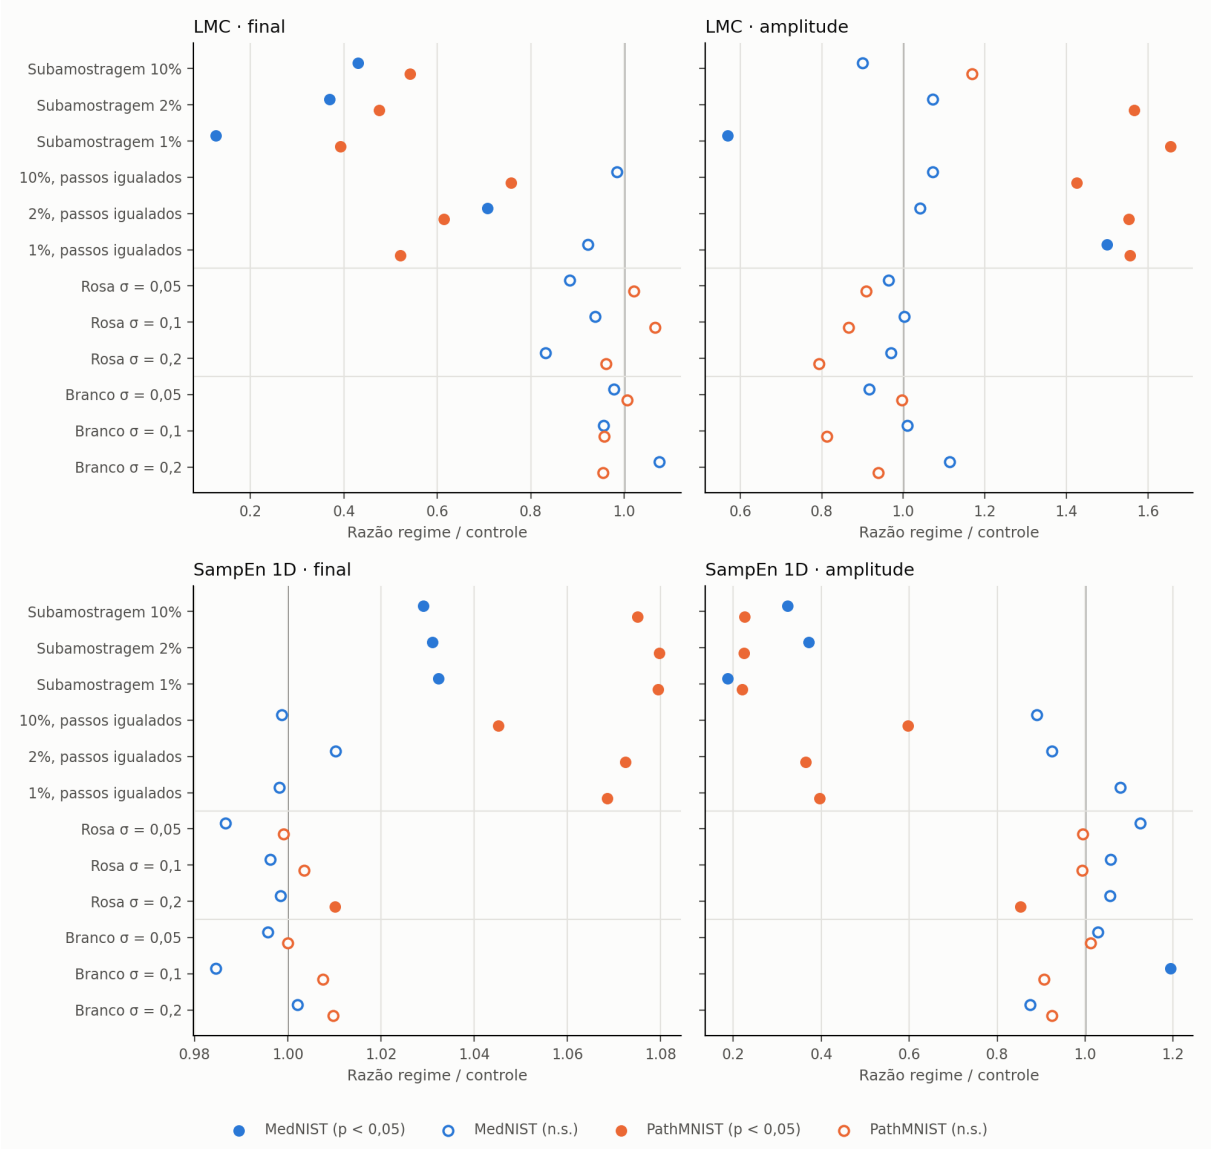


Figura 2 – Razão entre a média de cada regime e a do controle, no MedNIST e no PathMNIST (ResNet-18). Ponto cheio: Mann-Whitney $p < 0{,}05$, sem correção para múltiplos testes. A linha vertical marca a razão igual a 1.

Fonte: Elaborado pelo autor.

Tabela 6 – PathMNIST: razão entre a média de cada regime e a do controle, com o valor-p do teste de Mann-Whitney bilateral entre parênteses. Controle com $n = 8$; regimes com $n = 5$.

	LMC		SampEn	
Regime	Final	Amplitude	Final	Amplitude
Subamostragem 10 %	0,54 (0,0016)	1,17 (0,17)	1,08 (0,0016)	0,23 (0,0016)
Subamostragem 2 %	0,48 (0,0016)	1,57 (0,0016)	1,08 (0,0016)	0,22 (0,0016)
Subamostragem 1 %	0,39 (0,0016)	1,66 (0,0016)	1,08 (0,0016)	0,22 (0,0016)
10 %, passos igualados	0,76 (0,0031)	1,43 (0,0016)	1,05 (0,0016)	0,60 (0,0016)
2 %, passos igualados	0,61 (0,0016)	1,55 (0,0016)	1,07 (0,0016)	0,36 (0,0016)
1 %, passos igualados	0,52 (0,0016)	1,56 (0,0016)	1,07 (0,0016)	0,40 (0,0016)
Rosa, $\sigma = 0{,}05$	1,02 (0,28)	0,91 (0,35)	1,00 (0,94)	0,99 (0,94)
Rosa, $\sigma = 0{,}1$	1,07 (0,17)	0,87 (0,22)	1,00 (0,44)	0,99 (0,83)
Rosa, $\sigma = 0{,}2$	0,96 (0,94)	0,79 (0,093)	1,01 (0,045)	0,85 (0,030)
Branco, $\sigma = 0{,}05$	1,01 (0,72)	1,00 (0,83)	1,00 (1,00)	1,01 (0,83)
Branco, $\sigma = 0{,}1$	0,96 (1,00)	0,81 (0,093)	1,01 (0,13)	0,91 (0,22)
Branco, $\sigma = 0{,}2$	0,95 (0,52)	0,94 (0,62)	1,01 (0,065)	0,92 (0,28)

Fonte: Elaborado pelo autor.

O que se repete. Três comportamentos do MedNIST reaparecem. Na subamostragem curta, a LMC final cai para entre 0,39 e 0,54 vezes a do controle, a SampEn final fica ligeiramente acima (1,08 vezes) e a amplitude da SampEn cai para cerca de um quinto. O ruído nas imagens, embora derrube o desempenho de forma muito mais acentuada que no MedNIST, não altera as medidas de forma consistente: os dois únicos valores-p abaixo de 0,05 (SampEn final e amplitude com ruído rosa a $\sigma = 0{,}2$, razões de 1,01 e 0,85) não se repetem nos níveis vizinhos nem no outro repositório. Por fim, a DenseNet-121 volta a diferir da ResNet-18 na SampEn, agora de modo muito mais acentuado: a SampEn final é 0,58 vezes a da ResNet-18 (1,20 contra 2,06; $p = 0{,}0016$) e sua amplitude relativa, 11,4 vezes maior. A LMC final da DenseNet-121, que no MedNIST não diferia, no PathMNIST é 1,84 vezes maior ($p = 0{,}0016$).

O que não se repete. A diferença está na subamostragem com passos igualados. No MedNIST, igualar os passos fazia desaparecer quase todo o efeito (Seção 4.3); no PathMNIST, as quatro estatísticas diferem do controle nas três frações, todas com $p \leq 0{,}0031$: a LMC final fica entre 0,52 e 0,76 vezes a do controle, e a amplitude da SampEn, entre 0,36 e 0,60 vezes. Na prática, a SampEn da camada densa nesses regimes termina perto do valor inicial (2,15 a 2,21, contra 2,20 no início), enquanto a do controle desce até 2,06. A leitura compatível com os dois repositórios é que o número de passos explica a diferença quando a rede, mesmo com poucos dados, chega a uma solução que generaliza — caso do MedNIST, em que a validação fica acima de 0,99 —, mas não quando ela memoriza o subconjunto, caso do PathMNIST. Nessa leitura, as medidas registrariam a quantidade de dados apenas quando ela muda o tipo de solução encontrada. É uma interpretação a partir de dois repositórios, ainda não testada diretamente.

4.7 Limitações dos Resultados Atuais

1. Os experimentos usam dois repositórios, ambos em 64×64; o MedNIST é reconhecidamente fácil e satura rapidamente. Como os dois divergem na subamostragem com passos igualados, a interpretação proposta na Seção 4.6 depende de um terceiro repositório, de dificuldade intermediária, para ser confirmada.

2. No PathMNIST, a acurácia avaliada oscila entre épocas por efeito da normalização em lote; o desempenho é reportado na melhor época, o que favorece levemente todos os regimes da mesma forma.

3. Os regimes têm cinco sementes, o que limita o poder dos testes; os efeitos que sobrevivem ao controle dos passos precisam de confirmação com mais execuções.

4. As comparações não foram corrigidas para múltiplos testes; valores-p isolados próximos de 0,05 não devem ser interpretados como efeito.

5. Os regimes usam uma única arquitetura, a ResNet-18; a DenseNet-121 entra apenas como controle.

Referências

ADVANI, M. S.; SAXE, A. M.; SOMPOLINSKY, H. High-dimensional dynamics of generalization error in neural networks. **Neural Networks**, v. 132, p. 428–446, 2020.

ARPIT, D. et al. A closer look at memorization in deep networks. In: **Proceedings of the 34th International Conference on Machine Learning (ICML)**. [S.l.: s.n.], 2017. p. 233–242.

BARTLETT, P. L.; FOSTER, D. J.; TELGARSKY, M. Spectrally-normalized margin bounds for neural networks. In: **Advances in Neural Information Processing Systems (NeurIPS)**. [S.l.: s.n.], 2017. v. 30.

COSTA, M.; GOLDBERGER, A. L.; PENG, C.-K. Multiscale entropy analysis of complex physiologic time series. **Physical Review Letters**, v. 89, n. 6, p. 068102, 2002.

COSTA, M.; GOLDBERGER, A. L.; PENG, C.-K. Multiscale entropy analysis of biological signals. **Physical Review E**, v. 71, n. 2, p. 021906, 2005.

DELGADO-BONAL, A.; MARSHAK, A. Approximate entropy and sample entropy: A comprehensive tutorial. **Entropy**, v. 21, n. 6, p. 541, 2019.

DZIUGAITE, G. K.; ROY, D. M. Computing nonvacuous generalization bounds for deep (stochastic) neural networks with many more parameters than training data. In: **Proceedings of the 33rd Conference on Uncertainty in Artificial Intelligence (UAI)**. [S.l.: s.n.], 2017.

HE, K. et al. Deep residual learning for image recognition. p. 770–778, 2016.

HUANG, G. et al. Densely connected convolutional networks. In: **Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)**. [S.l.: s.n.], 2017. p. 4700–4708.

JIANG, Y. et al. Fantastic generalization measures and where to find them. In: **International Conference on Learning Representations (ICLR)**. [S.l.: s.n.], 2020.

LAMBERTI, P. W. et al. Intensive entropic non-triviality measure. **Physica A: Statistical Mechanics and its Applications**, v. 334, n. 1–2, p. 119–131, 2004.

LÓPEZ-RUIZ, R.; MANCINI, H. L.; CALBET, X. A statistical measure of complexity. **Physics Letters A**, v. 209, n. 5–6, p. 321–326, 1995.

MARTIN, C. H.; PENG, T.; MAHONEY, M. W. Predicting trends in the quality of state-of-the-art neural networks without access to training or testing data. **Nature Communications**, v. 12, n. 1, p. 4122, 2021.

PINCUS, S. M. Approximate entropy as a measure of system complexity. **Proceedings of the National Academy of Sciences**, v. 88, n. 6, p. 2297–2301, 1991.

POWER, A. et al. **Grokking: generalization beyond overfitting on small algorithmic datasets**. 2022. ArXiv:2201.02177.

PRECHELT, L. Automatic early stopping using cross validation: quantifying the criteria. **Neural Networks**, v. 11, n. 4, p. 761–767, 1998.

RICHMAN, J. S.; MOORMAN, J. R. Physiological time-series analysis using approximate entropy and sample entropy. **American Journal of Physiology – Heart and Circulatory Physiology**, v. 278, n. 6, p. H2039–H2049, 2000.

ROSSO, O. A. et al. Generalized statistical complexity measure. **International Journal of Bifurcation and Chaos**, v. 20, n. 3, p. 775–785, 2010.

SHANNON, C. E. A mathematical theory of communication. **Bell System Technical Journal**, v. 27, n. 3, p. 379–423, 1948.

YANG, J. et al. MedMNIST v2 – a large-scale lightweight benchmark for 2D and 3D biomedical image classification. **Scientific Data**, v. 10, n. 1, p. 41, 2023.

YENTES, J. M. et al. The appropriate use of approximate entropy and sample entropy with short data sets. **Annals of Biomedical Engineering**, v. 41, n. 2, p. 349–365, 2013.

ZHANG, C. et al. Understanding deep learning requires rethinking generalization. In: **International Conference on Learning Representations (ICLR)**. [S.l.: s.n.], 2017.