Universidade de São Paulo
Faculdade de Filosofia, Ciências e Letras de Ribeirão Preto
Departamento de Computação e Matemática
Programa de Pós-Graduação em Computação Aplicada

Cássio Silva Takarada

Complexidade Estatística dos Pesos de Redes Neurais Profundas como Marcador de Overfitting

Ribeirão Preto–SP

2026

Cássio Silva Takarada

Complexidade Estatística dos Pesos de Redes Neurais Profundas como Marcador de Overfitting

Monografia apresentada à Faculdade de Filosofia, Ciências e Letras de Ribeirão Preto da Universidade de São Paulo, como parte das exigências para a obtenção do título de Mestre em Ciências.

Prof. Dr. Luiz Otávio Murta Junior

Ribeirão Preto–SP

2026

Takarada, Cássio Silva
Complexidade estatística dos pesos de redes neurais profundas como marcador de *overfitting* / Cássio Silva Takarada; orientador Luiz Otávio Murta Junior. – Ribeirão Preto, 2026.

[PREENCHER: número de folhas] f. : il.

Dissertação (Mestrado – Programa de Pós-Graduação em Computação Aplicada) – Faculdade de Filosofia, Ciências e Letras de Ribeirão Preto, Universidade de São Paulo, 2026.

1. Aprendizado profundo. 2. Complexidade estatística. 3. Entropia amostral. 4. *Overfitting*. 5. Imagens médicas. I. Murta Junior, Luiz Otávio, orient. II. Título.

[PREENCHER: CDD]

[PREENCHER: Elaborada por ..., CRB-8/....]

Cássio Silva Takarada

Complexidade Estatística dos Pesos de Redes Neurais Profundas como Marcador de *Overfitting*

Dissertação apresentada ao Programa de Pós-Graduação em Computação Aplicada da Faculdade de Filosofia, Ciências e Letras de Ribeirão Preto da Universidade de São Paulo, como parte das exigências para a obtenção do título de Mestre em Ciências.

Trabalho aprovado. Ribeirão Preto, [PREENCHER: dia] de [PREENCHER: mês] de [PREENCHER: ano].

Prof. Dr. Luiz Otávio Murta Junior
Orientador — FFCLRP/USP

[PREENCHER: Prof. Dr. Nome do 1º examinador]
[PREENCHER: instituição]

[PREENCHER: Prof. Dr. Nome do 2º examinador]
[PREENCHER: instituição]

AGRADECIMENTOS

Em primeiro lugar, agradeço a Deus pois sem Ele tudo o que sou seria em vão. Todas as oportunidades que tive e tenho de crescer e me aprimorar, tanto pessoalmente quanto profissionalmente, veio através Dele.

Subsequentemente, agradeço ao professor doutor Luiz Otávio Murta Júnior, por ter me acolhido e acreditado em mim para executar essa tão renomada pesquisa, bem como fazer parte de um grupo seleto de pessoas extremamente capacitadas.

Também, agradeço a minha família. Especialmente minha esposa e meu filho, pessoas as quais me dão força de vontade e determinação para continuar me aprimorando. Agradeço também aos meus pais, que são minha base e exemplo de pessoas e profissionais. Em adendo, agradeço ao meu irmão que me apoia em tudo que eu faço em minha vida, sempre dizendo “sim” quando preciso dele.

E por fim, agradeço aos meus amigos, que sem perceber, com seus pequenos atos, fazem minha vida mais fácil. Agradeço, especialmente, ao Alexandre Gomes da Silva, Matheus Rossato Silva e Airton Monte Serrat Borin Júnior. Os quais fizeram parte desse grupo seleto de pesquisadores que estenderam a mão sempre que precisei.

À todos, meu sincero agradecimento!

"Nada há encoberto que não haja de revelar-se,
nem oculto que não haja de saber-se."
Mateus 10:26

"Ego cogito ergo sum."
René Descartes

RESUMO

O diagnóstico de sobreajuste (*overfitting*) em redes neurais profundas depende, na prática corrente, de um conjunto de validação rotulado, representativo e suficientemente grande — condição frequentemente inviável em imagens médicas, nas quais a anotação é onerosa e exige especialista. Esta dissertação investiga se medidas de complexidade estatística calculadas exclusivamente sobre os pesos da rede, sem acesso a rótulo algum, constituem marcadores do início do sobreajuste. São consideradas a complexidade Lopez-Ruiz–Mancini–Calbet (LMC), produto da entropia de Shannon pela distância estatística ao equilíbrio, a entropia amostral (SampEn) e sua variante bidimensional (SampEn2D), calculadas a cada época sobre os pesos da camada densa de redes treinadas no conjunto MedNIST. A memorização é induzida por corrupção controlada de rótulos, preservando o volume de dados. Com oito execuções e controles estritamente pareados, a SampEn2D inflete $7{,}5 \pm 0{,}9$ épocas antes da degradação da acurácia de validação, com razão de amplitude de 5,7 vezes entre execuções com e sem memorização ($p = 0{,}00016$), resultado replicado na arquitetura DenseNet-121 (4,3 vezes; $p = 0{,}0016$). A complexidade LMC, contudo, não discrimina memorização na camada densa (1,1 vez; $p = 0{,}19$). Conclui-se que a capacidade de marcar o sobreajuste depende da medida empregada.

Palavras-chave: Complexidade estatística; Entropia amostral; Sobreajuste; Aprendizagem profunda; Imagens médicas; Memorização; Complexidade LMC.

ABSTRACT

Diagnosing overfitting in deep neural networks currently relies on a labelled validation set that is representative and sufficiently large — a condition often unattainable in medical imaging, where annotation is costly and requires expert knowledge. This dissertation investigates whether statistical complexity measures computed exclusively from network weights, without access to any label, can serve as markers of the onset of overfitting. Three measures are considered: the Lopez-Ruiz–Mancini–Calbet (LMC) complexity, defined as the product of Shannon entropy and the statistical distance from equilibrium; sample entropy (SampEn); and its two-dimensional variant (SampEn2D), computed at every epoch over the dense-layer weights of networks trained on the MedNIST dataset. Memorisation is induced by controlled label corruption, preserving data volume. With eight runs and strictly paired controls, SampEn2D inflects 7.5 ± 0.9 epochs before validation accuracy degrades, with an amplitude ratio of 5.7 between runs with and without memorisation ($p = 0.00016$), a result replicated on the DenseNet-121 architecture (4.3 times; $p = 0.0016$). LMC complexity, however, fails to discriminate memorisation in the dense layer (1.1 times; $p = 0.19$). The findings indicate that the ability to mark overfitting depends on the measure employed.

Keywords: Statistical complexity; Sample entropy; Overfitting; Deep learning; Medical imaging; Memorisation; LMC complexity.

LISTA DE ILUSTRAÇÕES

Figura 1 – Estrutura de nível superior da ResNet-18: oito módulos nomeados em sequência. As caixas indicam o tipo de camada (azul: Conv2d; verde: BatchNorm2d; cinza: sem parâmetros; laranja: Linear). As caixas `layer1`–`layer4` são contêineres `Sequential` de blocos residuais. 38
Figura 2 – Acurácias de treino, em modo de avaliação, e de validação ao longo das épocas em execução com 25 % de rótulos efetivamente errados. O cruzamento das curvas caracteriza a memorização. 44
Figura 3 – Trajetória dos três indicadores na camada densa e das curvas de validação, em execução com corrupção de rótulos. A região sombreada corresponde às épocas posteriores ao início do sobreajuste, excluídas das conclusões. 45
Figura 4 – Época do alerta e época da âncora em função do nível de corrupção de rótulos. A época do alerta é estável; a da âncora antecipa-se com o aumento da corrupção. 47
Figura 5 – Trajetória dos indicadores na camada densa da DenseNet-121, em execução com corrupção de rótulos. 48

LISTA DE TABELAS

Tabela 1 – Comparação dos trabalhos discutidos quanto à dependência de dados rotulados, à natureza temporal da leitura e ao objeto medido. 35
Tabela 2 – Evidência de memorização nas oito execuções com corrupção de rótulos e nos oito controles pareados, em ResNet-18. Acurácias em modo de avaliação. 43
Tabela 3 – Amplitude de variação dos indicadores na camada densa, em ResNet-18, com oito execuções por grupo. Valores como média ± desvio-padrão amostral; p obtido por teste de Mann-Whitney bilateral. 44
Tabela 4 – Antecedência dos indicadores em relação à queda sustentada da acurácia de validação, em épocas, nas oito execuções com corrupção em ResNet-18. 45
Tabela 5 – Época do alerta emitido pelo monitor e época da âncora, por nível de corrupção, com três sementes por nível. 46
Tabela 6 – Resultados na DenseNet-121, com oito execuções com corrupção e cinco controles pareados. 47
Tabela 7 – Comparação das duas ordens de achatamento na SampEn 1D da camada densa. 48
Tabela 8 – Efeito da correção do pareamento sobre as razões de amplitude da SampEn2D. 49
Tabela 9 – Mapeamento elemento a elemento da camada Linear 2×3. 61
Tabela 10 – Validação da LMC ($N = 100$ *bins*). Os casos uniforme e degenerado reproduzem os valores analíticos com precisão de máquina. 63
Tabela 11 – Validação da SampEn 1D ($m = 2$, $r = 0{,}2\,\sigma$, séries de 1000 amostras). . 64
Tabela 12 – Validação da SampEn 2D ($m = 2$, matrizes 64×64). O caso do ruído sob $r = 0{,}2\,\sigma$ reproduz a saturação que motiva $r = 0{,}5\,\sigma$. 64

SUMÁRIO

1 INTRODUÇÃO 19
1.1 Contexto da análise de imagens médicas no diagnóstico clínico . . . 19
1.2 Avanços em aprendizado profundo aplicados à medicina 19
1.3 Justificativa do uso de medidas de complexidade 20
1.3.1 Justificativa prática: o ponto de vista de quem treina a rede 21
1.4 Hipótese, objetivos e escopo 22
1.5 Organização do trabalho 23

2 FUNDAMENTAÇÃO TEÓRICA 25
2.1 Sistemas complexos, auto-organização e emergência 25
2.1.1 A noção de sistema complexo 25
2.1.2 Emergência 26
2.1.3 Auto-organização 26
2.1.4 Delimitação: o que não se pretende afirmar 27
2.2 Entropia de Shannon e teoria da informação 27
2.3 Entropia Aproximada e Entropia de Amostra 28
2.4 Entropia de Amostra Bidimensional (SampEn2D) 29
2.5 Entropia Multiescala (MSE) 30
2.6 Complexidade Estatística LMC 31
2.7 Estado da arte: leitura do estado interno de redes profundas 33
2.7.1 Memorização e os dois regimes do aprendizado 33
2.7.2 Limites de generalização por normas e margens 34
2.7.3 Abordagens espectrais 34
2.7.4 Abordagens informação-teóricas e a controvérsia do gargalo de informação . 34
2.7.5 Síntese e posicionamento da proposta 35

3 METODOLOGIA 37
3.1 Conjunto de dados 37
3.2 Arquiteturas 37
3.3 Protocolo de treinamento 38
3.4 Indução de memorização por corrupção de rótulos 38
3.4.1 Protocolo de corrupção de rótulos 39
3.5 A camada densa como objeto de medida 40
3.6 Medidas de complexidade 41
3.6.1 Complexidade LMC 41

3.6.2 Entropia amostral SampEn_{1D} . . . 41
3.6.3 SampEn 2D . . . 41
3.7 Monitoramento durante o treinamento . . . 41
3.8 Definição operacional da referência temporal . . . 42

4 RESULTADOS . . . 43
4.1 Memorização induzida na camada densa . . . 43
4.1.1 Confirmação da memorização . . . 43
4.1.2 Poder de discriminação dos indicadores . . . 44
4.1.3 Antecedência em relação à degradação da validação . . . 45
4.1.4 Efeito do nível de corrupção . . . 46
4.1.5 Generalização para outra arquitetura . . . 47
4.1.6 Ablação da ordem de achatamento . . . 48
4.1.7 Sobre o pareamento dos controles . . . 49

5 CONCLUSÃO . . . 51
5.1 Principais achados . . . 51
5.2 Reformulação da hipótese central . . . 52
5.3 Trabalhos Futuros . . . 52

REFERÊNCIAS . . . 55

APÊNDICES 59

APÊNDICE A – EXEMPLO NUMÉRICO DA ORDEM DE ACHATAMENTO DA CAMADA DENSA . . . 61
A.1 Camada Linear: matriz 2×3 . . . 61
A.2 Contraste: ordem por entrada . . . 62
A.3 Reprodutibilidade . . . 62

APÊNDICE B – VALIDAÇÃO NUMÉRICA DAS MEDIDAS DE COMPLEXIDADE . . . 63
B.1 Complexidade LMC . . . 63
B.2 Sample Entropy 1D . . . 63
B.3 Sample Entropy 2D . . . 64

1 INTRODUÇÃO

1.1 CONTEXTO DA ANÁLISE DE IMAGENS MÉDICAS NO DIAGNÓSTICO CLÍNICO

A imagem médica consolidou-se como um dos pilares do diagnóstico clínico contemporâneo. Modalidades como tomografia computadorizada, ressonância magnética, radiografia, ultrassonografia, tomografia por emissão de pósitrons e a histopatologia digital fornecem representações detalhadas de estruturas internas e teciduais que sustentam decisões de triagem, estadiamento e acompanhamento terapêutico em praticamente todas as especialidades médicas (JIANG et al., 2023). O volume de dados gerado por esses exames cresce de modo contínuo, ao mesmo tempo em que sua interpretação permanece uma tarefa que exige treinamento especializado e está sujeita a variabilidade inter e intraobservador. Esse cenário motiva o desenvolvimento de ferramentas computacionais capazes de oferecer suporte quantitativo à análise dessas imagens, notadamente em tarefas de classificação, segmentação e detecção de anomalias.

1.2 AVANÇOS EM APRENDIZADO PROFUNDO APLICADOS À MEDICINA

Nas últimas décadas o aprendizado profundo (*deep learning*, DL) emergiu como o paradigma dominante para o processamento de imagens médicas. Em particular, redes neurais convolucionais profundas, exemplificadas pela família de redes residuais introduzida por He et al. (2016), alcançaram desempenho próximo ou superior ao de especialistas humanos em diversas tarefas de classificação e detecção (JIANG et al., 2023). Esse progresso é sustentado, de um lado, pelo aumento sistemático do poder computacional e, de outro, pela disponibilização de coleções públicas padronizadas de imagens médicas que viabilizam treinamento, comparação e reprodutibilidade de modelos. Entre essas coleções destaca-se o *benchmark* MedMNIST v2 (YANG et al., 2023), que reúne dezoito conjuntos de classificação 2D e 3D oriundos de patologia, radiologia e oftalmologia, padronizados em baixa resolução para permitir prototipagem rápida sem perder representatividade das modalidades clínicas.

Apesar desses avanços, modelos profundos operam de modo essencialmente opaco do ponto de vista clínico: a relação entre os parâmetros aprendidos e as decisões de saída não é trivialmente legível, configurando o problema classicamente designado por *caixa-preta*. Levantamentos recentes apontam que essa limitação constitui hoje a principal

barreira à adoção de DL em fluxos diagnósticos sensíveis, mais relevante até que o ganho marginal de acurácia em métricas tradicionais (TENG et al., 2022). Nesse contexto, a interpretabilidade dos modelos depende não apenas de explicações *post hoc* sobre saídas individuais, mas também de instrumentos quantitativos que caracterizem o estado interno da rede durante o treinamento.

1.3 JUSTIFICATIVA DO USO DE MEDIDAS DE COMPLEXIDADE

Métricas tradicionais de avaliação — acurácia, perda de validação, área sob a curva ROC — capturam o comportamento do modelo sobre um conjunto de dados específico, mas não oferecem leitura direta sobre a organização estatística dos pesos aprendidos. Essa lacuna é particularmente visível no fenômeno do *overfitting*: redes com elevada capacidade podem memorizar o conjunto de treinamento de modo a atingir acurácia quase perfeita sobre ele, ao mesmo tempo em que generalizam mal para dados novos. Análises teóricas recentes da dinâmica de generalização em regimes de alta dimensionalidade indicam que os pesos atravessam fases qualitativamente distintas durante o treinamento, com implicações diretas sobre a capacidade preditiva do modelo (ADVANI et al., 2020), e métodos dedicados à detecção de *overfitting* em aplicações clínicas têm sido propostos como resposta prática a esse problema (ZHANG; BELL, 2025).

A presente dissertação parte da hipótese de que medidas de complexidade aplicadas diretamente aos pesos da rede podem servir como marcadores objetivos da maturação do treinamento e do início do sobreajuste. Duas famílias de medidas dão sustentação a essa abordagem. A primeira é a Entropia de Amostra (*Sample Entropy*, SampEn) introduzida por Richman e Moorman (2000) como refinamento da Entropia Aproximada de Pincus (1991); SampEn quantifica, sem viés sistemático associado a contagens de auto-coincidência, a regularidade de uma sequência de valores e tem aplicação consolidada na análise de sinais fisiológicos. Sua extensão bidimensional, SampEn2D, foi formalizada por Silva et al. (2016) para caracterizar a irregularidade de texturas espaciais em imagens biomédicas, e é diretamente aplicável à matriz de pesos de uma camada convolucional. A análise multiescala (Multiscale Entropy, MSE) proposta por Costa et al. (2002) complementa SampEn ao revelar regularidades que se manifestam em diferentes resoluções da mesma sequência ou matriz.

A segunda família é a complexidade estatística de López-Ruiz, Mancini e Calbet (LÓPEZ-RUIZ et al., 1995), definida pelo produto entre uma medida de incerteza, tipicamente a entropia de Shannon, e uma medida de desequilíbrio em relação à distribuição uniforme. Diferentemente de medidas puramente entrópicas, a complexidade LMC anula-se nos extremos de ordem perfeita e desordem perfeita, atingindo valores máximos em

regimes intermediários de auto-organização (ANTENEODO; PLASTINO, 1996). Aplicada à distribuição dos pesos de uma rede neural, espera-se que ela descreva quantitativamente a transição entre o estado inicial aleatório e o estado treinado. A combinação entre SampEn (sensível à estrutura sequencial e espacial dos pesos) e LMC (sensível à forma da distribuição marginal) constitui o eixo metodológico desta investigação.

1.3.1 Justificativa prática: o ponto de vista de quem treina a rede

A justificativa apresentada até aqui é de natureza metodológica: as medidas de complexidade oferecem uma leitura dos pesos que as métricas de desempenho não oferecem. Há, porém, uma segunda justificativa, de natureza prática, que motiva este trabalho de modo mais imediato e é formulada deliberadamente do ponto de vista de quem desenvolve e treina a rede.

A dependência atual dos dados rotulados

Para saber se uma rede aprendeu ou apenas memorizou, o desenvolvedor depende hoje, integralmente, dos dados. É preciso construir conjuntos de treino, validação e teste bem particionados, corretamente rotulados e representativos da população de interesse. Cada um desses requisitos custa tempo e recursos, e em imagens médicas frequentemente esbarra na indisponibilidade de especialistas para a anotação. O diagnóstico do treinamento é, portanto, função do orçamento de anotação disponível — e não uma propriedade que se possa ler diretamente do modelo.

O procedimento padrão para decidir quando interromper o ajuste, a parada antecipada, monitora o erro em um conjunto de validação separado (PRECHELT, 1998). O procedimento é sólido, mas transfere ao conjunto de validação toda a responsabilidade pelo diagnóstico: se ele é pequeno, desbalanceado ou pouco representativo, a estimativa do momento de parada torna-se ruidosa, e o desenvolvedor não dispõe de sinal alternativo com que confrontá-la. Em outras palavras, justamente no regime de poucos dados — aquele em que o sobreajuste é mais provável — o instrumento de medida é o menos confiável.

O que muda com um indicador calculado sobre os pesos

As medidas investigadas nesta dissertação são calculadas exclusivamente a partir dos pesos. Não consomem imagem, não consomem rótulo e não dependem de nenhuma partição. Caso sejam capazes de sinalizar a transição para o regime de memorização, o desenvolvedor passa a dispor de uma segunda leitura do treinamento, obtida por caminho independente daquele do conjunto de validação. As duas leituras podem então ser confrontadas: quando concordam, a decisão de parada ganha confiança; quando discordam, há indício de que a validação não é representativa.

Note-se que a proposta não é substituir a parada antecipada clássica, cuja fundamentação é sólida, mas acrescentar-lhe uma fonte de evidência independente.

Casos de uso

1. **Decidir quando interromper o treinamento.** Um aviso emitido antes da degradação observável na validação amplia a janela de decisão, em lugar de constatar a perda depois de consumada.

2. **Economizar recursos computacionais.** Detectar que a rede deixou de aprender evita épocas de treinamento que não trarão ganho, com impacto direto no custo de processamento.

3. **Comparar arquiteturas sem ampliar a anotação.** Como a medida não consome dados rotulados, a comparação entre arquiteturas candidatas não exige a ampliação do conjunto de validação.

4. **Diagnosticar quando a validação é pequena.** Em cenários nos quais o conjunto de validação é pequeno demais para ser confiável, um indicador independente fornece evidência adicional — precisamente o cenário típico em imagens médicas.

Entrega prática e delimitação

A contribuição não se esgota na constatação empírica. Entrega-se um monitor implementado em PyTorch, acoplável ao laço de treinamento de terceiros, que calcula os indicadores a cada época e devolve um estado do aprendizado, conforme descrito na Seção 3.7. O custo computacional é baixo quando a medida incide sobre a camada densa.

Registre-se, por honestidade, que a utilidade prática aqui descrita é *condicional* ao sucesso empírico dos indicadores, e que os resultados do Capítulo 4 mostram que esse sucesso não é uniforme: depende da medida empregada. As implicações dessa delimitação para o uso prático são discutidas no Capítulo 5.

1.4 HIPÓTESE, OBJETIVOS E ESCOPO

A hipótese central deste trabalho é que a complexidade estatística dos pesos de uma rede neural profunda evolui de modo sistemático durante o treinamento e constitui um marcador objetivo do início do *overfitting*. Mais especificamente, postula-se que a trajetória das medidas LMC e SampEn ao longo dos passos de otimização exibe inflexão não monotônica, e que essa inflexão precede ou coincide com a saturação da acurácia de validação.

A pesquisa adota um **escopo deliberadamente restrito** a fim de permitir o controle das variáveis de interesse e a reprodutibilidade plena dos experimentos:

- **Arquitetura:** ResNet-18 (HE et al., 2016), escolhida por sua importância histórica, profundidade moderada e papel de *baseline* consagrado em classificação de imagens médicas; parte dos experimentos é repetida com a DenseNet-121 para verificar a dependência em relação à arquitetura.
- **Conjunto de dados:** MedNIST, com seis classes de imagens médicas de diferentes modalidades (Seção 3.1).
- **Pesos analisados:** apenas os da camada densa (classificadora), calculando-se as medidas sobre a camada inteira.
- **Tarefa única:** classificação multiclasse, excluindo-se explicitamente segmentação semântica, detecção e tarefas ordinais.

Arquiteturas alternativas como U-Net, conjuntos de dados de maior escala como NIH ChestX-ray14 e TCIA, e tarefas adicionais como segmentação — mencionados no projeto de qualificação — ficam relegados a trabalhos futuros (Capítulo 5).

Os objetivos específicos são:

1. Implementar SampEn1D, SampEn2D e a complexidade LMC com validação numérica em casos analiticamente conhecidos (distribuições uniforme, gaussiana e séries periódicas), conforme o Apêndice B.
2. Extrair os pesos da camada densa a cada época, durante o treinamento, excluindo o vetor de viés da análise.
3. Calcular a trajetória das medidas de complexidade em execuções com corrupção de rótulos e em seus controles pareados, e confrontá-la com a evolução da perda e da acurácia de validação.
4. Avaliar se a inflexão das trajetórias LMC e SampEn coincide, antecipa ou sucede o início observável do sobreajuste, e comparar os comportamentos entre níveis de corrupção e entre arquiteturas.

1.5 ORGANIZAÇÃO DO TRABALHO

O restante desta dissertação está organizado em quatro capítulos. O Capítulo 2 apresenta a fundamentação teórica das medidas de complexidade utilizadas (Entropia de Shannon, ApEn, SampEn, SampEn2D, complexidade LMC) e situa-as no contexto da

literatura de redes neurais profundas e análise de séries de pesos. O Capítulo 3 descreve o conjunto de dados, as arquiteturas, o protocolo de treinamento, a indução de memorização por corrupção de rótulos, a camada densa como objeto de medida e os parâmetros adotados para cada medida (m, r, número de *bins*). O Capítulo 4 apresenta as trajetórias de complexidade da camada densa nas execuções com corrupção de rótulos e em seus controles pareados, e sua relação com a perda e a acurácia de validação. O Capítulo 5 sintetiza as evidências obtidas em relação à hipótese central, discute as limitações do recorte adotado e indica direções para extensões futuras envolvendo arquiteturas, modalidades de imagem e tarefas adicionais.

2 FUNDAMENTAÇÃO TEÓRICA

Este capítulo apresenta o aparato conceitual e operacional sobre o qual se constrói a metodologia da dissertação. A seção 2.2 retoma a entropia de Shannon e seus desdobramentos em entropia diferencial e divergências, dando base formal às medidas que vêm a seguir. A seção 2.3 percorre a transição da Entropia Aproximada (ApEn) para a Entropia de Amostra (SampEn), explicitando os vieses que motivaram o refinamento e a interpretação probabilística de SampEn como log-verossimilhança condicional. As seção 2.4 e seção 2.5 estendem SampEn ao domínio espacial bidimensional e ao plano multiescala, respectivamente, fornecendo as duas leituras complementares sobre a matriz de pesos de uma camada convolucional. Por fim, a seção 2.6 apresenta a complexidade estatística de López-Ruiz, Mancini e Calbet (LMC), discute a controvérsia sobre normalização e intensividade que se seguiu à proposta original e justifica a convenção $C = H \times D$ adotada no restante do trabalho.

2.1 SISTEMAS COMPLEXOS, AUTO-ORGANIZAÇÃO E EMERGÊNCIA

Esta seção fixa o vocabulário conceitual sobre o qual as medidas das seções seguintes se apoiam. A justificativa para sua presença é direta: o restante desta dissertação afirma que os pesos de uma rede em treinamento apresentam regimes de *auto-organização*, e essa afirmação não tem conteúdo verificável enquanto o termo não for definido.

2.1.1 A noção de sistema complexo

Um sistema complexo pode ser informalmente caracterizado como uma rede de muitos componentes que interagem entre si e cujo comportamento coletivo surge e evolui por auto-organização (SAYAMA, 2015). A caracterização carrega duas exigências que não são triviais. A primeira é a *multiplicidade* de componentes interagentes. A segunda, mais restritiva, é que a informação relevante do sistema resida nas *relações* entre as partes, e não nas partes isoladamente; se o comportamento do todo for recuperável pela simples soma dos comportamentos individuais, o sistema é agregado, não complexo.

Uma rede neural profunda em treinamento satisfaz ambas as exigências. Os milhões de pesos constituem componentes que interagem indiretamente, pela retropropagação do gradiente, e nenhum peso isolado codifica a função aprendida — o conteúdo do modelo está na configuração conjunta. Essa observação não é retórica: é ela que autoriza aplicar

ao treinamento o instrumental desenvolvido para sistemas complexos, em lugar de tratar a rede apenas como um problema de otimização de alta dimensão.

2.1.2 Emergência

Denomina-se *emergente* a propriedade que se manifesta no nível macroscópico do sistema e que não é redutível às propriedades dos componentes isolados (SAYAMA, 2015). O conceito exige, portanto, a distinção explícita de dois níveis de descrição: o microscópico, dos componentes, e o macroscópico, do comportamento observável.

Na presente dissertação essa distinção é operacional, e não apenas conceitual. O nível microscópico é o dos valores individuais dos pesos; o macroscópico é o da capacidade de generalização do modelo, aferida em dados não vistos. A hipótese central pode então ser reformulada nesses termos: pretende-se verificar se uma estatística calculada sobre o nível microscópico — a distribuição e a organização dos pesos — acompanha, e eventualmente antecipa, a transição de regime observada no nível macroscópico.

2.1.3 Auto-organização

Chama-se *auto-organização* ao processo pelo qual um sistema desenvolve estrutura macroscópica sem que essa estrutura seja imposta por um controle externo ou por um plano centralizado (SAYAMA, 2015). Emergência e auto-organização são conceitos distintos, ainda que frequentemente tratados como sinônimos: a primeira descreve uma relação entre níveis de descrição em um instante, e a segunda descreve a evolução temporal do sistema.

O treinamento por descida de gradiente é, nessa acepção, um processo de auto-organização. Nenhum agente externo especifica o valor que cada peso deve assumir; os valores resultam da aplicação iterada de uma regra local de atualização, e a estrutura que se observa ao final — filtros que respondem a padrões visuais, camadas que se especializam — não foi projetada peso a peso.

Interessa particularmente a este trabalho a observação de que sistemas em auto-organização não evoluem de modo homogêneo: eles frequentemente apresentam *transições de regime*, nas quais o comportamento qualitativo muda em intervalos relativamente curtos (SAYAMA, 2015). É exatamente essa a estrutura que a hipótese desta dissertação pressupõe. Se o treinamento consistisse em um processo homogêneo de melhoria gradual, não haveria transição a ser detectada, e a busca por um marcador do início do sobreajuste careceria de objeto. A existência de dois regimes sucessivos no aprendizado — um em que a rede extrai regularidades generalizáveis e outro em que passa a memorizar exemplos inconsistentes — é documentada empiricamente por Arpit et al. (2017) e constitui o pressuposto factual da proposta.

2.1.4 Delimitação: o que não se pretende afirmar

Convém delimitar o alcance do enquadramento para evitar leitura excessiva. O aparato de sistemas complexos é empregado aqui em sentido *descritivo*, e não como apelo a um mecanismo explicativo. Não se afirma que o treinamento de uma rede neural seja formalmente equivalente a algum dos modelos canônicos da área — autômatos celulares, sistemas de reação-difusão ou redes dinâmicas (SAYAMA, 2015) —, nem se pretende derivar as medidas empregadas a partir de primeiros princípios da teoria de sistemas complexos.

O que o enquadramento fornece é mais modesto e suficiente: a legitimidade de tratar a configuração dos pesos como estado de um sistema cuja organização macroscópica varia no tempo, e cujas transições podem, em princípio, ser detectadas por estatísticas calculadas sobre esse estado. As medidas específicas utilizadas provêm da teoria da informação e da análise de séries, apresentadas nas seções seguintes, e sua validade é estabelecida empiricamente no Capítulo 4, não por filiação teórica.

2.2 ENTROPIA DE SHANNON E TEORIA DA INFORMAÇÃO

A entropia de Shannon (SHANNON, 1948) é a pedra angular sobre a qual se assenta toda a discussão subsequente. Para uma variável aleatória discreta X que assume valores no alfabeto finito $\mathcal{X} = \{x_1, x_2, \ldots, x_N\}$ com distribuição de probabilidade $P = (p_1, p_2, \ldots, p_N)$, a entropia é definida por

$$H(X) = -\sum_{i=1}^{N} p_i \log_2 p_i, \tag{2.1}$$

adotando-se, por convenção, $0 \log_2 0 = 0$. A escolha do logaritmo na base 2 implica que H é medida em bits, interpretação diretamente associada ao número médio mínimo de dígitos binários necessário para codificar uma realização de X. A entropia satisfaz $0 \leq H(X) \leq \log_2 N$, com extremos alcançados, respectivamente, pela distribuição degenerada (existe i tal que $p_i = 1$) e pela distribuição uniforme ($p_i = 1/N$ para todo i). Caracterizações axiomáticas mostram que essas propriedades, junto da continuidade e da aditividade, determinam H a menos de um fator multiplicativo (COVER; THOMAS, 2006).

Quando X é uma variável contínua com função de densidade de probabilidade f, a generalização natural — a entropia diferencial — é dada por

$$h(X) = -\int_{\mathcal{X}} f(x) \log_2 f(x)\, dx, \tag{2.2}$$

sempre que a integral exista. Diferentemente da versão discreta, $h(X)$ pode assumir valores negativos e não é invariante sob mudança de escala, o que limita seu uso direto como índice de "incerteza". Em aplicações práticas com pesos de redes neurais, trabalha-se com a versão discretizada por meio de histogramas com N bins, recuperando a forma da Equação 2.1 a um custo controlado de viés e variância (COVER; THOMAS, 2006).

Uma medida de dissimilaridade entre duas distribuições P e Q sobre o mesmo alfabeto é a divergência de Kullback–Leibler

$$D_{\mathrm{KL}}(P\|Q) = \sum_{i=1}^{N} p_i \log_2 \frac{p_i}{q_i}, \tag{2.3}$$

que é não negativa e nula se, e somente se, $P = Q$. A Equação 2.3 é central nesta dissertação porque a noção de "desequilíbrio" subjacente à complexidade LMC pode ser interpretada como uma medida de afastamento entre P e a distribuição de referência (uniforme), tema retomado na seção 2.6.

2.3 ENTROPIA APROXIMADA E ENTROPIA DE AMOSTRA

O salto da teoria da informação para a análise de séries temporais finitas exige um estimador de regularidade que opere com poucos pontos e seja robusto a ruído moderado. A Entropia Aproximada (ApEn), introduzida por Pincus (1991), foi a primeira proposta a preencher esse papel para sinais fisiológicos. Dada uma série $\mathbf{u} = (u_1, u_2, \ldots, u_N)$, fixa-se um comprimento de embedding m e uma tolerância r e constroem-se os vetores $\mathbf{x}_i = (u_i, u_{i+1}, \ldots, u_{i+m-1})$ com $1 \le i \le N - m + 1$. Para cada i define-se

$$C_i^m(r) = \frac{\#\{j : d[\mathbf{x}_i, \mathbf{x}_j] \le r\}}{N - m + 1}, \tag{2.4}$$

onde $d[\cdot,\cdot]$ é a distância de Chebyshev (máximo das diferenças absolutas componente a componente) e a contagem inclui o caso $j = i$ (*self-match*). A ApEn é então

$$\mathrm{ApEn}(m, r, N) = \Phi^m(r) - \Phi^{m+1}(r), \quad \Phi^m(r) = \frac{1}{N - m + 1} \sum_{i=1}^{N-m+1} \ln C_i^m(r). \tag{2.5}$$

A inclusão de *self-matches* em $C_i^m(r)$ é simultaneamente o recurso que viabiliza a definição (evita logaritmo de zero) e a fonte de seus dois principais defeitos: (i) ApEn é sistematicamente enviesada para valores menores em séries curtas, e (ii) sua consistência relativa — a propriedade de que, ao se comparar duas séries em um mesmo r, a ordem dos valores se preserva quando r varia — não é garantida (RICHMAN; MOORMAN, 2000; DELGADO-BONAL; MARSHAK, 2019). A literatura subsequente documenta cenários em que classificações fisiológicas baseadas em ApEn se invertem ao se mudar a tolerância, comprometendo seu uso como marcador objetivo (YENTES et al., 2013; DELGADO-BONAL; MARSHAK, 2019).

A Entropia de Amostra (SampEn), proposta por Richman e Moorman (2000), remove essas limitações por construção. Em vez de calcular o logaritmo médio de probabilidades locais, conta-se globalmente o número de pares de templates próximos. Sejam

$$B^m(r) = \#\{(i,j) : i < j,\ d[\mathbf{x}_i, \mathbf{x}_j] \le r\}, \tag{2.6}$$

$$A^m(r) = \#\{(i,j) : i < j,\ d[\mathbf{x}_i, \mathbf{x}_j] \le r,\ |u_{i+m} - u_{j+m}| \le r\}, \tag{2.7}$$

isto é, $B^m(r)$ conta pares de janelas de comprimento m próximas e $A^m(r)$ conta os pares dessas janelas que permanecem próximas após um passo adicional. A SampEn é dada por

$$\mathrm{SampEn}(m, r, N) = -\ln \frac{A^m(r)}{B^m(r)}. \tag{2.8}$$

Pela construção, ambas as contagens excluem o par (i, i), eliminando o viés associado às auto-coincidências. A interpretação de Equação 2.8 é direta e instrutiva: SampEn é o negativo do logaritmo da probabilidade condicional de que duas janelas próximas em comprimento m permaneçam próximas em comprimento $m+1$. Valores baixos correspondem a séries muito regulares (a continuação é altamente previsível); valores altos, a séries irregulares (continuação imprevisível).

A Equação 2.8 herda independência tanto de N quanto da ordem dos pares por ser uma estatística baseada em razão de contagens globais. Demonstrou-se ainda que, em uma ampla família de processos estocásticos, SampEn possui consistência relativa entre tolerâncias, propriedade que ApEn não satisfaz (RICHMAN; MOORMAN, 2000). Por outro lado, a literatura recente registra cenários particulares de processos do tipo MIX contaminados por ruído em que mesmo SampEn pode falhar essa consistência, recomendando cautela ao se interpretar diferenças finas entre séries de naturezas distintas (DELGADO-BONAL; MARSHAK, 2019).

A escolha dos parâmetros m e r é prática consagrada na literatura. Pela análise sistemática de Yentes et al. (2013) sobre séries curtas, recomenda-se $m = 2$ e r entre 0,1 e 0,25 do desvio padrão da série, com $N \geq 200$ para evitar instabilidade estatística. Esta dissertação adota $m = 2$ e $r = 0{,}2 \times \sigma$, com σ tomado como desvio padrão populacional (`ddof`=0), em consonância com a convenção do grupo de pesquisa e com o intervalo recomendado pela literatura.

2.4 ENTROPIA DE AMOSTRA BIDIMENSIONAL (SAMPEN2D)

A extensão bidimensional da SampEn surge da observação de que pesos de camadas convolucionais e parâmetros de matrizes têm estrutura espacial: a vizinhança de um peso é tão informativa quanto sua sequência linear, e o domínio natural para análise é a matriz, não o vetor. Silva et al. (2014) apresentaram uma primeira formulação, validada posteriormente em Silva et al. (2016) sobre imagens de textura sintéticas, do banco Brodatz e de cortes histológicos de nervo sural, demonstrando que SampEn2D recupera as propriedades qualitativas de SampEn 1D ao mesmo tempo em que incorpora a dependência bidimensional.

Seja $\mathbf{W} \in \mathbb{R}^{H \times W}$ uma matriz de pesos extraída de uma camada da rede. Fixe-se um tamanho de janela m e uma tolerância r. As janelas $m \times m$ centradas em (i, j) formam a coleção $\mathcal{V}_m = \{\mathbf{V}_{i,j}^{(m)} : 1 \leq i \leq H - m, 1 \leq j \leq W - m\}$. Para uma janela maior

$(m+1)\times(m+1)$, analogamente, escreve-se $\mathcal{V}_{m+1}$. Por construção, restringe-se às posições (i,j) tais que ambas as janelas m e $m+1$ caibam integralmente em $\mathbf{W}$, garantindo emparelhamento entre $\mathcal{V}_m$ e $\mathcal{V}_{m+1}$. Em analogia com as Equação 2.6 e Equação 2.7, definem-se

$$B_{2\mathrm{D}}^{m}(r) = \#\{(p,q) : p \neq q,\ d[\mathbf{V}_p^{(m)}, \mathbf{V}_q^{(m)}] \leq r\}, \tag{2.9}$$

$$A_{2\mathrm{D}}^{m}(r) = \#\{(p,q) : p \neq q,\ d[\mathbf{V}_p^{(m+1)}, \mathbf{V}_q^{(m+1)}] \leq r\}, \tag{2.10}$$

em que p, q percorrem as posições válidas e $d[\cdot,\cdot]$ é a distância de Chebyshev sobre a janela vista como vetor. A *Sample Entropy 2D* é

$$\mathrm{SampEn2D}(m, r, \mathbf{W}) = -\ln \frac{A_{2\mathrm{D}}^{m}(r)}{B_{2\mathrm{D}}^{m}(r)}. \tag{2.11}$$

A interpretação probabilística replica a do caso unidimensional: SampEn2D é o negativo do logaritmo da probabilidade de que duas janelas $m \times m$ próximas tenham vizinhanças que permaneçam próximas quando a janela é estendida em uma linha e uma coluna.

A literatura aponta dois aspectos práticos relevantes. Primeiro, a SampEn2D pode produzir valores indefinidos para matrizes pequenas quando $A_{2\mathrm{D}}^{m}(r) = 0$, problema que motivou propostas alternativas baseadas em entropias de dispersão e fuzzificação. Segundo, o custo computacional cresce quadraticamente com o número de janelas válidas, tornando a estimativa custosa para matrizes grandes (SILVA et al., 2016). Para os fins desta dissertação, o tamanho típico das matrizes de uma camada convolucional na ResNet-18 mantém-se confortavelmente acima do regime patológico identificado pela literatura, e a SampEn2D é aplicada diretamente, sem recurso a substitutos.

2.5 ENTROPIA MULTIESCALA (MSE)

A SampEn captura irregularidade em uma escala fixa. No entanto, sistemas com correlações de longo alcance — batimentos cardíacos saudáveis, ruído $1/f$, dinâmica de redes complexas — apresentam estrutura em múltiplas escalas temporais simultaneamente. A Entropia Multiescala (MSE), proposta por Costa et al. (2002) e sistematizada em Costa et al. (2005), lê esse fenômeno por meio de uma sequência de granulações grosseiras (*coarse-grainings*) da série original.

Dada uma série $\mathbf{u}$ e um fator de escala $\tau \in \mathbb{N}^*$, constrói-se a série granulosa

$$y_j^{(\tau)} = \frac{1}{\tau} \sum_{i=(j-1)\tau+1}^{j\tau} u_i, \quad 1 \leq j \leq \lfloor N/\tau \rfloor, \tag{2.12}$$

isto é, médias de blocos não sobrepostos de comprimento τ. A escala $\tau = 1$ recupera a série original. Para cada τ, calcula-se SampEn da série granulosa, formando o perfil multiescala $\{\mathrm{SampEn}(m, r, y^{(\tau)}) : \tau = 1, 2, \ldots, \tau_{\max}\}$.

Um detalhe metodológico crítico: a tolerância r é fixada uma única vez a partir do desvio padrão da série *original* e mantida constante em todas as escalas, conforme prescrição de Costa et al. (2005). Recomputar r em cada escala invalidaria a comparação entre escalas, pois mudanças no perfil de complexidade ficariam confundidas com a renormalização local. A interpretação qualitativa da curva SampEn versus τ separa três classes principais: ruído branco (entropia decresce monotonicamente), ruído $1/f$ (entropia constante ao longo das escalas) e periódicos (entropia próxima de zero em todas as escalas). Sistemas fisiológicos saudáveis apresentam padrão similar ao $1/f$, enquanto patologias frequentemente colapsam para perfis monotonicamente decrescentes (COSTA et al., 2005).

2.6 COMPLEXIDADE ESTATÍSTICA LMC

A entropia, isoladamente, não é uma boa medida de complexidade. Distribuições uniformes (entropia máxima) são tão simples quanto distribuições degeneradas (entropia mínima), no sentido de que ambas são facilmente descritíveis e desprovidas de estrutura interna. López-Ruiz et al. (1995) — doravante LMC — propuseram, como remédio, uma medida que se anula em ambos os extremos e atinge valores máximos em regimes intermediários de auto-organização. Para uma distribuição $P = (p_1, \ldots, p_N)$, define-se o *desequilíbrio*

$$D(P) = \sum_{i=1}^{N} \left(p_i - \frac{1}{N} \right)^2 , \tag{2.13}$$

isto é, o quadrado da distância L_2 até a distribuição uniforme. A complexidade estatística LMC é o produto

$$C(P) = H(P) \times D(P), \tag{2.14}$$

em que H é a entropia de Shannon, dada pela Equação 2.1. Como H é máxima e D é nula sob a distribuição uniforme, e H é nula e D é máxima sob a distribuição degenerada, C se anula em ambos os extremos por construção. Para distribuições intermediárias, C assume valores estritamente positivos, refletindo simultaneamente incerteza e afastamento do equilíbrio (LÓPEZ-RUIZ et al., 1995).

A definição original gerou debate intenso. Anteneodo e Plastino (1996) demonstraram, no contexto de ensembles físicos, que C na forma Equação 2.14 *não* é uma quantidade intensiva: ao se duplicar o tamanho do sistema, C não satisfaz a relação de escala esperada de uma medida termodinâmica genuína. Esse fato limita a transferibilidade direta de C entre sistemas de tamanhos distintos e motivou a busca por refinamentos. Feldman e Crutchfield (1998), em uma revisão crítica das medidas de complexidade estatística disponíveis na época, articularam três desideratos: a medida deve (i) anular-se nos extremos de ordem e desordem perfeitas, (ii) ser intensiva, e (iii) capturar a presença de estrutura correlacional em escalas relevantes do sistema.

A resposta mais influente a essas críticas é a complexidade estatística generalizada (SCM, *Statistical Complexity Measure*), introduzida por Lamberti et al. (2004) e desenvolvida por Rosso et al. (2010). Em vez do produto $H \times D$, define-se

$$C_{\mathrm{SCM}}(P) = Q_J(P, P_e) \cdot H(P)/H_{\max}, \tag{2.15}$$

em que $H_{\max} = \log_2 N$ normaliza a entropia, P_e é a distribuição de equilíbrio (tipicamente uniforme), e $Q_J(P, P_e)$ é o desequilíbrio em divergência de Jensen-Shannon, normalizado de modo que $0 \leq Q_J \leq 1$. A construção Equação 2.15 é intensiva, limitada ao intervalo $[0, 1]$ e aplicável a uma variedade de sistemas dinâmicos contínuos e discretos.

Apesar das vantagens formais da SCM, esta dissertação adota a forma original Equação 2.14 — $C = H \times D$ em bits, sem normalização — por três razões metodológicas que merecem explicitação:

1. **Comparação intra-modelo, não inter-sistema.** O objeto de análise são as trajetórias de complexidade dos pesos de *uma mesma rede* na *mesma camada* ao longo do treinamento. As comparações são pareadas por *checkpoint*, *seed* e dataset; o argumento de intensividade de Anteneodo e Plastino (1996), que diz respeito à escalonamento entre sistemas de tamanhos distintos, não é ativado nesse desenho experimental.

2. **Sensibilidade a transições intermediárias.** A forma $H \times D$ é sensível justamente ao regime que interessa à hipótese central — a transição entre o estado inicial aleatório e o estado treinado. Versões normalizadas saturam nas extremidades do intervalo $[0, 1]$, comprimindo as diferenças que se busca medir. A versão não normalizada preserva a granularidade necessária para detectar inflexões sutis na trajetória.

3. **Convenção do grupo de pesquisa.** Trabalhos anteriores do mesmo grupo (SILVA et al., 2016; SILVA; JUNIOR, 2012) adotam a convenção $H \times D$ em bits, sem normalização, com binarização adaptativa da forma $N = \min(100, \max(10, n/5))$, onde n é o número de amostras. Manter essa convenção preserva a comparabilidade direta entre os resultados desta dissertação e os da literatura imediata.

A normalização adaptativa do número de bins N é especialmente relevante para a aplicação a pesos de redes neurais, onde o número de parâmetros varia ordens de grandeza entre camadas: tipicamente poucas centenas em camadas iniciais e dezenas de milhares em camadas profundas. A regra $N = \min(100, \max(10, n/5))$ garante resolução suficiente para camadas pequenas sem incorrer em viés de subamostragem em camadas grandes.

A combinação entre LMC (sensível à forma da distribuição marginal dos pesos) e SampEn (sensível à estrutura sequencial e espacial) fornece, portanto, dois ângulos complementares sobre o estado interno da rede ao longo do treinamento. Os parâmetros

operacionais adotados, junto da fundamentação aqui apresentada, são retomados em detalhe no Capítulo 3.

2.7 ESTADO DA ARTE: LEITURA DO ESTADO INTERNO DE REDES PROFUNDAS

Esta seção discute os trabalhos que se aproximam do problema desta dissertação. O critério de seleção adotado foi a existência de alguma tentativa de caracterizar o estado de generalização de uma rede a partir de seu *interior* — pesos, representações ou dinâmica de treinamento — em lugar de aferi-lo exclusivamente pelo desempenho em dados rotulados. A Seção 2.7.1 revisa o que se sabe sobre memorização. A Seção 2.7.2 discute a família de limites baseados em normas e margens. A Seção 2.7.3 trata das abordagens espectrais. A Seção 2.7.4 apresenta a família informação-teórica e a controvérsia que a acompanha. A Seção 2.7.5 sintetiza e posiciona a proposta.

2.7.1 Memorização e os dois regimes do aprendizado

Zhang et al. (2017) demonstraram que redes convolucionais de grande porte ajustam perfeitamente rótulos atribuídos ao acaso, e que esse comportamento persiste sob regularização explícita. O resultado é duplamente relevante para esta dissertação: estabelece que a capacidade de memorização não é acidente, mas propriedade das arquiteturas usuais, e fornece o protocolo de indução por corrupção controlada de rótulos adotado no Capítulo 3. A limitação, do ponto de vista aqui assumido, é que o diagnóstico permanece ancorado na comparação entre desempenho de treino e de teste.

Arpit et al. (2017) refinam o quadro ao mostrar que memorização e aprendizado de padrões não são simultâneos: redes tendem a aprender primeiro as regularidades simples e só depois memorizar os exemplos ruidosos. A existência de dois regimes sucessivos, e não de um processo homogêneo, é o pressuposto que torna plausível a hipótese desta dissertação — se há transição, pode haver assinatura da transição. Os autores, contudo, caracterizam os regimes por métricas que dependem dos dados, não da estrutura dos pesos.

Power et al. (2022) descrevem o fenômeno de *grokking*, em que a generalização emerge muito depois do ajuste completo do treino, às vezes após longo período de estagnação da validação. O fenômeno constitui contraexemplo aos critérios ingênuos de parada antecipada: uma interrupção baseada apenas na estagnação eliminaria justamente o regime em que a generalização acabaria por surgir. Um indicador que leia o estado interno, e não apenas o desempenho externo, é potencialmente capaz de distinguir estagnação de reorganização — questão registrada aqui como hipótese derivada, não testada neste trabalho.

2.7.2 Limites de generalização por normas e margens

Bartlett et al. (2017) propõem limites de generalização baseados em normas espectrais e margens, estabelecendo que propriedades geométricas dos pesos se relacionam com a capacidade de generalizar. Dziugaite e Roy (2017) obtêm, por via PAC-Bayesiana, limites não vacuosos para redes sobreparametrizadas — resultado notável, dado que limites clássicos tornam-se vazios nesse regime. Ambos representam avanços substantivos, mas produzem limites válidos para *um* estado da rede, tipicamente o final do treinamento, e não uma leitura acompanhável ao longo das épocas.

Jiang et al. (2020) conduzem o estudo empírico mais sistemático dessa família, avaliando um grande conjunto de medidas candidatas quanto à sua relação causal com a lacuna de generalização. A conclusão é cautelar e impõe exigência metodológica a qualquer trabalho subsequente: muitas medidas teoricamente motivadas correlacionam-se mal com a generalização observada, e medidas baseadas em otimização desempenham-se melhor do que as baseadas em norma. A consequência adotada nesta dissertação é que não basta exibir correlação entre indicador e sobreajuste em uma execução; é preciso demonstrar *discriminação* entre execuções com e sem memorização, com controles pareados e teste de significância.

2.7.3 Abordagens espectrais

Martin et al. (2021) mostram que propriedades de cauda pesada do espectro das matrizes de pesos permitem prever tendências de qualidade de modelos sem acesso aos dados de treino ou de teste. Este é o trabalho mais próximo do objetivo aqui perseguido, e convém explicitar as diferenças. A abordagem é *espectral*, apoiando-se nos autovalores das matrizes, ao passo que a desta dissertação é *informação-teórica*, apoiando-se na distribuição de valores e na organização espacial dos pesos. Além disso, o alvo em Martin et al. (2021) é comparar modelos já treinados, enquanto aqui o alvo é acompanhar a trajetória temporal de um único treinamento.

2.7.4 Abordagens informação-teóricas e a controvérsia do gargalo de informação

A família mais próxima em espírito a esta dissertação é a que aplica teoria da informação ao interior de redes profundas. Tishby e Zaslavsky (2015) propõem analisar redes no *plano de informação*, quantificando cada camada pela informação mútua que preserva a respeito da entrada e da saída, e interpretam o treinamento como otimização de um compromisso entre compressão e predição. Shwartz-Ziv e Tishby (2017) desenvolvem empiricamente essa leitura e relatam que a maior parte das épocas de treinamento é

consumida não no ajuste dos rótulos, mas na *compressão* da representação, identificando duas fases distintas na otimização — uma de deriva rápida e outra de relaxação estocástica.

A pertinência para o presente trabalho é evidente: trata-se de literatura que afirma existirem transições de regime detectáveis por quantidades informação-teóricas calculadas sobre o interior da rede, o que é precisamente a estrutura da hipótese aqui investigada.

É imprescindível, porém, registrar que essas conclusões foram contestadas. Saxe et al. (2019) examinam os três principais postulados da teoria e concluem que nenhum deles se sustenta no caso geral: a existência de duas fases distintas, a relação causal entre compressão e boa generalização, e a atribuição da compressão ao comportamento difusivo do gradiente estocástico. Demonstram, em particular, que a trajetória observada no plano de informação depende predominantemente da não linearidade empregada — funções de saturação bilateral produzem fase de compressão, enquanto ativações lineares ou de saturação unilateral não a produzem — e que parte do efeito reflete decisões de estimação da informação mútua em redes determinísticas.

Essa controvérsia recomenda cautela e delimita o escopo do presente trabalho de modo produtivo. As medidas aqui empregadas *não* são estimativas de informação mútua entre camadas e dados, e portanto não herdam as dificuldades de estimação que Saxe e colaboradores identificam: LMC, SampEn e SampEn2D são estatísticas calculadas sobre os *valores dos pesos*, sem referência a qualquer distribuição conjunta com os dados. A escolha evita o problema metodológico central da controvérsia, ao custo de abdicar da interpretação formal em termos de compressão de informação.

2.7.5 Síntese e posicionamento da proposta

Tabela 1 – Comparação dos trabalhos discutidos quanto à dependência de dados rotulados, à natureza temporal da leitura e ao objeto medido.

Trabalho	**Objeto da medida**	**Exige rótulo**	**Leitura temporal**	**Avisa antes**
Prechelt (1998)	Erro de validação	Sim	Sim	Não
Zhang et al. (2017)	Desempenho	Sim	Não	Não
Arpit et al. (2017)	Desempenho	Sim	Sim	Não
Bartlett et al. (2017)	Norma espectral	Não	Não	Não
Dziugaite e Roy (2017)	Limite PAC-Bayes	Sim	Não	Não
Jiang et al. (2020)	Diversas	Sim	Não	Não
Martin et al. (2021)	Espectro dos pesos	Não	Não	Não
Tishby e Zaslavsky (2015)	Informação mútua	Sim	Não	Não
Shwartz-Ziv e Tishby (2017)	Informação mútua	Sim	Sim	Não
Esta dissertação	Complexidade dos pesos	Não	Sim	Sim

Fonte: Elaborado pelo autor.

A Tabela 1 organiza os trabalhos segundo três eixos. Quanto à dependência de rótulos, apenas Bartlett et al. (2017) e Martin et al. (2021) dispensam-nos, e ambos

por via espectral. Quanto à natureza temporal, Arpit et al. (2017) e Shwartz-Ziv e Tishby (2017) acompanham a trajetória do treinamento, mas ambos requerem acesso aos dados — o primeiro ao desempenho, o segundo à distribuição conjunta necessária para estimar informação mútua. A intersecção entre *dispensar rótulos* e *acompanhar a trajetória* permanece, até onde a revisão alcançou, não ocupada.

A proposta desta dissertação situa-se nessa intersecção e diferencia-se da literatura em quatro aspectos: (i) a medida é informação-teórica, mas incide sobre a distribuição de valores e a organização espacial dos pesos, não sobre o espectro das matrizes nem sobre informação mútua com os dados; (ii) a leitura é temporal, produzindo uma trajetória por época em lugar de um escalar ao final do treino; (iii) nenhum rótulo é consumido, o que a torna aplicável em cenários de anotação escassa; e (iv) a validação é feita por controles estritamente pareados com indução explícita de memorização, em resposta direta à advertência de Jiang et al. (2020) quanto a correlações espúrias.

Registre-se, por fim, uma limitação da própria revisão. A literatura de medidas de generalização é extensa e cresce rapidamente; a seleção aqui apresentada privilegiou trabalhos fundacionais de alta citação e os mais diretamente relacionados ao problema, não constituindo revisão sistemática no sentido metodológico do termo.

3 METODOLOGIA

Este capítulo descreve o protocolo experimental adotado para investigar a evolução da complexidade estatística dos pesos da camada densa de redes neurais profundas durante o treinamento. A exposição segue do dado bruto às medidas: o conjunto de dados (Seção 3.1), as arquiteturas (Seção 3.2) e o protocolo de treinamento (Seção 3.3); a indução de memorização por corrupção de rótulos (Seção 3.4); a camada densa como objeto de medida e a ordem de achatamento dos seus pesos (Seção 3.5); as medidas de complexidade (Seção 3.6); o monitoramento durante o treinamento (Seção 3.7); e a referência temporal empregada na análise (Seção 3.8).

3.1 CONJUNTO DE DADOS

Utiliza-se o MedNIST, conjunto de imagens médicas em escala de cinza, 64×64 pixels, distribuídas em seis classes: tomografia abdominal (*AbdomenCT*), ressonância de mama (*BreastMRI*), tomografia de tórax (*ChestCT*), radiografia de tórax (*CXR*), radiografia de mão (*Hand*) e tomografia de crânio (*HeadCT*). Emprega-se a partição oficial do conjunto em treinamento, validação e teste, com 47.164, 5895 e 5895 imagens, respectivamente. A semente que define a partição é fixa em todas as execuções e distinta da semente de inicialização dos pesos, de modo que todas as execuções compartilham exatamente os mesmos conjuntos de validação e de teste. O conjunto de teste é avaliado uma única vez por execução, ao final do treinamento.

3.2 ARQUITETURAS

Adota-se a ResNet-18 (HE et al., 2016) (implementação `torchvision`, sem pré-treinamento), com a camada totalmente conectada final substituída para as seis classes do MedNIST. Esta arquitetura totaliza aproximadamente 11,2 milhões de parâmetros distribuídos em **41 tensores com parâmetros aprendíveis**: 20 camadas convolucionais (`Conv2d`), 20 camadas de *batch normalization* (`BatchNorm2d`) e 1 camada totalmente conectada (`Linear`), que é o objeto das medidas deste trabalho (Figura 1).

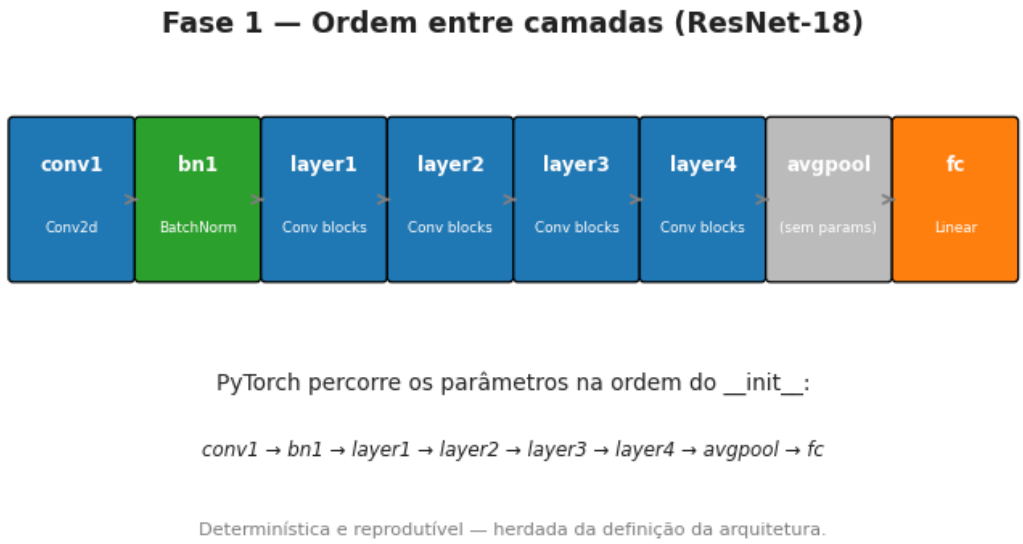


Figura 1 – Estrutura de nível superior da ResNet-18: oito módulos nomeados em sequência. As caixas indicam o tipo de camada (azul: Conv2d; verde: BatchNorm2d; cinza: sem parâmetros; laranja: Linear). As caixas `layer1`–`layer4` são contêineres `Sequential` de blocos residuais.

Para verificar se o comportamento observado depende da arquitetura, repete-se parte dos experimentos com a DenseNet-121 (implementação `torchvision`, sem pré-treinamento), com a camada classificadora igualmente substituída para seis classes.

3.3 PROTOCOLO DE TREINAMENTO

O treinamento emprega o otimizador AdamW com taxa de aprendizado 10^{-3} e *weight decay* nulo, entropia cruzada como função objetivo, lotes de 128 imagens e 60 épocas, sem aumento de dados. O *weight decay* e o aumento de dados são desligados deliberadamente: ambos combatem a memorização, que é justamente o fenômeno que o protocolo da Seção 3.4 provoca. Os experimentos foram executados em GPU (*torch* 2,4,1 e *torchvision* 0,19,1).

3.4 INDUÇÃO DE MEMORIZAÇÃO POR CORRUPÇÃO DE RÓTULOS

Para examinar se as medidas de complexidade respondem à *memorização* — isto é, ao ajuste a associações que não generalizam — e não apenas à escassez de dados, a perda de generalização é induzida por corrupção de rótulos.

A distinção importa porque subamostrar o treino reduz simultaneamente a quantidade de informação disponível e a diversidade dos exemplos, de modo que a degradação observada pode ter mais de uma origem. Corromper rótulos, em contrapartida, mantém o volume de dados e introduz exclusivamente associações inconsistentes, forçando a rede a memorizá-las (ZHANG et al., 2017).

3.4.1 Protocolo de corrupção de rótulos

Uma fração $\rho \in \{0{,}15;\ 0{,}30;\ 0{,}50\}$ dos exemplos do conjunto de treinamento tem seu rótulo substituído por um valor sorteado uniformemente entre *todas* as classes, inclusive a verdadeira — convenção adotada por Zhang et al. (2017). A consequência precisa ser declarada, para que a fração sorteada não seja confundida com a fração efetivamente errada: com K classes, uma fração sorteada ρ produz $\rho\,(K-1)/K$ de rótulos de fato incorretos. Nos experimentos com seis classes, portanto, $\rho = 0{,}30$ corresponde a 25 % de rótulos errados, e $\rho = 0{,}15$ e $\rho = 0{,}50$ correspondem a 12,5 % e 41,7 %, respectivamente. O registro de cada execução reporta as duas quantidades.

A corrupção incide *apenas* sobre o treino; validação e teste permanecem íntegros, de modo que a degradação da validação mede exatamente a perda de generalização induzida — corromper a régua junto com o objeto medido não mediria nada.

Convém registrar por que a indução por corrupção de rótulos foi preferida à alternativa de simplesmente reduzir o conjunto de treino. Experimentos preliminares mostraram que a redução produz um falso positivo convincente: com poucos passos de otimização, as estatísticas móveis das camadas de normalização em lote não convergem, e o modelo colapsa em modo de avaliação — inclusive sobre o próprio conjunto de treino. O quadro se parece com sobreajuste catastrófico, mas o mesmo modelo acerta cerca de 94,5 % da validação quando a normalização usa as estatísticas do lote corrente. Mede-se, nesse caso, um artefato de normalização, e não perda de generalização. A corrupção de rótulos não tem esse problema, pois preserva as 47.164 amostras de treino e mantém as estatísticas de normalização saudáveis.

A semente que governa a corrupção é independente daquela que governa a partição e a inicialização dos pesos. A separação é necessária: se ambas fossem a mesma, repetir o experimento alterando apenas a semente reproduziria os mesmos rótulos corrompidos, medindo sensibilidade à inicialização em lugar de replicação.

Cada execução com corrupção possui uma execução de controle **estritamente pareada**, idêntica a ela em arquitetura, partição, semente, número de épocas, decaimento de pesos e ausência de aumento de dados, diferindo unicamente por $\rho = 0$. O rigor desse pareamento é condição de validade: qualquer diferença adicional entre os grupos, como a presença de aumento de dados em apenas um deles, tornaria o contraste observado

atribuível a mais de uma causa.

A confirmação de que houve memorização, e não apenas degradação, é feita *a posteriori*: verifica-se que a acurácia de treino em modo de avaliação sobe até ajustar os rótulos corrompidos, enquanto a acurácia de validação cai.

3.5 A CAMADA DENSA COMO OBJETO DE MEDIDA

Seja a camada densa com M entradas $x_1, \ldots, x_M$ e N neurônios $n_1, \ldots, n_N$. A matriz de pesos é $W \in \mathbb{R}^{N \times M}$, e o elemento w_{ji} é o peso do *caminho* $x_i \to n_j$ — convenção que coincide com a forma nativa de `Linear.weight` no PyTorch, [out_features, in_features].

Como a SampEn_{1D} compara janelas consecutivas, a ordem de achatamento precisa ser fixada. Duas ordens são naturais. Na ordem *por neurônio*, percorrem-se todos os pesos que chegam a cada neurônio antes de passar ao seguinte:

$$v_n = (w_{11}, w_{12}, \ldots, w_{1M},\ w_{21}, \ldots, w_{2M},\ \ldots,\ w_{NM}), \tag{3.1}$$

o que corresponde ao achatamento nativo, sem transposição. Na ordem *por entrada*, percorrem-se todos os pesos que partem de cada entrada:

$$v_x = (w_{11}, w_{21}, \ldots, w_{N1},\ w_{12}, \ldots, w_{N2},\ \ldots), \tag{3.2}$$

equivalente a transpor W antes do achatamento. A Equação 3.1 mede a regularidade *dentro do campo receptivo de cada neurônio*; a Equação 3.2 mede a regularidade *da distribuição de uma mesma entrada entre os neurônios*. Adota-se a primeira como convenção padrão, por corresponder ao achatamento nativo do PyTorch, e a comparação entre as duas é reportada como ablação. O Apêndice A ilustra as duas ordens com um exemplo numérico. Para a complexidade LMC a distinção é irrelevante, pois a medida depende apenas do histograma dos valores e é invariante a permutações.

O vetor de viés é excluído da análise: o viés é um deslocamento aditivo do neurônio, não a ligação entre uma entrada e um neurônio, e portanto não é um caminho no sentido aqui adotado.

Na ResNet-18 aplicada a seis classes, a camada densa (`fc`) possui $6 \times 512 = 3.072$ pesos; na DenseNet-121 (`classifier`), $6 \times 1.024 = 6.144$. São quantidades que permitem calcular as medidas sobre a camada inteira, sem subamostragem.

3.6 MEDIDAS DE COMPLEXIDADE

Sobre a camada densa de cada época são calculadas as medidas descritas a seguir. Os parâmetros seguem convenções da literatura citada.

3.6.1 Complexidade LMC

A complexidade estatística LMC (LÓPEZ-RUIZ et al., 1995) é definida como o produto da entropia de Shannon (SHANNON, 1948) pelo desequilíbrio em relação à distribuição uniforme:

$$C_{\mathrm{LMC}}(p) \;=\; H(p)\cdot D(p), \tag{3.3}$$

onde, para um histograma normalizado p com N *bins*,

$$H(p) = -\sum_{i=1}^{N} p_i \log_2 p_i, \qquad D(p) = \sum_{i=1}^{N} \left(p_i - \tfrac{1}{N}\right)^2. \tag{3.4}$$

Adota-se $N = 100$ *bins*. A entropia é computada em bits ($\log_2$) e o produto $H \cdot D$ é reportado sem normalização adicional. Como a medida não é normalizada, sua escala depende de N, e nenhuma comparação entre execuções é legítima sem que o número de intervalos seja idêntico.

3.6.2 Entropia amostral SampEn_{1D}

A entropia amostral (RICHMAN; MOORMAN, 2000; PINCUS, 1991) é definida como

$$\mathrm{SampEn}(U, m, r) \;=\; -\log \frac{A^{m+1}(r)}{B^{m}(r)}, \tag{3.5}$$

onde U é o vetor de pesos achatado, m é o comprimento das sub-sequências comparadas e r é a tolerância de similaridade. As quantidades A^{m+1} e B^{m} contam pares de sub-sequências cuja distância de Chebyshev é menor ou igual a r. Adotam-se os parâmetros $m = 2$ e $r = 0{,}2\,\sigma(U)$ (YENTES et al., 2013), validados pelo grupo de pesquisa em estudos prévios.

3.6.3 SampEn 2D

A SampEn 2D (SILVA et al., 2016) opera diretamente sobre a matriz de pesos, sem *flatten*, preservando a estrutura nas duas direções e contornando por completo a escolha da ordem de achatamento discutida na Seção 3.5. Os parâmetros adotados são descritos na Seção 3.7.

3.7 MONITORAMENTO DURANTE O TREINAMENTO

As medidas são calculadas **a cada época, dentro do laço de treinamento**, e não sobre *snapshots* analisados posteriormente. A escolha decorre do objetivo: se o

propósito é oferecer ao desenvolvedor um aviso utilizável, a medida precisa estar disponível enquanto o treinamento ocorre, e não apenas em análise posterior.

São calculadas por época a complexidade LMC com $N_{bins} = 100$, a SampEn_{1D} com $m = 2$ e $r = 0{,}20\,\sigma$, e a SampEn2D com $m = 1$ e o mesmo r. A escolha de $m = 1$ para a variante bidimensional é deliberada e merece justificativa: com $m = 2$, as janelas comparadas são sub-matrizes 3×3, que em uma matriz de apenas seis linhas raramente encontram pares similares, produzindo contagens instáveis. Com $m = 1$, comparam-se janelas 1×1 contra 2×2, o que mantém as contagens em regime numericamente estável.

O custo do monitoramento é baixo, pois incide apenas sobre a camada densa, e pode ser desativado por opção de linha de comando.

3.8 DEFINIÇÃO OPERACIONAL DA REFERÊNCIA TEMPORAL

Para quantificar antecedência é preciso uma referência que produza um número de época. Adota-se como âncora a época em que a acurácia de validação passa a cair de forma sustentada.

A opção pela acurácia, e não pela perda de validação, decorre de uma observação empírica. Ancorando o diagnóstico na perda, o monitor sinalizava sobreajuste em todas as execuções, incluindo os controles, e em cerca de metade das épocas — consequência de o MedNIST saturar muito cedo, fazendo a perda de validação subir logo após as primeiras épocas mesmo em treinamentos saudáveis. Reancorado na acurácia, o comportamento tornou-se o esperado. O episódio ilustra que a definição operacional de sobreajuste não é detalhe de implementação, mas condição de validade do resultado.

4 RESULTADOS

Este capítulo apresenta os resultados obtidos sobre a camada densa das redes treinadas no MedNIST, segundo o protocolo descrito no Capítulo 3. Verifica-se, inicialmente, que a corrupção de rótulos produziu memorização efetiva; em seguida, comparam-se as trajetórias da LMC e das variantes de entropia amostral entre execuções com corrupção e seus controles pareados, examinando o efeito do nível de corrupção, da arquitetura e da ordem de achatamento dos pesos.

4.1 MEMORIZAÇÃO INDUZIDA NA CAMADA DENSA

Esta seção reporta os resultados do desenho descrito na Seção 3.4, no qual a perda de generalização é induzida por corrupção de rótulos e as medidas incidem integralmente sobre os 3072 pesos da camada densa. Todos os valores foram obtidos com execuções de controle *estritamente pareadas*, conforme discutido adiante na Seção 4.1.7.

4.1.1 Confirmação da memorização

Antes de avaliar os indicadores, é necessário verificar que o protocolo produziu de fato memorização, e não apenas degradação de desempenho. A Tabela 2 apresenta a evidência nas oito execuções com $\rho = 0{,}30$, isto é, 25 % de rótulos efetivamente errados.

Tabela 2 – Evidência de memorização nas oito execuções com corrupção de rótulos e nos oito controles pareados, em ResNet-18. Acurácias em modo de avaliação.

Grupo	**Treino inicial**	**Treino final**	**Validação máxima**	**Validação final**
Com corrupção ($n = 8$)	74,7 %	97,5 %	99,9 %	84,1 %
Controle pareado ($n = 8$)	—	100,0 %	100,0 %	100,0 %

Fonte: Elaborado pelo autor.

O padrão é inequívoco e reprodutível nas oito execuções. A acurácia de treino parte de aproximadamente 74,7 % — valor próximo do teto imposto pelos rótulos corrompidos — e sobe até 97,5 %, o que significa que a rede ajustou também a maior parte das associações inconsistentes. Simultaneamente, a acurácia de validação, que chega a 99,9 %, regride para 84,1 %. Não há explicação visual para rótulos sorteados ao acaso; o único modo de ajustá-los é memorizá-los. Nos controles pareados, treino e validação permanecem em 100 %, sem qualquer degradação — o que confirma que a memorização observada decorre da corrupção, e não do protocolo de treinamento.

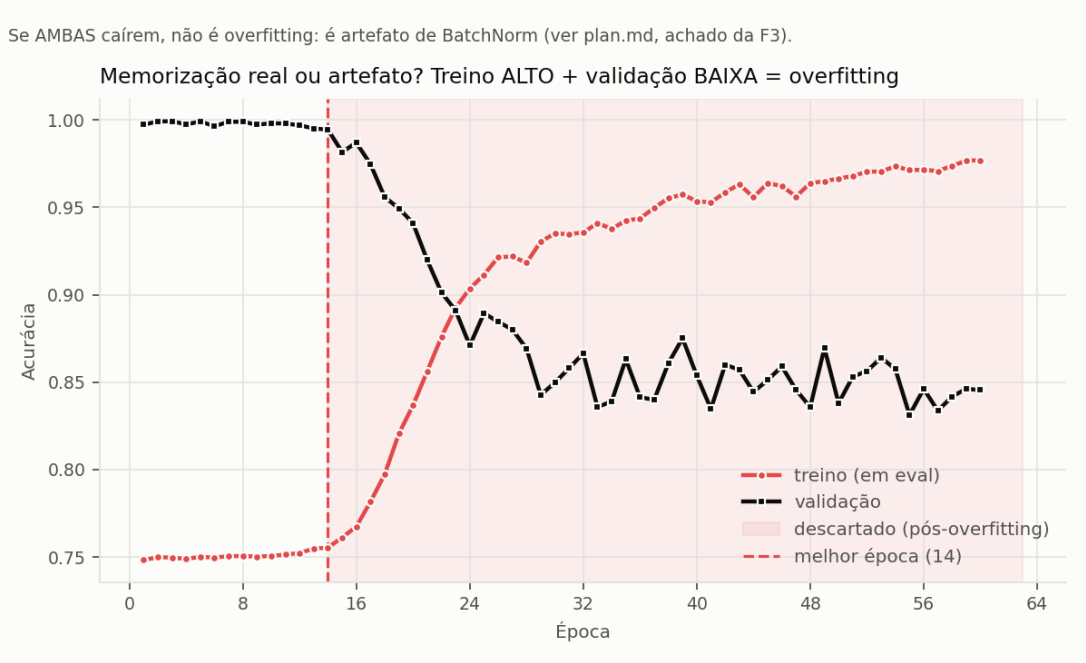


Figura 2 – Acurácias de treino, em modo de avaliação, e de validação ao longo das épocas em execução com 25 % de rótulos efetivamente errados. O cruzamento das curvas caracteriza a memorização.

Fonte: Elaborado pelo autor.

4.1.2 Poder de discriminação dos indicadores

O critério de avaliação adotado não é a amplitude absoluta de variação de cada indicador, mas a *razão* entre a amplitude observada nas execuções com corrupção e a observada nos controles. Um indicador que varia muito nas duas condições não informa nada sobre a memorização. A Tabela 3 apresenta os resultados.

Tabela 3 – Amplitude de variação dos indicadores na camada densa, em ResNet-18, com oito execuções por grupo. Valores como média ± desvio-padrão amostral; p obtido por teste de Mann-Whitney bilateral.

Indicador	**Com corrupção**	**Controle pareado**	**Razão**	p
LMC	$1{,}219 \pm 0{,}055$	$1{,}138 \pm 0{,}134$	1,07	0,195
SampEn 1D	$0{,}205 \pm 0{,}018$	$0{,}058 \pm 0{,}012$	3,51	0,00016
SampEn2D	$0{,}340 \pm 0{,}061$	$0{,}060 \pm 0{,}014$	5,65	0,00016

Fonte: Elaborado pelo autor.

O resultado é assimétrico e exige leitura cuidadosa. As duas variantes de entropia amostral discriminam as condições, e a bidimensional discrimina melhor. O valor $p = 0{,}00016$ é o menor alcançável pelo teste de Mann-Whitney com oito observações por grupo e corresponde à separação completa entre os grupos, sem qualquer sobreposição de valores.

A complexidade LMC, em contrapartida, **não discrimina** as duas condições. A razão de 1,07 é compatível com ausência de efeito, e o teste não rejeita a hipótese nula ($p = 0{,}195$). Este é um resultado negativo, e não uma limitação de potência: a amplitude média da LMC nas execuções com corrupção (1,219) situa-se dentro de um desvio-padrão da amplitude média dos controles ($1{,}138 \pm 0{,}134$).

A interpretação mais econômica desse achado remete à propriedade discutida na Seção 2.6: a LMC depende apenas do histograma dos valores dos pesos e é, portanto, invariante a qualquer permutação. Se a memorização reorganiza os pesos da camada densa sem alterar substancialmente a *distribuição* de seus valores, a LMC é cega a ela por construção. As variantes de entropia amostral, sensíveis à ordem, captam precisamente essa reorganização.

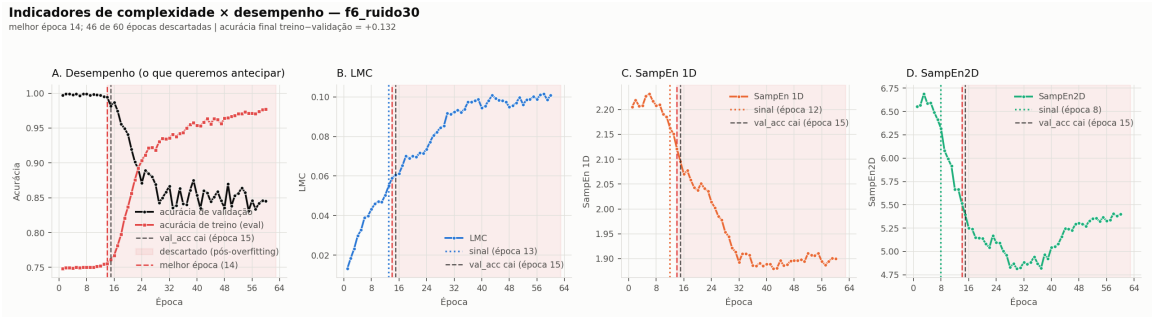


Figura 3 – Trajetória dos três indicadores na camada densa e das curvas de validação, em execução com corrupção de rótulos. A região sombreada corresponde às épocas posteriores ao início do sobreajuste, excluídas das conclusões.

Fonte: Elaborado pelo autor.

4.1.3 Antecedência em relação à degradação da validação

A antecedência é a diferença, em épocas, entre a inflexão do indicador e a âncora definida sobre a acurácia de validação. A Tabela 4 reporta os valores.

Tabela 4 – Antecedência dos indicadores em relação à queda sustentada da acurácia de validação, em épocas, nas oito execuções com corrupção em ResNet-18.

Indicador	**Média ± desvio**	**IC 95 %**	**Discrimina?**
SampEn2D	$7{,}50 \pm 0{,}93$	[6,73; 8,27]	Sim
SampEn 1D	$3{,}62 \pm 1{,}06$	[2,74; 4,51]	Sim
LMC	$3{,}00 \pm 1{,}85$	[1,45; 4,55]	Não

Fonte: Elaborado pelo autor.

A antecedência da LMC não constitui resultado positivo e não deve ser interpretada como tal. Como a Tabela 3 estabelece que o indicador não distingue as duas condições, a

época de sua inflexão não sinaliza coisa alguma: uma inflexão que ocorre igualmente nos controles não é aviso. A antecedência só é informativa para indicadores que previamente demonstraram discriminação.

A separação temporal da SampEn2D é quase completa. Nas oito execuções com corrupção, o indicador inflete nas épocas $\{7, 7, 7, 7, 7, 7, 8, 9\}$. Nos controles pareados, seis dos oito inflectem, e o fazem nas épocas $\{9, 23, 37, 42, 50, 55\}$; os dois restantes não inflectem dentro do horizonte de 60 épocas. Registre-se a honestidade do limite: há *um* controle que inflete na época 9, coincidindo com o valor máximo observado no grupo com corrupção. A separação é portanto quase perfeita, mas não perfeita, e a afirmação correta é de sobreposição mínima — em uma de dezesseis execuções.

4.1.4 Efeito do nível de corrupção

Variou-se a fração sorteada em $\rho \in \{0{,}15;\ 0{,}30;\ 0{,}50\}$, com três sementes por nível. O resultado não era o esperado e é, talvez, o mais interessante desta seção.

Tabela 5 – Época do alerta emitido pelo monitor e época da âncora, por nível de corrupção, com três sementes por nível.

ρ **sorteado**	**Errados de fato**	**Época do alerta**	**Época da âncora**	**Antecedência**
15 %	12,5 %	10,0	17,7	7,7
30 %	25,0 %	9,3	14,7	5,3
50 %	41,7 %	10,0	13,0	3,0
ANOVA de uma via		$F = 1{,}00$ $p = 0{,}42$	$F = 30{,}2$ $p = 0{,}0007$	

Fonte: Elaborado pelo autor.

A época em que o monitor emite o alerta é praticamente invariante ao nível de corrupção: médias de 10,0, 9,3 e 10,0 épocas, sem diferença estatisticamente detectável ($F = 1{,}00$; $p = 0{,}42$). O que se move é a âncora, isto é, o momento em que a degradação se torna visível na validação, que chega progressivamente mais cedo quanto maior a corrupção ($F = 30{,}2$; $p = 0{,}0007$).

A consequência prática é que a antecedência encolhe à medida que a corrupção aumenta, de aproximadamente 7,7 épocas a 15 % para 3,0 épocas a 50 %. Propõe-se a seguinte leitura: o indicador marca o *início* da memorização, cujo momento depende pouco da quantidade de rótulos errados, enquanto a validação mede o *sintoma*, que se manifesta tanto mais cedo quanto maior a corrupção. Trata-se de interpretação plausível e compatível com os dados, ainda não demonstrada de forma independente.

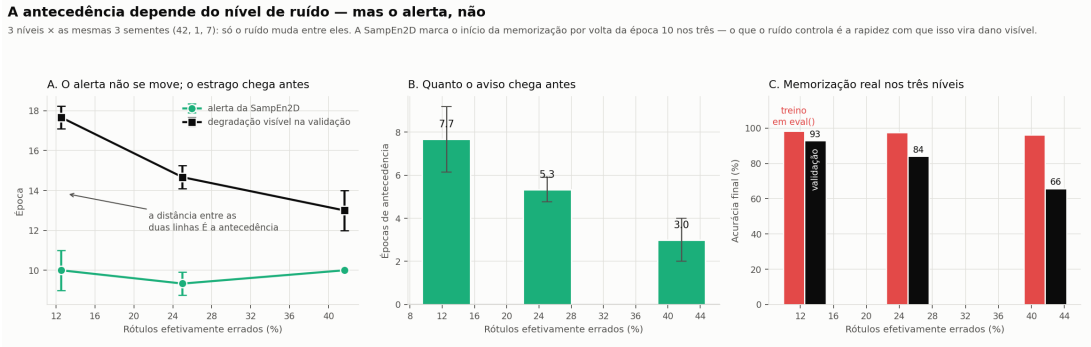


Figura 4 – Época do alerta e época da âncora em função do nível de corrupção de rótulos. A época do alerta é estável; a da âncora antecipa-se com o aumento da corrupção.

Fonte: Elaborado pelo autor.

4.1.5 Generalização para outra arquitetura

O experimento foi repetido com a DenseNet-121, com oito execuções com corrupção e cinco controles pareados. Os resultados constam da Tabela 6.

Tabela 6 – Resultados na DenseNet-121, com oito execuções com corrupção e cinco controles pareados.

Indicador	**Razão de amplitude**	p	**Antecedência (épocas)**
LMC	1,06	0,435	—
SampEn 1D	1,77	0,00155	$22{,}50 \pm 2{,}33$
SampEn2D	4,35	0,00155	$21{,}12 \pm 2{,}36$

Fonte: Elaborado pelo autor.

O achado central replica-se na segunda arquitetura. A SampEn2D discrimina com razão de 4,35 vezes ($p = 0{,}00155$) e a antecedência é consideravelmente maior, de $21{,}1 \pm 2{,}4$ épocas, com intervalo de confiança de 95 % entre 19,2 e 23,1. A LMC, de novo, não discrimina ($p = 0{,}435$), o que reforça a consistência desse resultado negativo entre arquiteturas.

Duas ressalvas, porém, devem ser explicitadas.

A primeira é que a razão de amplitude é menor do que na ResNet-18 (4,35 contra 5,65), e a SampEn 1D, que discriminava na ResNet, passa a ter poder marginal (1,77). O contraste, portanto, replica-se em direção, mas não em magnitude.

A segunda é mais relevante e não deve ser omitida: **na DenseNet-121 a época do sinal não separa os grupos**. As execuções com corrupção inflectem nas épocas $\{8, 9, 9, 9, 9, 11, 11, 12\}$, enquanto os controles pareados inflectem em $\{7, 8, 10, 16, 25\}$ — três deles, portanto, tão cedo ou mais cedo que as execuções com corrupção. Na ResNet-18

a separação temporal é quase perfeita; na DenseNet-121, não existe. O que discrimina nessa arquitetura é a *amplitude* da variação, não o *momento* em que ela começa. A consequência prática é direta: um monitor que emita alerta pelo simples cruzamento de um limiar temporal produziria falsos positivos na DenseNet-121, e o critério precisa incorporar a magnitude.

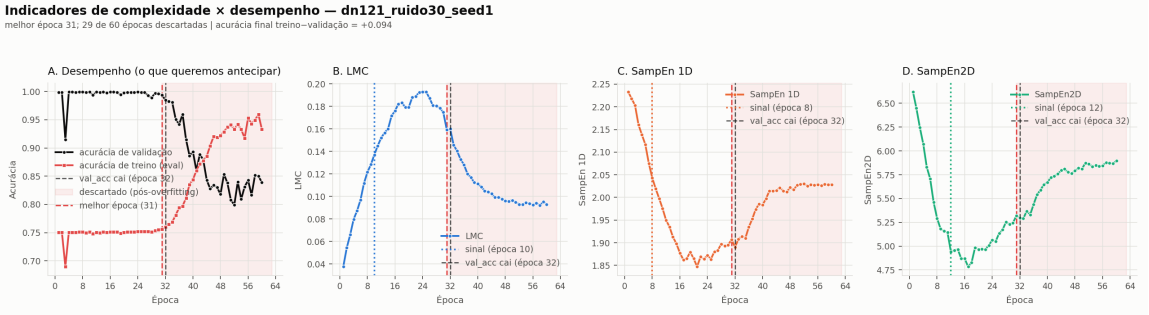


Figura 5 – Trajetória dos indicadores na camada densa da DenseNet-121, em execução com corrupção de rótulos.

Fonte: Elaborado pelo autor.

4.1.6 Ablação da ordem de achatamento

A Seção 3.5 fixou a ordem por neurônio como convenção padrão, por coerência com a decisão D2, e previu o reporte da comparação com a ordem por entrada. A Tabela 7 apresenta o resultado, obtido sobre cinco execuções com corrupção e cinco controles.

Tabela 7 – Comparação das duas ordens de achatamento na SampEn 1D da camada densa.

Ordem	**Razão de amplitude**	**Antecedência (épocas)**
Por neurônio (padrão adotado)	3,52	3,6
Por entrada	7,73	7,4

Fonte: Elaborado pelo autor.

O resultado contraria a convenção adotada, e isso precisa ser dito sem atenuação: a leitura *por entrada* é superior nos dois critérios, discriminando mais que o dobro (7,73 contra 3,52) e avisando com o dobro da antecedência (7,4 contra 3,6 épocas).

Há uma explicação plausível. Percorrer a matriz por entrada agrupa, para cada característica, os pesos que ela envia a *todas* as classes — e é exatamente aí que a memorização se manifesta, quando uma característica passa a apontar de forma desproporcional para uma classe específica. Percorrendo por neurônio, esse contraste dilui-se ao longo das 512 posições do campo receptivo.

Registre-se que o efeito prático dessa escolha é limitado, pois o indicador de melhor desempenho neste trabalho é a SampEn2D, que não achata a matriz e preserva as duas direções simultaneamente. A discussão de ordem afeta apenas a variante unidimensional. Ainda assim, a evidência recomenda reconsiderar a convenção adotada.

4.1.7 Sobre o pareamento dos controles

Um aspecto metodológico merece registro explícito, por afetar a validade de todos os números desta seção.

Em uma versão anterior deste conjunto de experimentos, as execuções de controle não eram estritamente pareadas: além de não terem rótulos corrompidos, elas empregavam aumento de dados, decaimento de pesos de 10^{-4} e horizonte de 40 épocas, contra ausência de aumento, decaimento nulo e 60 épocas nas execuções com corrupção. Como aumento de dados e decaimento de pesos são, ambos, formas de regularização que reduzem sobreajuste por conta própria, o contraste medido era atribuível a mais de uma causa, e não exclusivamente à memorização.

Todo o conjunto de controles foi então refeito com pareamento estrito, e os números reportados nesta seção são os dessa segunda versão. A comparação entre as duas consta da Tabela 8.

Tabela 8 – Efeito da correção do pareamento sobre as razões de amplitude da SampEn2D.

Arquitetura	**Controles não pareados**	**Controles pareados**	p **final**
ResNet-18	5,71 ($n = 8$)	5,65 ($n = 8$)	0,00016
DenseNet-121	2,80 ($n = 3$)	4,35 ($n = 8$)	0,00155

Fonte: Elaborado pelo autor.

Na ResNet-18 a razão praticamente não se alterou, passando de 5,71 para 5,65. Esse é um resultado importante em si: como a correção removeu a regularização dos controles e o contraste permaneceu, conclui-se que o efeito medido decorre da memorização, e não das diferenças de regularização. Na DenseNet-121 a razão *aumentou*, de 2,80 para 4,35, e passou a ser estatisticamente significativa — o que indica que a aparente fraqueza dessa arquitetura, registrada em análise preliminar, era em boa parte artefato do pareamento inadequado, agravado pelo número reduzido de execuções.

5 CONCLUSÃO

Este trabalho investigou a hipótese de que a complexidade estatística dos pesos de redes neurais profundas constitui um marcador objetivo do início do *overfitting*, instanciando-a no contexto de classificação de imagens médicas com a arquitetura ResNet-18 e o conjunto MedNIST. A abordagem articulou duas medidas complementares — a complexidade LMC (LÓPEZ-RUIZ et al., 1995) e a entropia amostral SampEn (RICHMAN; MOORMAN, 2000), esta nas variantes unidimensional e bidimensional — calculadas a cada época sobre a camada densa, em execuções nas quais a perda de generalização foi induzida por corrupção controlada de rótulos e em controles estritamente pareados, com replicação parcial na DenseNet-121.

5.1 PRINCIPAIS ACHADOS

O desenho descrito na Seção 3.4 e reportado na Seção 4.1 induz memorização por corrupção controlada de rótulos e mede a camada densa integralmente. Seus resultados sustentam três achados e obrigam a reformular a hipótese central.

1. **A SampEn2D da camada densa antecipa a degradação da validação.** Em oito execuções com controles estritamente pareados, a inflexão precede a queda sustentada da acurácia de validação em $7{,}50 \pm 0{,}93$ épocas, com intervalo de confiança de 95 % entre 6,73 e 8,27. A razão de amplitude entre execuções com e sem memorização é de 5,65 vezes ($p = 0{,}00016$, o menor valor alcançável pelo teste com oito observações por grupo). O achado replica-se na DenseNet-121, com razão de 4,35 vezes ($p = 0{,}00155$) e antecedência de $21{,}1 \pm 2{,}4$ épocas.

2. **A complexidade LMC não discrimina memorização na camada densa.** A razão de amplitude é de 1,07 na ResNet-18 ($p = 0{,}195$) e 1,06 na DenseNet-121 ($p = 0{,}435$). Trata-se de resultado negativo, e não de insuficiência de potência estatística: a amplitude média das execuções com corrupção situa-se dentro de um desvio-padrão da amplitude média dos controles. A leitura proposta remete à invariância da LMC a permutações — se a memorização reorganiza os pesos sem alterar substancialmente a distribuição de seus valores, a medida é cega a ela por construção.

3. **A época do alerta é invariante ao nível de corrupção.** Com 12,5 %, 25 % e 41,7 % de rótulos efetivamente errados, a época em que o indicador inflete permanece estatisticamente indistinguível ($F = 1{,}00$; $p = 0{,}42$), enquanto a época em que a

degradação se torna visível na validação antecipa-se de modo significativo ($F = 30{,}2$; $p = 0{,}0007$). A leitura compatível com os dados é que o indicador marca o *início* da memorização, cujo momento depende pouco da quantidade de rótulos errados, enquanto a validação mede o *sintoma*.

5.2 REFORMULAÇÃO DA HIPÓTESE CENTRAL

A hipótese enunciada na Seção 1.4 afirmava que a complexidade estatística dos pesos constitui marcador objetivo do início do sobreajuste. Os resultados obrigam a qualificá-la, e a qualificação é o principal aporte conceitual desta dissertação.

O que os resultados autorizam afirmar, em caráter conclusivo, é mais modesto e mais preciso do que a hipótese original: **a capacidade de marcar o sobreajuste não é propriedade das medidas de complexidade em geral, mas de medidas específicas**. Na camada densa, sob memorização induzida, a SampEn2D discrimina as execuções com e sem memorização, e a LMC não.

Essa reformulação tem consequência prática direta para quem pretenda empregar os indicadores. Não é possível recomendar uma medida única como marcador de sobreajuste. É possível, com base nos resultados obtidos, recomendar a SampEn2D sobre a camada densa quando a preocupação for memorização de associações inconsistentes. A generalidade dessa recomendação, porém, permanece limitada pelas condições em que foi estabelecida.

Registre-se ainda uma delimitação que restringe a transposição prática dos achados: na DenseNet-121, embora a amplitude discrimine, a época do sinal *não* separa os grupos. Um monitor que emitisse alerta pelo simples cruzamento de um limiar temporal produziria falsos positivos nessa arquitetura. O critério de alerta precisa incorporar a magnitude da variação, e não apenas o momento em que ela se inicia.

5.3 TRABALHOS FUTUROS

A partir das limitações identificadas, perfilam-se os desdobramentos abaixo. Registre-se que dois itens originalmente previstos como trabalho futuro foram realizados no curso desta pesquisa e constam do Capítulo 4: a extensão para SampEn2D e a comparação com uma segunda arquitetura (DenseNet-121).

1. **Repositório de maior dificuldade.** Repetir os experimentos em um conjunto no qual a escassez de dados produza perda de generalização, permitindo comparar, sobre a camada densa e no mesmo repositório, a memorização induzida por corrupção de rótulos e o sobreajuste por subamostragem do treino.

2. **Sobreajuste espontâneo.** Toda a evidência deste trabalho provém de memorização induzida por corrupção de rótulos. Resta demonstrar que os indicadores se comportam do mesmo modo diante de sobreajuste surgido por escassez de dados sem corrupção — situação mais próxima da prática. O experimento exige cautela com o falso positivo de normalização em lote descrito na Seção 3.4.

3. **Reconsideração da ordem de achatamento.** A ablação da Seção 4.1.6 mostra que a leitura por entrada supera a convenção adotada nos dois critérios avaliados. Convém reavaliar a convenção, ainda que o efeito prático seja limitado pela superioridade da SampEn2D, que não achata a matriz.

4. **Análise multiescala** (MSE) (COSTA et al., 2002; COSTA et al., 2005) da matriz de pesos da camada densa, para investigar dependências em diferentes escalas.

5. **Comparação com outras arquiteturas** (EfficientNet, Wide ResNet) para verificar se o comportamento observado na ResNet-18 e na DenseNet-121 se mantém.

6. **Análise de sensibilidade à regularização explícita** (*weight decay*, *dropout*, *label smoothing*) para testar se a manipulação dirigida da propensão ao sobreajuste altera o comportamento das medidas na camada densa.

7. **Dados substitutos (*surrogate data*)** como teste de hipótese nula sobre a trajetória de complexidade, permitindo caracterizar o quanto da estrutura observada se afasta do comportamento esperado sob inicialização aleatória mais ruído.

8. **Aplicação prática** do marcador proposto como critério de parada precoce em pipelines de treinamento contínuo, comparando custo computacional e desempenho com baselines tradicionais baseados em *loss* de validação.

REFERÊNCIAS

ADVANI, M. S.; SAXE, A. M.; SOMPOLINSKY, H. High-dimensional dynamics of generalization error in neural networks. **Neural Networks**, v. 132, p. 428–446, 2020.

ANTENEODO, C.; PLASTINO, A. R. Some features of the lópez-ruiz-mancini-calbet (LMC) statistical measure of complexity. **Physics Letters A**, v. 223, n. 5, p. 348–354, 1996.

ARPIT, D. et al. A closer look at memorization in deep networks. In: **Proceedings of the 34th International Conference on Machine Learning (ICML)**. [S.l.: s.n.], 2017. p. 233–242.

BARTLETT, P. L.; FOSTER, D. J.; TELGARSKY, M. Spectrally-normalized margin bounds for neural networks. In: **Advances in Neural Information Processing Systems (NeurIPS)**. [S.l.: s.n.], 2017. v. 30.

COSTA, M.; GOLDBERGER, A. L.; PENG, C.-K. Multiscale entropy analysis of complex physiologic time series. **Physical Review Letters**, v. 89, n. 6, p. 068102, 2002.

_____. Multiscale entropy analysis of biological signals. **Physical Review E**, v. 71, n. 2, p. 021906, 2005.

COVER, T. M.; THOMAS, J. A. **Elements of Information Theory**. 2. ed. Hoboken, NJ: Wiley-Interscience, 2006.

DELGADO-BONAL, A.; MARSHAK, A. Approximate entropy and sample entropy: A comprehensive tutorial. **Entropy**, v. 21, n. 6, p. 541, 2019.

DZIUGAITE, G. K.; ROY, D. M. Computing nonvacuous generalization bounds for deep (stochastic) neural networks with many more parameters than training data. In: **Proceedings of the 33rd Conference on Uncertainty in Artificial Intelligence (UAI)**. [S.l.: s.n.], 2017.

FELDMAN, D. P.; CRUTCHFIELD, J. P. Measures of statistical complexity: Why? **Physics Letters A**, v. 238, n. 4–5, p. 244–252, 1998.

HE, K. et al. Deep residual learning for image recognition. p. 770–778, 2016.

JIANG, X. et al. Deep learning for medical image-based cancer diagnosis. **Cancers**, v. 15, n. 14, p. 3608, 2023.

JIANG, Y. et al. Fantastic generalization measures and where to find them. In: **International Conference on Learning Representations (ICLR)**. [S.l.: s.n.], 2020.

LAMBERTI, P. W. et al. Intensive entropic non-triviality measure. **Physica A: Statistical Mechanics and its Applications**, v. 334, n. 1–2, p. 119–131, 2004.

LÓPEZ-RUIZ, R.; MANCINI, H. L.; CALBET, X. A statistical measure of complexity. **Physics Letters A**, v. 209, n. 5–6, p. 321–326, 1995.

MARTIN, C. H.; PENG, T.; MAHONEY, M. W. Predicting trends in the quality of state-of-the-art neural networks without access to training or testing data. **Nature Communications**, v. 12, n. 1, p. 4122, 2021.

PINCUS, S. M. Approximate entropy as a measure of system complexity. **Proceedings of the National Academy of Sciences**, v. 88, n. 6, p. 2297–2301, 1991.

POWER, A. et al. **Grokking: generalization beyond overfitting on small algorithmic datasets**. 2022. ArXiv:2201.02177.

PRECHELT, L. Automatic early stopping using cross validation: quantifying the criteria. **Neural Networks**, v. 11, n. 4, p. 761–767, 1998.

RICHMAN, J. S.; MOORMAN, J. R. Physiological time-series analysis using approximate entropy and sample entropy. **American Journal of Physiology – Heart and Circulatory Physiology**, v. 278, n. 6, p. H2039–H2049, 2000.

ROSSO, O. A. et al. Generalized statistical complexity measure. **International Journal of Bifurcation and Chaos**, v. 20, n. 3, p. 775–785, 2010.

SAXE, A. M. et al. On the information bottleneck theory of deep learning. **Journal of Statistical Mechanics: Theory and Experiment**, v. 2019, n. 12, p. 124020, 2019.

SAYAMA, H. **Introduction to the Modeling and Analysis of Complex Systems**. Geneseo, NY: Open SUNY Textbooks, 2015. Licença Creative Commons BY-NC-SA 3.0. ISBN 978-1-942341-08-6.

SHANNON, C. E. A mathematical theory of communication. **Bell System Technical Journal**, v. 27, n. 3, p. 379–423, 1948.

SHWARTZ-ZIV, R.; TISHBY, N. **Opening the black box of deep neural networks via information**. 2017. ArXiv:1703.00810.

SILVA, L. E. V. et al. Two-dimensional sample entropy analysis of rat sural nerve aging. In: **Proceedings of the 36th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)**. [S.l.: s.n.], 2014. p. 3345–3348.

_____. Two-dimensional sample entropy: assessing image texture through irregularity. **Biomedical Physics & Engineering Express**, v. 2, n. 4, p. 045002, 2016.

SILVA, L. E. V.; JUNIOR, L. O. M. Evaluation of physiologic complexity in time series using generalized sample entropy and surrogate data analysis. **Chaos: An Interdisciplinary Journal of Nonlinear Science**, v. 22, n. 4, p. 043105, 2012.

TENG, Q. et al. A survey on the interpretability of deep learning in medical diagnosis. **Multimedia Systems**, v. 28, n. 6, p. 2335–2355, 2022.

TISHBY, N.; ZASLAVSKY, N. Deep learning and the information bottleneck principle. In: **IEEE Information Theory Workshop (ITW)**. [S.l.: s.n.], 2015. p. 1–5.

YANG, J. et al. MedMNIST v2 – a large-scale lightweight benchmark for 2D and 3D biomedical image classification. **Scientific Data**, v. 10, n. 1, p. 41, 2023.

YENTES, J. M. et al. The appropriate use of approximate entropy and sample entropy with short data sets. **Annals of Biomedical Engineering**, v. 41, n. 2, p. 349–365, 2013.

ZHANG, C. et al. Understanding deep learning requires rethinking generalization. In: **International Conference on Learning Representations (ICLR)**. [S.l.: s.n.], 2017.

ZHANG, J.; BELL, M. A. L. Overfit detection method for deep neural networks trained to beamform ultrasound images. **Ultrasonics**, v. 148, p. 107562, 2025.

Apêndices

APÊNDICE A – EXEMPLO NUMÉRICO DA ORDEM DE ACHATAMENTO DA CAMADA DENSA

Este apêndice complementa a Seção 3.5, rastreando, elemento a elemento, a correspondência entre a matriz de pesos de uma camada `Linear` do PyTorch e a sequência linear sobre a qual a SampEn_{1D} é calculada. Usa-se uma camada mínima, 2×3, primeiro na ordem por neurônio (Equação 3.1) e em seguida na ordem por entrada (Equação 3.2).

A.1 CAMADA LINEAR: MATRIZ 2×3

Considere uma camada `nn.Linear(in_features=3, out_features=2)` cujo tensor `weight` de *shape* $[\mathrm{Out}, \mathrm{In}] = [2, 3]$ recebe valores inteiros para facilitar o rastreamento:

$$W_{\mathrm{lin}} = \begin{pmatrix} w_{0,0} & w_{0,1} & w_{0,2} \\ w_{1,0} & w_{1,1} & w_{1,2} \end{pmatrix} = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{pmatrix}. \tag{A.1}$$

Aplicando `W_lin.flatten()` obtemos o vetor

$$W_{\mathrm{lin}}\texttt{.flatten()} = [\,1,\ 2,\ 3,\ 4,\ 5,\ 6\,]. \tag{A.2}$$

A Tabela 9 mostra a correspondência elemento a elemento. Note que a leitura é feita **linha por linha**: primeiro saem todos os três pesos de entrada do neurônio de saída Out $= 0$, depois os três pesos do neurônio Out $= 1$. Cada linha contígua do vetor corresponde a *um único neurônio de saída*.

Tabela 9 – Mapeamento elemento a elemento da camada Linear 2×3.

Posição no vetor	0 (→) 5	1	2	3	4
Elemento	$w_{0,0}$ $w_{1,2}$	$w_{0,1}$	$w_{0,2}$	$w_{1,0}$	$w_{1,1}$
Valor	1 6	2	3	4	5
Pertence a	**Saída** Out $= 0$			**Saída** Out $= 1$	

A.2 CONTRASTE: ORDEM POR ENTRADA

Transpondo a mesma matriz antes do achatamento, percorrem-se primeiro todos os pesos que partem da entrada In = 0, depois os da entrada In = 1, e assim por diante:

$$W_{\text{lin}}^{\top}.\texttt{flatten()} \;=\; [\,1,\; 4,\; 2,\; 5,\; 3,\; 6\,]. \tag{A.3}$$

Os dois vetores contêm exatamente os mesmos seis valores, e portanto o mesmo histograma: a complexidade LMC é idêntica nas duas ordens. O que muda é a vizinhança de cada valor, à qual a SampEn_{1D} é sensível.

A.3 REPRODUTIBILIDADE

Os vetores apresentados neste apêndice podem ser reproduzidos diretamente em PyTorch:

```
import torch

# Linear (Out=2, In=3)
W_lin = torch.tensor([[1., 2., 3.],
                      [4., 5., 6.]])
print(W_lin.flatten().tolist())      # ordem por neuronio
# [1.0, 2.0, 3.0, 4.0, 5.0, 6.0]
print(W_lin.t().flatten().tolist())  # ordem por entrada
# [1.0, 4.0, 2.0, 5.0, 3.0, 6.0]
```

APÊNDICE B – VALIDAÇÃO NUMÉRICA DAS MEDIDAS DE COMPLEXIDADE

Este apêndice cumpre a parte do objetivo específico 1 (Capítulo 1) referente à *validação numérica das medidas em casos analiticamente conhecidos*. As implementações descritas na seção 3.6 — complexidade LMC e *Sample Entropy* 1D e 2D — são aplicadas a distribuições e séries cujo comportamento esperado é conhecido em forma fechada ou qualitativamente, verificando-se que os valores produzidos coincidem com a teoria. Todos os resultados desta seção são reproduzíveis executando `scripts/validacao_numerica.py` (semente 42, `numpy` 1.26); para a LMC fixou-se $N = 100$ *bins*, de modo que a entropia da uniforme tem valor de referência $\log_2 N \approx 6{,}6439$ bits.

B.1 COMPLEXIDADE LMC

Para a forma adotada $C = H \times D$, com H em bits e $D = \sum_i (p_i - 1/N)^2$, os dois extremos têm valor analítico exato: a distribuição *uniforme* maximiza a entropia ($H = \log_2 N$) e anula o desequilíbrio ($D = 0$), enquanto a distribuição *degenerada* (toda a massa em um único *bin*) anula a entropia ($H = 0$) e atinge $D = 1 - 1/N$; em ambos os casos $C = 0$. Uma distribuição *gaussiana* representa o regime intermediário, com $0 < H < \log_2 N$, $D > 0$ e, portanto, $C > 0$. A Tabela 10 confirma os três comportamentos.

Tabela 10 – Validação da LMC ($N = 100$ *bins*). Os casos uniforme e degenerado reproduzem os valores analíticos com precisão de máquina.

Distribuição	H (bits)	D	$C = H \times D$	Esperado
Uniforme	6,6439	0,00000	0,00000	$H = \log_2 N,\ D \approx 0,\ C \approx 0$
Degenerada	0,0000	0,99000	0,00000	$H = 0,\ D = 1 - 1/N,\ C = 0$
Gaussiana	5,4638	0,01646	0,08994	$0 < H < \log_2 N,\ D > 0,\ C > 0$

B.2 SAMPLE ENTROPY 1D

Com $m = 2$ e $r = 0{,}2\,\sigma$, uma série *constante* é perfeitamente regular e produz SampEn $= 0$ por definição; uma série *periódica* é altamente previsível e produz valor próximo de zero; *ruído branco gaussiano* maximiza a irregularidade e produz um valor finito e elevado, da ordem de 2,1 — compatível com o reportado na literatura para sinais sem estrutura sob essa parametrização. A Tabela 11 confirma a ordenação esperada.

Tabela 11 – Validação da SampEn 1D ($m = 2$, $r = 0{,}2\,\sigma$, séries de 1000 amostras).

Série	SampEn	Esperado
Constante	0,0000	0 (perfeitamente regular)
Periódica (seno, $T = 20$)	0,1864	≈ 0 (previsível)
Ruído branco gaussiano	2,0934	finito e elevado (irregular)

B.3 SAMPLE ENTROPY 2D

A SampEn 2D preserva os limites esperados: uma matriz *constante* produz 0, e uma matriz com *estrutura periódica* produz valor baixo. Para *ruído branco* 64×64, a tolerância padrão $r = 0{,}2\,\sigma$ satura em $+\infty$ — nenhum par de janelas $(m+1) \times (m+1)$ casa dentro da tolerância —, exatamente o comportamento que motivou a adoção de $r = 0{,}5\,\sigma$ na subseção 3.6.3; sob essa tolerância o valor torna-se finito ($\approx 6{,}46$). A validação, portanto, não apenas confirma os limites como reproduz de forma independente a justificativa metodológica para a calibração de r no caso 2D.

Tabela 12 – Validação da SampEn 2D ($m = 2$, matrizes 64×64). O caso do ruído sob $r = 0{,}2\,\sigma$ reproduz a saturação que motiva $r = 0{,}5\,\sigma$.

Matriz	SampEn 2D	Esperado
Constante	0,0000	0 (regular)
Estrutura periódica	0,8173	baixa (estruturada)
Ruído branco ($r = 0{,}2\,\sigma$)	$+\infty$	satura (motiva $r = 0{,}5\,\sigma$)
Ruído branco ($r = 0{,}5\,\sigma$)	6,4636	finito e elevado (irregular)

Em conjunto, as três validações estabelecem que as implementações reproduzem os valores analíticos exatos nos extremos (LMC nas distribuições uniforme e degenerada; SampEn em séries constantes) e a ordenação qualitativa esperada nos regimes intermediários, sustentando o uso das medidas nas análises do Capítulo 4.