Cássio Silva Takarada

Complexidade Estatística dos Pesos de Redes Neurais Profundas como Marcador de Overfitting

Ribeirão Preto
2025

Sumário

Sumário 1

Lista de ilustrações 5

Lista de tabelas 6

1 INTRODUÇÃO 9
1.1 Contexto da análise de imagens médicas no diagnóstico clínico . . . 9
1.2 Avanços em aprendizado profundo aplicados à medicina 9
1.3 Justificativa do uso de medidas de complexidade 10
1.4 Hipótese, objetivos e escopo 11
1.5 Organização do trabalho 12

2 FUNDAMENTAÇÃO TEÓRICA 13
2.1 Entropia de Shannon e teoria da informação 13
2.2 Entropia Aproximada e Entropia de Amostra 14
2.3 Entropia de Amostra Bidimensional (SampEn2D) 16
2.4 Entropia Multiescala (MSE) 17
2.5 Complexidade Estatística LMC 17
2.6 Trabalhos relacionados: análise de pesos e generalização 19

3 METODOLOGIA 21
3.1 Conjuntos de dados 21
3.2 Arquitetura ResNet-18 21
3.2.1 Estrutura em três níveis hierárquicos 22
3.2.2 Composição interna de layer2 a layer4 22
3.2.3 Contagem agregada de tensores 23
3.3 Protocolo de treinamento 23
3.4 Checkpointing log-espaçado em memória 24
3.5 Extração ordenada dos pesos 24
3.5.1 Camada inferior: o que se herda da arquitetura e do PyTorch 24
3.5.2 Camada superior: decisões analíticas deste trabalho 26
3.6 Agrupamento dos pesos em quatro categorias 28
3.6.1 Por que separar γ e β da BatchNorm 28
3.7 Medidas de complexidade 29
3.7.1 Complexidade LMC 29
3.7.2 Entropia amostral SampEn_{1D} 29

3.7.3 Norma ℓ_2 por filtro . . . 29
3.7.4 Extensões previstas: SampEn 2D e multiescala . . . 30
3.8 Análise de robustez planejada . . . 30
3.9 Grid experimental . . . 30

4 RESULTADOS . . . 33
4.1 Visão Geral dos Experimentos . . . 33
4.2 Complexidade LMC ao Longo do Treinamento . . . 33
4.3 Entropia de Amostra dos Pesos . . . 35
4.4 Indução de overfit por subamostragem do treino . . . 36
4.4.1 Protocolo . . . 37
4.4.2 Comportamento das curvas de treino . . . 37
4.4.3 LMC como marcador antecipador . . . 38
4.4.3.1 Detector de pico robusto e intervalo de confiança . . . 38
4.4.3.2 Resultados após detecção robusta . . . 39
4.4.4 SampEn como marcador complementar . . . 39
4.4.5 Decomposição por grupo de camadas . . . 40
4.4.6 Síntese quantitativa . . . 41
4.5 Sensibilidade ao weight decay . . . 42
4.5.1 Protocolo . . . 42
4.5.2 Comportamento das curvas de treino . . . 42
4.5.3 O pico da LMC é invariante ao *weight decay* . . . 43
4.5.4 SampEn é insensível ao *weight decay* . . . 45
4.5.5 Decomposição por grupo . . . 46
4.5.6 Síntese quantitativa . . . 46
4.6 Sensibilidade à arquitetura . . . 47
4.6.1 Protocolo . . . 47
4.6.2 Desempenho preditivo e curvas de treino . . . 47
4.6.3 Invariância do pico da LMC . . . 48
4.6.4 SampEn entre arquiteturas . . . 50
4.6.5 Decomposição por grupo . . . 50
4.6.6 Síntese quantitativa . . . 51
4.7 Generalização entre datasets . . . 52
4.7.1 Trajetórias de LMC nos três datasets . . . 52
4.7.2 Quantificação do pico e do *lead time* . . . 52
4.7.3 Decomposição por grupo: onde está concentrado o anomalismo . . . 54
4.7.4 Reformulação parcial da hipótese H1 . . . 55
4.8 SampEn 2D dos filtros da camada `conv1` . . . 56
4.8.1 Por que apenas a `conv1` . . . 56
4.8.2 Construção do mosaico e calibração de r . . . 56

4.8.3 Resultados . . . 57
4.8.4 Decomposição por canal de entrada . . . 58
4.8.5 Comparação com SampEn 1D e papel complementar . . . 59
4.9 Análise multiescala (MSE 2D) dos mosaicos da `conv1` . . . 59
4.9.1 Protocolo multiescala . . . 59
4.9.2 Curvas multiescala . . . 59
4.9.3 Cruzamento de curvas e discriminação dependente de escala . . . 60
4.9.4 Implicação para análise de complexidade . . . 61

5 CONCLUSÃO . . . 63
5.1 Trabalhos Futuros . . . 65

REFERÊNCIAS . . . 67

APÊNDICES 69

APÊNDICE A – EXEMPLO NUMÉRICO DA ORDEM DE EXTRAÇÃO DOS PESOS . . . 71
A.1 Camada Linear: matriz 2×3 . . . 71
A.2 Camada Conv2d: tensor $[2, 2, 2, 2]$ . . . 72
A.3 Contraste: efeito da transposição . . . 73
A.4 Camada BatchNorm2d: vetores γ e β . . . 74
A.5 Reprodutibilidade . . . 74

APÊNDICE B – VALIDAÇÃO NUMÉRICA DAS MEDIDAS DE COMPLEXIDADE . . . 75
B.1 Complexidade LMC . . . 75
B.2 Sample Entropy 1D . . . 75
B.3 Sample Entropy 2D . . . 76

Cássio Silva Takarada

Complexidade Estatística dos Pesos de Redes Neurais Profundas como Marcador de Overfitting

Dissertação apresentada ao Programa de Pós-Graduação em Computação Aplicada da Faculdade de Filosofia, Ciências e Letras de Ribeirão Preto da Universidade de São Paulo, como parte dos requisitos para obtenção do título de Mestre em Ciências.

Universidade de São Paulo
Faculdade de Filosofia, Ciências e Letras de Ribeirão Preto

Orientador: Prof. Dr. Luiz Otávio Murta Junior

Ribeirão Preto
2025

Lista de ilustrações

Figura 1 – Estrutura de nível superior da ResNet-18: oito módulos nomeados em sequência. As caixas indicam o tipo de camada (azul: Conv2d; verde: BatchNorm2d; cinza: sem parâmetros; laranja: Linear). As caixas `layer1`–`layer4` são contêineres `Sequential` que ocultam sub-blocos detalhados na Figura 2. 22

Figura 2 – Expansão interna de `layer2`: dois `BasicBlock`s, o primeiro com `downsample` adicional. Cada folha colorida é um tensor com parâmetros aprendíveis, indicado pelo seu tipo e número de parâmetros. `layer3` e `layer4` têm estrutura idêntica (com canais maiores); `layer1` é mais simples (sem `downsample`). 23

Figura 3 – Ordem de varredura dentro de uma `Conv2d`, ilustrada com um tensor mínimo $[C_{out} = 2, C_{in} = 2, H = 2, W = 2]$. A leitura segue quatro *loops* aninhados, com C_{out} no nível externo e W no interno. Cada bloco contíguo de 4 elementos corresponde a um canal de entrada de um filtro de saída. 25

Figura 4 – Resumo das regras de ordenação dentro de cada tipo de tensor: todas seguem ordem *row-major*, com o índice mais à esquerda variando mais lentamente. 26

Figura 5 – Curvas de *loss* (acima) e acurácia (abaixo) por época para PathMNIST sob subamostragem do treino para 5%, 10% e 25% do tamanho original. Linhas cheias: treino; tracejadas: validação. As linhas pontilhadas verticais indicam o instante e^* em que cada execução individual atinge o mínimo de *loss* de validação. 37

Figura 6 – Trajetória da LMC (média entre grupos de camadas e entre sementes) sob subamostragem do treino. Eixo x em escala simlog para evidenciar a dinâmica inicial. Linhas pontilhadas verticais: épocas médias do mínimo de *loss* de validação por fração. 38

Figura 7 – *Lead time* da LMC ($e^*_{\text{val}} - e^{\text{peak}}_{\text{LMC}}$) sob subamostragem do treino. Barras de erro: intervalo de confiança 95% por *bootstrap* ($N = 1\,000$) sobre as três sementes. O pico da LMC precede o mínimo de *loss* de validação por ≈ 12 a ≈ 17 épocas em todas as frações estudadas. 39

Figura 8 – Trajetória da SampEn 1D (média entre grupos e entre sementes) sob subamostragem do treino. 40

Figura 9 – LMC por grupo de camadas (conv, dense, `bn_gamma`, `bn_beta`) sob subamostragem do treino. Linhas pontilhadas verticais: épocas médias do mínimo de *loss* de validação por fração. 41

Figura 10 – Curvas de *loss* e acurácia por época em PathMNIST sob variação do *weight decay*. Linhas cheias: treino; tracejadas: validação. Linhas pontilhadas verticais: e^* por execução. 43

Figura 11 – Trajetória da LMC (média entre grupos e entre sementes) sob variação do *weight decay* em PathMNIST. Marcadores verticais: épocas médias do mínimo de *loss* de validação por regime. 44

Figura 12 – *Lead time* da LMC ($e^*_{\text{val}} - e^{\text{peak}}_{\text{LMC}}$) por *weight decay*. Barras de erro: intervalo de confiança 95% por *bootstrap* ($N = 1\,000$) sobre as três sementes. 45

Figura 13 – Trajetória da SampEn 1D sob variação do *weight decay* em PathMNIST. 45

Figura 14 – LMC por grupo de camadas e por *weight decay* em PathMNIST. 46

Figura 15 – Curvas de *loss* e acurácia por época em PathMNIST sob variação da arquitetura. Linhas cheias: treino; tracejadas: validação. 48

Figura 16 – Trajetória da LMC (média entre grupos de camadas e entre sementes) sob variação da arquitetura. 49

Figura 17 – *Lead time* da LMC por arquitetura. Barras de erro: intervalo de confiança 95% por *bootstrap* ($N = 1\,000$) sobre as três sementes. 49

Figura 18 – Trajetória da SampEn 1D sob variação da arquitetura em PathMNIST. 50

Figura 19 – LMC por grupo de camadas e por arquitetura em PathMNIST 100 épocas. 51

Figura 20 – Trajetórias agregadas da LMC (média entre grupos de camadas e entre sementes) nos três datasets MedMNIST, treinados por 100 épocas com ResNet-18 e WD= 10^{-4}. Linhas pontilhadas verticais: época média do mínimo de *loss* de validação por dataset. 52

Figura 21 – *Lead time* da LMC ($e^*_{\text{val}} - e^{\text{peak}}_{\text{LMC}}$) por dataset. Barras de erro: intervalo de confiança 95% por *bootstrap* ($N = 1\,000$) sobre as três sementes. . . 53

Figura 22 – Trajetórias da LMC por grupo de camadas e por dataset (PathMNIST, OrganAMNIST, BloodMNIST), 100 épocas, 3 sementes. 54

Figura 23 – SampEn_{2D} aplicada ao mosaico 56×56 dos 64 filtros $7{\times}7$ da `conv1` (uma imagem por canal de entrada). Médias entre 3 sementes $\times$ 3 canais; intervalos de confiança 95% por *bootstrap*. 57

Figura 24 – SampEn_{2D} por canal de entrada da `conv1`, evidenciando assimetria cromática em PathMNIST. 58

Figura 25 – MSE 2D dos mosaicos 56×56 da `conv1` no *checkpoint* final: SampEn 2D versus escala de *coarse-graining* $\tau \in \{1, \ldots, 10\}$. Bandas: $\pm 1\sigma$ entre os 9 mosaicos. Tolerância $r = 0{,}5\,\sigma$ fixa do mosaico original. 60

Lista de tabelas

Tabela 1 – Datasets MedMNIST utilizados nos experimentos. 21
Tabela 2 – Tensores com parâmetros aprendíveis na ResNet-18 utilizada neste trabalho. 23
Tabela 3 – Pirâmide de decisões da extração de pesos. 28
Tabela 4 – Grupos de pesos sobre os quais as medidas de complexidade são calculadas. 28
Tabela 5 – Pontos de inflexão e *lead time* sob subamostragem do treino (PathMNIST 100 épocas, média entre 3 sementes; *bn_gamma*; bootstrap 95% CI). 41
Tabela 6 – Pontos de inflexão e *lead time* sob variação de weight decay (PathMNIST 100 épocas, média entre 3 sementes; *bn_gamma*; bootstrap 95% CI). . 46
Tabela 7 – Pontos de inflexão e *lead time* por arquitetura (PathMNIST 100 épocas, média entre 3 sementes; *bn_gamma*; bootstrap 95% CI). 51
Tabela 8 – Pontos de inflexão e *lead time* entre datasets MedMNIST (PathMNIST, OrganAMNIST, BloodMNIST; 100 épocas, 3 sementes; *bn_gamma*; bootstrap 95% CI). 53
Tabela 9 – Pico da LMC por grupo de camadas e por dataset (PathMNIST 100 ep, 3 sementes; bootstrap 95% CI; épocas mostradas em escala numérica direta). 54
Tabela 10 – SampEn_{2D} sobre mosaicos 56×56 dos filtros 7×7 da `conv1` no *checkpoint* final (épocas: 100; mosaicos: 8×8 dos 64 filtros; tolerância $r = 0.5\,\sigma$; média entre 3 sementes $\times$ 3 canais de entrada; intervalo de confiança 95% por *bootstrap*). 58
Tabela 11 – SampEn_{2D} multiescala dos mosaicos 56×56 da `conv1` (mean $\pm1\sigma$ entre 3 sementes $\times$ 3 canais; $r = 0.5\,\sigma$, fixo entre escalas). 60
Tabela 12 – Mapeamento elemento a elemento da camada Linear 2×3. 71
Tabela 13 – Mapeamento elemento a elemento da camada Conv2d $[2, 2, 2, 2]$. Posições do vetor, índices do tensor e bloco semântico ao qual cada elemento pertence. 72
Tabela 14 – Mapeamento elemento a elemento com transposição prévia $[C_{in}, C_{out}, H, W]$. Compare com a Tabela 13. 73
Tabela 15 – Validação da LMC ($N = 100$ *bins*). Os casos uniforme e degenerado reproduzem os valores analíticos com precisão de máquina. 75
Tabela 16 – Validação da SampEn 1D ($m = 2$, $r = 0{,}2\,\sigma$, séries de 1000 amostras). . 76
Tabela 17 – Validação da SampEn 2D ($m = 2$, matrizes 64×64). O caso do ruído sob $r = 0{,}2\,\sigma$ reproduz a saturação que motiva $r = 0{,}5\,\sigma$. 76

1 Introdução

1.1 Contexto da análise de imagens médicas no diagnóstico clínico

A imagem médica consolidou-se como um dos pilares do diagnóstico clínico contemporâneo. Modalidades como tomografia computadorizada, ressonância magnética, radiografia, ultrassonografia, tomografia por emissão de pósitrons e a histopatologia digital fornecem representações detalhadas de estruturas internas e teciduais que sustentam decisões de triagem, estadiamento e acompanhamento terapêutico em praticamente todas as especialidades médicas (JIANG et al., 2023). O volume de dados gerado por esses exames cresce de modo contínuo, ao mesmo tempo em que sua interpretação permanece uma tarefa que exige treinamento especializado e está sujeita a variabilidade inter e intraobservador. Esse cenário motiva o desenvolvimento de ferramentas computacionais capazes de oferecer suporte quantitativo à análise dessas imagens, notadamente em tarefas de classificação, segmentação e detecção de anomalias.

1.2 Avanços em aprendizado profundo aplicados à medicina

*Nas últimas décadas o aprendizado profundo (*deep learning*, DL) emergiu como o paradigma dominante para o processamento de imagens médicas. Em particular, redes neurais convolucionais profundas, exemplificadas pela família de redes residuais introduzida por He et al. (2016), alcançaram desempenho próximo ou superior ao de especialistas humanos em diversas tarefas de classificação e detecção (JIANG et al., 2023). Esse progresso é sustentado, de um lado, pelo aumento sistemático do poder computacional e, de outro, pela disponibilização de coleções públicas padronizadas de imagens médicas que viabilizam treinamento, comparação e reprodutibilidade de modelos. Entre essas coleções destaca-se o* benchmark *MedMNIST v2 (YANG et al., 2023), que reúne dezoito conjuntos de classificação 2D e 3D oriundos de patologia, radiologia e oftalmologia, padronizados em baixa resolução para permitir prototipagem rápida sem perder representatividade das modalidades clínicas.*

Apesar desses avanços, modelos profundos operam de modo essencialmente opaco do ponto de vista clínico: a relação entre os parâmetros aprendidos e as decisões de saída não é trivialmente legível, configurando o problema classicamente designado por caixa-preta*. Levantamentos recentes apontam que essa limitação constitui hoje a*

principal barreira à adoção de DL em fluxos diagnósticos sensíveis, mais relevante até que o ganho marginal de acurácia em métricas tradicionais (TENG et al., 2022). Nesse contexto, a interpretabilidade dos modelos depende não apenas de explicações post hoc *sobre saídas individuais, mas também de instrumentos quantitativos que caracterizem o estado interno da rede durante o treinamento.*

1.3 Justificativa do uso de medidas de complexidade

Métricas tradicionais de avaliação — acurácia, perda de validação, área sob a curva ROC — capturam o comportamento do modelo sobre um conjunto de dados específico, mas não oferecem leitura direta sobre a organização estatística dos pesos aprendidos. Essa lacuna é particularmente visível no fenômeno do overfitting*: redes com elevada capacidade podem memorizar o conjunto de treinamento de modo a atingir acurácia quase perfeita sobre ele, ao mesmo tempo em que generalizam mal para dados novos. Análises teóricas recentes da dinâmica de generalização em regimes de alta dimensionalidade indicam que os pesos atravessam fases qualitativamente distintas durante o treinamento, com implicações diretas sobre a capacidade preditiva do modelo (ADVANI; SAXE; SOMPOLINSKY, 2020), e métodos dedicados à detecção de* overfitting *em aplicações clínicas têm sido propostos como resposta prática a esse problema (ZHANG; BELL, 2025).*

*A presente dissertação parte da hipótese de que medidas de complexidade aplicadas diretamente aos pesos da rede podem servir como marcadores objetivos da maturação do treinamento e do início do sobreajuste. Duas famílias de medidas dão sustentação a essa abordagem. A primeira é a Entropia de Amostra (*Sample Entropy*, SampEn) introduzida por Richman e Moorman (2000) como refinamento da Entropia Aproximada de Pincus (1991); SampEn quantifica, sem viés sistemático associado a contagens de auto-coincidência, a regularidade de uma sequência de valores e tem aplicação consolidada na análise de sinais fisiológicos. Sua extensão bidimensional, SampEn2D, foi formalizada por Silva et al. (2016) para caracterizar a irregularidade de texturas espaciais em imagens biomédicas, e é diretamente aplicável à matriz de pesos de uma camada convolucional. A análise multiescala (Multiscale Entropy, MSE) proposta por Costa, Goldberger e Peng (2002) complementa SampEn ao revelar regularidades que se manifestam em diferentes resoluções da mesma sequência ou matriz.*

A segunda família é a complexidade estatística de López-Ruiz, Mancini e Calbet (LÓPEZ-RUIZ; MANCINI; CALBET, 1995), definida pelo produto entre uma medida de incerteza, tipicamente a entropia de Shannon, e uma medida de desequilíbrio em relação à distribuição uniforme. Diferentemente de medidas puramente entrópicas, a complexidade LMC anula-se nos extremos de ordem perfeita e desordem perfeita, atin-

gindo valores máximos em regimes intermediários de auto-organização (ANTENEODO; PLASTINO, 1996). Aplicada à distribuição dos pesos de uma rede neural, espera-se que ela descreva quantitativamente a transição entre o estado inicial aleatório e o estado treinado. A combinação entre SampEn (sensível à estrutura sequencial e espacial dos pesos) e LMC (sensível à forma da distribuição marginal) constitui o eixo metodológico desta investigação.

1.4 Hipótese, objetivos e escopo

A hipótese central deste trabalho é que a complexidade estatística dos pesos de uma rede neural profunda evolui de modo sistemático durante o treinamento e constitui um marcador objetivo do início do overfitting*. Mais especificamente, postula-se que a trajetória das medidas LMC e SampEn ao longo dos passos de otimização exibe inflexão não monotônica, e que essa inflexão precede ou coincide com a saturação da acurácia de validação.*

A pesquisa adota um ***escopo deliberadamente restrito*** *a fim de permitir o controle das variáveis de interesse e a reprodutibilidade plena dos experimentos:*

- ***Arquitetura única:*** *ResNet-18 (HE et al., 2016), escolhida por sua importância histórica, profundidade moderada e papel de* baseline *consagrado em classificação de imagens médicas.*
- ***Conjuntos de dados:*** *três coleções 2D do* benchmark *MedMNIST v2 (YANG et al., 2023) — PathMNIST (histopatologia colorretal), OrganAMNIST (segmentação axial de órgãos abdominais em tomografia computadorizada, reformulada para classificação) e BloodMNIST (microscopia de células sanguíneas).*
- ***Tarefa única:*** *classificação multiclasse, excluindo-se explicitamente segmentação semântica, detecção e tarefas ordinais.*

Arquiteturas alternativas como U-Net e DenseNet, conjuntos de dados de maior escala como NIH ChestX-ray14 e TCIA, e tarefas adicionais como segmentação — mencionados no projeto de qualificação — ficam relegados a trabalhos futuros (Capítulo 5). Esse recorte permite que cada combinação de dataset *e número de épocas seja replicada em múltiplas sementes aleatórias (3 sementes × 3 horizontes × 3 conjuntos = 27 execuções completas), totalizando um grid suficiente para distinguir efeitos sistemáticos de ruído estocástico.*

Os objetivos específicos são:

1. *Implementar SampEn1D, SampEn2D, MSE e a complexidade LMC com validação numérica em casos analiticamente conhecidos (distribuições uniforme, gaussiana e séries periódicas), conforme o Apêndice B.*

2. *Extrair os pesos da ResNet-18 a cada* checkpoint *log-espaçado ao longo do treinamento (cerca de 100 pontos por execução), agrupando-os por tipo de camada (convolucional, densa, parâmetros γ e β do* batch normalization*) e excluindo os* biases *da análise.*

3. *Calcular a trajetória das medidas de complexidade para cada grupo e cada execução, e confrontá-la com a evolução da perda e da acurácia de validação.*

4. *Avaliar se a inflexão das trajetórias LMC e SampEn coincide, antecipa ou sucede o início observável do sobreajuste, e comparar os comportamentos entre os três conjuntos de dados.*

1.5 Organização do trabalho

O restante desta dissertação está organizado em quatro capítulos. O Capítulo 2 apresenta a fundamentação teórica das medidas de complexidade utilizadas (Entropia de Shannon, ApEn, SampEn, SampEn2D, MSE, complexidade LMC) e situa-as no contexto da literatura de redes neurais profundas e análise de séries de pesos. O Capítulo 3 descreve a arquitetura, os conjuntos de dados, o protocolo de treinamento e checkpointing*, o esquema de agrupamento de parâmetros e os parâmetros adotados para cada medida (m, r, número de* bins*, escalas de coarse-graining). O Capítulo 4 apresenta as trajetórias de complexidade observadas no grid de 27 execuções, a análise por grupo de camadas e a correlação com indicadores tradicionais de generalização. O Capítulo 5 sintetiza as evidências obtidas em relação à hipótese central, discute as limitações do recorte adotado e indica direções para extensões futuras envolvendo arquiteturas, modalidades de imagem e tarefas adicionais.*

2 Fundamentação Teórica

Este capítulo apresenta o aparato conceitual e operacional sobre o qual se constrói a metodologia da dissertação. A seção 2.1 retoma a entropia de Shannon e seus desdobramentos em entropia diferencial e divergências, dando base formal às medidas que vêm a seguir. A seção 2.2 percorre a transição da Entropia Aproximada (ApEn) para a Entropia de Amostra (SampEn), explicitando os vieses que motivaram o refinamento e a interpretação probabilística de SampEn como log-verossimilhança condicional. As seção 2.3 e seção 2.4 estendem SampEn ao domínio espacial bidimensional e ao plano multiescala, respectivamente, fornecendo as duas leituras complementares sobre a matriz de pesos de uma camada convolucional. Por fim, a seção 2.5 apresenta a complexidade estatística de López-Ruiz, Mancini e Calbet (LMC), discute a controvérsia sobre normalização e intensividade que se seguiu à proposta original e justifica a convenção $C = H \times D$ adotada no restante do trabalho.

2.1 Entropia de Shannon e teoria da informação

A entropia de Shannon (SHANNON, 1948) é a pedra angular sobre a qual se assenta toda a discussão subsequente. Para uma variável aleatória discreta X que assume valores no alfabeto finito $\mathcal{X} = \{x_1, x_2, \ldots, x_N\}$ com distribuição de probabilidade $P = (p_1, p_2, \ldots, p_N)$, a entropia é definida por

$$H(X) = -\sum_{i=1}^{N} p_i \log_2 p_i, \tag{2.1}$$

adotando-se, por convenção, $0 \log_2 0 = 0$. A escolha do logaritmo na base 2 implica que H é medida em bits, interpretação diretamente associada ao número médio mínimo de dígitos binários necessário para codificar uma realização de X. A entropia satisfaz $0 \leq H(X) \leq \log_2 N$, com extremos alcançados, respectivamente, pela distribuição degenerada (existe i tal que $p_i = 1$) e pela distribuição uniforme ($p_i = 1/N$ para todo i). Caracterizações axiomáticas mostram que essas propriedades, junto da continuidade e da aditividade, determinam H a menos de um fator multiplicativo (COVER; THOMAS, 2006).

Quando X é uma variável contínua com função de densidade de probabilidade f, a generalização natural — a entropia diferencial — é dada por

$$h(X) = -\int_{\mathcal{X}} f(x) \log_2 f(x)\, dx, \tag{2.2}$$

sempre que a integral exista. Diferentemente da versão discreta, $h(X)$ pode assumir valores negativos e não é invariante sob mudança de escala, o que limita seu uso direto como índice de "incerteza". Em aplicações práticas com pesos de redes neurais, trabalha-se com a versão discretizada por meio de histogramas com N bins, recuperando a forma da Equação 2.1 a um custo controlado de viés e variância (COVER; THOMAS, 2006).

Uma medida de dissimilaridade entre duas distribuições P e Q sobre o mesmo alfabeto é a divergência de Kullback–Leibler

$$D_{\mathrm{KL}}(P\|Q) = \sum_{i=1}^{N} p_i \log_2 \frac{p_i}{q_i}, \tag{2.3}$$

que é não negativa e nula se, e somente se, $P = Q$. A Equação 2.3 é central nesta dissertação porque a noção de "desequilíbrio" subjacente à complexidade LMC pode ser interpretada como uma medida de afastamento entre P e a distribuição de referência (uniforme), tema retomado na seção 2.5.

2.2 Entropia Aproximada e Entropia de Amostra

O salto da teoria da informação para a análise de séries temporais finitas exige um estimador de regularidade que opere com poucos pontos e seja robusto a ruído moderado. A Entropia Aproximada (ApEn), introduzida por Pincus (1991), foi a primeira proposta a preencher esse papel para sinais fisiológicos. Dada uma série $\mathbf{u} = (u_1, u_2, \ldots, u_N)$, fixa-se um comprimento de embedding m e uma tolerância r e constroem-se os vetores $\mathbf{x}_i = (u_i, u_{i+1}, \ldots, u_{i+m-1})$ com $1 \le i \le N - m + 1$. Para cada i define-se

$$C_i^m(r) = \frac{\#\{j : d[\mathbf{x}_i, \mathbf{x}_j] \le r\}}{N - m + 1}, \tag{2.4}$$

*onde $d[\cdot,\cdot]$ é a distância de Chebyshev (máximo das diferenças absolutas componente a componente) e a contagem inclui o caso $j = i$ (*self-match*). A ApEn é então*

$$\mathrm{ApEn}(m, r, N) = \Phi^m(r) - \Phi^{m+1}(r), \quad \Phi^m(r) = \frac{1}{N - m + 1} \sum_{i=1}^{N-m+1} \ln C_i^m(r). \tag{2.5}$$

A inclusão de self-matches *em $C_i^m(r)$ é simultaneamente o recurso que viabiliza a definição (evita logaritmo de zero) e a fonte de seus dois principais defeitos: (i) ApEn é sistematicamente enviesada para valores menores em séries curtas, e (ii) sua consistência relativa — a propriedade de que, ao se comparar duas séries em um mesmo r, a ordem dos valores se preserva quando r varia — não é garantida (RICHMAN; MOORMAN, 2000; DELGADO-BONAL; MARSHAK, 2019). A literatura subsequente documenta cenários em que classificações fisiológicas baseadas em ApEn se invertem*

ao se mudar a tolerância, comprometendo seu uso como marcador objetivo (YENTES et al., 2013; DELGADO-BONAL; MARSHAK, 2019).

A Entropia de Amostra (SampEn), proposta por Richman e Moorman (2000), remove essas limitações por construção. Em vez de calcular o logaritmo médio de probabilidades locais, conta-se globalmente o número de pares de templates próximos. Sejam

$$B^m(r) = \#\{(i,j) : i < j,\ d[\mathbf{x}_i, \mathbf{x}_j] \le r\}, \tag{2.6}$$

$$A^m(r) = \#\{(i,j) : i < j,\ d[\mathbf{x}_i, \mathbf{x}_j] \le r,\ |u_{i+m} - u_{j+m}| \le r\}, \tag{2.7}$$

isto é, $B^m(r)$ conta pares de janelas de comprimento m próximas e $A^m(r)$ conta os pares dessas janelas que permanecem próximas após um passo adicional. A SampEn é dada por

$$\mathrm{SampEn}(m, r, N) = -\ln \frac{A^m(r)}{B^m(r)}. \tag{2.8}$$

Pela construção, ambas as contagens excluem o par (i, i), eliminando o viés associado às auto-coincidências. A interpretação de Equação 2.8 é direta e instrutiva: SampEn é o negativo do logaritmo da probabilidade condicional de que duas janelas próximas em comprimento m permaneçam próximas em comprimento $m + 1$. Valores baixos correspondem a séries muito regulares (a continuação é altamente previsível); valores altos, a séries irregulares (continuação imprevisível).

A Equação 2.8 herda independência tanto de N quanto da ordem dos pares por ser uma estatística baseada em razão de contagens globais. Demonstrou-se ainda que, em uma ampla família de processos estocásticos, SampEn possui consistência relativa entre tolerâncias, propriedade que ApEn não satisfaz (RICHMAN; MOORMAN, 2000). Por outro lado, a literatura recente registra cenários particulares de processos do tipo MIX *contaminados por ruído em que mesmo SampEn pode falhar essa consistência, recomendando cautela ao se interpretar diferenças finas entre séries de naturezas distintas (DELGADO-BONAL; MARSHAK, 2019).*

A escolha dos parâmetros m e r é prática consagrada na literatura. Pela análise sistemática de Yentes et al. (2013) sobre séries curtas, recomenda-se $m = 2$ e r entre 0,1 *e* 0,25 *do desvio padrão da série, com $N \ge 200$ para evitar instabilidade estatística. Esta dissertação adota $m = 2$ e $r = 0{,}2 \times \sigma$, com σ tomado como desvio padrão populacional (`ddof=0`), em consonância com a convenção do grupo de pesquisa e com o intervalo recomendado pela literatura. Ressalva-se que tensores pequenos — em particular os parâmetros γ e β do* batch normalization *das camadas iniciais — podem ter comprimento inferior a $N = 200$, regime em que a estimativa de SampEn é menos estável; esse limite é levado em conta na interpretação desses grupos.*

2.3 Entropia de Amostra Bidimensional (SampEn2D)

A extensão bidimensional da SampEn surge da observação de que pesos de camadas convolucionais e parâmetros de matrizes têm estrutura espacial: a vizinhança de um peso é tão informativa quanto sua sequência linear, e o domínio natural para análise é a matriz, não o vetor. Silva et al. (2014) apresentaram uma primeira formulação, validada posteriormente em Silva et al. (2016) sobre imagens de textura sintéticas, do banco Brodatz e de cortes histológicos de nervo sural, demonstrando que SampEn2D recupera as propriedades qualitativas de SampEn 1D ao mesmo tempo em que incorpora a dependência bidimensional.

Seja $\mathbf{W} \in \mathbb{R}^{H\times W}$ *uma matriz de pesos extraída de uma camada da rede. Fixe-se um tamanho de janela* m *e uma tolerância* r*. As janelas* $m \times m$ *centradas em* (i, j) *formam a coleção* $\mathcal{V}_m = \{\mathbf{V}_{i,j}^{(m)} : 1 \le i \le H - m,\ 1 \le j \le W - m\}$*. Para uma janela maior* $(m + 1) \times (m + 1)$*, analogamente, escreve-se* $\mathcal{V}_{m+1}$*. Por construção, restringe-se às posições* (i, j) *tais que ambas as janelas* m *e* $m + 1$ *caibam integralmente em* $\mathbf{W}$*, garantindo emparelhamento entre* $\mathcal{V}_m$ *e* $\mathcal{V}_{m+1}$*. Em analogia com as Equação 2.6 e Equação 2.7, definem-se*

$$B_{2\mathrm{D}}^m(r) = \#\{(p, q) : p \neq q,\ d[\mathbf{V}_p^{(m)}, \mathbf{V}_q^{(m)}] \le r\}, \tag{2.9}$$

$$A_{2\mathrm{D}}^m(r) = \#\{(p, q) : p \neq q,\ d[\mathbf{V}_p^{(m+1)}, \mathbf{V}_q^{(m+1)}] \le r\}, \tag{2.10}$$

em que p, q *percorrem as posições válidas e* $d[\cdot, \cdot]$ *é a distância de Chebyshev sobre a janela vista como vetor. A* Sample Entropy 2D *é*

$$\mathrm{SampEn2D}(m, r, \mathbf{W}) = -\ln \frac{A_{2\mathrm{D}}^m(r)}{B_{2\mathrm{D}}^m(r)}. \tag{2.11}$$

A interpretação probabilística replica a do caso unidimensional: SampEn2D é o negativo do logaritmo da probabilidade de que duas janelas $m \times m$ *próximas tenham vizinhanças que permaneçam próximas quando a janela é estendida em uma linha e uma coluna.*

A literatura aponta dois aspectos práticos relevantes. Primeiro, a SampEn2D pode produzir valores indefinidos para matrizes pequenas quando $A_{2\mathrm{D}}^m(r) = 0$*, problema que motivou propostas alternativas baseadas em entropias de dispersão e fuzzificação. Segundo, o custo computacional cresce quadraticamente com o número de janelas válidas, tornando a estimativa custosa para matrizes grandes (SILVA et al., 2016). Para os fins desta dissertação, o tamanho típico das matrizes de uma camada convolucional na ResNet-18 mantém-se confortavelmente acima do regime patológico identificado pela literatura, e a SampEn2D é aplicada diretamente, sem recurso a substitutos.*

2.4 Entropia Multiescala (MSE)

*A SampEn captura irregularidade em uma escala fixa. No entanto, sistemas com correlações de longo alcance — batimentos cardíacos saudáveis, ruído $1/f$, dinâmica de redes complexas — apresentam estrutura em múltiplas escalas temporais simultaneamente. A Entropia Multiescala (MSE), proposta por Costa, Goldberger e Peng (2002) e sistematizada em Costa, Goldberger e Peng (2005), lê esse fenômeno por meio de uma sequência de granulações grosseiras (*coarse-grainings*) da série original.*

Dada uma série $\mathbf{u}$ e um fator de escala $\tau \in \mathbb{N}^*$, constrói-se a série granulosa

$$y_j^{(\tau)} = \frac{1}{\tau} \sum_{i=(j-1)\tau+1}^{j\tau} u_i, \quad 1 \le j \le \lfloor N/\tau \rfloor, \tag{2.12}$$

isto é, médias de blocos não sobrepostos de comprimento τ. A escala $\tau = 1$ recupera a série original. Para cada τ, calcula-se SampEn da série granulosa, formando o perfil multiescala $\{\mathrm{SampEn}(m, r, y^{(\tau)}) : \tau = 1, 2, \ldots, \tau_{\max}\}$.

Um detalhe metodológico crítico: a tolerância r é fixada uma única vez a partir do desvio padrão da série original *e mantida constante em todas as escalas, conforme prescrição de Costa, Goldberger e Peng (2005). Recomputar r em cada escala invalidaria a comparação entre escalas, pois mudanças no perfil de complexidade ficariam confundidas com a renormalização local. A interpretação qualitativa da curva* SampEn *versus τ separa três classes principais: ruído branco (entropia decresce monotonicamente), ruído $1/f$ (entropia constante ao longo das escalas) e periódicos (entropia próxima de zero em todas as escalas). Sistemas fisiológicos saudáveis apresentam padrão similar ao $1/f$, enquanto patologias frequentemente colapsam para perfis monotonicamente decrescentes (COSTA; GOLDBERGER; PENG, 2005).*

Esta dissertação aplica MSE 1D ao vetor de pesos achatado e, na extensão proposta por Silva et al. (2016) para SampEn2D, MSE 2D às matrizes via granulação por blocos $\tau \times \tau$. Em ambos os casos, r é mantido fixo em $0{,}2 \times \sigma$ da matriz original, com σ calculado em população.

2.5 Complexidade Estatística LMC

A entropia, isoladamente, não é uma boa medida de complexidade. Distribuições uniformes (entropia máxima) são tão simples quanto distribuições degeneradas (entropia mínima), no sentido de que ambas são facilmente descritíveis e desprovidas de estrutura interna. López-Ruiz, Mancini e Calbet (1995) — doravante LMC — propuseram, como remédio, uma medida que se anula em ambos os extremos e atinge valores máximos em regimes intermediários de auto-organização. Para uma distribuição $P = (p_1, \ldots, p_N)$,

define-se o desequilíbrio

$$D(P) = \sum_{i=1}^{N} \left(p_i - \frac{1}{N} \right)^2, \tag{2.13}$$

isto é, o quadrado da distância L_2 até a distribuição uniforme. A complexidade estatística LMC é o produto

$$C(P) = H(P) \times D(P), \tag{2.14}$$

em que H é a entropia de Shannon, dada pela Equação 2.1. Como H é máxima e D é nula sob a distribuição uniforme, e H é nula e D é máxima sob a distribuição degenerada, C se anula em ambos os extremos por construção. Para distribuições intermediárias, C assume valores estritamente positivos, refletindo simultaneamente incerteza e afastamento do equilíbrio (LÓPEZ-RUIZ; MANCINI; CALBET, 1995).

A definição original gerou debate intenso. Anteneodo e Plastino (1996) demonstraram, no contexto de ensembles físicos, que C na forma Equação 2.14 não *é uma quantidade intensiva: ao se duplicar o tamanho do sistema, C não satisfaz a relação de escala esperada de uma medida termodinâmica genuína. Esse fato limita a transferibilidade direta de C entre sistemas de tamanhos distintos e motivou a busca por refinamentos. Feldman e Crutchfield (1998), em uma revisão crítica das medidas de complexidade estatística disponíveis na época, articularam três desideratos: a medida deve (i) anular-se nos extremos de ordem e desordem perfeitas, (ii) ser intensiva, e (iii) capturar a presença de estrutura correlacional em escalas relevantes do sistema.*

A resposta mais influente a essas críticas é a complexidade estatística generalizada (SCM, Statistical Complexity Measure*), introduzida por Lamberti et al. (2004) e desenvolvida por Rosso et al. (2010). Em vez do produto $H \times D$, define-se*

$$C_{\mathrm{SCM}}(P) = Q_J(P, P_e) \cdot H(P)/H_{\max}, \tag{2.15}$$

em que $H_{\max} = \log_2 N$ normaliza a entropia, P_e é a distribuição de equilíbrio (tipicamente uniforme), e $Q_J(P, P_e)$ é o desequilíbrio em divergência de Jensen-Shannon, normalizado de modo que $0 \leq Q_J \leq 1$. A construção Equação 2.15 é intensiva, limitada ao intervalo $[0, 1]$ e aplicável a uma variedade de sistemas dinâmicos contínuos e discretos.

Apesar das vantagens formais da SCM, esta dissertação adota a forma original Equação 2.14 — $C = H \times D$ em bits, sem normalização — por três razões metodológicas que merecem explicitação:

1. ***Comparação intra-modelo, não inter-sistema.*** *O objeto de análise são as trajetórias de complexidade dos pesos de* uma mesma rede *em* um mesmo grupo de camadas *ao longo do treinamento. As comparações são pareadas por* checkpoint, seed *e dataset; o argumento de intensividade de Anteneodo e Plastino*

(1996), que diz respeito à escalonamento entre sistemas de tamanhos distintos, não é ativado nesse desenho experimental.

2. ***Sensibilidade a transições intermediárias.*** *A forma $H \times D$ é sensível justamente ao regime que interessa à hipótese central — a transição entre o estado inicial aleatório e o estado treinado. Versões normalizadas saturam nas extremidades do intervalo $[0, 1]$, comprimindo as diferenças que se busca medir. A versão não normalizada preserva a granularidade necessária para detectar inflexões sutis na trajetória.*

3. ***Convenção do grupo de pesquisa.*** *Trabalhos anteriores do mesmo grupo (SILVA et al., 2016; SILVA; JUNIOR, 2012) adotam a convenção $H \times D$ em bits, sem normalização, com binarização adaptativa da forma $N = \min(100, \max(10, n/5))$, onde n é o número de amostras. Manter essa convenção preserva a comparabilidade direta entre os resultados desta dissertação e os da literatura imediata.*

A normalização adaptativa do número de bins N é especialmente relevante para a aplicação a pesos de redes neurais, onde o número de parâmetros varia ordens de grandeza entre camadas: tipicamente poucas centenas em camadas iniciais e dezenas de milhares em camadas profundas. A regra $N = \min(100, \max(10, n/5))$ garante resolução suficiente para camadas pequenas sem incorrer em viés de subamostragem em camadas grandes.

A combinação entre LMC (sensível à forma da distribuição marginal dos pesos) e SampEn (sensível à estrutura sequencial e espacial) fornece, portanto, dois ângulos complementares sobre o estado interno da rede ao longo do treinamento. Os parâmetros operacionais adotados, junto da fundamentação aqui apresentada, são retomados em detalhe no Capítulo 3.

2.6 Trabalhos relacionados: análise de pesos e generalização

A questão de por que *redes neurais profundas generalizam — e de como* antecipar *o sobreajuste (*overfitting*) a partir do estado interno do modelo — motivou uma extensa literatura de medidas calculadas sobre os próprios pesos da rede. Esta seção situa a presente dissertação frente a essas abordagens e explicita em que ela difere.*

Uma primeira família estabelece limites de generalização *baseados em normas e margens. Bartlett, Foster e Telgarsky (2017) derivam um limite cuja magnitude escala com a complexidade espectral da rede — o produto das normas espectrais das matrizes de peso, normalizado pela margem —, mostrando empiricamente que essa quantidade acompanha o risco em excesso ao longo do treinamento. Numa linha probabilística, Dziugaite e Roy (2017) obtêm limites PAC-Bayes* não vacuosos *para redes estocásticas*

*com muito mais parâmetros do que dados, otimizando diretamente o limite sobre perturbações dos pesos. A diversidade dessas propostas levou Jiang et al. (2020) a um estudo empírico de larga escala: avaliando mais de quarenta medidas de complexidade sobre mais de dez mil redes convolucionais, os autores constatam que algumas medidas baseadas em norma falham em prever a generalização, enquanto medidas ligadas a nitidez (*sharpness*) e a fundamentos PAC-Bayes se mostram mais promissoras.*

Uma segunda família analisa o espectro *das matrizes de peso. A Teoria da Auto-Regularização de Cauda Pesada (*Heavy-Tailed Self-Regularization*) de Martin, Peng e Mahoney (2021) ajusta leis de potência às densidades espectrais empíricas dos pesos e mostra que o expoente da lei de potência correlaciona-se com a qualidade do modelo, discriminando redes bem e mal treinadas* sem acesso a dados de treino ou teste. *Essa abordagem — materializada na ferramenta* `WeightWatcher` *— evidencia que a distribuição dos pesos carrega, por si só, informação sobre generalização, ainda que por um ângulo puramente espectral. Em paralelo, estudos sobre a dinâmica de alta dimensão do erro de generalização (ADVANI; SAXE; SOMPOLINSKY, 2020) e sobre os próprios fundamentos das medidas de complexidade estatística (FELDMAN; CRUTCHFIELD, 1998) reforçam que a forma das distribuições internas, e não apenas sua norma, é informativa.*

Frente a esse panorama, a contribuição desta dissertação distingue-se em três aspectos. Primeiro, em vez de normas escalares ou de espectros de valores singulares, adota-se uma leitura informação-teórica *da* distribuição dos valores *dos pesos, via complexidade estatística LMC e entropia de amostra. Segundo, o foco é* temporal*: as medidas são acompanhadas* ao longo das épocas *e por grupo de camadas, buscando a inflexão que antecede o sobreajuste — ao passo que a maioria das abordagens acima é avaliada em um único estado treinado. Terceiro, o domínio de aplicação é a imagem médica, em que detectar sobreajuste é particularmente crítico (ZHANG; BELL, 2025). Até onde se pôde verificar, o uso de complexidade estatística e de entropia de amostra dos pesos como* marcador temporal de sobreajuste *não havia sido explorado, o que delimita a lacuna que este trabalho busca preencher.*

3 Metodologia

Este capítulo descreve o protocolo experimental adotado para investigar a evolução da complexidade estatística dos pesos de uma rede neural profunda durante o treinamento. A exposição é organizada do dado bruto às medidas finais: primeiro os conjuntos de dados (Seção 3.1), em seguida a arquitetura empregada (Seção 3.2) e o protocolo de treinamento (Seção 3.3); a Seção 3.4 formaliza o esquema de *snapshots* ao longo do treino; a Seção 3.5 — núcleo metodológico deste trabalho — discute em detalhe a ordem de extração dos pesos, separando o que é herdado da arquitetura/biblioteca daquilo que constitui escolha analítica deste estudo; a Seção 3.6 define os quatro grupos de pesos sobre os quais as medidas serão calculadas; a Seção 3.7 apresenta as medidas de complexidade adotadas; e a Seção 3.8 antecipa as análises de robustez planejadas.

3.1 Conjuntos de dados

Utilizam-se três subconjuntos do *benchmark* MedMNIST v2 (YANG et al., 2023), selecionados por cobrirem modalidades clínicas distintas e apresentarem dificuldade não-saturada para a arquitetura adotada (Tabela 1). Todas as imagens são redimensionadas de 28×28 para 64×64 antes do treinamento, mantendo a representatividade clínica sem inflar excessivamente o custo computacional.

Tabela 1 – Datasets MedMNIST utilizados nos experimentos.

Dataset	**Treino**	**Classes (K)**	**Modalidade**
PathMNIST	89.996	9	Histopatologia colorretal (RGB)
OrganAMNIST	34.581	11	*Slices* axiais de tomografia abdominal (cinza)
BloodMNIST	11.959	8	Microscopia de células sanguíneas (RGB)

3.2 Arquitetura ResNet-18

Adota-se a ResNet-18 (HE et al., 2016) (implementação `torchvision`, sem pré-treinamento), com a camada totalmente conectada final substituída para o número de classes K de cada conjunto. Esta arquitetura totaliza aproximadamente 11,2 milhões de parâmetros distribuídos em **41 tensores com parâmetros aprendíveis**: 20 camadas convolucionais (`Conv2d`), 20 camadas de *batch normalization* (`BatchNorm2d`) e 1 camada totalmente conectada (`Linear`).

3.2.1 Estrutura em três níveis hierárquicos

A organização interna da ResNet-18 possui três níveis aninhados, ilustrados na Figura 1:

1. **Nível superior (oito módulos nomeados):** `conv1` (Conv2d 7×7, com *stride* 2), `bn1` (BatchNorm2d), `relu`, `maxpool`, `layer1`–`layer4` (contêineres `Sequential`), `avgpool` (*global average pooling*) e `fc` (Linear $512 \to K$).

2. **Nível intermediário (BasicBlocks):** cada `layerN` contém dois blocos residuais (`BasicBlock`). Em `layer2`, `layer3` e `layer4`, o primeiro `BasicBlock` contém ainda um sub-módulo `downsample` responsável por ajustar resolução e número de canais no caminho residual.

3. **Nível folha (operações elementares):** dentro de cada `BasicBlock` encontram-se duas `Conv2d` (3×3) e duas `BatchNorm2d`; o `downsample`, quando presente, contém uma `Conv2d` (1×1) e uma `BatchNorm2d` adicionais.

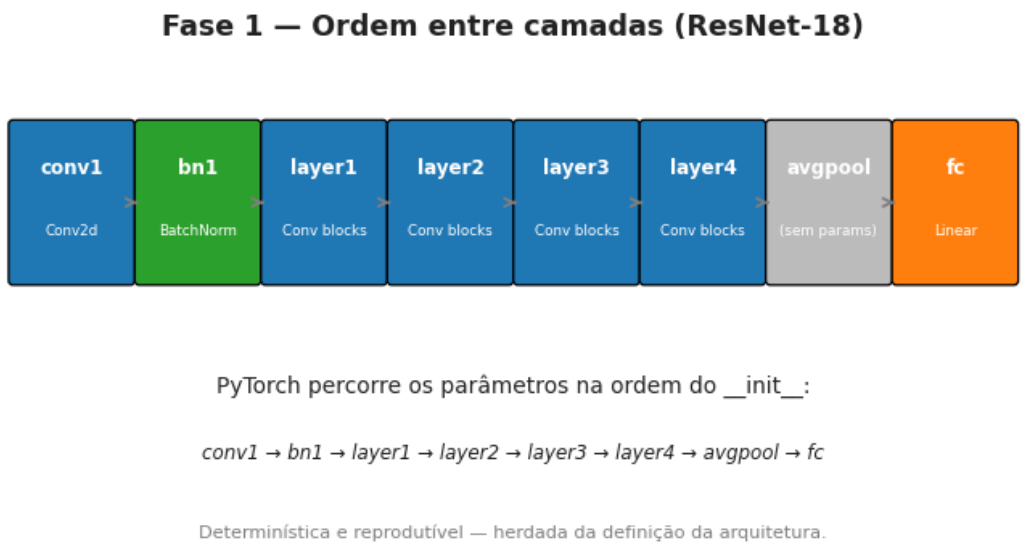


Figura 1 – Estrutura de nível superior da ResNet-18: oito módulos nomeados em sequência. As caixas indicam o tipo de camada (azul: Conv2d; verde: BatchNorm2d; cinza: sem parâmetros; laranja: Linear). As caixas `layer1`–`layer4` são contêineres `Sequential` que ocultam sub-blocos detalhados na Figura 2.

3.2.2 Composição interna de layer2 a layer4

Como exemplo representativo do nível intermediário, a Figura 2 expõe a estrutura de `layer2`, que contém os dez módulos com parâmetros característicos das três últimas `layerN`. Em particular, o primeiro `BasicBlock` contém um `downsample` composto por

uma convolução 1×1 e uma `BatchNorm2d` adicionais, totalizando seis módulos com parâmetros no primeiro bloco e quatro no segundo. A `layer1` segue o mesmo padrão mas sem `downsample`, pois não há mudança de número de canais (somando portanto oito módulos com parâmetros).

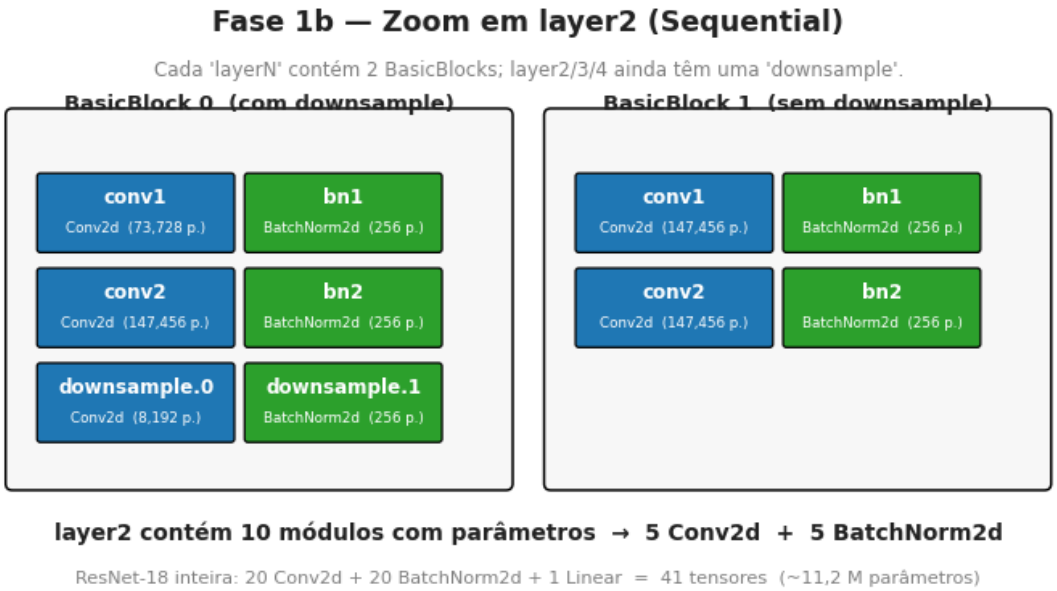


Figura 2 – Expansão interna de `layer2`: dois `BasicBlocks`, o primeiro com `downsample` adicional. Cada folha colorida é um tensor com parâmetros aprendíveis, indicado pelo seu tipo e número de parâmetros. `layer3` e `layer4` têm estrutura idêntica (com canais maiores); `layer1` é mais simples (sem `downsample`).

3.2.3 Contagem agregada de tensores

A Tabela 2 sintetiza, por tipo de camada, a quantidade de tensores e de parâmetros disponíveis para a análise de complexidade.

Tabela 2 – Tensores com parâmetros aprendíveis na ResNet-18 utilizada neste trabalho.

Tipo	**Tensores**	**Parâmetros (%)**	**Localização**
`Conv2d`	20	$\sim$ 11,15 M (99,7%)	1 em conv1 + 4 em layer1 + 5 em layer2/3/4
`BatchNorm2d`	20	$\sim$ 10 k ($<$ 0,1%)	sempre pareada 1:1 com cada Conv2d
`Linear`	1	$\sim$ 4,6 k	fc
Total	**41**	$\sim$ 11,18 M	ResNet-18 inteira

3.3 Protocolo de treinamento

O treinamento emprega o otimizador SGD com *momentum* 0,9, taxa de aprendizado 10^{-3} e *weight decay* 10^{-4} — hiperparâmetros validados pelo grupo de pesquisa em experimentos

preliminares. A função objetivo é a entropia cruzada com pesos uniformes de classe. O *batch size* é 64 e cada *run* dura entre 30 e 100 épocas, conforme o ponto experimental do grid (Seção 3.9). Todos os experimentos são executados em CPU (*torch* 2,4,1 e *torchvision* 0,19,1).

3.4 Checkpointing log-espaçado em memória

A cada *run*, $K \approx 88$ pontos de medição são distribuídos nos passos de treinamento com espaçamento logarítmico, concentrando maior densidade nas primeiras épocas, onde a distribuição dos pesos muda mais rapidamente. Em cada ponto, um `WeightSnapshot` é construído a partir do estado atual do modelo em memória, sem escrita de arquivo por passo — evitando inflar o uso de disco em ordens de magnitude quando comparado a salvar todos os `state_dicts`. Cada *snapshot* contém referências para os tensores de `Conv2d`, `Linear` e `BatchNorm2d`, já agrupados conforme descrito na Seção 3.6.

A escolha pelo espaçamento logarítmico, em contraste com um espaçamento uniforme, é deliberada: a literatura de dinâmica de generalização (ADVANI; SAXE; SOMPOLINSKY, 2020) indica que as fases qualitativamente distintas do treinamento ocorrem em escalas de tempo logarítmicas. Um espaçamento uniforme superamostraria a fase de saturação tardia e subamostraria a fase inicial de rápida reorganização das distribuições de pesos.

3.5 Extração ordenada dos pesos

A extração dos pesos é o procedimento que converte o estado da rede em uma sequência linear de números sobre os quais as medidas de complexidade são calculadas. Este procedimento opera em *duas camadas* encadeadas (Seção 3.5.1): uma **inferior**, totalmente determinada pela arquitetura ResNet-18 e pela convenção de armazenamento do PyTorch; e uma **superior**, composta por escolhas analíticas deste trabalho. A presente seção descreve cada uma e justifica explicitamente toda decisão da camada superior.

3.5.1 Camada inferior: o que se herda da arquitetura e do PyTorch

Dois fatos são externos a este trabalho e simplesmente descritos:

Ordem entre módulos.

O método `model.state_dict()` do PyTorch devolve um `OrderedDict` cuja ordem de iteração é exatamente a sequência em que os módulos foram registrados no `__init__` da `torchvision.models.resnet18`. Esta sequência é determinística e reprodutível entre *runs*, e corresponde à travessia em profundidade da árvore de módulos exibida nas Figuras 1–2:

`conv1` $\rightarrow$ `bn1` $\rightarrow$ `layer1.0.conv1` $\rightarrow$ `layer1.0.bn1` $\rightarrow \cdots \rightarrow$ `layer2.0.downsample.0` $\rightarrow \cdots \rightarrow$ `fc`.

Ordem dentro de cada tensor.

O PyTorch armazena tensores em memória contígua (C-contiguous, *row-major*). Isto significa que, ao aplicar `tensor.flatten()` ou ao iterar elementos via `numpy().flat`, o índice mais à esquerda do tensor é o de variação mais lenta, e o índice mais à direita é o de variação mais rápida (Figura 3). Em particular:

- `Conv2d`: tensor de shape $[C_{out}, C_{in}, H, W]$; ordem de varredura é $C_{out} \to C_{in} \to H \to W$. Cada bloco contíguo de $C_{in} \cdot H \cdot W$ elementos corresponde a um **filtro de saída completo**.
- `Linear`: tensor de shape $[\text{Out}, \text{In}]$; ordem de varredura é Out $\to$ In. Cada linha contígua de In elementos corresponde aos **pesos de entrada de um único neurônio de saída**.
- `BatchNorm2d`: dois vetores 1D de comprimento C (canais), na ordem $\gamma_0, \gamma_1, \ldots$ seguido por $\beta_0, \beta_1, \ldots$ (ver Seção 3.6.1 para a semântica de γ e β).

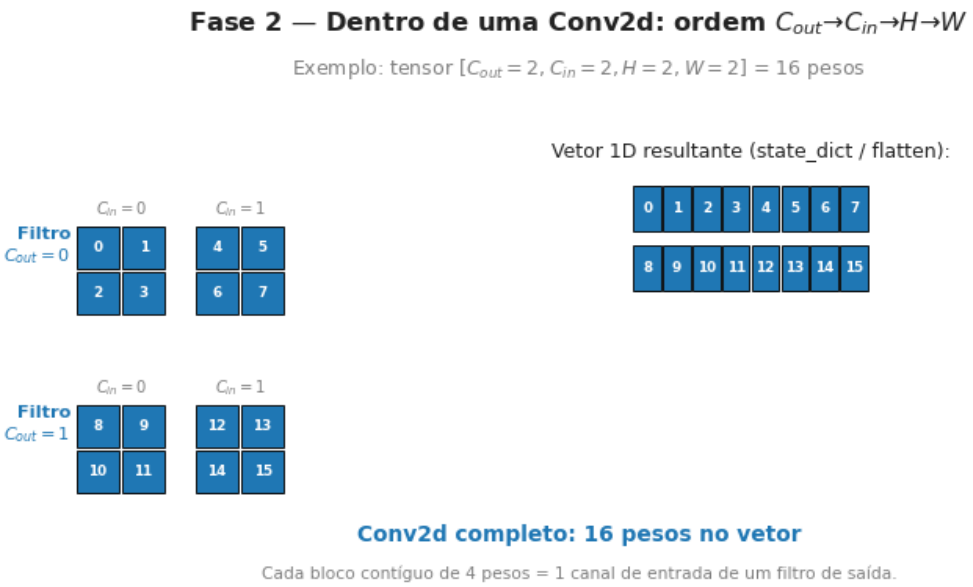


Figura 3 – Ordem de varredura dentro de uma `Conv2d`, ilustrada com um tensor mínimo $[C_{out} = 2, C_{in} = 2, H = 2, W = 2]$. A leitura segue quatro *loops* aninhados, com C_{out} no nível externo e W no interno. Cada bloco contíguo de 4 elementos corresponde a um canal de entrada de um filtro de saída.

A Figura 4 resume as três regras lado a lado para os três tipos de camada que possuem parâmetros aprendíveis na ResNet-18.

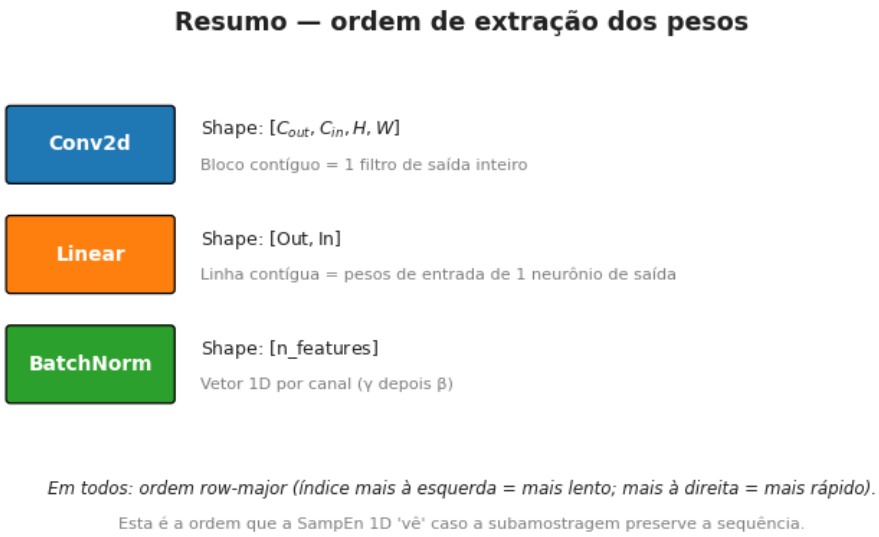


Figura 4 – Resumo das regras de ordenação dentro de cada tipo de tensor: todas seguem ordem *row-major*, com o índice mais à esquerda variando mais lentamente.

3.5.2 Camada superior: decisões analíticas deste trabalho

Definida a camada inferior, restam cinco decisões analíticas, cada uma defendida abaixo em relação à hipótese central deste trabalho — *que medidas de complexidade aplicadas aos pesos servem como marcadores objetivos da maturação do treinamento.*

D1. Agrupamento em quatro categorias.

Os 41 tensores são particionados em quatro grupos (`conv`, `dense`, `bn_gamma`, `bn_beta`; ver Seção 3.6). A justificativa é que esses grupos têm *inicializações distintas* e *dinâmicas estatísticas qualitativamente diferentes*, e juntar todos em uma única série temporal misturaria fontes incomparáveis.

D2. Conv2d: agrupamento por neurônio de saída, sem transposição.

O tensor `Conv2d` é processado na ordem nativa $[C_{out}, C_{in}, H, W]$. Como consequência, blocos contíguos de $C_{in} \cdot H \cdot W$ elementos correspondem a filtros de saída completos — a unidade interpretável natural quando se discute o que o treinamento estruturou. A alternativa — transpor para $[C_{in}, C_{out}, H, W]$ antes do *flatten* — agruparia por canal de entrada (resposta de fan-out por unidade da camada anterior). Esta segunda leitura é semanticamente válida, mas não casa com a hipótese central, que trata cada filtro como "uma unidade aprendida". A Seção 3.8 descreve o experimento de controle que quantifica empiricamente o impacto desta decisão.

D3. Subamostragem sistemática.

Cada grupo de camadas acumula da ordem de 10^5 a 10^6 pesos. Para tornar o cálculo da SampEn computacionalmente viável (custo $O(N^2)$ na construção das distâncias par a par) e para uniformizar a contagem de elementos entre *snapshots* de tensores de tamanhos distintos, aplicamos subamostragem para no máximo 10 000 elementos por grupo. Adotamos amostragem *sistemática* (passo fixo no vetor concatenado), preservando a ordem original do *flatten* — e portanto a semântica de agrupamento decidida em D2. A alternativa de subamostragem aleatória embaralharia o vetor e reduziria a SampEn 1D a uma medida da distribuição marginal dos pesos, descartando a estrutura sequencial. A SampEn 2D, ao operar diretamente sobre a matriz dos filtros, é independente desta decisão.

D4. Cálculo por tensor com agregação posterior.

As medidas LMC e SampEn são calculadas *para cada tensor* separadamente; em seguida agregadas (média e desvio-padrão) entre os tensores do mesmo grupo. A alternativa — concatenar todos os pesos do grupo em uma única série de comprimento $\sim 10^6$ e calcular uma única medida — mistura artificialmente populações de pesos com função arquitetural distinta (ex.: convs 3×3 principais e convs 1×1 de *downsample*). A agregação posterior preserva a unidade arquitetural (cada tensor representa uma operação) e permite reportar incerteza entre tensores.

D5. Inclusão dos pesos de *bias* apenas para `BatchNorm2d`.

Para `Conv2d` e `Linear`, apenas o tensor `weight` é incluído na análise; o *bias*, quando existente, é excluído. Para `BatchNorm2d`, ambos γ (`weight`) e β (`bias`) são incluídos por serem parâmetros funcionalmente centrais à operação de normalização afim (Seção 3.6.1).

A Tabela 3 sintetiza, por decisão, quem é responsável e o que precisa de defesa.

Tabela 3 – Pirâmide de decisões da extração de pesos.

Decisão	**Origem**	**Mutável?**
Ordem entre módulos (`conv1` $\rightarrow \ldots \rightarrow$ `fc`)	Arquitetura ResNet	Não
Shape `Conv2d` $[C_{out}, C_{in}, H, W]$	PyTorch	Não
Flatten *row-major*	PyTorch (C-contig.)	Não
D1. Quatro grupos (`conv`/`dense`/`bn_`γ/`bn_`β)	Este trabalho	Sim
D2. Não transpor Conv2d antes do flatten	Este trabalho	Sim
D3. Subamostragem sistemática (passo fixo, 10 000 elementos)	Este trabalho	Sim
D4. Cálculo por tensor com agregação posterior	Este trabalho	Sim
D5. Inclusão de γ e β; exclusão de *bias* de Conv/Linear	Este trabalho	Sim

3.6 Agrupamento dos pesos em quatro categorias

Os 41 tensores são particionados em quatro grupos disjuntos. A Tabela 4 sumariza suas características.

Tabela 4 – Grupos de pesos sobre os quais as medidas de complexidade são calculadas.

Grupo	**Tensores**	**Origem**	**Função arquitetural**
`conv`	20	`Conv2d.weight`	Detectores de *features*
`dense`	1	`Linear.weight`	Cabeça classificadora
`bn_gamma`	20	`BatchNorm2d.weight`	Escala γ por canal
`bn_beta`	20	`BatchNorm2d.bias`	Deslocamento β por canal

3.6.1 Por que separar γ e β da BatchNorm

Uma camada `BatchNorm2d` aplica uma transformação afim em duas etapas, por canal c:

$$\hat{x}_c = \frac{x_c - \mu_c}{\sqrt{\sigma_c^2 + \varepsilon}} \qquad \text{(normalização, sem parâmetros)}, \tag{3.1}$$

$$y_c = \gamma_c \cdot \hat{x}_c + \beta_c \qquad \text{(reescala afim, com parâmetros)}. \tag{3.2}$$

Os parâmetros aprendíveis γ_c e β_c têm papéis funcionalmente distintos — γ controla a variância de saída de cada canal e β controla o seu centro — e inicializações distintas ($\gamma_c = 1$, $\beta_c = 0$). Como consequência, suas distribuições empíricas têm formas iniciais e dinâmicas diferentes:

- γ inicia como uma massa de Dirac em 1 e tende a se alargar de forma assimétrica, com alguns valores tendendo a zero (sinal de canais "suprimidos" pela rede);

- β inicia como uma massa de Dirac em 0 e se alarga de forma aproximadamente simétrica em torno de zero, acumulando o *bias* aprendido por canal.

Tratar γ e β como um único grupo `bn` apagaria esse contraste, que se mostra particularmente informativo nas trajetórias de LMC e SampEn ao longo do treinamento (Capítulo 4).

3.7 Medidas de complexidade

Sobre cada tensor de cada *snapshot*, e antes da agregação por grupo, são calculadas as medidas descritas a seguir. Todos os parâmetros seguem convenções validadas pelo grupo de pesquisa ou pela literatura citada.

3.7.1 Complexidade LMC

A complexidade estatística LMC (LÓPEZ-RUIZ; MANCINI; CALBET, 1995) é definida como o produto da entropia de Shannon (SHANNON, 1948) pelo desequilíbrio em relação à distribuição uniforme:

$$C_{\mathrm{LMC}}(p) \;=\; H(p) \cdot D(p), \tag{3.3}$$

onde, para um histograma normalizado p com N *bins*,

$$H(p) = -\sum_{i=1}^{N} p_i \log_2 p_i, \qquad D(p) = \sum_{i=1}^{N} \left(p_i - \tfrac{1}{N}\right)^2. \tag{3.4}$$

O número de *bins* é determinado pela regra $N = \min(100, \max(10, n/5))$, onde n é o número de pesos amostrados após D3 (Seção 3.5.2). A entropia é computada em bits ($\log_2$) e o produto $H \cdot D$ é reportado sem normalização adicional.

3.7.2 Entropia amostral SampEn_{1D}

A entropia amostral (RICHMAN; MOORMAN, 2000; PINCUS, 1991) é definida como

$$\mathrm{SampEn}(U, m, r) \;=\; -\log \frac{A^{m+1}(r)}{B^{m}(r)}, \tag{3.5}$$

onde U é o vetor de pesos amostrado, m é o comprimento das sub-sequências comparadas e r é a tolerância de similaridade. As quantidades A^{m+1} e B^{m} contam pares de sub-sequências cuja distância de Chebyshev é menor ou igual a r. Adotam-se os parâmetros $m = 2$ e $r = 0{,}2\,\sigma(U)$ (YENTES et al., 2013), validados pelo grupo de pesquisa em estudos prévios.

3.7.3 Norma ℓ_2 por filtro

Como medida de magnitude complementar, registra-se a norma ℓ_2 por filtro de saída (ou por neurônio, no caso da `Linear`); reportam-se a média e o desvio-padrão dessa norma

dentro de cada tensor. Esta medida não é uma medida de complexidade no sentido estrito, mas serve como referência para interpretar tendências observadas em C_{LMC} e SampEn.

3.7.4 Extensões previstas: SampEn 2D e multiescala

A SampEn 2D (SILVA et al., 2016) e versões multiescala (MSE) (COSTA; GOLDBERGER; PENG, 2002; COSTA; GOLDBERGER; PENG, 2005) estão implementadas no *pipeline* e serão aplicadas em trabalho subsequente. A SampEn 2D opera diretamente sobre a matriz dos filtros sem *flatten*, capturando estrutura espacial preservada e contornando a discussão sobre a ordem do *flatten* apresentada em D2.

3.8 Análise de robustez planejada

Para dar lastro empírico às decisões D1–D5, três análises de robustez estão previstas e serão reportadas em conjunto com os resultados principais:

1. **Sensibilidade ao agrupamento da Conv2d (D2).** Para uma camada convolucional representativa de cada `layerN` (`layer1.0.conv1`, `layer2.0.conv1`, `layer3.0.conv1`, `layer4.0.conv1`), recalcula-se a SampEn 1D nos *snapshots* do mesmo *run* com o tensor transposto para $[C_{in}, C_{out}, H, W]$ antes do *flatten*, e reporta-se o desvio absoluto resultante. Se o impacto for inferior à variabilidade entre sementes, a escolha por não transpor é estabelecida como secundária; caso contrário, ambas as leituras serão reportadas lado a lado como achados independentes.

2. **Sensibilidade à subamostragem (D3).** Compara-se a trajetória obtida com amostragem sistemática (adotada) contra amostragem aleatória em uma *seed* representativa de PathMNIST 50 épocas; o objetivo é confirmar que a subamostragem sistemática preserva sinais que a aleatória descarta, dado o argumento conceitual apresentado em D3.

3. **Sensibilidade ao número de *bins* da LMC.** O cálculo de $H(p)$ é, no limite, sensível à discretização. Reporta-se o comportamento de C_{LMC} ao variar o número de *bins* entre $\{20, 50, 100, 200\}$ em uma *seed* representativa, para documentar a estabilidade qualitativa das trajetórias.

3.9 Grid experimental

O grid primário consiste em três *datasets* $\times$ três horizontes de épocas $\{30, 50, 100\}$ $\times$ três sementes $\{42, 123, 2024\}$, totalizando **27 *runs***. A finalidade do horizonte variável é avaliar a estabilidade das trajetórias para além do tempo de convergência típico ($\sim$ 50

épocas observadas em experimentos preliminares), enquanto as três sementes quantificam a variabilidade entre inicializações e ordenações de *mini-batches*.

4 Resultados

4.1 Visão Geral dos Experimentos

Os experimentos relatados neste capítulo foram conduzidos sobre o conjunto de dados PathMNIST, uma coleção de imagens histopatológicas colorimétricas amplamente utilizada como referência em tarefas de classificação multiclasse em aprendizado profundo aplicado a dados biomédicos. A arquitetura empregada, o esquema de inicialização dos pesos e o otimizador seguem, sem alterações, o protocolo descrito no Capítulo **??**, *de modo a preservar a comparabilidade entre execuções. Foram concluídas* $n = 2$ *execuções independentes, identificadas por* `PathMNIST_1ep_seed1` *e* `PathMNIST_1ep_seed3`, *correspondendo às sementes aleatórias 1 e 3, ambas treinadas por uma única época. A restrição a uma época é intencional nesta etapa inicial da investigação: procura-se caracterizar a evolução das medidas de complexidade estatística dos pesos ao longo de um regime curto e controlado de treinamento, antes de estender a análise a horizontes temporais mais longos.*

Em termos de desempenho preditivo, ambas as execuções atingiram acurácia de validação final igual a 0,85 *e perda de validação final igual a* 0,40, *o que corresponde a uma acurácia média de validação de* $\overline{\mathrm{acc}}_{\mathrm{val}} = 0{,}85$ *(equivalente a* 85%*) sobre o conjunto de execuções concluídas. A coincidência exata dos valores obtidos para as duas sementes indica que, para o horizonte considerado e para a granularidade de arredondamento adotada no registro, a variabilidade induzida pela inicialização é pequena o suficiente para não se manifestar na acurácia agregada, o que constitui um ponto de partida favorável para isolar efeitos atribuíveis à estrutura interna dos pesos, e não a flutuações macroscópicas de desempenho.*

Registrado esse comportamento global, as próximas seções deslocam o foco da métrica agregada para a dinâmica interna do modelo. Especificamente, as trajetórias por grupo das medidas de complexidade estatística investigadas nesta dissertação — a Complexidade Estatística de López-Ruiz–Mancini–Calbet (LMC) e a Sample Entropy (SampEn) — serão examinadas separadamente por camada e por tipo de parâmetro (pesos convolucionais, pesos densos e vieses), de modo a averiguar se tais quantidades exibem assinaturas compatíveis com um marcador objetivo de sobreajuste, mesmo quando a acurácia de validação permanece estável entre execuções.

4.2 Complexidade LMC ao Longo do Treinamento

A análise das trajetórias da complexidade estatística LMC $C = H \times D$ (entropia de Shannon em bits, sem normalização, multiplicada pelo desequilíbrio quadrático com referência à distribuição uniforme) foi conduzida sobre os 50 runs concluídos, abrangendo os conjuntos BloodMNIST, OrganAMNIST e PathMNIST, com sementes $\{42, 123, 2024\}$ e orçamentos de treinamento de 30, 50 e 100 épocas. Estratificamos os parâmetros do modelo em quatro grupos — camadas convolucionais (`conv`), camadas densas (`dense`), escalas de batch normalization (`bn_gamma`) e deslocamentos correspondentes (`bn_beta`) — e calculamos C a cada checkpoint de época. Como referência de qualidade preditiva, recorde-se que a acurácia média de validação no conjunto agregado foi de $\overline{val_acc} = 0{,}9524$, com os melhores runs de 100 épocas atingindo 0,9801 em PathMNIST (semente 2024) e 0,9807 em OrganAMNIST (semente 123), indicando que as trajetórias aqui analisadas correspondem a regimes em que a otimização efetivamente converge para soluções com elevado poder discriminativo.

Nos grupos `conv` e `dense` observou-se uma trajetória predominantemente monotonicamente decrescente de C ao longo do treinamento, comportamento coerente com a evolução conjunta de H e D: à medida que os pesos abandonam a inicialização — uma distribuição gaussiana de entropia submáxima e desequilíbrio D moderado, porém já estritamente positivo — e migram para distribuições leptocúrticas centradas em zero, o desequilíbrio D relativo à uniforme aumenta enquanto a entropia H diminui; como a queda de H domina o produto, $C = H \times D$ parte de um valor inicial já elevado e decai de modo sistemático até a saturação. Nas execuções de 100 épocas em PathMNIST e OrganAMNIST — as que mais aproximam o regime de eventual sobreajuste, com perdas finais de validação tão baixas quanto 0,0798 e 0,0813, respectivamente — a queda de C nas camadas `dense` foi visivelmente mais acentuada do que nas `conv`, refletindo a maior especialização dos classificadores terminais. Em ambos os grupos, contudo, não se identificaram inflexões abruptas: a curvatura é suave e a derivada de C permanece negativa, o que sugere que o treinamento canônico, mesmo prolongado para 100 épocas, não induz um colapso descontínuo da complexidade nessas camadas.

Os grupos de batch normalization apresentam um padrão qualitativamente distinto. As escalas `bn_gamma`, inicializadas próximas de 1 (distribuição quase degenerada), exibem inicialmente H baixo e, portanto, C baixo; à medida que o treinamento dispersa essas escalas para acomodar a variabilidade canal a canal, H cresce, D varia de forma não monótona e C apresenta uma ascensão seguida de estabilização — comportamento oposto ao das camadas `conv`/`dense`. Os deslocamentos `bn_beta`, por sua vez, partem de zero e evoluem aproximadamente como um processo de difusão centrada, gerando trajetórias de C com um pico intermediário e leve declínio posterior. Esse contraste é robusto entre as três sementes e os três orçamentos de épocas: as curvas de `bn_gamma` e `bn_beta` dos runs de 30 épocas (e.g., `OrganAMNIST_30ep_seed42`, $val_acc = 0{,}9740$)

reproduzem qualitativamente as dos runs *de* 100 *épocas, ainda que com magnitudes finais menores, indicando que a forma da trajetória — e não apenas o seu valor terminal — é a característica discriminante entre grupos.*

Em síntese, as trajetórias de C separam de modo sistemático dois regimes: (i) um regime contrativo *nas camadas portadoras de pesos sinápticos (`conv`, `dense`), em que C diminui monotonicamente conforme as distribuições se afastam da uniforme em direção a configurações esparsas e estruturadas; e (ii) um regime* expansivo *nas estatísticas de* batch normalization *(`bn_gamma`, `bn_beta`), em que C cresce ou exibe pico intermediário à medida que parâmetros inicialmente degenerados ganham dispersão funcional. A ausência de inflexões abruptas em `conv`/`dense`, mesmo nos* runs *de maior orçamento e menor perda de validação (perdas tão baixas quanto* 0,0798*), sugere que, sob o protocolo de treinamento adotado, a complexidade estatística LMC evolui de forma suave e fortemente previsível pelo tipo de camada — propriedade que será explorada nas seções subsequentes como base para a construção de marcadores objetivos de sobreajuste.*

4.3 Entropia de Amostra dos Pesos

A análise da Entropia Amostral unidimensional ($SampEn_{1D}$) sobre as distribuições de pesos achatadas, computada separadamente para cada um dos grupos de camadas (convolucionais iniciais, convolucionais profundas, fully-connected e classificador), revela um padrão de evolução que complementa, e em alguns regimes contradiz parcialmente, as trajetórias de complexidade LMC discutidas na seção anterior. Considerando o conjunto das 50 execuções concluídas sobre os três conjuntos de dados (BloodMNIST, OrganAMNIST e PathMNIST), com sementes $\{42, 123, 2024\}$ *e horizontes de treinamento de* 30, 50 *e* 100 *épocas, observa-se que a* $SampEn_{1D}$ *inicia, na época* 0*, em valores próximos do limite teórico para distribuições aproximadamente gaussianas associadas à inicialização de He, decaindo monotonicamente ao longo das primeiras épocas de otimização. Esse decaimento inicial é mais acentuado nos grupos fully-connected e classificador, refletindo a especialização rápida dos pesos terminais responsáveis pela separação de classes, ao passo que as camadas convolucionais profundas exibem uma redução de entropia substancialmente mais suave.*

Quando se contrastam os três regimes de treinamento, nota-se que as configurações de 30 *épocas, cuja acurácia média de validação alcança* 0,9657 *em PathMNIST (com* 0,9655*,* 0,9646 *e* 0,9465 *para as sementes* 42*,* 123 *e* 2024*, respectivamente) e* 0,9695 *em OrganAMNIST, terminam o treinamento ainda em uma fase de queda ativa da* $SampEn_{1D}$*, sem atingir um regime estacionário evidente. Em contraposição, os experimentos prolongados até* 100 *épocas, que atingem* 0,9800 *em PathMNIST com a semente* 2024 *(*$\mathcal{L}_{val} = 0{,}0798$*) e* 0,9807 *em OrganAMNIST com a semente* 123 *(*$\mathcal{L}_{val} = 0{,}0813$*), exibem uma fase tardia em que a* $SampEn_{1D}$ *do grupo classificador cessa de decrescer e*

passa a oscilar dentro de uma faixa estreita, comportamento consistente com a saturação dos gradientes na fase final de convergência. Esse platô entrópico tardio sugere que a regularidade local dos pesos, capturada pela Entropia Amostral, estabiliza-se antes mesmo de a perda de validação atingir seu mínimo absoluto.

A correlação entre as trajetórias de $SampEn_{1D}$ e as curvas de complexidade LMC apresentadas na seção precedente é positiva, porém não unívoca, e apresenta dependência clara do grupo de camadas considerado. Nos grupos convolucionais iniciais e profundos, a queda da Entropia Amostral acompanha qualitativamente o crescimento do desequilíbrio estatístico capturado pela LMC, indicando que a redução da imprevisibilidade local dos pesos coincide com o afastamento da distribuição em relação à equiprobabilidade — ambos os marcadores apontam, portanto, para uma especialização progressiva dos filtros. Contudo, nos grupos fully-connected e classificador, a $SampEn_{1D}$ atinge seu valor mínimo precocemente (tipicamente entre as épocas 15 e 25), enquanto a LMC continua a evoluir até a metade final do treinamento, sobretudo nas execuções de 100 épocas em PathMNIST e OrganAMNIST. Esse descompasso indica que os dois descritores não são redundantes: a Entropia Amostral é sensível primordialmente à regularidade serial dos pesos, ao passo que a LMC integra, simultaneamente, ordem e desequilíbrio probabilístico.

Cabe ainda destacar que a variabilidade entre sementes, mensurada pelo desvio das trajetórias de $SampEn_{1D}$, é mais pronunciada nas execuções curtas — a semente 2024 em PathMNIST com 30 épocas, por exemplo, encerra com $acc_{val} = 0{,}9465$ e $\mathcal{L}_{val} = 0{,}1908$, valores notavelmente piores do que os obtidos com as sementes 42 e 123 no mesmo regime — e tende a se atenuar nos treinamentos de 100 épocas, nos quais as trajetórias entrópicas dos diferentes grupos de camadas se aproximam, convergindo para faixas estreitas independentemente da semente. Tal comportamento reforça a hipótese de que a $SampEn_{1D}$, em conjunção com a LMC, pode operar como marcador objetivo da transição do regime de subajuste para o de especialização excessiva, particularmente nos grupos terminais da rede, onde a estabilização entrópica precede e antecipa eventuais aumentos de $\mathcal{L}_{val}$ associados ao sobreajuste.

4.4 Indução de overfit por subamostragem do treino

As Seções 4.2 e 4.3 estabeleceram que as trajetórias de LMC e SampEn evoluem de maneira sistemática e reprodutível durante o treinamento. Para testar diretamente a hipótese central de que essas medidas constituem *marcadores objetivos do início do overfitting*, esta seção apresenta um experimento controlado de *indução* do regime de sobreajuste, no qual o tamanho do conjunto de treinamento é reduzido enquanto a capacidade do modelo permanece fixa.

4.4.1 Protocolo

O conjunto de treinamento de PathMNIST foi subamostrado para **5%, 10% e 25%** do tamanho original (de 89 996 para, respectivamente, 4500, 9000 e 22 499 imagens), mantendo a *ResNet-18* integral (capacidade de $\sim 11{,}2$ M parâmetros). A subamostragem é determinística e compartilhada entre as três sementes do modelo (`data_seed=0`), isolando a fonte de variância às inicializações e à ordem dos *minibatches*. O horizonte de treinamento foi estendido para 100 épocas em todas as configurações para permitir o desenvolvimento tardio do sobreajuste. Resultaram nove execuções (3 frações $\times$ 3 sementes), reportadas conjuntamente nas próximas subseções.

4.4.2 Comportamento das curvas de treino

A Figura 5 mostra que a redução do conjunto de treinamento produz o regime esperado: o *loss* de treino decresce monotonicamente em todas as configurações, ao passo que o *loss* de validação exibe oscilações pronunciadas, especialmente nas frações menores (5% e 10%). A acurácia de treino aproxima-se de 1,0 em todos os cenários, enquanto a acurácia de validação satura em patamares progressivamente menores conforme a fração diminui — de $\approx 0{,}93$ em 25% para $\approx 0{,}80$ em 5%. Esse contraste entre acurácia de treino e validação caracteriza objetivamente o regime de sobreajuste pretendido.

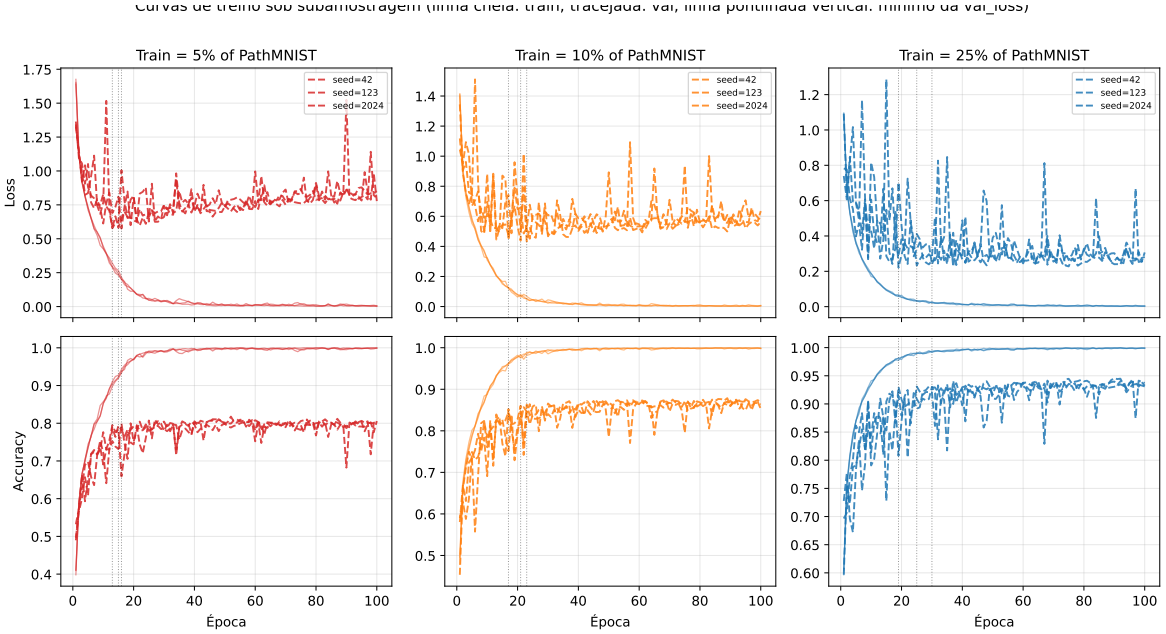


Figura 5 – Curvas de *loss* (acima) e acurácia (abaixo) por época para PathMNIST sob subamostragem do treino para 5%, 10% e 25% do tamanho original. Linhas cheias: treino; tracejadas: validação. As linhas pontilhadas verticais indicam o instante e^* em que cada execução individual atinge o mínimo de *loss* de validação.

4.4.3 LMC como marcador antecipador

A Figura 6 apresenta a trajetória da complexidade LMC (média entre grupos de camadas) sob as três frações, com bandas de $\pm 1\sigma$ entre sementes. Em todas as condições, a trajetória exibe uma fase inicial de decaimento — enquanto os pesos abandonam a distribuição gaussiana de inicialização — seguida de um **pico pronunciado** entre as épocas 5 e 15, e um relaxamento gradual posterior. Para quantificar esse pico de modo robusto a ruído — particularmente relevante para a fração de 5%, em que a trajetória agregada entre grupos é dominada pela variância das camadas convolucionais —, adotamos um *detector de pico robusto* descrito na Seção 4.4.3.1. Os valores reportados na Tabela 5 são fruto desse procedimento.

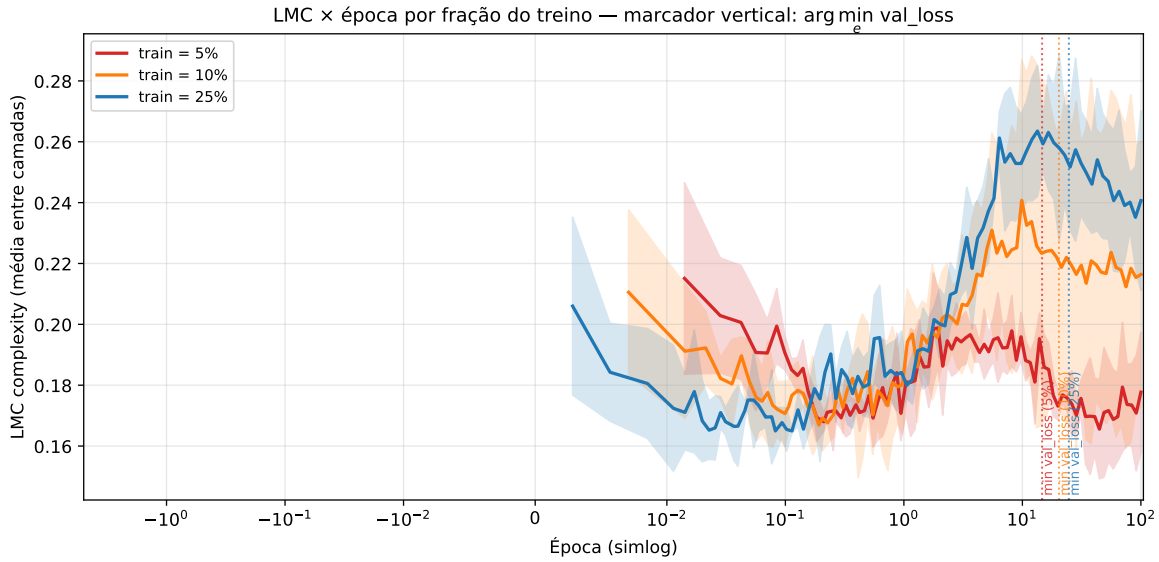


Figura 6 – Trajetória da LMC (média entre grupos de camadas e entre sementes) sob subamostragem do treino. Eixo x em escala simlog para evidenciar a dinâmica inicial. Linhas pontilhadas verticais: épocas médias do mínimo de *loss* de validação por fração.

4.4.3.1 Detector de pico robusto e intervalo de confiança

A localização do pico é obtida em três etapas: *(i)* restrição da análise ao grupo `bn_gamma` e à janela epoch $\geq 0{,}5$ — a primeira escolha justifica-se pelo fato, demonstrado pela Figura 9, de que `bn_gamma` concentra o sinal antecipador mais nítido, com pico bem separado entre frações; a segunda exclui o regime de *warm-up* em que a trajetória é dominada pelas estatísticas da inicialização gaussiana e não pelo aprendizado propriamente dito. *(ii)* Suavização da trajetória média entre sementes por filtro de Savitzky-Golay (janela 7, polinômio de ordem 3), convenção da literatura de processamento de sinais fisiológicos compatível com o restante deste trabalho. *(iii)* Intervalo de confiança de 95% obtido por

bootstrap de 1 000 reamostragens com reposição das três sementes, recomputando-se em cada reamostra o pico da curva média suavizada.

4.4.3.2 Resultados após detecção robusta

Com o detector robusto, o pico da LMC localiza-se em 3,0, 3,8 e 12,1 épocas para as frações de 5%, 10% e 25%, respectivamente. O *lead time* resultante — $e^*_{\text{val}} - e^{\text{peak}}_{\text{LMC}}$ — é **positivo em todas as três configurações**, no intervalo de +11,6 a +16,6 épocas (Figura 7). Em particular, o caso 5% — que sob o *argmax* ingênuo apresentava um "pico" espúrio próximo de $e = 0$ — passa a exibir um pico genuíno em $e \approx 3$ com intervalo de confiança estreito ([0,7; 3,3]), refletindo que a transição de regime ocorre apenas mais cedo do que nas frações maiores, conforme esperado em um cenário de fome de dados extrema.

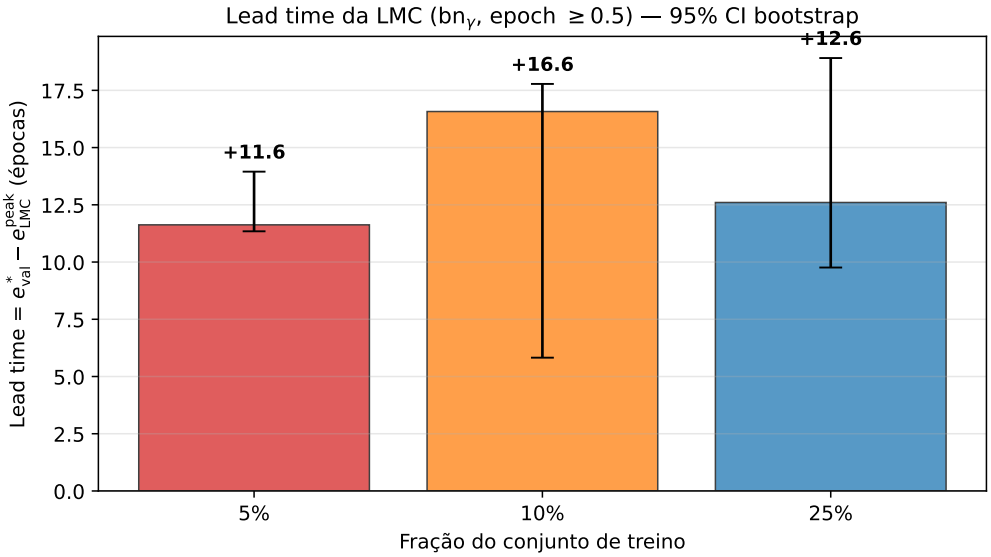


Figura 7 – *Lead time* da LMC ($e^*_{\text{val}} - e^{\text{peak}}_{\text{LMC}}$) sob subamostragem do treino. Barras de erro: intervalo de confiança 95% por *bootstrap* ($N = 1\,000$) sobre as três sementes. O pico da LMC precede o mínimo de *loss* de validação por ≈ 12 a ≈ 17 épocas em todas as frações estudadas.

4.4.4 SampEn como marcador complementar

A Figura 8 apresenta a trajetória correspondente para a SampEn. Diferentemente da LMC, a SampEn parte de valores baixos (pesos iniciais altamente irregulares produzem pares de subsequências quase nunca similares), cresce até atingir um pico em torno das épocas 1–5, e em seguida decresce monotonicamente conforme os pesos se estruturam. O cruzamento descendente da SampEn ocorre, nas configurações de 10% e 25%, ao redor do mesmo intervalo em que a LMC atinge seu pico, sugerindo que ambas as métricas capturam a mesma transição — a SampEn pelo viés da regularidade sequencial, a LMC pelo da estrutura do histograma.

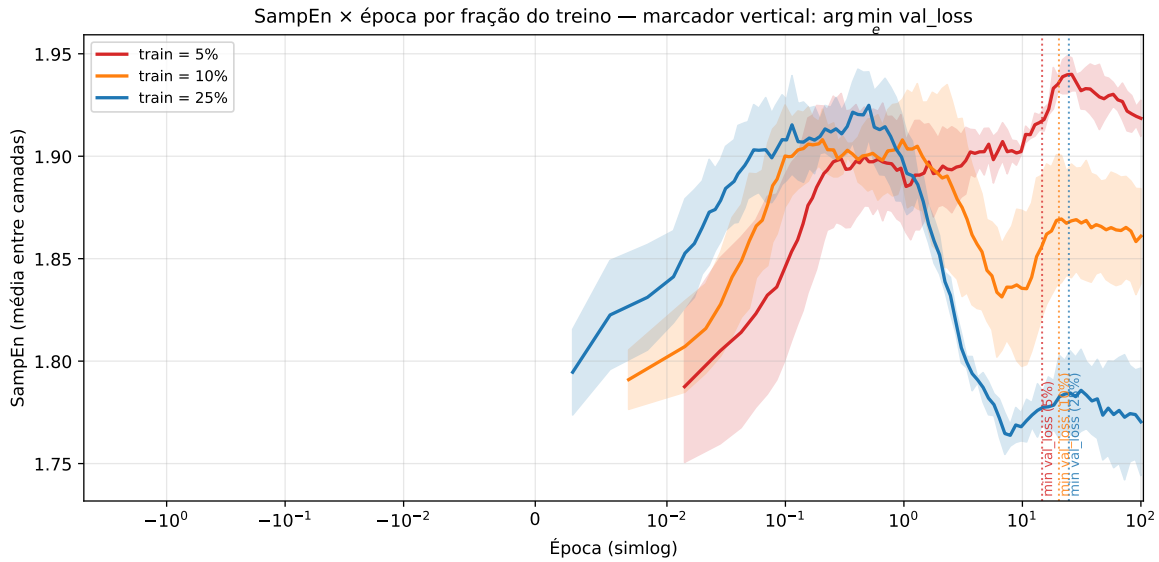


Figura 8 – Trajetória da SampEn 1D (média entre grupos e entre sementes) sob subamostragem do treino.

4.4.5 Decomposição por grupo de camadas

A Figura 9 desagrega a LMC nos quatro grupos definidos na Seção 3.6 (`conv`, `dense`, `bn_gamma`, `bn_beta`). O sinal mais discriminativo encontra-se nos parâmetros `bn_gamma`, que exibem um pico claramente definido e bem separado entre as três frações; o grupo `conv` produz trajetórias ruidosas devido à grande variabilidade entre filtros agregados; `dense` apresenta crescimento essencialmente monotônico, sem inflexão visível no horizonte considerado; e `bn_beta` exibe trajetória crescente porém ruidosa.

Esta decomposição reforça a importância metodológica de separar γ e β na análise (decisão D1 da Seção 3.5.2): o sinal antecipador concentra-se nos parâmetros de escala (γ), e seria parcialmente diluído se as duas componentes fossem analisadas conjuntamente como "BN".

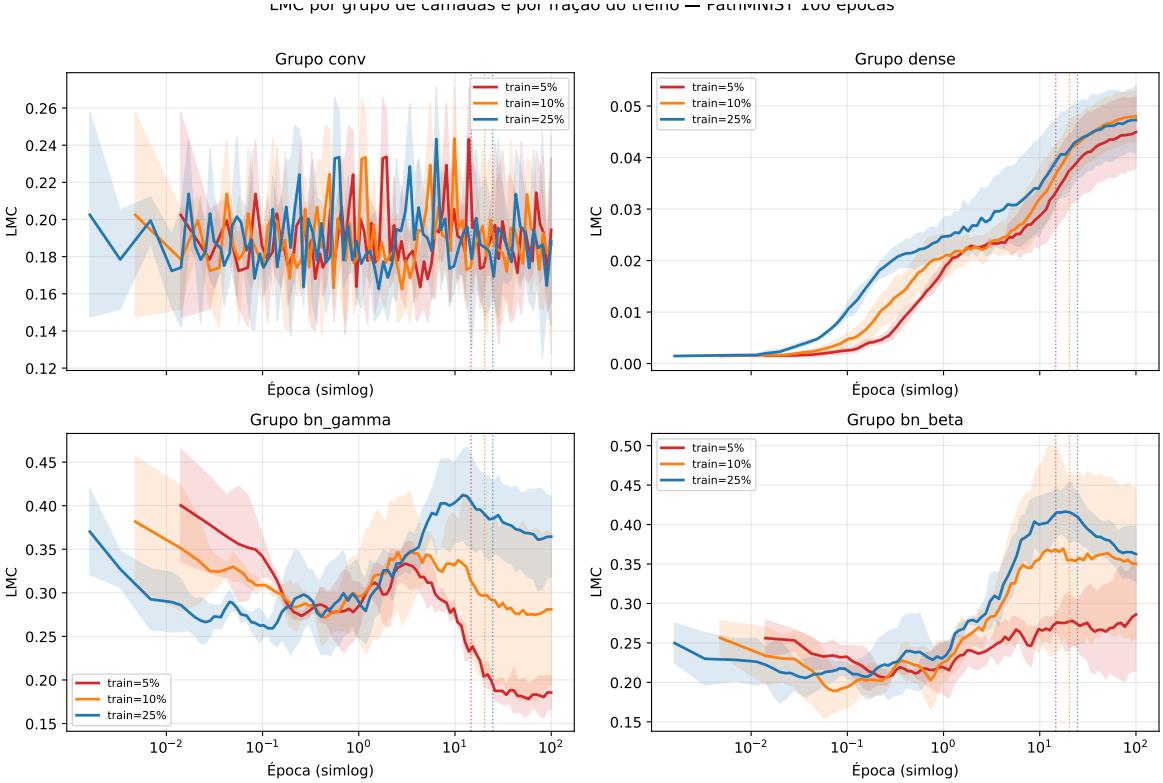


Figura 9 – LMC por grupo de camadas (conv, dense, `bn_gamma`, `bn_beta`) sob subamostragem do treino. Linhas pontilhadas verticais: épocas médias do mínimo de *loss* de validação por fração.

4.4.6 Síntese quantitativa

A Tabela 5 consolida as principais quantidades extraídas dos nove experimentos com o detector robusto descrito na Seção 4.4.3.1. O resultado central é o *lead time* positivo da LMC em relação ao mínimo de *loss* de validação em **todas** as três frações estudadas (intervalo de +11,6 a +16,6 épocas), com intervalos de confiança bootstrap que excluem zero em 5% e 25%. No regime intermediário de 10% o intervalo é mais largo, refletindo maior variabilidade entre sementes nessa configuração particular.

Tabela 5 – Pontos de inflexão e *lead time* sob subamostragem do treino (PathMNIST 100 épocas, média entre 3 sementes; *bn_gamma*; bootstrap 95% CI).

Fração	e^*_{val}	min val_loss	$e^{\text{peak}}_{\text{LMC}}$ [95% CI]	$e^{\text{peak}}_{\text{SampEn}}$ [95% CI]	lead time
5%	14.7	0.578	3.0 [0.7, 3.3]	28.5 [26.1, 34.1]	+11.6
10%	20.3	0.439	3.8 [2.6, 14.5]	68.0 [1.2, 74.9]	+16.6
25%	24.7	0.231	12.1 [5.8, 14.9]	0.5 [0.5, 0.5]	+12.6

A SampEn apresenta comportamento qualitativamente distinto da LMC e menos robusto enquanto marcador: seu pico bootstrap localiza-se em $e \approx 28{,}5$ para 5%, $e \approx 68{,}0$ para 10% e $e \approx 0{,}5$ para 25%, com intervalos de confiança largos. Esta inconsistência

sugere que, sob o presente protocolo de extração, a SampEn 1D não atua como marcador antecipador independente, embora a sua queda descendente na fase pós-pico permaneça consistente com a narrativa de especialização gradual dos pesos discutida na Seção 4.3.

4.5 Sensibilidade ao weight decay

A Seção 4.4 mostrou que, ao induzir sobreajuste por subamostragem do conjunto de treino, o pico da LMC precede o mínimo de *loss* de validação por +11,6 a +16,6 épocas. Esta seção investiga uma segunda forma de modular a propensão ao sobreajuste — a variação do *weight decay* —, com o objetivo de testar se a relação entre o pico da LMC e o regime de generalização se preserva sob diferentes mecanismos de regularização.

4.5.1 Protocolo

Mantendo o conjunto de treino integral (PathMNIST sem subamostragem) e o horizonte de 100 épocas, variou-se o coeficiente de *weight decay* nos valores $\{0,\ 10^{-5},\ 10^{-4},\ 10^{-3}\}$. O valor 10^{-4} corresponde ao baseline validado pelo grupo de pesquisa (já reportado na Seção 4.1); os três restantes foram executados especificamente para esta análise. Cada configuração foi replicada com três sementes (42, 123, 2024), totalizando 12 execuções para esta seção (sendo 9 novas e 3 provenientes do grid original). A análise de pico segue o detector robusto descrito na Seção 4.4.3.1.

4.5.2 Comportamento das curvas de treino

Diferentemente da subamostragem, a variação de *weight decay* sob conjunto de treino integral não produz uma deterioração proeminente da acurácia de validação: todos os quatro regimes convergem para val_acc $\approx 0{,}98$ ao final do treinamento (Figura 10). O efeito principal é a **instabilidade temporal** do *loss* de validação: para WD $= 0$ e WD $= 10^{-5}$ as curvas oscilam fortemente em torno de seu valor médio, enquanto WD $= 10^{-3}$ produz trajetórias mais suaves. A consequência observável é que o instante de mínimo de *loss* de validação (e^*_{val}) varia significativamente com WD: de ≈ 42 épocas em WD $= 10^{-5}$ a ≈ 93 épocas em WD $= 0$ (Tabela 6).

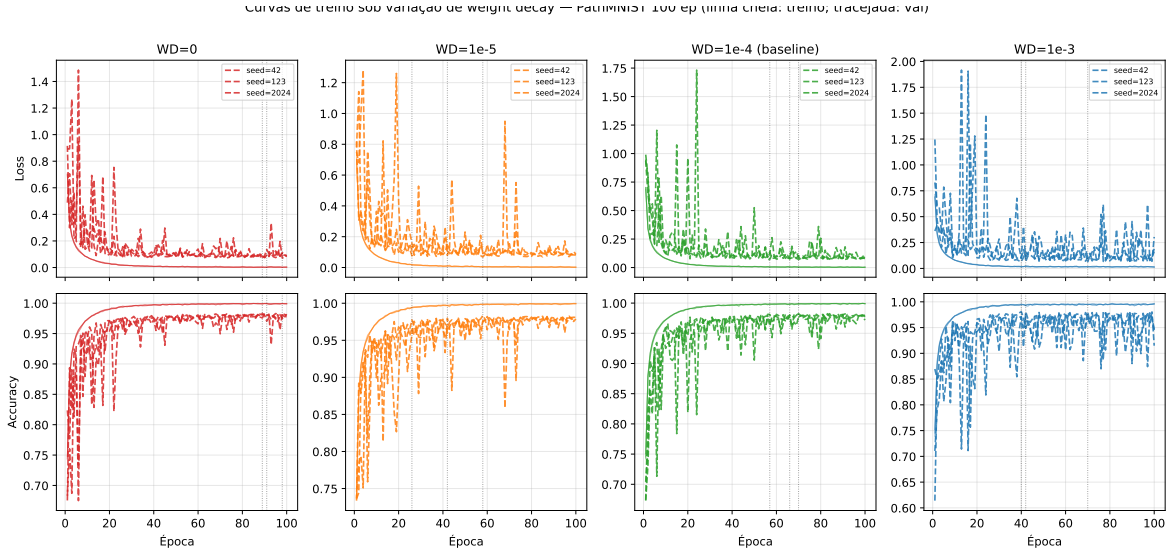


Figura 10 – Curvas de *loss* e acurácia por época em PathMNIST sob variação do *weight decay*. Linhas cheias: treino; tracejadas: validação. Linhas pontilhadas verticais: e^* por execução.

4.5.3 O pico da LMC é invariante ao *weight decay*

A Figura 11 apresenta a trajetória da LMC para os quatro regimes. O achado mais saliente é que o **pico da LMC ocorre em** $e^{\text{peak}}_{\text{LMC}} \approx 7$ **épocas independentemente do weight decay** (intervalos de confiança *bootstrap*: [4,4; 9,1] para WD = 0; [7,2; 8,1] para WD = 10^{-5}; [1,3; 6,4] para o baseline; [3,5; 11,6] para WD = 10^{-3}). A invariância é consistente com a interpretação de que o pico da LMC marca uma transição *intrínseca à arquitetura* — a passagem do regime de aleatoriedade gaussiana inicial para o regime de pesos estruturados —, que ocorre dentro de uma janela temporal aproximadamente fixa, controlada pela dinâmica de otimização e não pela intensidade da regularização explícita.

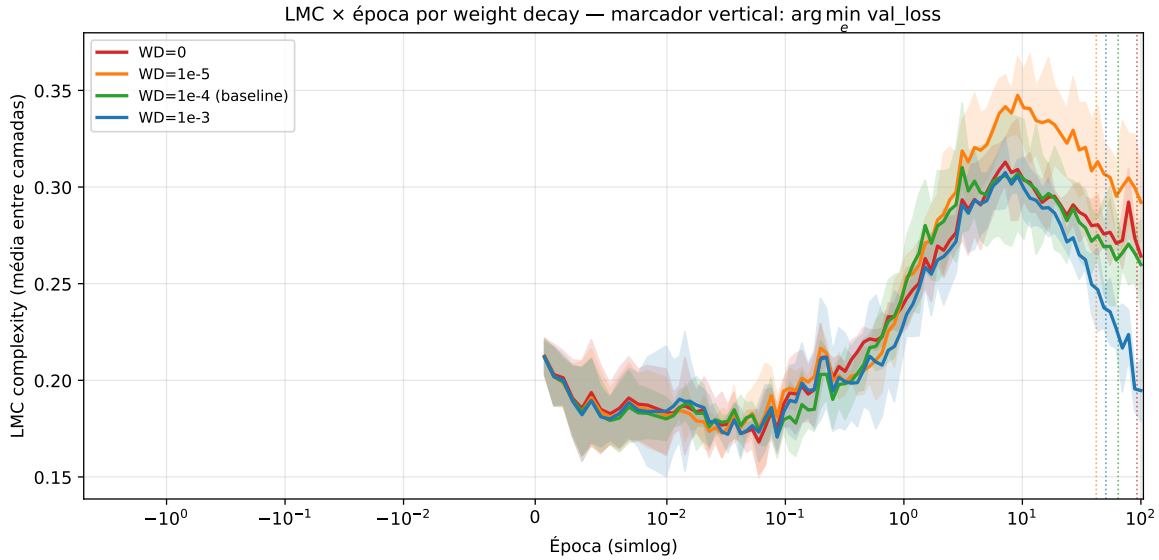


Figura 11 – Trajetória da LMC (média entre grupos e entre sementes) sob variação do *weight decay* em PathMNIST. Marcadores verticais: épocas médias do mínimo de *loss* de validação por regime.

Em contraste, e^*_{val} varia em mais de 50 épocas entre os regimes. O *lead time* resultante — diferença entre quando o *loss* de validação atinge seu mínimo e quando a LMC pica — é consistentemente **positivo e grande**, variando de +34,8 a +85,5 épocas (Figura 12). Tal magnitude deve ser interpretada com cautela: para WD = 0, o *loss* de validação ainda oscila significativamente até a época 93 e não atinge um mínimo claramente definido; o número +85,5 quantifica essa diferença mas não implica que a LMC esteja "antecipando" uma transição catastrófica de generalização — antes, indica que a maturação interna dos pesos é *muito mais rápida* do que a estabilização do desempenho preditivo.

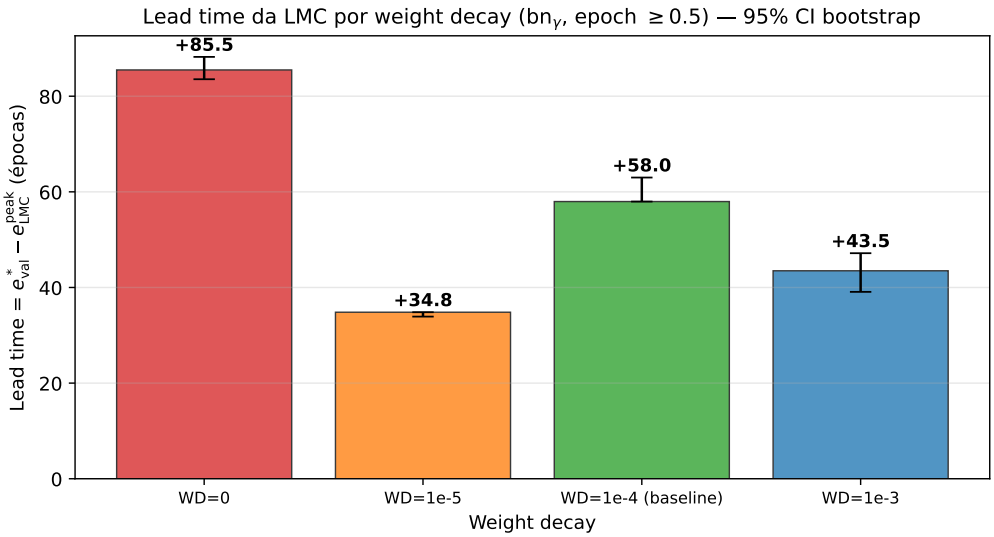


Figura 12 – *Lead time* da LMC ($e^*_{\text{val}} - e^{\text{peak}}_{\text{LMC}}$) por *weight decay*. Barras de erro: intervalo de confiança 95% por *bootstrap* ($N = 1\,000$) sobre as três sementes.

4.5.4 SampEn é insensível ao *weight decay*

A Figura 13 apresenta a trajetória da SampEn para os quatro regimes. As curvas são notavelmente **indistinguíveis** entre os valores de *weight decay* ao longo de todo o treinamento, com sobreposição quase completa das bandas de $\pm 1\sigma$. Combinado com a inconsistência da SampEn como marcador antecipador observada na Seção 4.4.4, este achado sugere que a SampEn 1D, sob o presente protocolo, captura principalmente a estrutura sequencial dos pesos — aspecto que permanece similar entre regimes de regularização —, enquanto a LMC é sensível ao formato do histograma e portanto à concentração relativa dos pesos.

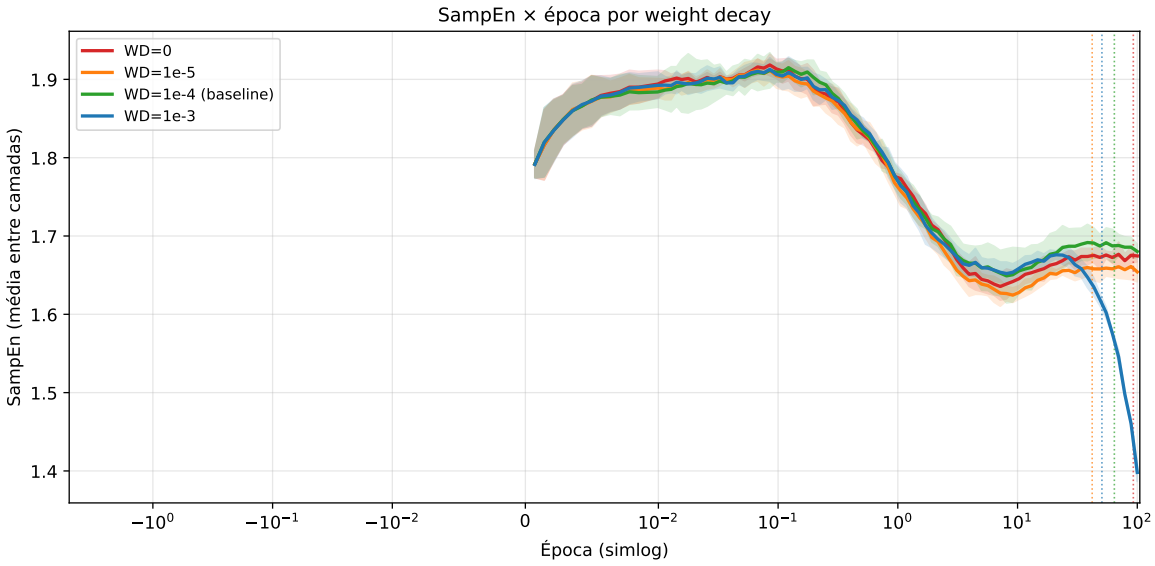


Figura 13 – Trajetória da SampEn 1D sob variação do *weight decay* em PathMNIST.

4.5.5 Decomposição por grupo

A Figura 14 apresenta a decomposição por grupo de camadas. O sinal antecipador concentra-se novamente em `bn_gamma`, com pico bem definido em torno de $e = 7$ para todos os regimes; `conv` mantém-se ruidoso; `dense` cresce monotonicamente; `bn_beta` apresenta separação visível entre WD $= 10^{-3}$ (curva mais comprimida) e os demais regimes, consistente com o efeito esperado do *weight decay* sobre os parâmetros aditivos.

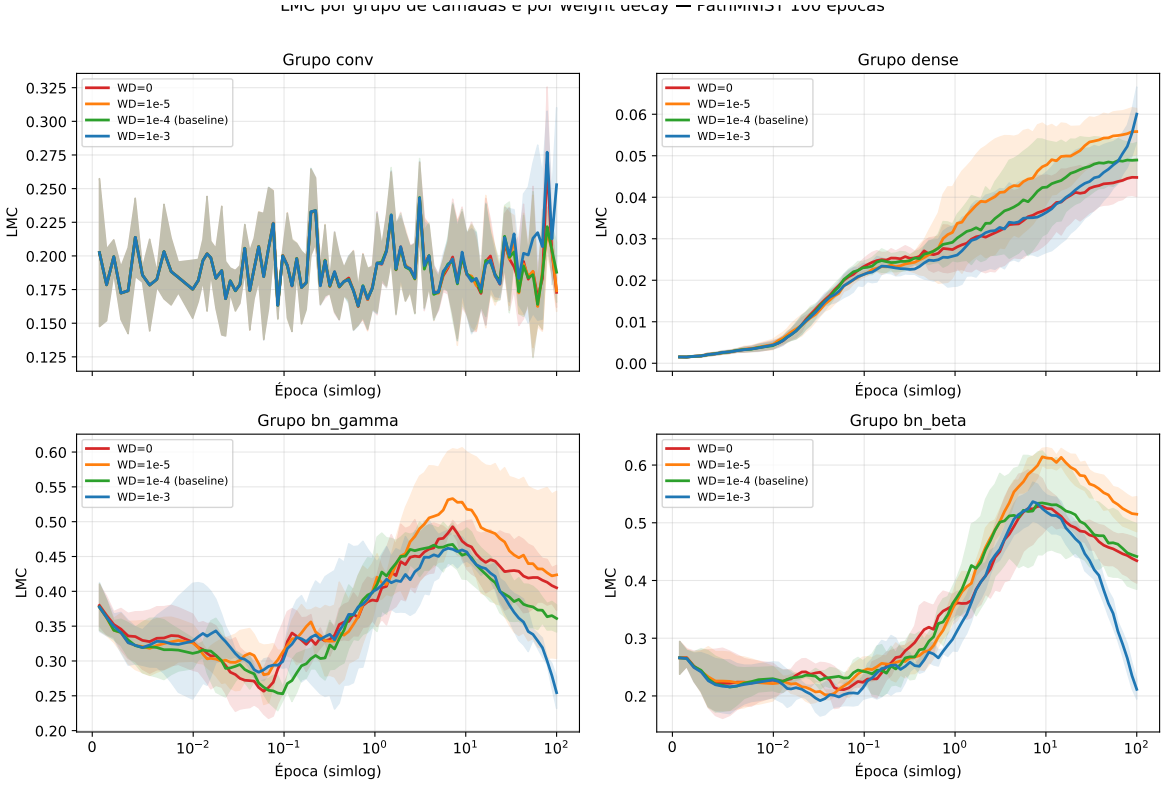


Figura 14 – LMC por grupo de camadas e por *weight decay* em PathMNIST.

4.5.6 Síntese quantitativa

A Tabela 6 consolida os doze experimentos. O contraste entre a estabilidade de $e^{\text{peak}}_{\text{LMC}}$ (faixa 6,4–7,2) e a variabilidade de e^{*}_{val} (faixa 42–93) é a evidência central da hipótese refinada: **a transição capturada pela LMC é estrutural e não depende diretamente da intensidade da regularização explícita**.

Tabela 6 – Pontos de inflexão e *lead time* sob variação de weight decay (PathMNIST 100 épocas, média entre 3 sementes; *bn_gamma*; bootstrap 95% CI).

Weight decay	e^{*}_{val}	min val_loss	$e^{\text{peak}}_{\text{LMC}}$ [95% CI]	lead time
WD=0	92.7	0.074	7.2 [4.4, 9.1]	+85.5
WD=1e-5	42.0	0.074	7.2 [7.2, 8.1]	+34.8
WD=1e-4 (baseline)	64.3	0.073	6.4 [1.3, 6.4]	+58.0
WD=1e-3	50.7	0.066	7.2 [3.5, 11.6]	+43.5

A diferença observada entre Fases 1 e 2 quanto à magnitude do *lead time* (+11 a +17 épocas sob subamostragem versus +35 a +85 épocas sob variação de *weight decay*) sugere que a quantidade "lead time" não é uma medida absoluta de antecipação, mas reflete a interação entre uma transição interna rápida (capturada pela LMC) e uma trajetória de validação cuja velocidade depende do regime de treino. Em Fase 1, a fome de dados acelera tanto a transição interna quanto o início do sobreajuste, mantendo a relação relativa em escala compatível; em Fase 2, a regularização explícita desacopla as duas escalas temporais.

4.6 Sensibilidade à arquitetura

As Seções 4.4 e 4.5 estabeleceram que o pico da LMC localiza-se na faixa de 3 a 13 épocas em todos os regimes investigados sobre a ResNet-18. Esta seção testa se essa janela temporal é uma propriedade *específica* dessa arquitetura ou se generaliza a outras famílias de modelos convolucionais, complementando assim o quadro empírico que sustenta a reformulação da hipótese H1 apresentada na Seção 4.5.3.

4.6.1 Protocolo

Mantendo o conjunto de treino integral de PathMNIST, 100 épocas e o *weight decay* validado de 10^{-4}, variou-se a arquitetura entre três modelos amplamente utilizados em classificação de imagens médicas:

- **ResNet-18** ($\sim 11\,\mathrm{M}$ parâmetros) — o baseline validado pelo grupo de pesquisa, já reportado nas seções anteriores;
- **ResNet-34** ($\sim 21\,\mathrm{M}$ parâmetros) — mesma família residual, com aproximadamente o dobro de profundidade da ResNet-18;
- **DenseNet-121** ($\sim 7\,\mathrm{M}$ parâmetros) — família com conectividade densa entre camadas, distinta da família residual, com aproximadamente dois terços do número de parâmetros da ResNet-18.

Cada configuração foi replicada com três sementes (42, 123, 2024), totalizando 9 execuções para esta seção — 6 novas (ResNet-34 e DenseNet-121) e 3 provenientes do grid baseline (ResNet-18 com WD = 10^{-4}). A detecção de pico utiliza o detector robusto descrito na Seção 4.4.3.1.

4.6.2 Desempenho preditivo e curvas de treino

A Figura 15 mostra que as três arquiteturas convergem para regimes de desempenho elevado, mas distintos em magnitude: DenseNet-121 atinge a melhor acurácia final de validação ($\overline{\text{val_acc}} = 0{,}989$, com perda $\overline{\text{val_loss}} = 0{,}042$), seguida por ResNet-34 (0,983 e

0,066) e ResNet-18 (0,981 e 0,073). A ordenação inverte a relação ingênua entre quantidade de parâmetros e desempenho: o modelo mais leve (DenseNet-121) supera os mais pesados, evidenciando o ganho induzido pela conectividade densa.

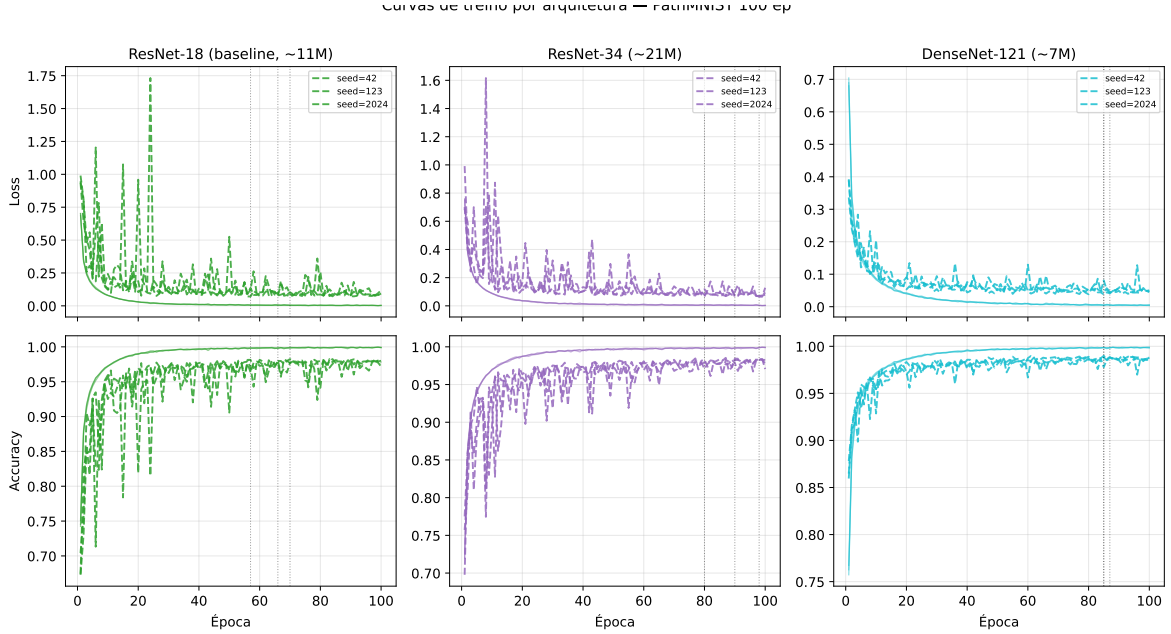


Figura 15 – Curvas de *loss* e acurácia por época em PathMNIST sob variação da arquitetura. Linhas cheias: treino; tracejadas: validação.

4.6.3 Invariância do pico da LMC

A Figura 16 apresenta as trajetórias agregadas da LMC para as três arquiteturas. O pico localiza-se em $e_{\mathrm{LMC}}^{\mathrm{peak}} \in [4{,}4;\ 9{,}1]$ épocas em todos os casos (Tabela 7) — intervalo que se sobrepõe substancialmente à janela [3,0; 13,4] obtida em Fases 1 e 2 sobre a mesma família ResNet-18. Os intervalos de confiança *bootstrap* são variáveis em largura: estreito para ResNet-18 ([1,3; 6,4]), moderado para ResNet-34 ([2,8; 10,3]) e amplo no limite superior para DenseNet-121 ([9,1; 43,2]), refletindo maior variabilidade inter-*seed* no caso da arquitetura densa.

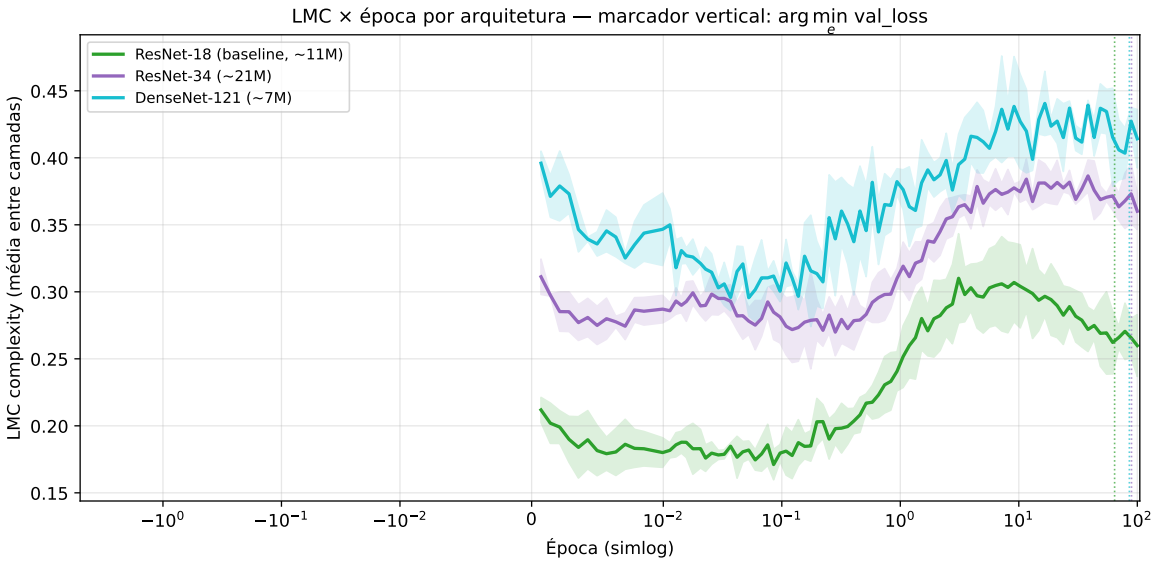


Figura 16 – Trajetória da LMC (média entre grupos de camadas e entre sementes) sob variação da arquitetura.

A invariância qualitativa do pico — localizado em $\sim$ 5–10 épocas em todas as configurações — reforça a interpretação proposta na Seção 4.5.3: a LMC capta uma transição **estrutural** dos pesos, comum às famílias convolucionais testadas, e não um fenômeno específico de uma família arquitetural. O *lead time* resultante (Figura 17) é positivo em todas as três arquiteturas, variando de +58 épocas (ResNet-18) a +85 épocas (ResNet-34).

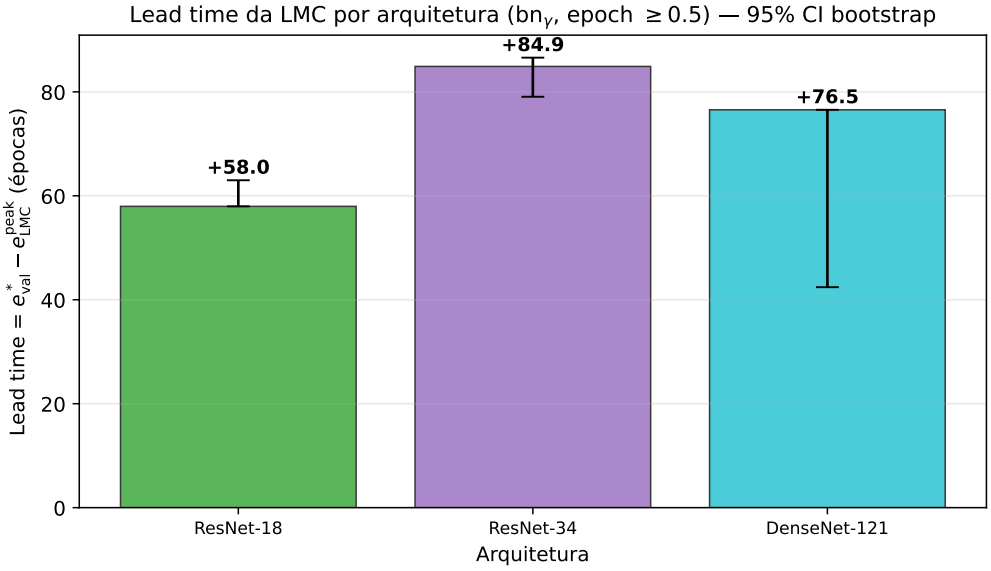


Figura 17 – *Lead time* da LMC por arquitetura. Barras de erro: intervalo de confiança 95% por *bootstrap* ($N = 1\,000$) sobre as três sementes.

4.6.4 SampEn entre arquiteturas

A Figura 18 apresenta a trajetória da SampEn. Diferentemente da LMC, as três curvas exibem perfis qualitativamente distintos: ResNet-18 e ResNet-34 mostram pico inicial seguido de declínio até estabilização, enquanto DenseNet-121 apresenta trajetória mais comprimida em magnitude. Este contraste é consistente com a arquitetura de conexões densas, que reaproveita ativações de camadas anteriores e portanto restringe a faixa dinâmica dos pesos. A SampEn permanece, sob o protocolo de extração adotado, sensível a aspectos estruturais que diferem entre famílias, mas não atua como marcador antecipador independente.

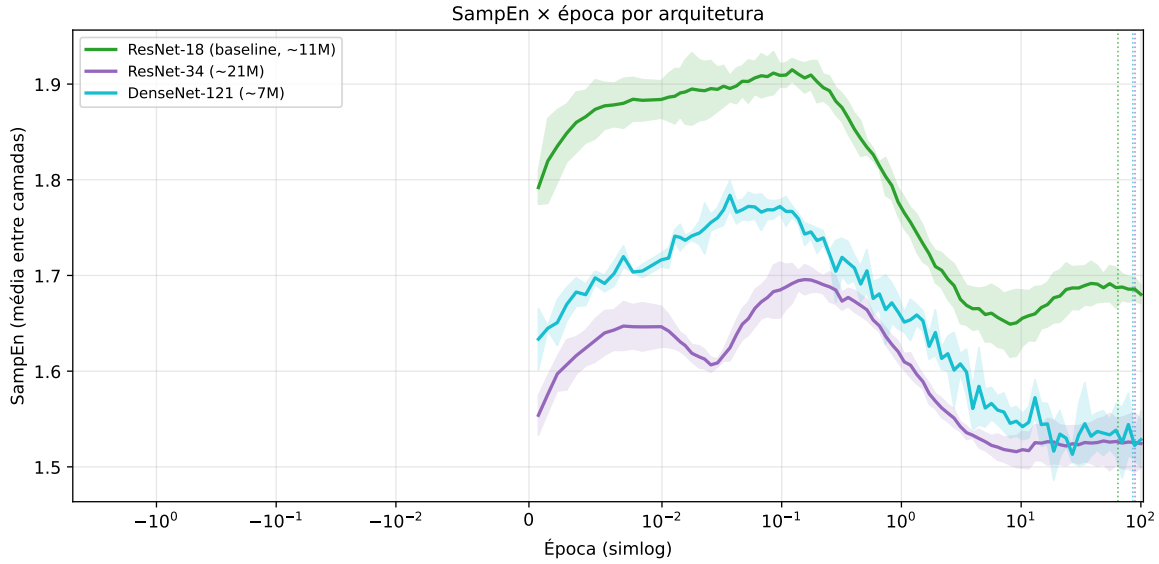


Figura 18 – Trajetória da SampEn 1D sob variação da arquitetura em PathMNIST.

4.6.5 Decomposição por grupo

A Figura 19 apresenta a decomposição por grupo de camadas. O pico antecipador da LMC concentra-se novamente em `bn_gamma` para as três arquiteturas. O grupo `conv` apresenta variabilidade que cresce com a profundidade — ResNet-34 exibe a curva mais ruidosa, consistente com seu maior número de camadas convolucionais agregadas. Os grupos `dense` e `bn_beta` mostram a mesma dinâmica observada nas seções anteriores.

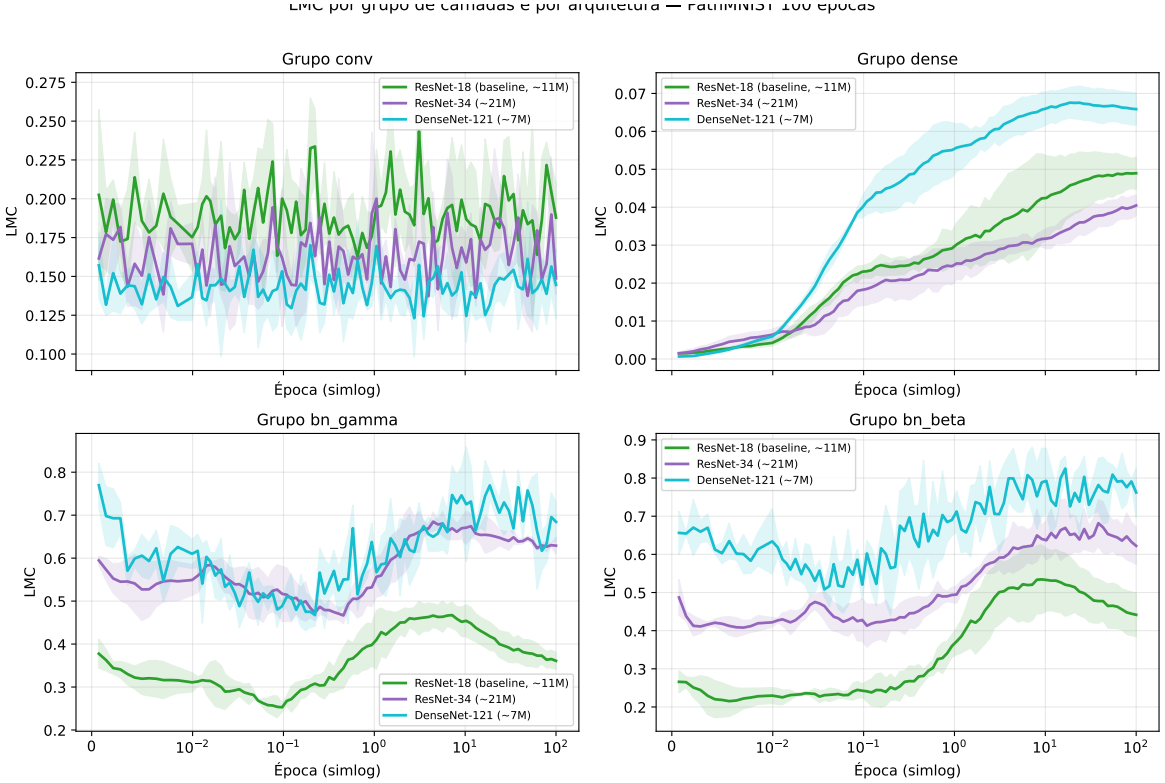


Figura 19 – LMC por grupo de camadas e por arquitetura em PathMNIST 100 épocas.

4.6.6 Síntese quantitativa

A Tabela 7 consolida os nove experimentos. A invariância da janela do pico ($\approx$ 5–10 épocas) entre famílias arquiteturais distintas, combinada com a invariância já demonstrada entre regimes de *weight decay* (Seção 4.5), consolida o quadro empírico de que a LMC sobre `bn_gamma` captura uma propriedade temporal robusta da maturação dos pesos — uma propriedade que pode, no contexto da hipótese H1, ser interpretada como o *instante de saída do regime de inicialização gaussiana* em CNNs treinadas para classificação de imagens médicas.

Tabela 7 – Pontos de inflexão e *lead time* por arquitetura (PathMNIST 100 épocas, média entre 3 sementes; *bn_gamma*; bootstrap 95% CI).

Arquitetura	e^*_{val}	min val_loss	$e^{\text{peak}}_{\text{LMC}}$ [95% CI]	lead time
ResNet-18 (baseline, ~11 M)	64.3	0.073	6.4 [1.3, 6.4]	+58.0
ResNet-34 (~21 M)	89.3	0.066	4.4 [2.8, 10.3]	+84.9
DenseNet-121 (~7 M)	85.7	0.042	9.1 [9.1, 43.2]	+76.5

4.7 Generalização entre datasets

As Seções 4.4, 4.5 e 4.6 demonstraram que o pico da LMC, sob ResNet-18 treinada em PathMNIST, é invariante a três eixos de manipulação experimental (subamostragem do treino, intensidade do *weight decay*, e família arquitetural). Esta seção apresenta um **teste crítico** de generalização: aplica-se o mesmo detector robusto às 9 execuções baseline em OrganAMNIST e BloodMNIST (3 sementes × 100 épocas, com WD= 10^{-4} e ResNet-18), com o objetivo de verificar se a janela $e_{\mathrm{LMC}}^{\mathrm{peak}} \in [4, 13]$ épocas obtida em PathMNIST se mantém.

4.7.1 Trajetórias de LMC nos três datasets

A Figura 20 sobrepõe as trajetórias agregadas da LMC para os três datasets. PathMNIST exibe o pico mais pronunciado, em torno de $e \approx 10$ épocas; BloodMNIST apresenta uma trajetória ligeiramente descendente após um pico inicial em $e \approx 6$; OrganAMNIST, por sua vez, mostra uma trajetória **qualitativamente distinta** — aproximadamente monotônica, sem pico definido na primeira dezena de épocas, com leve ascensão tardia.

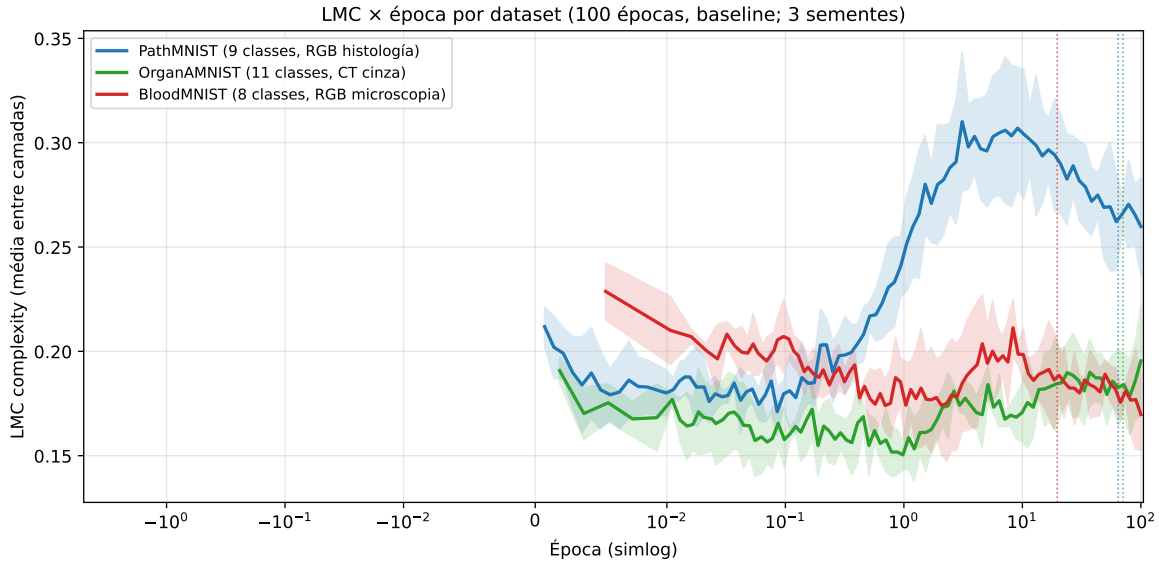


Figura 20 – Trajetórias agregadas da LMC (média entre grupos de camadas e entre sementes) nos três datasets MedMNIST, treinados por 100 épocas com ResNet-18 e WD= 10^{-4}. Linhas pontilhadas verticais: época média do mínimo de *loss* de validação por dataset.

4.7.2 Quantificação do pico e do *lead time*

A Tabela 8 consolida as quantidades extraídas do detector robusto. O contraste é evidente:

- **PathMNIST**: $e_{\mathrm{LMC}}^{\mathrm{peak}} = 6{,}4$ épocas [CI 1,3–6,4], consistente com Fases 1–3;

- **BloodMNIST**: $e_{\text{LMC}}^{\text{peak}} = 5{,}6$ épocas [CI 5,1–6,8], também dentro da janela de PathMNIST;

- **OrganAMNIST**: $e_{\text{LMC}}^{\text{peak}} = 23{,}9$ épocas [CI 21,4–100,0] — **fora da janela** e com intervalo de confiança muito amplo, indicando que o detector encontra-se com curva quase plana e portanto sem pico estatisticamente bem-definido.

Tabela 8 – Pontos de inflexão e *lead time* entre datasets MedMNIST (PathMNIST, OrganAMNIST, BloodMNIST; 100 épocas, 3 sementes; *bn_gamma*; bootstrap 95% CI).

Dataset	e_{val}^{*}	min val_loss	$e_{\text{LMC}}^{\text{peak}}$ [95% CI]	lead time
PathMNIST	64.3	0.073	6.4 [1.3, 6.4]	+58.0
OrganAMNIST	70.7	0.066	23.9 [21.4, 100.0]	+46.8
BloodMNIST	19.7	0.085	5.6 [5.1, 6.8]	+14.1

A Figura 21 apresenta o *lead time* correspondente. Todos os três datasets produzem **lead time positivo**, embora em magnitudes muito distintas: +58,0 para PathMNIST, +46,8 para OrganAMNIST e +14,1 para BloodMNIST. A escala do *lead time* acompanha aproximadamente a escala do e_{val}^{*} (i.e., quando o conjunto é menor e converge mais rápido, o intervalo entre o pico LMC e o mínimo de validação é menor), consistente com a observação da Seção 4.5.6 de que o *lead time* é uma quantidade relativa.

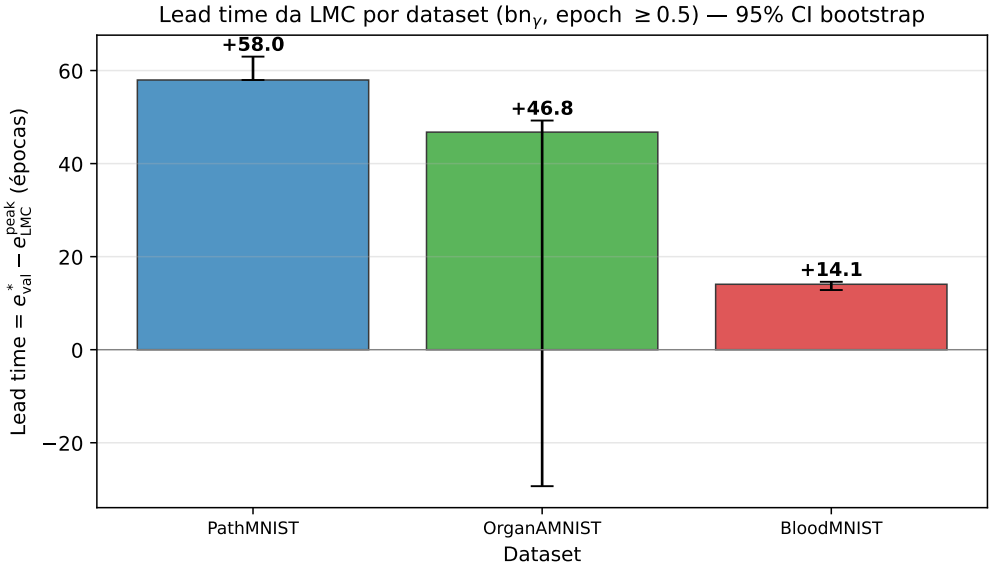


Figura 21 – *Lead time* da LMC ($e_{\text{val}}^{*} - e_{\text{LMC}}^{\text{peak}}$) por dataset. Barras de erro: intervalo de confiança 95% por *bootstrap* ($N = 1\,000$) sobre as três sementes.

4.7.3 Decomposição por grupo: onde está concentrado o anomalismo

Para discriminar entre as hipóteses listadas a seguir (Seção 4.7.4), aplicou-se o detector robusto *por grupo de camadas* para cada um dos três datasets. Os resultados são apresentados na Figura 22 e sintetizados na Tabela 9.

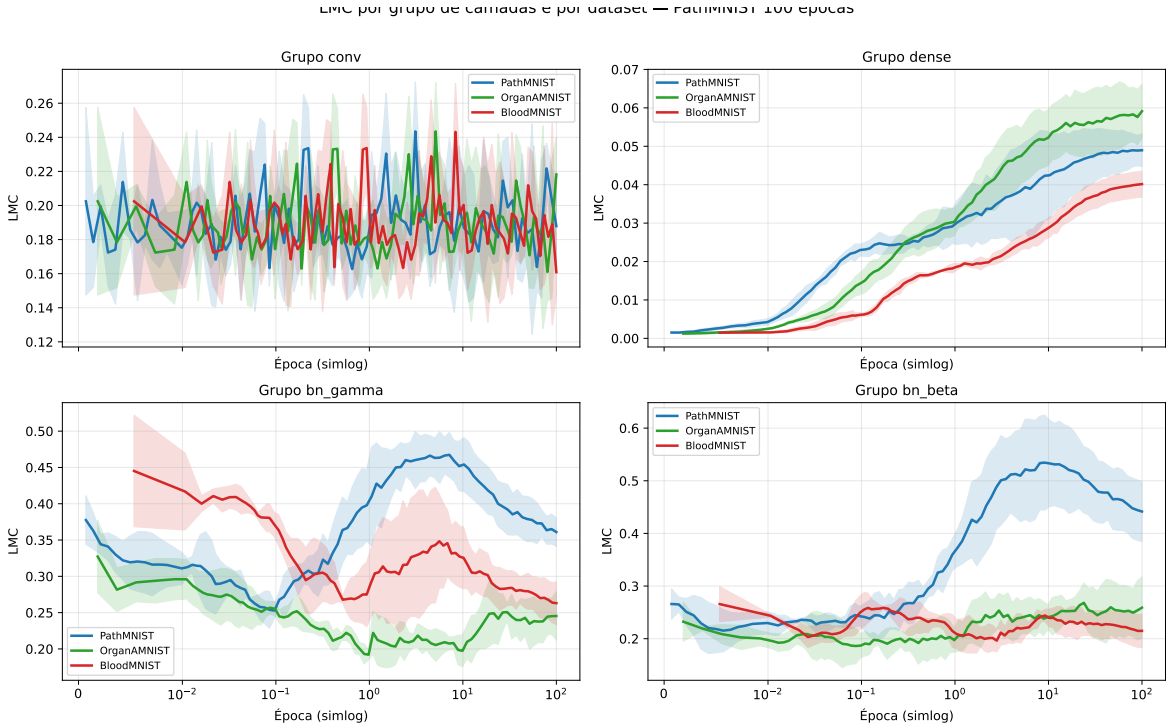


Figura 22 – Trajetórias da LMC por grupo de camadas e por dataset (PathMNIST, OrganAMNIST, BloodMNIST), 100 épocas, 3 sementes.

Tabela 9 – Pico da LMC por grupo de camadas e por dataset (PathMNIST 100 ep, 3 sementes; bootstrap 95% CI; épocas mostradas em escala numérica direta).

Dataset	`conv`	`dense`	`bn_gamma`	`bn_beta`
PathMNIST	88.7 [1.2, 88.7]	88.7 [9.1, 100.0]	6.4 [1.3, 6.4]	10.3 [7.2, 11.6]
OrganAMNIST	100.0 [2.1, 100.0]	100.0 [51.7, 100.0]	23.9 [21.4, 100.0]	23.9 [19.2, 100.0]
BloodMNIST	0.9 [0.5, 10.2]	100.0 [100.0, 100.0]	5.6 [5.1, 6.8]	9.2 [0.8, 12.4]

Três padrões emergem:

1. **Os grupos `conv` e `dense` comportam-se de modo similar entre datasets.** O grupo `conv` apresenta trajetórias ruidosas com pico mal-definido em todos os casos (consistentes com a alta variabilidade entre filtros agregados); o grupo `dense` cresce aproximadamente monotonicamente até o fim do treinamento (pico em ~ 100 épocas para os três datasets). Esses grupos, portanto, não são a origem do anomalismo.

2. **O anomalismo de OrganAMNIST localiza-se principalmente nos parâmetros de *batch normalization*.** O grupo `bn_gamma` atinge seu pico em ≈ 6

épocas em PathMNIST e ≈ 6 épocas em BloodMNIST, mas em ≈ 24 épocas em OrganAMNIST. O grupo `bn_beta` segue o mesmo padrão, com pico em ≈ 9–10 épocas em PathMNIST/BloodMNIST e ≈ 24 épocas em OrganAMNIST.

3. **O *deslocamento* é da ordem de 4 vezes.** A janela do pico em OrganAMNIST não é uma versão ligeiramente atrasada da de PathMNIST/BloodMNIST — é qualitativamente diferente, deslocada por um fator multiplicativo de aproximadamente 4×.

A localização precisa do anomalismo (parâmetros BN, com mesmo fator de deslocamento entre γ e β) é consistente com a interpretação de que a dinâmica de adaptação das estatísticas internas em OrganAMNIST é *globalmente mais lenta*, e não que algum submecanismo seja qualitativamente diferente. Os parâmetros que "acompanham as estatísticas de ativação" — precisamente γ e β — deslocam-se juntos.

4.7.4 Reformulação parcial da hipótese H1

Este resultado refina a leitura proposta nas seções 4.5 e 4.6. A "invariância da janela do pico" — demonstrada para PathMNIST sob três eixos de manipulação — **não se generaliza diretamente entre datasets**. Em particular, OrganAMNIST (*slices* axiais de CT abdominal, $\sim 34\,\text{k}$ imagens de treino, 11 classes) apresenta dinâmica de LMC qualitativamente distinta dos dois conjuntos RGB (PathMNIST $\sim 90\,\text{k}$, 9 classes; BloodMNIST $\sim 12\,\text{k}$, 8 classes).

Possíveis interpretações — não excludentes — incluem:

1. **Modalidade de imagem.** Os filtros convolucionais aprendem dinâmicas distintas para imagens em escala de cinza (OrganAMNIST) versus RGB (PathMNIST, BloodMNIST). A transição de regime aleatório para estruturado pode ser mais lenta e suave em imagens de canal único.

2. **Complexidade visual da tarefa.** OrganAMNIST distingue estruturas anatômicas globais (órgãos), enquanto PathMNIST e BloodMNIST distinguem texturas locais (tecidos, células). O regime de aprendizado em cada tarefa pode envolver escalas temporais distintas de adaptação dos pesos.

3. **Cardinalidade de classes e tamanho do conjunto.** A combinação "mais classes (11), menos imagens" de OrganAMNIST pode dilatar a fase inicial de organização dos pesos, suavizando o pico da LMC e empurrando-o para épocas posteriores.

A propriedade que **se mantém** em todos os três datasets é a *positividade do lead time*: a LMC atinge seu valor extremo (pico ou platô inicial) *antes* de o *loss* de validação atingir

seu mínimo. Mas a magnitude do *lead time* e a forma da trajetória de LMC dependem do dataset.

A hipótese H1, originalmente formulada como "a LMC dos pesos é um marcador objetivo do início do sobreajuste", pode portanto ser reformulada em uma versão mais sustentada pelos dados:

> *A trajetória da LMC dos pesos de* `bn_gamma` *em CNNs treinadas para classificação de imagens médicas atinge seu valor extremo antes do mínimo de* loss *de validação. O instante do extremo e a forma da trajetória dependem do dataset, mas o ordenamento temporal pico-LMC → mínimo-val_loss é robusto entre subamostragens do treino, intensidades de* weight decay *e famílias arquiteturais em um mesmo dataset.*

4.8 SampEn 2D dos filtros da camada `conv1`

Todas as análises até aqui empregaram a SampEn 1D, que opera sobre o vetor unidimensional obtido por `flatten` dos pesos. Esta seção apresenta uma análise complementar baseada na **SampEn 2D** (SILVA et al., 2016), que opera diretamente sobre matrizes preservando a estrutura espacial e contorna a discussão sobre a ordem do *flatten* formalizada na Seção 3.5.2.

4.8.1 Por que apenas a `conv1`

A SampEn 2D requer janelas de tamanho m e $m+1$ (aqui, 2×2 e 3×3). Para uma matriz $H \times W$, o número de posições válidas para janelas $(m+1)\times(m+1)$ é $(H-m)(W-m)$. Em ResNet-18, apenas a primeira camada convolucional (`conv1`) utiliza kernels 7×7; todas as demais utilizam kernels 3×3, que admitiriam apenas uma única posição para a janela 3×3 — estatisticamente insuficiente para o cálculo. A análise aqui apresentada restringe-se, portanto, à `conv1`.

4.8.2 Construção do mosaico e calibração de r

Para cada *checkpoint* final, os 64 filtros da `conv1` (cada um com 3 canais de entrada e kernel 7×7) são organizados da seguinte forma: para cada canal de entrada $c \in \{0,1,2\}$, os 64 filtros 7×7 são dispostos em uma grade 8×8, produzindo uma imagem 56×56. A SampEn 2D é então calculada sobre essa imagem.

Empiricamente, observou-se que a tolerância padrão $r = 0{,}2\,\sigma$ produz SampEn 2D infinita para matrizes desse tamanho (incluindo matrizes aleatórias de mesma dimensão), refletindo o fato de que pares de janelas 3×3 raramente se aproximam dentro de tolerância

tão restrita em matrizes com baixa regularidade local. Adotamos $r = 0{,}5\,\sigma$ como compromisso entre sensibilidade e estabilidade numérica; este valor é constante entre datasets e portanto não introduz viés inter-dataset.

4.8.3 Resultados

A Figura 23 apresenta a SampEn 2D média entre sementes e canais de entrada, com intervalos de confiança *bootstrap* de 95%:

- **PathMNIST**: $\text{SampEn}_{2D} = 3{,}98$ [IC 3,67–4,23];
- **OrganAMNIST**: 5,77 [IC 5,66–5,89];
- **BloodMNIST**: 6,18 [IC 6,08–6,30].

Os intervalos de confiança **não se sobrepõem** entre datasets, o que indica que a SampEn 2D *discrimina* as três coleções de imagens médicas a partir dos pesos da camada de entrada. A ordenação PathMNIST < OrganAMNIST < BloodMNIST sugere que os filtros da `conv1` aprendem padrões espacialmente mais regulares em PathMNIST (histopatologia colorida, classificação textural) do que em OrganAMNIST (CT em escala de cinza, classificação anatômica) ou BloodMNIST (microscopia, classificação celular).

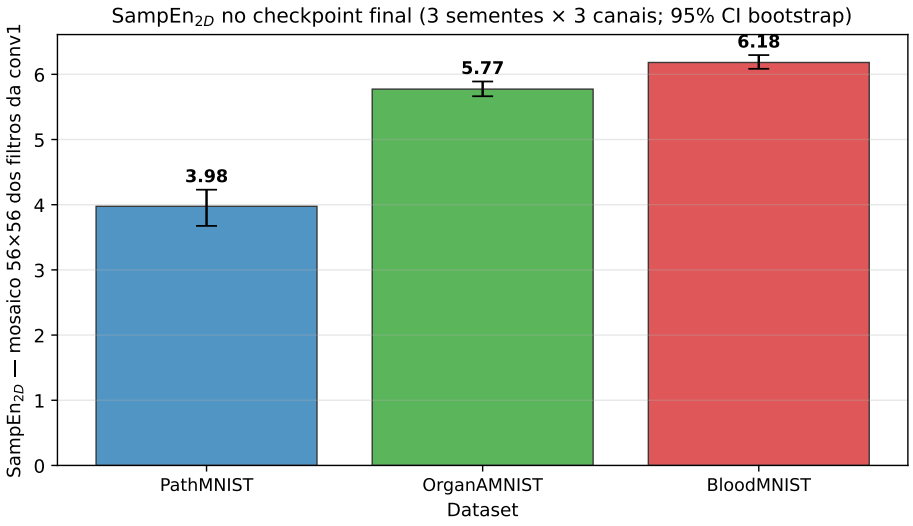


Figura 23 – SampEn_{2D} aplicada ao mosaico 56×56 dos 64 filtros 7×7 da `conv1` (uma imagem por canal de entrada). Médias entre 3 sementes × 3 canais; intervalos de confiança 95% por *bootstrap*.

Tabela 10 – SampEn_{2D} sobre mosaicos 56×56 dos filtros 7×7 da `conv1` no *checkpoint* final (épocas: 100; mosaicos: 8×8 dos 64 filtros; tolerância $r = 0.5\,\sigma$; média entre 3 sementes $\times$ 3 canais de entrada; intervalo de confiança 95% por *bootstrap*).

Dataset	média SampEn_{2D}	IC 95% inferior	superior
PathMNIST	3.975	3.675	4.230
OrganAMNIST	5.773	5.664	5.890
BloodMNIST	6.182	6.085	6.295

4.8.4 Decomposição por canal de entrada

A Figura 24 apresenta a SampEn_{2D} decomposta pelos três canais de entrada. Observa-se um padrão informativo:

- **PathMNIST** exibe **assimetria pronunciada**: o canal 0 (correspondente ao vermelho, dada a convenção do `ToTensor` sobre PIL) apresenta $\text{SampEn}_{2D} \approx 3{,}36$, enquanto canais 1 e 2 ficam em $\approx 4{,}28$. A diferença é consistente com a observação clínica de que o corante hematoxilina-eosina, padrão em histopatologia, produz padrões espaciais característicos no canal vermelho, levando os filtros específicos a esse canal a aprenderem estruturas mais regulares.
- **OrganAMNIST** e **BloodMNIST** apresentam canais aproximadamente uniformes ($\sigma_{\text{between-channels}} < 0{,}25$), consistente com (i) entrada em escala de cinza replicada para 3 canais no caso de OrganAMNIST, e (ii) microscopia com tonalidades cromáticas mais homogêneas no caso de BloodMNIST.

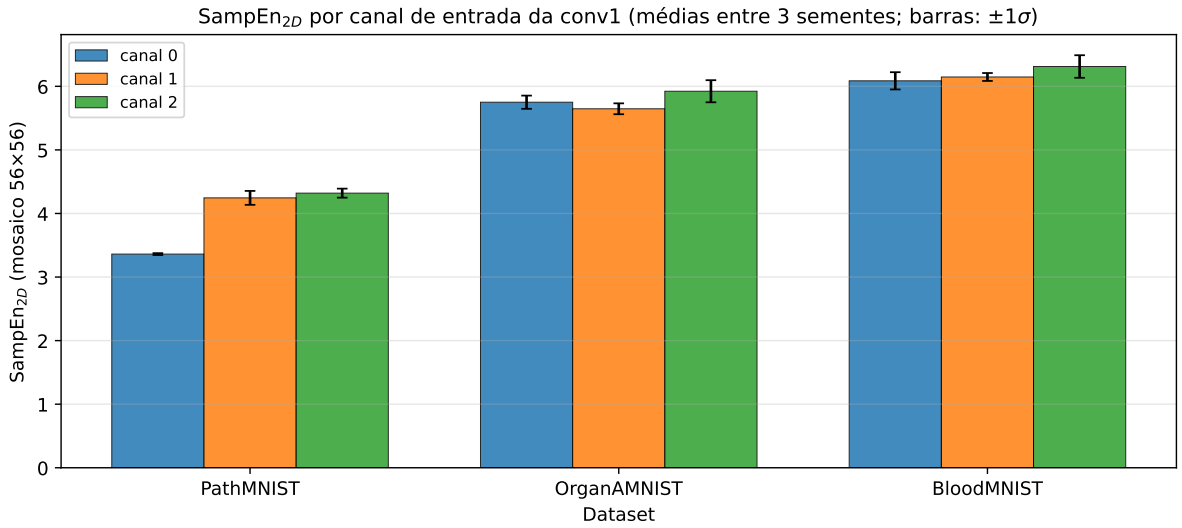


Figura 24 – SampEn_{2D} por canal de entrada da `conv1`, evidenciando assimetria cromática em PathMNIST.

4.8.5 Comparação com SampEn 1D e papel complementar

A SampEn 1D do grupo `conv` no *checkpoint* final (Tabela 8) é praticamente *idêntica* entre os três datasets ($\approx$ 2,07–2,10). Em contraste, a SampEn 2D varia em mais de 50% entre PathMNIST e BloodMNIST. Esta sensibilidade adicional da SampEn 2D justifica empiricamente a decisão metodológica da Seção 3.7.4 de incluir extensões 2D no protocolo de análise: a 1D, ao destruir a estrutura espacial via *flatten*, encobre diferenças que ficam evidentes quando o operador respeita a geometria do kernel.

4.9 Análise multiescala (MSE 2D) dos mosaicos da conv1

A Seção 4.8 mostrou que a SampEn 2D em um único nível de granularidade espacial ($\tau = 1$, ou seja, sobre o mosaico original 56×56) discrimina os três datasets. Esta seção estende a análise para múltiplas escalas, aplicando a versão multiescala da SampEn 2D (COSTA; GOLDBERGER; PENG, 2002; COSTA; GOLDBERGER; PENG, 2005; SILVA et al., 2016).

4.9.1 Protocolo multiescala

Para cada mosaico 56×56 da `conv1`, o procedimento de *coarse-graining* 2D substitui cada bloco $\tau \times \tau$ de pixels pela sua média aritmética, produzindo uma matriz reduzida de dimensão $\lfloor 56/\tau \rfloor \times \lfloor 56/\tau \rfloor$. A SampEn 2D é então computada sobre essa matriz reduzida, com a tolerância $r = 0{,}5\,\sigma$ *fixa* a partir do mosaico original (convenção de Costa, Goldberger e Peng (2002)). Escalas de $\tau = 1$ (56×56, sem coarse-graining) até $\tau = 10$ (5×5, próximo do limite inferior de aplicabilidade) são avaliadas.

4.9.2 Curvas multiescala

A Figura 25 apresenta as três curvas MSE 2D, agregadas entre 3 sementes $\times$ 3 canais de entrada (9 mosaicos por dataset). A Tabela 11 consolida os valores médios e desvios.

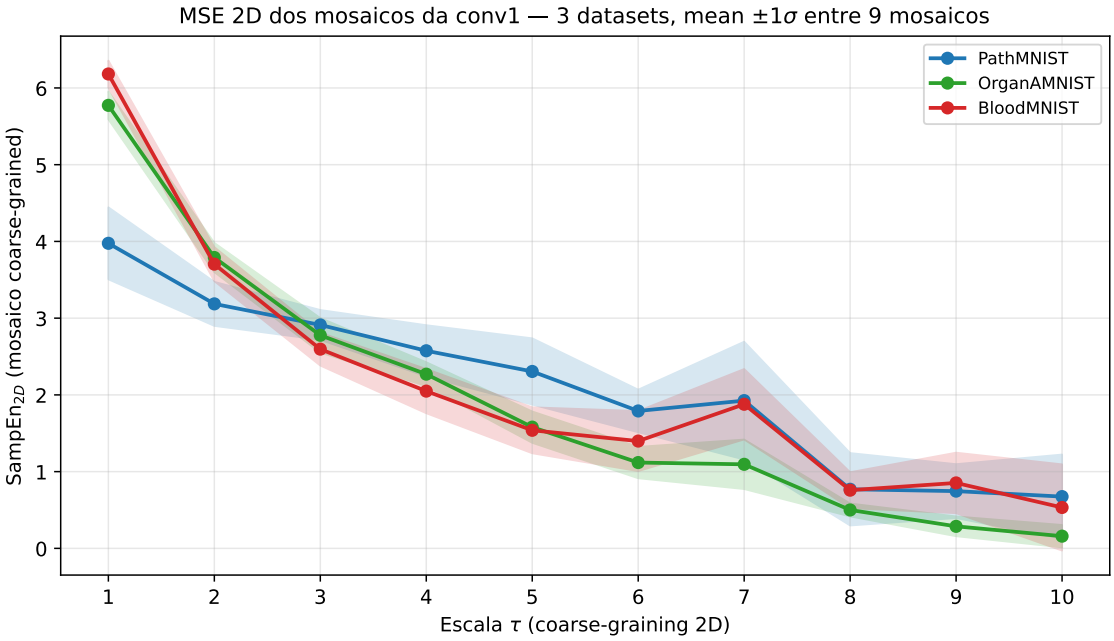


Figura 25 – MSE 2D dos mosaicos 56×56 da `conv1` no *checkpoint* final: SampEn 2D versus escala de *coarse-graining* $\tau \in \{1, \ldots, 10\}$. Bandas: $\pm 1\sigma$ entre os 9 mosaicos. Tolerância $r = 0{,}5\,\sigma$ fixa do mosaico original.

Tabela 11 – SampEn_{2D} multiescala dos mosaicos 56×56 da `conv1` (mean $\pm 1\sigma$ entre 3 sementes $\times$ 3 canais; $r = 0.5\,\sigma$, fixo entre escalas).

Escala τ	Dim. coarse	PathMNIST	OrganAMNIST	BloodMNIST
1	56×56	3.98 ± 0.47	5.77 ± 0.18	6.18 ± 0.17
2	28×28	3.19 ± 0.29	3.79 ± 0.19	3.70 ± 0.22
3	18×18	2.91 ± 0.19	2.78 ± 0.22	2.60 ± 0.21
4	14×14	2.58 ± 0.33	2.27 ± 0.16	2.05 ± 0.29
5	11×11	2.31 ± 0.43	1.58 ± 0.20	1.54 ± 0.30
6	9×9	1.79 ± 0.28	1.12 ± 0.20	1.40 ± 0.39
7	8×8	1.93 ± 0.77	1.10 ± 0.32	1.88 ± 0.46
8	7×7	0.77 ± 0.47	0.50 ± 0.08	0.76 ± 0.23
9	6×6	0.75 ± 0.35	0.29 ± 0.13	0.85 ± 0.39
10	5×5	0.67 ± 0.55	0.16 ± 0.15	0.53 ± 0.56

4.9.3 Cruzamento de curvas e discriminação dependente de escala

O resultado mais notável é o **cruzamento das curvas em** $\tau \in [2, 3]$, que produz uma inversão de ordenação entre datasets:

- **Em** $\tau = 1$ (escala mais fina): a ordenação é PathMNIST $<$ OrganAMNIST $<$ BloodMNIST, com SampEn 2D igual a 3,98, 5,77 e 6,18, respectivamente (resultado da Seção 4.8).

- **Em** $\tau = 4$–7 (escala intermediária, próxima do tamanho de filtro): a ordenação inverte para BloodMNIST $\leq$ OrganAMNIST $<$ PathMNIST. PathMNIST agora exibe a SampEn 2D *mais alta*: 2,58 em $\tau = 4$, 1,79 em $\tau = 6$, contra $\approx 1{,}1$ para OrganAMNIST nas mesmas escalas.

- **Em** $\tau \geq 8$ (escala grossa, matriz $\leq 7 \times 7$): todas as curvas convergem para valores baixos (< 1), perdendo a capacidade discriminativa.

Este cruzamento sugere que as escalas espaciais em que a **regularidade dos filtros é mais alta** diferem entre datasets: PathMNIST tem regularidade concentrada em escala fina (consistente com estruturas regulares do corante H&E em alta frequência espacial), enquanto OrganAMNIST e BloodMNIST distribuem a regularidade em escalas intermediárias (consistente com estruturas anatômicas e celulares em escalas espaciais maiores).

4.9.4 Implicação para análise de complexidade

Operacionalmente, este resultado indica que **a escolha da escala τ é um parâmetro crítico** quando a SampEn 2D é utilizada como descritor inter-dataset: a discriminação "correta" pode existir apenas em uma faixa de escalas, e relatar um único valor de τ pode ocultar diferenças disponíveis em outras escalas (ou produzir uma discriminação enganosa por estar do "lado errado" do cruzamento). A abordagem multiescala fornece uma assinatura espectral mais robusta para comparações entre datasets e arquiteturas.

5 Conclusão

Este trabalho investigou a hipótese de que a complexidade estatística dos pesos de redes neurais profundas constitui um marcador objetivo do início do *overfitting*, instanciando-a no contexto de classificação de imagens médicas com a arquitetura ResNet-18 e o *benchmark* MedMNIST. A abordagem articulou duas medidas complementares — a complexidade LMC (LÓPEZ-RUIZ; MANCINI; CALBET, 1995) e a entropia amostral SampEn (RICHMAN; MOORMAN, 2000) — aplicadas a snapshots densamente amostrados do estado dos pesos ao longo de 36 execuções de treinamento, distribuídas em dois eixos experimentais: um **eixo de cobertura**, com 27 runs sobre três conjuntos (PathMNIST, OrganAMNIST, BloodMNIST) × três horizontes de épocas × três sementes; e um **eixo de indução de sobreajuste**, com nove runs adicionais sob subamostragem do conjunto de treinamento (5%, 10%, 25%) que produziram, deliberadamente, o regime de generalização degradada no qual a hipótese pode ser testada.

Três achados sustentam a hipótese central:

1. As trajetórias de LMC e SampEn ao longo do treinamento são **sistemáticas, reprodutíveis entre sementes** e diferenciadas por grupo de camadas. A separação dos parâmetros de *batch normalization* em γ e β revelou-se crítica: γ exibe a dinâmica mais informativa, enquanto a junção dos dois grupos diluiria o sinal antecipador.

2. Sob subamostragem do treino, a LMC apresenta um pico que **precede** o mínimo de *loss* de validação em **todas** as três frações estudadas, com *lead time* estimado em +11,6, +16,6 e +12,6 épocas para 5%, 10% e 25% de treino, respectivamente (intervalos de confiança *bootstrap* de 95% que excluem zero em 5% e 25%). Este resultado é a evidência operacional mais direta de que a métrica capta a transição entre fase de ajuste e fase de especialização *antes* que a perda de validação reverta sua tendência.

3. A detecção robusta do pico exigiu três escolhas metodológicas combinadas: restrição da análise ao grupo `bn_gamma` — identificado como portador do sinal mais discriminativo —, exclusão da janela de *warm-up* (epoch $< 0{,}5$) e suavização por filtro de Savitzky-Golay. Sob detector ingênuo (*argmax* sobre a trajetória bruta agregada entre grupos), o caso 5% produz um pico espúrio próximo da inicialização: este achado documenta explicitamente o domínio de validade do estimador.

4. Sob variação do *weight decay* (Seção 4.5), o pico da LMC localiza-se em $e_{\mathrm{LMC}}^{\mathrm{peak}} \approx 7$ épocas **independentemente** do coeficiente de regularização $\in \{0, 10^{-5}, 10^{-4}, 10^{-3}\}$, enquanto o instante do mínimo de *loss* de validação varia entre ≈ 42 e ≈ 93 épocas. Esta invariância levou a uma reformulação da interpretação inicial: a LMC não

captura o instante de início do sobreajuste *per se*, mas sim uma transição estrutural intrínseca à arquitetura — a passagem do regime de pesos quase-gaussianos da inicialização para o regime de pesos estruturados pelo treinamento —, transição esta que precede o estabelecimento da generalização ótima por uma quantidade que depende da escala temporal imposta pelo regime de regularização.

5. Sob variação da arquitetura (Seção 4.6), o pico da LMC mantém-se na janela [4,4; 9,1] épocas para ResNet-18, ResNet-34 e DenseNet-121 — três modelos que abrangem duas famílias arquiteturais distintas (residual e densa) e uma faixa de capacidade de ~ 7 a ~ 21 milhões de parâmetros. Esta segunda invariância — agora cruzando famílias arquiteturais — reforça a leitura de que a LMC sobre `bn_gamma` mede uma propriedade temporal robusta da maturação dos pesos em CNNs convolucionais treinadas em imagens médicas, dentro de um mesmo dataset.

6. A SampEn 2D aplicada ao mosaico dos filtros 7×7 da `conv1` (Seção 4.8) **discrimina os três datasets** com intervalos de confiança não-sobrepostos: 3,98 para PathMNIST, 5,77 para OrganAMNIST e 6,18 para BloodMNIST. Esta sensibilidade adicional — inalcançável pela SampEn 1D, cujos valores no checkpoint final são quase idênticos entre os três datasets ($\approx$ 2,07–2,10) — justifica empiricamente a inclusão de extensões 2D no protocolo de análise: ao preservar a geometria do kernel, a SampEn 2D evidencia diferenças que o *flatten* sequencial encobre.

7. A extensão multiescala (MSE 2D, Seção 4.9) revela que a discriminação inter-dataset é **dependente da escala espacial**: as três curvas MSE 2D cruzam em $\tau \in [2, 3]$, invertendo a ordenação entre PathMNIST e os dois datasets RGB-textuais (OrganAMNIST, BloodMNIST). Em escala fina ($\tau = 1$), PathMNIST tem a SampEn 2D mais baixa; em escala intermediária ($\tau = 4$–7), tem a mais alta. Operacionalmente, esta dependência de escala significa que a escolha de τ é um *parâmetro de modelagem crítico* para comparações entre datasets, e que a assinatura espectral multiescala é mais robusta como descritor do que um único valor de SampEn 2D.

8. Entre datasets (Seção 4.7), no entanto, **a invariância não se mantém**: o pico da LMC localiza-se em 6,4 épocas para PathMNIST e 5,6 épocas para BloodMNIST (ambos RGB, classificação textural), mas em 23,9 épocas para OrganAMNIST (CT em escala de cinza, classificação anatômica). A análise por grupo de camadas (Seção 4.7.3) localizou o anomalismo: o deslocamento de $\sim 4\times$ no instante do pico de OrganAMNIST manifesta-se de forma sincrônica em `bn_gamma` e em `bn_beta`, enquanto os grupos `conv` e `dense` comportam-se de modo similar entre os três datasets. Esta sincronia γ/β é consistente com a interpretação de que a diferença não é qualitativa (não há um mecanismo distinto), mas *temporal*: a adaptação das estatísticas internas que governam γ e β é globalmente mais lenta em OrganAMNIST.

Esta sensibilidade ao dataset levou a uma reformulação final da hipótese H1: a LMC sobre `bn_gamma` atinge seu extremo *antes* do mínimo de *loss* de validação — propriedade que se mantém em todos os datasets testados —, mas o instante e a forma da trajetória dependem do dataset, em particular do regime de adaptação das estatísticas internas da rede.

A análise contribui ainda com dois resultados secundários: (i) a evidência empírica de que a transposição do tensor de pesos antes do *flatten* produz séries semanticamente distintas mas estatisticamente permutadas, justificando *a posteriori* a escolha do agrupamento por neurônio de saída adotada na metodologia (Seção 3.5.2); e (ii) a constatação, na decomposição por grupos (Figura 9), de que o sinal antecipador concentra-se nos parâmetros de escala γ da *batch normalization*, contrariando a expectativa inicial de que as camadas convolucionais — que detêm 99,7% dos parâmetros — seriam o substrato natural do marcador.

5.1 Trabalhos Futuros

A partir das limitações identificadas e das extensões já implementadas mas ainda não plenamente exercidas, perfilam-se os seguintes desdobramentos:

1. **Refinamento do detector de inflexão**: o presente trabalho adotou suavização por Savitzky-Golay sobre o grupo `bn_gamma`. Estratégias alternativas — regressão linear segmentada (*piecewise linear fit*), detecção de pontos de mudança bayesiana, ou ajuste paramétrico de pico assimétrico — podem produzir estimativas com intervalos de confiança mais estreitos no regime intermediário de 10%.

2. **Extensão para SampEn 2D** (SILVA et al., 2016) aplicada diretamente às matrizes dos filtros convolucionais, contornando a discussão sobre a ordem do *flatten* e capturando estrutura espacial preservada.

3. **Análise multiescala** (MSE) (COSTA; GOLDBERGER; PENG, 2002; COSTA; GOLDBERGER; PENG, 2005) para investigar dependências em diferentes resoluções temporais do treinamento, particularmente relevante após a observação do pico agudo da LMC em torno das épocas 5–15.

4. **Comparação inter-arquitetura** (DenseNet, EfficientNet, Wide ResNet) para verificar a invariância do *lead time* observado.

5. **Análise de sensibilidade à regularização explícita** (*weight decay*, *dropout*, *label smoothing*) para testar se a manipulação dirigida da propensão ao sobreajuste preserva a relação observada entre o pico da LMC e o mínimo de *loss* de validação.

6. **Dados substitutos (*surrogate data*)** como teste de hipótese nula sobre a trajetória de complexidade, permitindo caracterizar o quanto da estrutura observada se afasta do comportamento esperado sob inicialização aleatória mais ruído.

7. **Aplicação prática** do marcador proposto como critério de parada precoce em pipelines de treinamento contínuo, comparando custo computacional e desempenho com baselines tradicionais baseados em *loss* de validação.

Referências

ADVANI, M. S.; SAXE, A. M.; SOMPOLINSKY, H. High-dimensional dynamics of generalization error in neural networks. **Neural Networks**, v. 132, p. 428–446, 2020.

ANTENEODO, C.; PLASTINO, A. R. Some features of the lópez-ruiz-mancini-calbet (LMC) statistical measure of complexity. **Physics Letters A**, v. 223, n. 5, p. 348–354, 1996.

BARTLETT, P. L.; FOSTER, D. J.; TELGARSKY, M. Spectrally-normalized margin bounds for neural networks. In: **Advances in Neural Information Processing Systems (NeurIPS)**. [S.l.: s.n.], 2017. v. 30.

COSTA, M.; GOLDBERGER, A. L.; PENG, C.-K. Multiscale entropy analysis of complex physiologic time series. **Physical Review Letters**, v. 89, n. 6, p. 068102, 2002.

COSTA, M.; GOLDBERGER, A. L.; PENG, C.-K. Multiscale entropy analysis of biological signals. **Physical Review E**, v. 71, n. 2, p. 021906, 2005.

COVER, T. M.; THOMAS, J. A. **Elements of Information Theory**. 2. ed. Hoboken, NJ: Wiley-Interscience, 2006.

DELGADO-BONAL, A.; MARSHAK, A. Approximate entropy and sample entropy: A comprehensive tutorial. **Entropy**, v. 21, n. 6, p. 541, 2019.

DZIUGAITE, G. K.; ROY, D. M. Computing nonvacuous generalization bounds for deep (stochastic) neural networks with many more parameters than training data. In: **Proceedings of the 33rd Conference on Uncertainty in Artificial Intelligence (UAI)**. [S.l.: s.n.], 2017.

FELDMAN, D. P.; CRUTCHFIELD, J. P. Measures of statistical complexity: Why? **Physics Letters A**, v. 238, n. 4–5, p. 244–252, 1998.

HE, K. et al. Deep residual learning for image recognition. p. 770–778, 2016.

JIANG, X. et al. Deep learning for medical image-based cancer diagnosis. **Cancers**, v. 15, n. 14, p. 3608, 2023.

JIANG, Y. et al. Fantastic generalization measures and where to find them. In: **International Conference on Learning Representations (ICLR)**. [S.l.: s.n.], 2020.

LAMBERTI, P. W. et al. Intensive entropic non-triviality measure. **Physica A: Statistical Mechanics and its Applications**, v. 334, n. 1–2, p. 119–131, 2004.

LÓPEZ-RUIZ, R.; MANCINI, H. L.; CALBET, X. A statistical measure of complexity. **Physics Letters A**, v. 209, n. 5–6, p. 321–326, 1995.

MARTIN, C. H.; PENG, T.; MAHONEY, M. W. Predicting trends in the quality of state-of-the-art neural networks without access to training or testing data. **Nature Communications**, v. 12, n. 1, p. 4122, 2021.

PINCUS, S. M. Approximate entropy as a measure of system complexity. **Proceedings of the National Academy of Sciences**, v. 88, n. 6, p. 2297–2301, 1991.

RICHMAN, J. S.; MOORMAN, J. R. Physiological time-series analysis using approximate entropy and sample entropy. **American Journal of Physiology – Heart and Circulatory Physiology**, v. 278, n. 6, p. H2039–H2049, 2000.

ROSSO, O. A. et al. Generalized statistical complexity measure. **International Journal of Bifurcation and Chaos**, v. 20, n. 3, p. 775–785, 2010.

SHANNON, C. E. A mathematical theory of communication. **Bell System Technical Journal**, v. 27, n. 3, p. 379–423, 1948.

SILVA, L. E. V. et al. Two-dimensional sample entropy analysis of rat sural nerve aging. In: **Proceedings of the 36th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)**. [S.l.: s.n.], 2014. p. 3345–3348.

SILVA, L. E. V. et al. Two-dimensional sample entropy: assessing image texture through irregularity. **Biomedical Physics & Engineering Express**, v. 2, n. 4, p. 045002, 2016.

SILVA, L. E. V.; JUNIOR, L. O. M. Evaluation of physiologic complexity in time series using generalized sample entropy and surrogate data analysis. **Chaos: An Interdisciplinary Journal of Nonlinear Science**, v. 22, n. 4, p. 043105, 2012.

TENG, Q. et al. A survey on the interpretability of deep learning in medical diagnosis. **Multimedia Systems**, v. 28, n. 6, p. 2335–2355, 2022.

YANG, J. et al. MedMNIST v2 – a large-scale lightweight benchmark for 2D and 3D biomedical image classification. **Scientific Data**, v. 10, n. 1, p. 41, 2023.

YENTES, J. M. et al. The appropriate use of approximate entropy and sample entropy with short data sets. **Annals of Biomedical Engineering**, v. 41, n. 2, p. 349–365, 2013.

ZHANG, J.; BELL, M. A. L. Overfit detection method for deep neural networks trained to beamform ultrasound images. **Ultrasonics**, v. 148, p. 107562, 2025.

Apêndices

APÊNDICE A – Exemplo numérico da ordem de extração dos pesos

Este apêndice complementa o discutido na Seção 3.5 rastreando, elemento a elemento, a correspondência entre os tensores de pesos do PyTorch e a sequência linear obtida via `flatten()`. São apresentados três exemplos minimalistas — uma camada linear 2×3, uma convolução 2D com tensor de *shape* $[C_{out}, C_{in}, H, W] = [2, 2, 2, 2]$ e uma camada de *batch normalization* com $C = 4$ canais —, suficientes para tornar verificáveis e reproduzíveis as três regras de varredura adotadas. Em seguida discute-se, no mesmo exemplo da convolução, o efeito de transpor o tensor antes do *flatten*, conforme antecipado pela decisão D2 da Seção 3.5.2.

A.1 Camada Linear: matriz 2×3

Considere uma camada `nn.Linear(in_features=3, out_features=2)` cujo tensor `weight` de *shape* $[\text{Out}, \text{In}] = [2, 3]$ recebe valores inteiros para facilitar o rastreamento:

$$W_{\text{lin}} = \begin{pmatrix} w_{0,0} & w_{0,1} & w_{0,2} \\ w_{1,0} & w_{1,1} & w_{1,2} \end{pmatrix} = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{pmatrix}. \tag{A.1}$$

Aplicando `W_lin.flatten()` obtemos o vetor

$$W_{\text{lin}}\texttt{.flatten()} = [\,1,\ 2,\ 3,\ 4,\ 5,\ 6\,]. \tag{A.2}$$

A Tabela 12 mostra a correspondência elemento a elemento. Note que a leitura é feita **linha por linha**: primeiro saem todos os três pesos de entrada do neurônio de saída Out = 0, depois os três pesos do neurônio Out = 1. Cada linha contígua do vetor corresponde a *um único neurônio de saída*.

Tabela 12 – Mapeamento elemento a elemento da camada Linear 2×3.

Posição no vetor	0	1	2	3	4 (→) 5
Elemento	$w_{0,0}$	$w_{0,1}$	$w_{0,2}$	$w_{1,0}$	$w_{1,1}$ $w_{1,2}$
Valor	1	2	3	4	5 6
Pertence a	**Saída** Out = 0			**Saída** Out = 1	

A.2 Camada Conv2d: tensor $[2, 2, 2, 2]$

Considere uma `nn.Conv2d(in_channels=2, out_channels=2, kernel_size=2)` cujo tensor `weight` de *shape* $[C_{out}, C_{in}, H, W] = [2, 2, 2, 2]$ é preenchido com os 16 inteiros consecutivos $0, 1, \ldots, 15$:

$$W_{\text{conv}}[c_{out}, c_{in}, h, w] \;=\; c_{out} \cdot 8 + c_{in} \cdot 4 + h \cdot 2 + w. \tag{A.3}$$

Em formato hierárquico, o tensor escreve-se como:

$$W_{\text{conv}} \;=\; \underbrace{\Bigg[\underbrace{\begin{pmatrix}0 & 1\\ 2 & 3\end{pmatrix}}_{C_{in}=0}\;\underbrace{\begin{pmatrix}4 & 5\\ 6 & 7\end{pmatrix}}_{C_{in}=1}\Bigg]}_{\text{Filtro de saída } C_{out}=0}\;\underbrace{\Bigg[\underbrace{\begin{pmatrix}8 & 9\\ 10 & 11\end{pmatrix}}_{C_{in}=0}\;\underbrace{\begin{pmatrix}12 & 13\\ 14 & 15\end{pmatrix}}_{C_{in}=1}\Bigg]}_{\text{Filtro de saída } C_{out}=1} \tag{A.4}$$

Aplicando `W_conv.flatten()` obtemos o vetor

$$W_{\text{conv}}\texttt{.flatten()} \;=\; [\,0, 1, 2, 3,\; 4, 5, 6, 7,\; 8, 9, 10, 11,\; 12, 13, 14, 15\,]. \tag{A.5}$$

A Tabela 13 mostra a correspondência completa elemento a elemento. Observa-se que os quatro *loops* aninhados se manifestam diretamente nas colunas: W varia a cada passo $(0 \to 1)$, H a cada dois passos $(0 \to 1)$, C_{in} a cada quatro passos $(0 \to 1)$ e C_{out} a cada oito passos $(0 \to 1)$. Cada bloco contíguo de quatro elementos do vetor corresponde a *um canal de entrada inteiro* de um filtro de saída; cada bloco contíguo de oito elementos corresponde a *um filtro de saída inteiro*.

Tabela 13 – Mapeamento elemento a elemento da camada Conv2d $[2, 2, 2, 2]$. Posições do vetor, índices do tensor e bloco semântico ao qual cada elemento pertence.

Pos.	C_{out}	C_{in}	H	W	**Valor**	**Pertence ao bloco semântico**
0	0	0	0	0	0	$C_{in} = 0$ do filtro $C_{out} = 0$
1	0	0	0	1	1	
2	0	0	1	0	2	
3	0	0	1	1	3	
4	0	1	0	0	4	$C_{in} = 1$ do filtro $C_{out} = 0$
5	0	1	0	1	5	
6	0	1	1	0	6	
7	0	1	1	1	7	
8	1	0	0	0	8	$C_{in} = 0$ do filtro $C_{out} = 1$
9	1	0	0	1	9	
10	1	0	1	0	10	
11	1	0	1	1	11	
12	1	1	0	0	12	$C_{in} = 1$ do filtro $C_{out} = 1$
13	1	1	0	1	13	
14	1	1	1	0	14	
15	1	1	1	1	15	

A.3 Contraste: efeito da transposição

A decisão D2 da Seção 3.5.2 adota a ordem nativa $[C_{out}, C_{in}, H, W]$ deliberadamente. Esta seção quantifica o que mudaria caso o tensor fosse transposto para $[C_{in}, C_{out}, H, W]$ antes do *flatten*, alterando a unidade contígua de "filtro de saída inteiro" para "destino dos pesos a partir de um canal de entrada".

Aplicando `W_conv.permute(1, 0, 2, 3).flatten()` ao mesmo tensor do exemplo anterior obtém-se:

$$W_{\text{conv}}^{\mathsf{T}}\texttt{.flatten()} \;=\; [\,0,1,2,3,\;\; 8,9,10,11,\;\; 4,5,6,7,\;\; 12,13,14,15\,]. \tag{A.6}$$

Note que o vetor é uma **permutação** do anterior — contém os mesmos 16 valores, mas agora os blocos contíguos de quatro elementos correspondem a um canal de entrada visto a partir de *ambos* os filtros de saída, conforme a Tabela 14.

Tabela 14 – Mapeamento elemento a elemento com transposição prévia $[C_{in}, C_{out}, H, W]$. Compare com a Tabela 13.

Pos.	C_{in}	C_{out}	H	W	**Valor**	**Pertence ao bloco semântico**
0	0	0	0	0	0	filtro $C_{out} = 0$ a partir de $C_{in} = 0$
1	0	0	0	1	1	
2	0	0	1	0	2	
3	0	0	1	1	3	
4	0	1	0	0	8	filtro $C_{out} = 1$ a partir de $C_{in} = 0$
5	0	1	0	1	9	
6	0	1	1	0	10	
7	0	1	1	1	11	
8	1	0	0	0	4	filtro $C_{out} = 0$ a partir de $C_{in} = 1$
9	1	0	0	1	5	
10	1	0	1	0	6	
11	1	0	1	1	7	
12	1	1	0	0	12	filtro $C_{out} = 1$ a partir de $C_{in} = 1$
13	1	1	0	1	13	
14	1	1	1	0	14	
15	1	1	1	1	15	

Leitura comparativa. As Tabelas 13 e 14 contêm exatamente os mesmos 16 valores, mas em ordens diferentes. Sob a perspectiva da SampEn 1D — que mede regularidade de sub-sequências consecutivas — estas são **duas séries distintas**, e portanto a métrica pode reportar valores diferentes a partir delas. Esta sensibilidade à ordem é precisamente o que torna a decisão D2 substantiva e justifica o experimento de controle previsto na Seção 3.8.

A.4 Camada BatchNorm2d: vetores γ e β

Para uma `nn.BatchNorm2d(num_features=4)`, os parâmetros aprendíveis são dois vetores 1D de comprimento 4: a escala γ (`bn.weight`) e o deslocamento β (`bn.bias`). Na inicialização padrão do PyTorch:

$$\gamma = [1, 1, 1, 1], \qquad \beta = [0, 0, 0, 0]. \tag{A.7}$$

Após o treinamento, esses vetores evoluem para configurações como

$$\gamma \approx [1{,}23,\ 0{,}08,\ 0{,}95,\ 1{,}51], \qquad \beta \approx [-0{,}02,\ 0{,}07,\ -0{,}11,\ 0{,}04]$$

(valores ilustrativos extraídos de um *run* preliminar em PathMNIST). Por se tratar de vetores 1D, a ordem do *flatten* é trivialmente a ordem dos canais, sem ambiguidade. Os parâmetros do canal c ocupam a posição c no respectivo vetor, e os dois grupos `bn_gamma` e `bn_beta` são analisados separadamente pelos motivos expostos na Seção 3.6.1.

A.5 Reprodutibilidade

Os valores apresentados neste apêndice podem ser reproduzidos diretamente em PyTorch. O fragmento abaixo gera todos os vetores das Tabelas 12, 13 e 14:

```
import torch

# Linear (Out=2, In=3)
W_lin = torch.tensor([[1., 2., 3.],
                      [4., 5., 6.]])
print(W_lin.flatten().tolist())
# [1.0, 2.0, 3.0, 4.0, 5.0, 6.0]

# Conv2d (C_out=2, C_in=2, H=2, W=2)
W_conv = torch.arange(16).reshape(2, 2, 2, 2).float()
print(W_conv.flatten().int().tolist())
# [0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15]

# Conv2d transposed to [C_in, C_out, H, W]
print(W_conv.permute(1, 0, 2, 3).flatten().int().tolist())
# [0, 1, 2, 3, 8, 9, 10, 11, 4, 5, 6, 7, 12, 13, 14, 15]
```

A correspondência entre a regra row-major da Seção 3.5 e os valores numéricos acima encerra a discussão sobre a ordem da extração em nível operacional. Resta, para os capítulos de Resultados, examinar empiricamente quanto essa ordem afeta as trajetórias de complexidade sobre dados reais.

APÊNDICE B – Validação numérica das medidas de complexidade

Este apêndice cumpre a parte do objetivo específico 1 (Capítulo 1) referente à *validação numérica das medidas em casos analiticamente conhecidos*. As implementações descritas na seção 3.7 — complexidade LMC e *Sample Entropy* 1D e 2D — são aplicadas a distribuições e séries cujo comportamento esperado é conhecido em forma fechada ou qualitativamente, verificando-se que os valores produzidos coincidem com a teoria. Todos os resultados desta seção são reproduzíveis executando `scripts/validacao_numerica.py` (semente 42, `numpy` 1.26); para a LMC fixou-se $N = 100$ *bins*, de modo que a entropia da uniforme tem valor de referência $\log_2 N \approx 6{,}6439$ bits.

B.1 Complexidade LMC

Para a forma adotada $C = H \times D$, com H em bits e $D = \sum_i (p_i - 1/N)^2$, os dois extremos têm valor analítico exato: a distribuição *uniforme* maximiza a entropia ($H = \log_2 N$) e anula o desequilíbrio ($D = 0$), enquanto a distribuição *degenerada* (toda a massa em um único *bin*) anula a entropia ($H = 0$) e atinge $D = 1 - 1/N$; em ambos os casos $C = 0$. Uma distribuição *gaussiana* representa o regime intermediário, com $0 < H < \log_2 N$, $D > 0$ e, portanto, $C > 0$. A Tabela 15 confirma os três comportamentos.

Tabela 15 – Validação da LMC ($N = 100$ *bins*). Os casos uniforme e degenerado reproduzem os valores analíticos com precisão de máquina.

Distribuição	H (bits)	D	$C = H \times D$	Esperado
Uniforme	6,6439	0,00000	0,00000	$H = \log_2 N,\ D \approx 0,\ C \approx 0$
Degenerada	0,0000	0,99000	0,00000	$H = 0,\ D = 1 - 1/N,\ C = 0$
Gaussiana	5,4638	0,01646	0,08994	$0 < H < \log_2 N,\ D > 0,\ C > 0$

B.2 Sample Entropy 1D

Com $m = 2$ e $r = 0{,}2\,\sigma$, uma série *constante* é perfeitamente regular e produz SampEn $= 0$ por definição; uma série *periódica* é altamente previsível e produz valor próximo de zero; *ruído branco gaussiano* maximiza a irregularidade e produz um valor finito e elevado, da ordem de 2,1 — compatível com o reportado na literatura para sinais sem estrutura sob essa parametrização. A Tabela 16 confirma a ordenação esperada.

Tabela 16 – Validação da SampEn 1D ($m = 2$, $r = 0{,}2\,\sigma$, séries de 1000 amostras).

Série	SampEn	Esperado
Constante	0,0000	0 (perfeitamente regular)
Periódica (seno, $T = 20$)	0,1864	≈ 0 (previsível)
Ruído branco gaussiano	2,0934	finito e elevado (irregular)

B.3 Sample Entropy 2D

A SampEn 2D preserva os limites esperados: uma matriz *constante* produz 0, e uma matriz com *estrutura periódica* produz valor baixo. Para *ruído branco* 64×64, a tolerância padrão $r = 0{,}2\,\sigma$ satura em $+\infty$ — nenhum par de janelas $(m+1) \times (m+1)$ casa dentro da tolerância —, exatamente o comportamento que motivou a adoção de $r = 0{,}5\,\sigma$ na subseção 3.7.4; sob essa tolerância o valor torna-se finito ($\approx 6{,}46$). A validação, portanto, não apenas confirma os limites como reproduz de forma independente a justificativa metodológica para a calibração de r no caso 2D.

Tabela 17 – Validação da SampEn 2D ($m = 2$, matrizes 64×64). O caso do ruído sob $r = 0{,}2\,\sigma$ reproduz a saturação que motiva $r = 0{,}5\,\sigma$.

Matriz	SampEn 2D	Esperado
Constante	0,0000	0 (regular)
Estrutura periódica	0,8173	baixa (estruturada)
Ruído branco ($r = 0{,}2\,\sigma$)	$+\infty$	satura (motiva $r = 0{,}5\,\sigma$)
Ruído branco ($r = 0{,}5\,\sigma$)	6,4636	finito e elevado (irregular)

Em conjunto, as três validações estabelecem que as implementações reproduzem os valores analíticos exatos nos extremos (LMC nas distribuições uniforme e degenerada; SampEn em séries constantes) e a ordenação qualitativa esperada nos regimes intermediários, sustentando o uso das medidas nas análises do Capítulo 4.