Universidade de São Paulo
Faculdade de Filosofia, Ciências e Letras de Ribeirão Preto
Departamento de Computação e Matemática
Programa de Pós-Graduação em Computação Aplicada

Cássio Silva Takarada

Complexidade Estatística dos Pesos de Redes Neurais Profundas como Marcador de Overfitting

Ribeirão Preto–SP

2026

Cássio Silva Takarada

Complexidade Estatística dos Pesos de Redes Neurais Profundas como Marcador de Overfitting

Monografia apresentada à Faculdade de Filosofia, Ciências e Letras de Ribeirão Preto da Universidade de São Paulo, como parte das exigências para a obtenção do título de Mestre em Ciências.

Prof. Dr. Luiz Otávio Murta Junior

Ribeirão Preto–SP

2026

Takarada, Cássio Silva
Complexidade estatística dos pesos de redes neurais profundas como marcador de *overfitting* / Cássio Silva Takarada; orientador Luiz Otávio Murta Junior. – Ribeirão Preto, 2026.

[PREENCHER: número de folhas] f. : il.

Dissertação (Mestrado – Programa de Pós-Graduação em Computação Aplicada) – Faculdade de Filosofia, Ciências e Letras de Ribeirão Preto, Universidade de São Paulo, 2026.

1. Aprendizado profundo. 2. Complexidade estatística. 3. Entropia amostral. 4. *Overfitting*. 5. Imagens médicas. I. Murta Junior, Luiz Otávio, orient. II. Título.

[PREENCHER: CDD]

[PREENCHER: Elaborada por ..., CRB-8/....]

Cássio Silva Takarada

Complexidade Estatística dos Pesos de Redes Neurais Profundas como Marcador de *Overfitting*

Dissertação apresentada ao Programa de Pós-Graduação em Computação Aplicada da Faculdade de Filosofia, Ciências e Letras de Ribeirão Preto da Universidade de São Paulo, como parte das exigências para a obtenção do título de Mestre em Ciências.

Trabalho aprovado. Ribeirão Preto, [PREENCHER: dia] de [PREENCHER: mês] de [PREENCHER: ano].

Prof. Dr. Luiz Otávio Murta Junior
Orientador — FFCLRP/USP

[PREENCHER: Prof. Dr. Nome do 1º examinador]
[PREENCHER: instituição]

[PREENCHER: Prof. Dr. Nome do 2º examinador]
[PREENCHER: instituição]

AGRADECIMENTOS

Em primeiro lugar, agradeço a Deus pois sem Ele tudo o que sou seria em vão. Todas as oportunidades que tive e tenho de crescer e me aprimorar, tanto pessoalmente quanto profissionalmente, veio através Dele.

Subsequentemente, agradeço ao professor doutor Luiz Otávio Murta Júnior, por ter me acolhido e acreditado em mim para executar essa tão renomada pesquisa, bem como fazer parte de um grupo seleto de pessoas extremamente capacitadas.

Também, agradeço a minha família. Especialmente minha esposa e meu filho, pessoas as quais me dão força de vontade e determinação para continuar me aprimorando. Agradeço também aos meus pais, que são minha base e exemplo de pessoas e profissionais. Em adendo, agradeço ao meu irmão que me apoia em tudo que eu faço em minha vida, sempre dizendo “sim” quando preciso dele.

E por fim, agradeço aos meus amigos, que sem perceber, com seus pequenos atos, fazem minha vida mais fácil. Agradeço, especialmente, ao Alexandre Gomes da Silva, Matheus Rossato Silva e Airton Monte Serrat Borin Júnior. Os quais fizeram parte desse grupo seleto de pesquisadores que estenderam a mão sempre que precisei.

À todos, meu sincero agradecimento!

"Nada há encoberto que não haja de revelar-se,
nem oculto que não haja de saber-se."
Mateus 10:26

"Ego cogito ergo sum."
René Descartes

RESUMO

O diagnóstico de sobreajuste (*overfitting*) em redes neurais profundas depende, na prática corrente, de um conjunto de validação rotulado, representativo e suficientemente grande — condição frequentemente inviável em imagens médicas, nas quais a anotação é onerosa e exige especialista. Esta dissertação investiga se medidas de complexidade estatística calculadas exclusivamente sobre os pesos da rede, sem acesso a rótulo algum, constituem marcadores do início do sobreajuste. São consideradas a complexidade Lopez-Ruiz–Mancini–Calbet (LMC), produto da entropia de Shannon pela distância estatística ao equilíbrio, a entropia amostral (SampEn), sua variante bidimensional (SampEn2D) e a versão multiescala (MSE), acompanhadas ao longo das épocas de treinamento. Dois desenhos experimentais complementares são empregados. No primeiro, o sobreajuste é induzido por subamostragem do conjunto de treinamento sobre três subconjuntos do repositório MedMNIST, e as medidas incidem sobre os parâmetros convolucionais e de normalização em lote; nesse regime, a LMC apresenta pico que precede o mínimo da perda de validação, com antecedência da ordem de doze a dezessete épocas. No segundo, a memorização é induzida por corrupção controlada de rótulos, preservando o volume de dados, e as medidas incidem integralmente sobre os pesos da camada densa. Nesse regime, com oito execuções e controles estritamente pareados, a SampEn2D inflete $7{,}5 \pm 0{,}9$ épocas antes da degradação da acurácia de validação, com razão de amplitude de 5,7 vezes entre execuções com e sem memorização ($p = 0{,}00016$), resultado replicado na arquitetura DenseNet-121 (4,3 vezes; $p = 0{,}0016$). A complexidade LMC, contudo, não discrimina memorização na camada densa (1,1 vez; $p = 0{,}19$). Conclui-se que a capacidade de marcar o sobreajuste depende conjuntamente da medida empregada, do grupo de pesos observado e do mecanismo que origina a perda de generalização.

Palavras-chave: Complexidade estatística; Entropia amostral; Sobreajuste; Aprendizagem profunda; Imagens médicas; Memorização; Complexidade LMC.

ABSTRACT

Diagnosing overfitting in deep neural networks currently relies on a labelled validation set that is representative and sufficiently large — a condition often unattainable in medical imaging, where annotation is costly and requires expert knowledge. This dissertation investigates whether statistical complexity measures computed exclusively from network weights, without access to any label, can serve as markers of the onset of overfitting. Four measures are considered and tracked across training epochs: the Lopez-Ruiz–Mancini–Calbet (LMC) complexity, defined as the product of Shannon entropy and the statistical distance from equilibrium; sample entropy (SampEn); its two-dimensional variant (SampEn2D); and the multiscale version (MSE). Two complementary experimental designs are employed. In the first, overfitting is induced by subsampling the training set across three subsets of the MedMNIST repository, with the measures applied to convolutional and batch normalisation parameters; in this regime, LMC exhibits a peak preceding the minimum validation loss, with a lead time on the order of twelve to seventeen epochs. In the second, memorisation is induced by controlled label corruption, preserving data volume, and the measures are computed over the entire dense layer. In this regime, with eight runs and strictly paired controls, SampEn2D inflects 7.5 ± 0.9 epochs before validation accuracy degrades, with an amplitude ratio of 5.7 between runs with and without memorisation ($p = 0.00016$), a result replicated on the DenseNet-121 architecture (4.3 times; $p = 0.0016$). LMC complexity, however, fails to discriminate memorisation in the dense layer (1.1 times; $p = 0.19$). The findings indicate that the ability to mark overfitting depends jointly on the measure employed, on the group of weights observed, and on the mechanism that gives rise to the loss of generalisation.

Keywords: Statistical complexity; Sample entropy; Overfitting; Deep learning; Medical imaging; Memorisation; LMC complexity.

LISTA DE ILUSTRAÇÕES

Figura 1 – Estrutura de nível superior da ResNet-18: oito módulos nomeados em sequência. As caixas indicam o tipo de camada (azul: Conv2d; verde: BatchNorm2d; cinza: sem parâmetros; laranja: Linear). As caixas `layer1`–`layer4` são contêineres `Sequential` que ocultam sub-blocos detalhados na Figura 2. 42

Figura 2 – Expansão interna de `layer2`: dois `BasicBlock`s, o primeiro com `downsample` adicional. Cada folha colorida é um tensor com parâmetros aprendíveis, indicado pelo seu tipo e número de parâmetros. `layer3` e `layer4` têm estrutura idêntica (com canais maiores); `layer1` é mais simples (sem `downsample`). 43

Figura 3 – Ordem de varredura dentro de uma `Conv2d`, ilustrada com um tensor mínimo $[C_{out} = 2, C_{in} = 2, H = 2, W = 2]$. A leitura segue quatro *loops* aninhados, com C_{out} no nível externo e W no interno. Cada bloco contíguo de 4 elementos corresponde a um canal de entrada de um filtro de saída. 46

Figura 4 – Resumo das regras de ordenação dentro de cada tipo de tensor: todas seguem ordem *row-major*, com o índice mais à esquerda variando mais lentamente. 46

Figura 5 – Curvas de *loss* (acima) e acurácia (abaixo) por época para PathMNIST sob subamostragem do treino para 5%, 10% e 25% do tamanho original. Linhas cheias: treino; tracejadas: validação. As linhas pontilhadas verticais indicam o instante e^* em que cada execução individual atinge o mínimo de *loss* de validação. 62

Figura 6 – Trajetória da LMC (média entre grupos de camadas e entre sementes) sob subamostragem do treino. Eixo x em escala simlog para evidenciar a dinâmica inicial. Linhas pontilhadas verticais: épocas médias do mínimo de *loss* de validação por fração. 63

Figura 7 – *Lead time* da LMC ($e^*_{\text{val}} - e^{\text{peak}}_{\text{LMC}}$) sob subamostragem do treino. Barras de erro: intervalo de confiança 95% por *bootstrap* ($N = 1\,000$) sobre as três sementes. O pico da LMC precede o mínimo de *loss* de validação por ≈ 12 a ≈ 17 épocas em todas as frações estudadas. 64

Figura 8 – Trajetória da SampEn 1D (média entre grupos e entre sementes) sob subamostragem do treino. 65

Figura 9 – LMC por grupo de camadas (conv, dense, `bn_gamma`, `bn_beta`) sob subamostragem do treino. Linhas pontilhadas verticais: épocas médias do mínimo de *loss* de validação por fração. 66
Figura 10 – Curvas de *loss* e acurácia por época em PathMNIST sob variação do *weight decay*. Linhas cheias: treino; tracejadas: validação. Linhas pontilhadas verticais: e^* por execução. 68
Figura 11 – Trajetória da LMC (média entre grupos e entre sementes) sob variação do *weight decay* em PathMNIST. Marcadores verticais: épocas médias do mínimo de *loss* de validação por regime. 69
Figura 12 – *Lead time* da LMC ($e^*_{\text{val}} - e^{\text{peak}}_{\text{LMC}}$) por *weight decay*. Barras de erro: intervalo de confiança 95% por *bootstrap* ($N = 1\,000$) sobre as três sementes. 70
Figura 13 – Trajetória da SampEn 1D sob variação do *weight decay* em PathMNIST. 71
Figura 14 – LMC por grupo de camadas e por *weight decay* em PathMNIST. 72
Figura 15 – Curvas de *loss* e acurácia por época em PathMNIST sob variação da arquitetura. Linhas cheias: treino; tracejadas: validação. 74
Figura 16 – Trajetória da LMC (média entre grupos de camadas e entre sementes) sob variação da arquitetura. 75
Figura 17 – *Lead time* da LMC por arquitetura. Barras de erro: intervalo de confiança 95% por *bootstrap* ($N = 1\,000$) sobre as três sementes. 75
Figura 18 – Trajetória da SampEn 1D sob variação da arquitetura em PathMNIST. 76
Figura 19 – LMC por grupo de camadas e por arquitetura em PathMNIST 100 épocas. 77
Figura 20 – Trajetórias agregadas da LMC (média entre grupos de camadas e entre sementes) nos três datasets MedMNIST, treinados por 100 épocas com ResNet-18 e WD= 10^{-4}. Linhas pontilhadas verticais: época média do mínimo de *loss* de validação por dataset. 78
Figura 21 – *Lead time* da LMC ($e^*_{\text{val}} - e^{\text{peak}}_{\text{LMC}}$) por dataset. Barras de erro: intervalo de confiança 95% por *bootstrap* ($N = 1\,000$) sobre as três sementes. . . 79
Figura 22 – Trajetórias da LMC por grupo de camadas e por dataset (PathMNIST, OrganAMNIST, BloodMNIST), 100 épocas, 3 sementes. 80
Figura 23 – SampEn_{2D} aplicada ao mosaico 56×56 dos 64 filtros 7×7 da `conv1` (uma imagem por canal de entrada). Médias entre 3 sementes $\times$ 3 canais; intervalos de confiança 95% por *bootstrap*. 83
Figura 24 – SampEn_{2D} por canal de entrada da `conv1`, evidenciando assimetria cromática em PathMNIST. 84
Figura 25 – MSE 2D dos mosaicos 56×56 da `conv1` no *checkpoint* final: SampEn 2D versus escala de *coarse-graining* $\tau \in \{1, \ldots, 10\}$. Bandas: $\pm1\sigma$ entre os 9 mosaicos. Tolerância $r = 0{,}5\,\sigma$ fixa do mosaico original. 86

Figura 26 – Acurácias de treino, em modo de avaliação, e de validação ao longo das épocas em execução com 25 % de rótulos efetivamente errados. O cruzamento das curvas caracteriza a memorização. 88
Figura 27 – Trajetória dos três indicadores na camada densa e das curvas de validação, em execução com corrupção de rótulos. A região sombreada corresponde às épocas posteriores ao início do sobreajuste, excluídas das conclusões. 90
Figura 28 – Época do alerta e época da âncora em função do nível de corrupção de rótulos. A época do alerta é estável; a da âncora antecipa-se com o aumento da corrupção. 91
Figura 29 – Trajetória dos indicadores na camada densa da DenseNet-121, em execução com corrupção de rótulos. 93

LISTA DE TABELAS

Tabela 1 – Comparação dos trabalhos discutidos quanto à dependência de dados rotulados, à natureza temporal da leitura e ao objeto medido. 40

Tabela 2 – Datasets MedMNIST utilizados nos experimentos. 41

Tabela 3 – Tensores com parâmetros aprendíveis na ResNet-18 utilizada neste trabalho. 43

Tabela 4 – Pirâmide de decisões da extração de pesos. 49

Tabela 5 – Grupos de pesos sobre os quais as medidas de complexidade são calculadas. 49

Tabela 6 – SampEn_{1D} do grupo `conv` sob diferentes esquemas de subamostragem e ordenação, em três sementes de PathMNIST com 100 épocas. 52

Tabela 7 – Complexidade LMC do grupo `bn_`γ em função do número de intervalos do histograma, em três sementes de PathMNIST com 100 épocas. . . . 52

Tabela 8 – Comparação entre os dois desenhos experimentais. 54

Tabela 9 – Acurácia de validação final no grid principal, por conjunto de dados e por horizonte de treinamento. Valores como média ± desvio-padrão amostral entre execuções. 57

Tabela 10 – Pontos de inflexão e *lead time* sob subamostragem do treino (PathMNIST 100 épocas, média entre 3 sementes; *bn_gamma*; bootstrap 95% CI). 66

Tabela 11 – Pontos de inflexão e *lead time* sob variação de weight decay (PathMNIST 100 épocas, média entre 3 sementes; *bn_gamma*; bootstrap 95% CI). . 72

Tabela 12 – Pontos de inflexão e *lead time* por arquitetura (PathMNIST 100 épocas, média entre 3 sementes; *bn_gamma*; bootstrap 95% CI). 77

Tabela 13 – Pontos de inflexão e *lead time* entre datasets MedMNIST (PathMNIST, OrganAMNIST, BloodMNIST; 100 épocas, 3 sementes; *bn_gamma*; bootstrap 95% CI). 79

Tabela 14 – Pico da LMC por grupo de camadas e por dataset (PathMNIST 100 ep, 3 sementes; bootstrap 95% CI; épocas mostradas em escala numérica direta). 80

Tabela 15 – SampEn_{2D} sobre mosaicos 56×56 dos filtros 7×7 da `conv1` no *checkpoint* final (épocas: 100; mosaicos: 8×8 dos 64 filtros; tolerância $r = 0.5\,\sigma$; média entre 3 sementes $\times$ 3 canais de entrada; intervalo de confiança 95% por *bootstrap*). 84

Tabela 16 – SampEn_{2D} multiescala dos mosaicos 56×56 da `conv1` (mean $\pm1\sigma$ entre 3 sementes $\times$ 3 canais; $r = 0.5\,\sigma$, fixo entre escalas). 86

Tabela 17 – Evidência de memorização nas oito execuções com corrupção de rótulos e nos oito controles pareados, em ResNet-18. Acurácias em modo de avaliação. 88
Tabela 18 – Amplitude de variação dos indicadores na camada densa, em ResNet-18, com oito execuções por grupo. Valores como média ± desvio-padrão amostral; p obtido por teste de Mann-Whitney bilateral. 89
Tabela 19 – Antecedência dos indicadores em relação à queda sustentada da acurácia de validação, em épocas, nas oito execuções com corrupção em ResNet-18. 90
Tabela 20 – Época do alerta emitido pelo monitor e época da âncora, por nível de corrupção, com três sementes por nível. 91
Tabela 21 – Resultados na DenseNet-121, com oito execuções com corrupção e cinco controles pareados. 92
Tabela 22 – Comparação das duas ordens de achatamento na SampEn 1D da camada densa. 93
Tabela 23 – Efeito da correção do pareamento sobre as razões de amplitude da SampEn2D. 94
Tabela 24 – Delineamento cruzado pretendido. As duas células sem marca constituíam o objeto desta seção. 95
Tabela 25 – Amplitude de variação da LMC sobre `bn_gamma` e sobre a camada densa, sob corrupção de rótulos, com oito execuções por grupo. 96
Tabela 26 – Degradação da acurácia de validação por fração do conjunto de treino, em ResNet-18 sobre o MedNIST. A queda é a diferença entre a acurácia máxima e a final. Valores como média ± desvio-padrão amostral. . . . 97
Tabela 27 – Mapeamento elemento a elemento da camada Linear 2×3. 111
Tabela 28 – Mapeamento elemento a elemento da camada Conv2d $[2, 2, 2, 2]$. Posições do vetor, índices do tensor e bloco semântico ao qual cada elemento pertence. 112
Tabela 29 – Mapeamento elemento a elemento com transposição prévia $[C_{in}, C_{out}, H, W]$. Compare com a Tabela 28. 113
Tabela 30 – Validação da LMC ($N = 100$ *bins*). Os casos uniforme e degenerado reproduzem os valores analíticos com precisão de máquina. 117
Tabela 31 – Validação da SampEn 1D ($m = 2$, $r = 0{,}2\,\sigma$, séries de 1000 amostras). . 118
Tabela 32 – Validação da SampEn 2D ($m = 2$, matrizes 64×64). O caso do ruído sob $r = 0{,}2\,\sigma$ reproduz a saturação que motiva $r = 0{,}5\,\sigma$. 118

SUMÁRIO

1 INTRODUÇÃO 23
1.1 Contexto da análise de imagens médicas no diagnóstico clínico . . . 23
1.2 Avanços em aprendizado profundo aplicados à medicina 23
1.3 Justificativa do uso de medidas de complexidade 24
1.3.1 Justificativa prática: o ponto de vista de quem treina a rede 25
1.4 Hipótese, objetivos e escopo 26
1.5 Organização do trabalho 28

2 FUNDAMENTAÇÃO TEÓRICA 29
2.1 Sistemas complexos, auto-organização e emergência 29
2.1.1 A noção de sistema complexo 29
2.1.2 Emergência 30
2.1.3 Auto-organização 30
2.1.4 Delimitação: o que não se pretende afirmar 31
2.2 Entropia de Shannon e teoria da informação 31
2.3 Entropia Aproximada e Entropia de Amostra 32
2.4 Entropia de Amostra Bidimensional (SampEn2D) 33
2.5 Entropia Multiescala (MSE) 34
2.6 Complexidade Estatística LMC 35
2.7 Estado da arte: leitura do estado interno de redes profundas 37
2.7.1 Memorização e os dois regimes do aprendizado 37
2.7.2 Limites de generalização por normas e margens 38
2.7.3 Abordagens espectrais 38
2.7.4 Abordagens informação-teóricas e a controvérsia do gargalo de informação . 39
2.7.5 Síntese e posicionamento da proposta 40

3 METODOLOGIA 41
3.1 Conjuntos de dados 41
3.2 Arquitetura ResNet-18 41
3.2.1 Estrutura em três níveis hierárquicos 42
3.2.2 Composição interna de layer2 a layer4 42
3.2.3 Contagem agregada de tensores 43
3.3 Protocolo de treinamento 44
3.4 Checkpointing log-espaçado em memória 44
3.5 Extração ordenada dos pesos 44

3.5.1 Camada inferior: o que se herda da arquitetura e do PyTorch 44
3.5.2 Camada superior: decisões analíticas deste trabalho 47
3.6 Agrupamento dos pesos em quatro categorias 49
3.6.1 Por que separar γ e β da BatchNorm 49
3.7 Medidas de complexidade 50
3.7.1 Complexidade LMC 50
3.7.2 Entropia amostral SampEn_{1D} 50
3.7.3 Norma ℓ_2 por filtro 51
3.7.4 SampEn 2D e análise multiescala 51
3.8 Análise de robustez 51
3.8.1 Sensibilidade à ordem de subamostragem (D3) 51
3.8.2 Sensibilidade ao número de intervalos da LMC 52
3.9 Grid experimental 53
3.10 Segundo desenho experimental: memorização induzida e a camada densa 53
3.10.1 Diferenças em relação ao primeiro desenho 54
3.10.2 Protocolo de corrupção de rótulos 54
3.10.3 A camada densa como objeto de medida 55
3.10.4 Monitoramento durante o treinamento 56
3.10.5 Definição operacional da referência temporal 56

4 RESULTADOS 57
4.1 Visão Geral dos Experimentos 57
4.2 Complexidade LMC ao Longo do Treinamento 58
4.3 Entropia de Amostra dos Pesos 59
4.4 Indução de overfit por subamostragem do treino 61
4.4.1 Protocolo 61
4.4.2 Comportamento das curvas de treino 61
4.4.3 LMC como marcador antecipador 62
4.4.3.1 Detector de pico robusto e intervalo de confiança 63
4.4.3.2 Resultados após detecção robusta 63
4.4.4 SampEn como marcador complementar 64
4.4.5 Decomposição por grupo de camadas 65
4.4.6 Síntese quantitativa 66
4.5 Sensibilidade ao weight decay 67
4.5.1 Protocolo 67
4.5.2 Comportamento das curvas de treino 67
4.5.3 O pico da LMC é invariante ao *weight decay* 68
4.5.4 SampEn é insensível ao *weight decay* 70
4.5.5 Decomposição por grupo 71

4.5.6 Síntese quantitativa . . . 72
4.6 Sensibilidade à arquitetura . . . 73
4.6.1 Protocolo . . . 73
4.6.2 Desempenho preditivo e curvas de treino . . . 73
4.6.3 Invariância do pico da LMC . . . 74
4.6.4 SampEn entre arquiteturas . . . 76
4.6.5 Decomposição por grupo . . . 76
4.6.6 Síntese quantitativa . . . 77
4.7 Generalização entre datasets . . . 78
4.7.1 Trajetórias de LMC nos três datasets . . . 78
4.7.2 Quantificação do pico e do *lead time* . . . 78
4.7.3 Decomposição por grupo: onde está concentrado o anomalismo . . . 80
4.7.4 Reformulação parcial da hipótese H1 . . . 81
4.8 SampEn 2D dos filtros da camada `conv1` . . . 82
4.8.1 Por que apenas a `conv1` . . . 82
4.8.2 Construção do mosaico e calibração de r . . . 82
4.8.3 Resultados . . . 83
4.8.4 Decomposição por canal de entrada . . . 84
4.8.5 Comparação com SampEn 1D e papel complementar . . . 85
4.9 Análise multiescala (MSE 2D) dos mosaicos da `conv1` . . . 85
4.9.1 Protocolo multiescala . . . 85
4.9.2 Curvas multiescala . . . 85
4.9.3 Cruzamento de curvas e discriminação dependente de escala . . . 86
4.9.4 Implicação para análise de complexidade . . . 87
4.10 Segundo desenho: memorização induzida na camada densa . . . 87
4.10.1 Confirmação da memorização . . . 87
4.10.2 Poder de discriminação dos indicadores . . . 88
4.10.3 Antecedência em relação à degradação da validação . . . 90
4.10.4 Efeito do nível de corrupção . . . 91
4.10.5 Generalização para outra arquitetura . . . 92
4.10.6 Ablação da ordem de achatamento . . . 93
4.10.7 Sobre o pareamento dos controles . . . 94
4.10.8 Tensão com os resultados do primeiro desenho . . . 94
4.11 Delineamento cruzado: o grupo de pesos ou o mecanismo? . . . 95
4.11.1 Célula A: a LMC sobre os γ sob corrupção de rótulos . . . 96
4.11.2 Célula B: subamostragem não induz sobreajuste no MedNIST . . . 96
4.11.3 O que o delineamento parcial autoriza concluir . . . 97

5 CONCLUSÃO . . . 99
5.1 Achados do segundo desenho experimental . . . 101

5.2 Reformulação da hipótese central 102
5.3 Trabalhos Futuros 103

REFERÊNCIAS 105

APÊNDICES 109

APÊNDICE A – EXEMPLO NUMÉRICO DA ORDEM DE EXTRAÇÃO DOS PESOS 111
A.1 Camada Linear: matriz 2×3 111
A.2 Camada Conv2d: tensor $[2, 2, 2, 2]$ 112
A.3 Contraste: efeito da transposição 113
A.4 Camada BatchNorm2d: vetores γ e β 114
A.5 Reprodutibilidade 114

APÊNDICE B – VALIDAÇÃO NUMÉRICA DAS MEDIDAS DE COMPLEXIDADE 117
B.1 Complexidade LMC 117
B.2 Sample Entropy 1D 117
B.3 Sample Entropy 2D 118

1 INTRODUÇÃO

1.1 CONTEXTO DA ANÁLISE DE IMAGENS MÉDICAS NO DIAGNÓSTICO CLÍNICO

A imagem médica consolidou-se como um dos pilares do diagnóstico clínico contemporâneo. Modalidades como tomografia computadorizada, ressonância magnética, radiografia, ultrassonografia, tomografia por emissão de pósitrons e a histopatologia digital fornecem representações detalhadas de estruturas internas e teciduais que sustentam decisões de triagem, estadiamento e acompanhamento terapêutico em praticamente todas as especialidades médicas (JIANG et al., 2023). O volume de dados gerado por esses exames cresce de modo contínuo, ao mesmo tempo em que sua interpretação permanece uma tarefa que exige treinamento especializado e está sujeita a variabilidade inter e intraobservador. Esse cenário motiva o desenvolvimento de ferramentas computacionais capazes de oferecer suporte quantitativo à análise dessas imagens, notadamente em tarefas de classificação, segmentação e detecção de anomalias.

1.2 AVANÇOS EM APRENDIZADO PROFUNDO APLICADOS À MEDICINA

Nas últimas décadas o aprendizado profundo (*deep learning*, DL) emergiu como o paradigma dominante para o processamento de imagens médicas. Em particular, redes neurais convolucionais profundas, exemplificadas pela família de redes residuais introduzida por He et al. (2016), alcançaram desempenho próximo ou superior ao de especialistas humanos em diversas tarefas de classificação e detecção (JIANG et al., 2023). Esse progresso é sustentado, de um lado, pelo aumento sistemático do poder computacional e, de outro, pela disponibilização de coleções públicas padronizadas de imagens médicas que viabilizam treinamento, comparação e reprodutibilidade de modelos. Entre essas coleções destaca-se o *benchmark* MedMNIST v2 (YANG et al., 2023), que reúne dezoito conjuntos de classificação 2D e 3D oriundos de patologia, radiologia e oftalmologia, padronizados em baixa resolução para permitir prototipagem rápida sem perder representatividade das modalidades clínicas.

Apesar desses avanços, modelos profundos operam de modo essencialmente opaco do ponto de vista clínico: a relação entre os parâmetros aprendidos e as decisões de saída não é trivialmente legível, configurando o problema classicamente designado por *caixa-preta*. Levantamentos recentes apontam que essa limitação constitui hoje a principal

barreira à adoção de DL em fluxos diagnósticos sensíveis, mais relevante até que o ganho marginal de acurácia em métricas tradicionais (TENG et al., 2022). Nesse contexto, a interpretabilidade dos modelos depende não apenas de explicações *post hoc* sobre saídas individuais, mas também de instrumentos quantitativos que caracterizem o estado interno da rede durante o treinamento.

1.3 JUSTIFICATIVA DO USO DE MEDIDAS DE COMPLEXIDADE

Métricas tradicionais de avaliação — acurácia, perda de validação, área sob a curva ROC — capturam o comportamento do modelo sobre um conjunto de dados específico, mas não oferecem leitura direta sobre a organização estatística dos pesos aprendidos. Essa lacuna é particularmente visível no fenômeno do *overfitting*: redes com elevada capacidade podem memorizar o conjunto de treinamento de modo a atingir acurácia quase perfeita sobre ele, ao mesmo tempo em que generalizam mal para dados novos. Análises teóricas recentes da dinâmica de generalização em regimes de alta dimensionalidade indicam que os pesos atravessam fases qualitativamente distintas durante o treinamento, com implicações diretas sobre a capacidade preditiva do modelo (ADVANI et al., 2020), e métodos dedicados à detecção de *overfitting* em aplicações clínicas têm sido propostos como resposta prática a esse problema (ZHANG; BELL, 2025).

A presente dissertação parte da hipótese de que medidas de complexidade aplicadas diretamente aos pesos da rede podem servir como marcadores objetivos da maturação do treinamento e do início do sobreajuste. Duas famílias de medidas dão sustentação a essa abordagem. A primeira é a Entropia de Amostra (*Sample Entropy*, SampEn) introduzida por Richman e Moorman (2000) como refinamento da Entropia Aproximada de Pincus (1991); SampEn quantifica, sem viés sistemático associado a contagens de auto-coincidência, a regularidade de uma sequência de valores e tem aplicação consolidada na análise de sinais fisiológicos. Sua extensão bidimensional, SampEn2D, foi formalizada por Silva et al. (2016) para caracterizar a irregularidade de texturas espaciais em imagens biomédicas, e é diretamente aplicável à matriz de pesos de uma camada convolucional. A análise multiescala (Multiscale Entropy, MSE) proposta por Costa et al. (2002) complementa SampEn ao revelar regularidades que se manifestam em diferentes resoluções da mesma sequência ou matriz.

A segunda família é a complexidade estatística de López-Ruiz, Mancini e Calbet (LÓPEZ-RUIZ et al., 1995), definida pelo produto entre uma medida de incerteza, tipicamente a entropia de Shannon, e uma medida de desequilíbrio em relação à distribuição uniforme. Diferentemente de medidas puramente entrópicas, a complexidade LMC anula-se nos extremos de ordem perfeita e desordem perfeita, atingindo valores máximos em

regimes intermediários de auto-organização (ANTENEODO; PLASTINO, 1996). Aplicada à distribuição dos pesos de uma rede neural, espera-se que ela descreva quantitativamente a transição entre o estado inicial aleatório e o estado treinado. A combinação entre SampEn (sensível à estrutura sequencial e espacial dos pesos) e LMC (sensível à forma da distribuição marginal) constitui o eixo metodológico desta investigação.

1.3.1 Justificativa prática: o ponto de vista de quem treina a rede

A justificativa apresentada até aqui é de natureza metodológica: as medidas de complexidade oferecem uma leitura dos pesos que as métricas de desempenho não oferecem. Há, porém, uma segunda justificativa, de natureza prática, que motiva este trabalho de modo mais imediato e é formulada deliberadamente do ponto de vista de quem desenvolve e treina a rede.

A dependência atual dos dados rotulados

Para saber se uma rede aprendeu ou apenas memorizou, o desenvolvedor depende hoje, integralmente, dos dados. É preciso construir conjuntos de treino, validação e teste bem particionados, corretamente rotulados e representativos da população de interesse. Cada um desses requisitos custa tempo e recursos, e em imagens médicas frequentemente esbarra na indisponibilidade de especialistas para a anotação. O diagnóstico do treinamento é, portanto, função do orçamento de anotação disponível — e não uma propriedade que se possa ler diretamente do modelo.

O procedimento padrão para decidir quando interromper o ajuste, a parada antecipada, monitora o erro em um conjunto de validação separado (PRECHELT, 1998). O procedimento é sólido, mas transfere ao conjunto de validação toda a responsabilidade pelo diagnóstico: se ele é pequeno, desbalanceado ou pouco representativo, a estimativa do momento de parada torna-se ruidosa, e o desenvolvedor não dispõe de sinal alternativo com que confrontá-la. Em outras palavras, justamente no regime de poucos dados — aquele em que o sobreajuste é mais provável — o instrumento de medida é o menos confiável.

O que muda com um indicador calculado sobre os pesos

As medidas investigadas nesta dissertação são calculadas exclusivamente a partir dos pesos. Não consomem imagem, não consomem rótulo e não dependem de nenhuma partição. Caso sejam capazes de sinalizar a transição para o regime de memorização, o desenvolvedor passa a dispor de uma segunda leitura do treinamento, obtida por caminho independente daquele do conjunto de validação. As duas leituras podem então ser confrontadas: quando concordam, a decisão de parada ganha confiança; quando discordam, há indício de que a validação não é representativa.

Note-se que a proposta não é substituir a parada antecipada clássica, cuja fundamentação é sólida, mas acrescentar-lhe uma fonte de evidência independente.

Casos de uso

1. **Decidir quando interromper o treinamento.** Um aviso emitido antes da degradação observável na validação amplia a janela de decisão, em lugar de constatar a perda depois de consumada.

2. **Economizar recursos computacionais.** Detectar que a rede deixou de aprender evita épocas de treinamento que não trarão ganho, com impacto direto no custo de processamento.

3. **Comparar arquiteturas sem ampliar a anotação.** Como a medida não consome dados rotulados, a comparação entre arquiteturas candidatas não exige a ampliação do conjunto de validação.

4. **Diagnosticar quando a validação é pequena.** Em cenários nos quais o conjunto de validação é pequeno demais para ser confiável, um indicador independente fornece evidência adicional — precisamente o cenário típico em imagens médicas.

Entrega prática e delimitação

A contribuição não se esgota na constatação empírica. Entrega-se um monitor implementado em PyTorch, acoplável ao laço de treinamento de terceiros, que calcula os indicadores a cada época e devolve um estado do aprendizado, conforme descrito na Seção 3.10.4. O custo computacional é baixo quando a medida incide sobre a camada densa.

Registre-se, por honestidade, que a utilidade prática aqui descrita é *condicional* ao sucesso empírico dos indicadores, e que os resultados do Capítulo 4 mostram que esse sucesso não é uniforme: depende da medida empregada, do grupo de pesos observado e do mecanismo que origina a perda de generalização. As implicações dessa delimitação para o uso prático são discutidas no Capítulo 5.

1.4 HIPÓTESE, OBJETIVOS E ESCOPO

A hipótese central deste trabalho é que a complexidade estatística dos pesos de uma rede neural profunda evolui de modo sistemático durante o treinamento e constitui um marcador objetivo do início do *overfitting*. Mais especificamente, postula-se que a trajetória das medidas LMC e SampEn ao longo dos passos de otimização exibe inflexão

não monotônica, e que essa inflexão precede ou coincide com a saturação da acurácia de validação.

A pesquisa adota um **escopo deliberadamente restrito** a fim de permitir o controle das variáveis de interesse e a reprodutibilidade plena dos experimentos:

- **Arquitetura única:** ResNet-18 (HE et al., 2016), escolhida por sua importância histórica, profundidade moderada e papel de *baseline* consagrado em classificação de imagens médicas.
- **Conjuntos de dados:** três coleções 2D do *benchmark* MedMNIST v2 (YANG et al., 2023) — PathMNIST (histopatologia colorretal), OrganAMNIST (segmentação axial de órgãos abdominais em tomografia computadorizada, reformulada para classificação) e BloodMNIST (microscopia de células sanguíneas).
- **Tarefa única:** classificação multiclasse, excluindo-se explicitamente segmentação semântica, detecção e tarefas ordinais.

Arquiteturas alternativas como U-Net e DenseNet, conjuntos de dados de maior escala como NIH ChestX-ray14 e TCIA, e tarefas adicionais como segmentação — mencionados no projeto de qualificação — ficam relegados a trabalhos futuros (Capítulo 5). Esse recorte permite que cada combinação de *dataset* e número de épocas seja replicada em múltiplas sementes aleatórias (3 sementes $\times$ 3 horizontes $\times$ 3 conjuntos $=$ 27 execuções completas), totalizando um grid suficiente para distinguir efeitos sistemáticos de ruído estocástico.

Os objetivos específicos são:

1. Implementar SampEn1D, SampEn2D, MSE e a complexidade LMC com validação numérica em casos analiticamente conhecidos (distribuições uniforme, gaussiana e séries periódicas), conforme o Apêndice B.
2. Extrair os pesos da ResNet-18 a cada *checkpoint* log-espaçado ao longo do treinamento (cerca de 100 pontos por execução), agrupando-os por tipo de camada (convolucional, densa, parâmetros γ e β do *batch normalization*) e excluindo os *biases* da análise.
3. Calcular a trajetória das medidas de complexidade para cada grupo e cada execução, e confrontá-la com a evolução da perda e da acurácia de validação.
4. Avaliar se a inflexão das trajetórias LMC e SampEn coincide, antecipa ou sucede o início observável do sobreajuste, e comparar os comportamentos entre os três conjuntos de dados.

1.5 ORGANIZAÇÃO DO TRABALHO

O restante desta dissertação está organizado em quatro capítulos. O Capítulo 2 apresenta a fundamentação teórica das medidas de complexidade utilizadas (Entropia de Shannon, ApEn, SampEn, SampEn2D, MSE, complexidade LMC) e situa-as no contexto da literatura de redes neurais profundas e análise de séries de pesos. O Capítulo 3 descreve a arquitetura, os conjuntos de dados, o protocolo de treinamento e *checkpointing*, o esquema de agrupamento de parâmetros e os parâmetros adotados para cada medida (m, r, número de *bins*, escalas de coarse-graining). O Capítulo 4 apresenta as trajetórias de complexidade observadas no grid de 27 execuções, a análise por grupo de camadas e a correlação com indicadores tradicionais de generalização. O Capítulo 5 sintetiza as evidências obtidas em relação à hipótese central, discute as limitações do recorte adotado e indica direções para extensões futuras envolvendo arquiteturas, modalidades de imagem e tarefas adicionais.

2 FUNDAMENTAÇÃO TEÓRICA

Este capítulo apresenta o aparato conceitual e operacional sobre o qual se constrói a metodologia da dissertação. A seção 2.2 retoma a entropia de Shannon e seus desdobramentos em entropia diferencial e divergências, dando base formal às medidas que vêm a seguir. A seção 2.3 percorre a transição da Entropia Aproximada (ApEn) para a Entropia de Amostra (SampEn), explicitando os vieses que motivaram o refinamento e a interpretação probabilística de SampEn como log-verossimilhança condicional. As seção 2.4 e seção 2.5 estendem SampEn ao domínio espacial bidimensional e ao plano multiescala, respectivamente, fornecendo as duas leituras complementares sobre a matriz de pesos de uma camada convolucional. Por fim, a seção 2.6 apresenta a complexidade estatística de López-Ruiz, Mancini e Calbet (LMC), discute a controvérsia sobre normalização e intensividade que se seguiu à proposta original e justifica a convenção $C = H \times D$ adotada no restante do trabalho.

2.1 SISTEMAS COMPLEXOS, AUTO-ORGANIZAÇÃO E EMERGÊNCIA

Esta seção fixa o vocabulário conceitual sobre o qual as medidas das seções seguintes se apoiam. A justificativa para sua presença é direta: o restante desta dissertação afirma que os pesos de uma rede em treinamento apresentam regimes de *auto-organização*, e essa afirmação não tem conteúdo verificável enquanto o termo não for definido.

2.1.1 A noção de sistema complexo

Um sistema complexo pode ser informalmente caracterizado como uma rede de muitos componentes que interagem entre si e cujo comportamento coletivo surge e evolui por auto-organização (SAYAMA, 2015). A caracterização carrega duas exigências que não são triviais. A primeira é a *multiplicidade* de componentes interagentes. A segunda, mais restritiva, é que a informação relevante do sistema resida nas *relações* entre as partes, e não nas partes isoladamente; se o comportamento do todo for recuperável pela simples soma dos comportamentos individuais, o sistema é agregado, não complexo.

Uma rede neural profunda em treinamento satisfaz ambas as exigências. Os milhões de pesos constituem componentes que interagem indiretamente, pela retropropagação do gradiente, e nenhum peso isolado codifica a função aprendida — o conteúdo do modelo está na configuração conjunta. Essa observação não é retórica: é ela que autoriza aplicar

ao treinamento o instrumental desenvolvido para sistemas complexos, em lugar de tratar a rede apenas como um problema de otimização de alta dimensão.

2.1.2 Emergência

Denomina-se *emergente* a propriedade que se manifesta no nível macroscópico do sistema e que não é redutível às propriedades dos componentes isolados (SAYAMA, 2015). O conceito exige, portanto, a distinção explícita de dois níveis de descrição: o microscópico, dos componentes, e o macroscópico, do comportamento observável.

Na presente dissertação essa distinção é operacional, e não apenas conceitual. O nível microscópico é o dos valores individuais dos pesos; o macroscópico é o da capacidade de generalização do modelo, aferida em dados não vistos. A hipótese central pode então ser reformulada nesses termos: pretende-se verificar se uma estatística calculada sobre o nível microscópico — a distribuição e a organização dos pesos — acompanha, e eventualmente antecipa, a transição de regime observada no nível macroscópico.

2.1.3 Auto-organização

Chama-se *auto-organização* ao processo pelo qual um sistema desenvolve estrutura macroscópica sem que essa estrutura seja imposta por um controle externo ou por um plano centralizado (SAYAMA, 2015). Emergência e auto-organização são conceitos distintos, ainda que frequentemente tratados como sinônimos: a primeira descreve uma relação entre níveis de descrição em um instante, e a segunda descreve a evolução temporal do sistema.

O treinamento por descida de gradiente é, nessa acepção, um processo de auto-organização. Nenhum agente externo especifica o valor que cada peso deve assumir; os valores resultam da aplicação iterada de uma regra local de atualização, e a estrutura que se observa ao final — filtros que respondem a padrões visuais, camadas que se especializam — não foi projetada peso a peso.

Interessa particularmente a este trabalho a observação de que sistemas em auto-organização não evoluem de modo homogêneo: eles frequentemente apresentam *transições de regime*, nas quais o comportamento qualitativo muda em intervalos relativamente curtos (SAYAMA, 2015). É exatamente essa a estrutura que a hipótese desta dissertação pressupõe. Se o treinamento consistisse em um processo homogêneo de melhoria gradual, não haveria transição a ser detectada, e a busca por um marcador do início do sobreajuste careceria de objeto. A existência de dois regimes sucessivos no aprendizado — um em que a rede extrai regularidades generalizáveis e outro em que passa a memorizar exemplos inconsistentes — é documentada empiricamente por Arpit et al. (2017) e constitui o pressuposto factual da proposta.

2.1.4 Delimitação: o que não se pretende afirmar

Convém delimitar o alcance do enquadramento para evitar leitura excessiva. O aparato de sistemas complexos é empregado aqui em sentido *descritivo*, e não como apelo a um mecanismo explicativo. Não se afirma que o treinamento de uma rede neural seja formalmente equivalente a algum dos modelos canônicos da área — autômatos celulares, sistemas de reação-difusão ou redes dinâmicas (SAYAMA, 2015) —, nem se pretende derivar as medidas empregadas a partir de primeiros princípios da teoria de sistemas complexos.

O que o enquadramento fornece é mais modesto e suficiente: a legitimidade de tratar a configuração dos pesos como estado de um sistema cuja organização macroscópica varia no tempo, e cujas transições podem, em princípio, ser detectadas por estatísticas calculadas sobre esse estado. As medidas específicas utilizadas provêm da teoria da informação e da análise de séries, apresentadas nas seções seguintes, e sua validade é estabelecida empiricamente no Capítulo 4, não por filiação teórica.

2.2 ENTROPIA DE SHANNON E TEORIA DA INFORMAÇÃO

A entropia de Shannon (SHANNON, 1948) é a pedra angular sobre a qual se assenta toda a discussão subsequente. Para uma variável aleatória discreta X que assume valores no alfabeto finito $\mathcal{X} = \{x_1, x_2, \ldots, x_N\}$ com distribuição de probabilidade $P = (p_1, p_2, \ldots, p_N)$, a entropia é definida por

$$H(X) = -\sum_{i=1}^{N} p_i \log_2 p_i, \tag{2.1}$$

adotando-se, por convenção, $0 \log_2 0 = 0$. A escolha do logaritmo na base 2 implica que H é medida em bits, interpretação diretamente associada ao número médio mínimo de dígitos binários necessário para codificar uma realização de X. A entropia satisfaz $0 \leq H(X) \leq \log_2 N$, com extremos alcançados, respectivamente, pela distribuição degenerada (existe i tal que $p_i = 1$) e pela distribuição uniforme ($p_i = 1/N$ para todo i). Caracterizações axiomáticas mostram que essas propriedades, junto da continuidade e da aditividade, determinam H a menos de um fator multiplicativo (COVER; THOMAS, 2006).

Quando X é uma variável contínua com função de densidade de probabilidade f, a generalização natural — a entropia diferencial — é dada por

$$h(X) = -\int_{\mathcal{X}} f(x) \log_2 f(x)\, dx, \tag{2.2}$$

sempre que a integral exista. Diferentemente da versão discreta, $h(X)$ pode assumir valores negativos e não é invariante sob mudança de escala, o que limita seu uso direto como índice de "incerteza". Em aplicações práticas com pesos de redes neurais, trabalha-se com a versão discretizada por meio de histogramas com N bins, recuperando a forma da Equação 2.1 a um custo controlado de viés e variância (COVER; THOMAS, 2006).

Uma medida de dissimilaridade entre duas distribuições P e Q sobre o mesmo alfabeto é a divergência de Kullback–Leibler

$$D_{\mathrm{KL}}(P\|Q) = \sum_{i=1}^{N} p_i \log_2 \frac{p_i}{q_i}, \tag{2.3}$$

que é não negativa e nula se, e somente se, $P = Q$. A Equação 2.3 é central nesta dissertação porque a noção de "desequilíbrio" subjacente à complexidade LMC pode ser interpretada como uma medida de afastamento entre P e a distribuição de referência (uniforme), tema retomado na seção 2.6.

2.3 ENTROPIA APROXIMADA E ENTROPIA DE AMOSTRA

O salto da teoria da informação para a análise de séries temporais finitas exige um estimador de regularidade que opere com poucos pontos e seja robusto a ruído moderado. A Entropia Aproximada (ApEn), introduzida por Pincus (1991), foi a primeira proposta a preencher esse papel para sinais fisiológicos. Dada uma série $\mathbf{u} = (u_1, u_2, \ldots, u_N)$, fixa-se um comprimento de embedding m e uma tolerância r e constroem-se os vetores $\mathbf{x}_i = (u_i, u_{i+1}, \ldots, u_{i+m-1})$ com $1 \le i \le N - m + 1$. Para cada i define-se

$$C_i^m(r) = \frac{\#\{j : d[\mathbf{x}_i, \mathbf{x}_j] \le r\}}{N - m + 1}, \tag{2.4}$$

onde $d[\cdot,\cdot]$ é a distância de Chebyshev (máximo das diferenças absolutas componente a componente) e a contagem inclui o caso $j = i$ (*self-match*). A ApEn é então

$$\mathrm{ApEn}(m, r, N) = \Phi^m(r) - \Phi^{m+1}(r), \quad \Phi^m(r) = \frac{1}{N - m + 1} \sum_{i=1}^{N-m+1} \ln C_i^m(r). \tag{2.5}$$

A inclusão de *self-matches* em $C_i^m(r)$ é simultaneamente o recurso que viabiliza a definição (evita logaritmo de zero) e a fonte de seus dois principais defeitos: (i) ApEn é sistematicamente enviesada para valores menores em séries curtas, e (ii) sua consistência relativa — a propriedade de que, ao se comparar duas séries em um mesmo r, a ordem dos valores se preserva quando r varia — não é garantida (RICHMAN; MOORMAN, 2000; DELGADO-BONAL; MARSHAK, 2019). A literatura subsequente documenta cenários em que classificações fisiológicas baseadas em ApEn se invertem ao se mudar a tolerância, comprometendo seu uso como marcador objetivo (YENTES et al., 2013; DELGADO-BONAL; MARSHAK, 2019).

A Entropia de Amostra (SampEn), proposta por Richman e Moorman (2000), remove essas limitações por construção. Em vez de calcular o logaritmo médio de probabilidades locais, conta-se globalmente o número de pares de templates próximos. Sejam

$$B^m(r) = \#\{(i,j) : i < j,\ d[\mathbf{x}_i, \mathbf{x}_j] \le r\}, \tag{2.6}$$

$$A^m(r) = \#\{(i,j) : i < j,\ d[\mathbf{x}_i, \mathbf{x}_j] \le r,\ |u_{i+m} - u_{j+m}| \le r\}, \tag{2.7}$$

isto é, $B^m(r)$ conta pares de janelas de comprimento m próximas e $A^m(r)$ conta os pares dessas janelas que permanecem próximas após um passo adicional. A SampEn é dada por

$$\mathrm{SampEn}(m, r, N) = -\ln \frac{A^m(r)}{B^m(r)}. \tag{2.8}$$

Pela construção, ambas as contagens excluem o par (i, i), eliminando o viés associado às auto-coincidências. A interpretação de Equação 2.8 é direta e instrutiva: SampEn é o negativo do logaritmo da probabilidade condicional de que duas janelas próximas em comprimento m permaneçam próximas em comprimento $m+1$. Valores baixos correspondem a séries muito regulares (a continuação é altamente previsível); valores altos, a séries irregulares (continuação imprevisível).

A Equação 2.8 herda independência tanto de N quanto da ordem dos pares por ser uma estatística baseada em razão de contagens globais. Demonstrou-se ainda que, em uma ampla família de processos estocásticos, SampEn possui consistência relativa entre tolerâncias, propriedade que ApEn não satisfaz (RICHMAN; MOORMAN, 2000). Por outro lado, a literatura recente registra cenários particulares de processos do tipo MIX contaminados por ruído em que mesmo SampEn pode falhar essa consistência, recomendando cautela ao se interpretar diferenças finas entre séries de naturezas distintas (DELGADO-BONAL; MARSHAK, 2019).

A escolha dos parâmetros m e r é prática consagrada na literatura. Pela análise sistemática de Yentes et al. (2013) sobre séries curtas, recomenda-se $m = 2$ e r entre 0,1 e 0,25 do desvio padrão da série, com $N \geq 200$ para evitar instabilidade estatística. Esta dissertação adota $m = 2$ e $r = 0{,}2 \times \sigma$, com σ tomado como desvio padrão populacional (`ddof`=0), em consonância com a convenção do grupo de pesquisa e com o intervalo recomendado pela literatura. Ressalva-se que tensores pequenos — em particular os parâmetros γ e β do *batch normalization* das camadas iniciais — podem ter comprimento inferior a $N = 200$, regime em que a estimativa de SampEn é menos estável; esse limite é levado em conta na interpretação desses grupos.

2.4 ENTROPIA DE AMOSTRA BIDIMENSIONAL (SAMPEN2D)

A extensão bidimensional da SampEn surge da observação de que pesos de camadas convolucionais e parâmetros de matrizes têm estrutura espacial: a vizinhança de um peso é tão informativa quanto sua sequência linear, e o domínio natural para análise é a matriz, não o vetor. Silva et al. (2014) apresentaram uma primeira formulação, validada posteriormente em Silva et al. (2016) sobre imagens de textura sintéticas, do banco Brodatz e de cortes histológicos de nervo sural, demonstrando que SampEn2D recupera as propriedades qualitativas de SampEn 1D ao mesmo tempo em que incorpora a dependência bidimensional.

Seja $\mathbf{W} \in \mathbb{R}^{H\times W}$ uma matriz de pesos extraída de uma camada da rede. Fixe-se um tamanho de janela m e uma tolerância r. As janelas $m \times m$ centradas em (i, j) formam a coleção $\mathcal{V}_m = \{\mathbf{V}_{i,j}^{(m)} : 1 \le i \le H - m, 1 \le j \le W - m\}$. Para uma janela maior $(m+1) \times (m+1)$, analogamente, escreve-se $\mathcal{V}_{m+1}$. Por construção, restringe-se às posições (i, j) tais que ambas as janelas m e $m + 1$ caibam integralmente em $\mathbf{W}$, garantindo emparelhamento entre $\mathcal{V}_m$ e $\mathcal{V}_{m+1}$. Em analogia com as Equação 2.6 e Equação 2.7, definem-se

$$B_{2\mathrm{D}}^{m}(r) = \#\{(p, q) : p \neq q,\ d[\mathbf{V}_p^{(m)}, \mathbf{V}_q^{(m)}] \le r\}, \tag{2.9}$$

$$A_{2\mathrm{D}}^{m}(r) = \#\{(p, q) : p \neq q,\ d[\mathbf{V}_p^{(m+1)}, \mathbf{V}_q^{(m+1)}] \le r\}, \tag{2.10}$$

em que p, q percorrem as posições válidas e $d[\cdot, \cdot]$ é a distância de Chebyshev sobre a janela vista como vetor. A *Sample Entropy 2D* é

$$\mathrm{SampEn2D}(m, r, \mathbf{W}) = -\ln \frac{A_{2\mathrm{D}}^{m}(r)}{B_{2\mathrm{D}}^{m}(r)}. \tag{2.11}$$

A interpretação probabilística replica a do caso unidimensional: SampEn2D é o negativo do logaritmo da probabilidade de que duas janelas $m \times m$ próximas tenham vizinhanças que permaneçam próximas quando a janela é estendida em uma linha e uma coluna.

A literatura aponta dois aspectos práticos relevantes. Primeiro, a SampEn2D pode produzir valores indefinidos para matrizes pequenas quando $A_{2\mathrm{D}}^{m}(r) = 0$, problema que motivou propostas alternativas baseadas em entropias de dispersão e fuzzificação. Segundo, o custo computacional cresce quadraticamente com o número de janelas válidas, tornando a estimativa custosa para matrizes grandes (SILVA et al., 2016). Para os fins desta dissertação, o tamanho típico das matrizes de uma camada convolucional na ResNet-18 mantém-se confortavelmente acima do regime patológico identificado pela literatura, e a SampEn2D é aplicada diretamente, sem recurso a substitutos.

2.5 ENTROPIA MULTIESCALA (MSE)

A SampEn captura irregularidade em uma escala fixa. No entanto, sistemas com correlações de longo alcance — batimentos cardíacos saudáveis, ruído $1/f$, dinâmica de redes complexas — apresentam estrutura em múltiplas escalas temporais simultaneamente. A Entropia Multiescala (MSE), proposta por Costa et al. (2002) e sistematizada em Costa et al. (2005), lê esse fenômeno por meio de uma sequência de granulações grosseiras (*coarse-grainings*) da série original.

Dada uma série $\mathbf{u}$ e um fator de escala $\tau \in \mathbb{N}^*$, constrói-se a série granulosa

$$y_j^{(\tau)} = \frac{1}{\tau} \sum_{i=(j-1)\tau+1}^{j\tau} u_i, \quad 1 \le j \le \lfloor N/\tau \rfloor, \tag{2.12}$$

isto é, médias de blocos não sobrepostos de comprimento τ. A escala $\tau = 1$ recupera a série original. Para cada τ, calcula-se SampEn da série granulosa, formando o perfil multiescala $\{\text{SampEn}(m, r, y^{(\tau)}) : \tau = 1, 2, \ldots, \tau_{\max}\}$.

Um detalhe metodológico crítico: a tolerância r é fixada uma única vez a partir do desvio padrão da série *original* e mantida constante em todas as escalas, conforme prescrição de Costa et al. (2005). Recomputar r em cada escala invalidaria a comparação entre escalas, pois mudanças no perfil de complexidade ficariam confundidas com a renormalização local. A interpretação qualitativa da curva SampEn versus τ separa três classes principais: ruído branco (entropia decresce monotonicamente), ruído $1/f$ (entropia constante ao longo das escalas) e periódicos (entropia próxima de zero em todas as escalas). Sistemas fisiológicos saudáveis apresentam padrão similar ao $1/f$, enquanto patologias frequentemente colapsam para perfis monotonicamente decrescentes (COSTA et al., 2005).

Esta dissertação aplica MSE 1D ao vetor de pesos achatado e, na extensão proposta por Silva et al. (2016) para SampEn2D, MSE 2D às matrizes via granulação por blocos $\tau \times \tau$. Em ambos os casos, r é mantido fixo em $0{,}2 \times \sigma$ da matriz original, com σ calculado em população.

2.6 COMPLEXIDADE ESTATÍSTICA LMC

A entropia, isoladamente, não é uma boa medida de complexidade. Distribuições uniformes (entropia máxima) são tão simples quanto distribuições degeneradas (entropia mínima), no sentido de que ambas são facilmente descritíveis e desprovidas de estrutura interna. López-Ruiz et al. (1995) — doravante LMC — propuseram, como remédio, uma medida que se anula em ambos os extremos e atinge valores máximos em regimes intermediários de auto-organização. Para uma distribuição $P = (p_1, \ldots, p_N)$, define-se o *desequilíbrio*

$$D(P) = \sum_{i=1}^{N} \left(p_i - \frac{1}{N} \right)^2, \tag{2.13}$$

isto é, o quadrado da distância L_2 até a distribuição uniforme. A complexidade estatística LMC é o produto

$$C(P) = H(P) \times D(P), \tag{2.14}$$

em que H é a entropia de Shannon, dada pela Equação 2.1. Como H é máxima e D é nula sob a distribuição uniforme, e H é nula e D é máxima sob a distribuição degenerada, C se anula em ambos os extremos por construção. Para distribuições intermediárias, C assume valores estritamente positivos, refletindo simultaneamente incerteza e afastamento do equilíbrio (LÓPEZ-RUIZ et al., 1995).

A definição original gerou debate intenso. Anteneodo e Plastino (1996) demonstraram, no contexto de ensembles físicos, que C na forma Equação 2.14 *não* é uma quantidade

intensiva: ao se duplicar o tamanho do sistema, C não satisfaz a relação de escala esperada de uma medida termodinâmica genuína. Esse fato limita a transferibilidade direta de C entre sistemas de tamanhos distintos e motivou a busca por refinamentos. Feldman e Crutchfield (1998), em uma revisão crítica das medidas de complexidade estatística disponíveis na época, articularam três desideratos: a medida deve (i) anular-se nos extremos de ordem e desordem perfeitas, (ii) ser intensiva, e (iii) capturar a presença de estrutura correlacional em escalas relevantes do sistema.

A resposta mais influente a essas críticas é a complexidade estatística generalizada (SCM, *Statistical Complexity Measure*), introduzida por Lamberti et al. (2004) e desenvolvida por Rosso et al. (2010). Em vez do produto $H \times D$, define-se

$$C_{\mathrm{SCM}}(P) = Q_J(P, P_e) \cdot H(P)/H_{\max}, \tag{2.15}$$

em que $H_{\max} = \log_2 N$ normaliza a entropia, P_e é a distribuição de equilíbrio (tipicamente uniforme), e $Q_J(P, P_e)$ é o desequilíbrio em divergência de Jensen-Shannon, normalizado de modo que $0 \leq Q_J \leq 1$. A construção Equação 2.15 é intensiva, limitada ao intervalo $[0, 1]$ e aplicável a uma variedade de sistemas dinâmicos contínuos e discretos.

Apesar das vantagens formais da SCM, esta dissertação adota a forma original Equação 2.14 — $C = H \times D$ em bits, sem normalização — por três razões metodológicas que merecem explicitação:

1. **Comparação intra-modelo, não inter-sistema.** O objeto de análise são as trajetórias de complexidade dos pesos de *uma mesma rede* em *um mesmo grupo de camadas* ao longo do treinamento. As comparações são pareadas por *checkpoint*, *seed* e dataset; o argumento de intensividade de Anteneodo e Plastino (1996), que diz respeito à escalonamento entre sistemas de tamanhos distintos, não é ativado nesse desenho experimental.

2. **Sensibilidade a transições intermediárias.** A forma $H \times D$ é sensível justamente ao regime que interessa à hipótese central — a transição entre o estado inicial aleatório e o estado treinado. Versões normalizadas saturam nas extremidades do intervalo $[0, 1]$, comprimindo as diferenças que se busca medir. A versão não normalizada preserva a granularidade necessária para detectar inflexões sutis na trajetória.

3. **Convenção do grupo de pesquisa.** Trabalhos anteriores do mesmo grupo (SILVA et al., 2016; SILVA; JUNIOR, 2012) adotam a convenção $H \times D$ em bits, sem normalização, com binarização adaptativa da forma $N = \min(100, \max(10, n/5))$, onde n é o número de amostras. Manter essa convenção preserva a comparabilidade direta entre os resultados desta dissertação e os da literatura imediata.

A normalização adaptativa do número de bins N é especialmente relevante para a aplicação a pesos de redes neurais, onde o número de parâmetros varia ordens de grandeza

entre camadas: tipicamente poucas centenas em camadas iniciais e dezenas de milhares em camadas profundas. A regra $N = \min(100, \max(10, n/5))$ garante resolução suficiente para camadas pequenas sem incorrer em viés de subamostragem em camadas grandes.

A combinação entre LMC (sensível à forma da distribuição marginal dos pesos) e SampEn (sensível à estrutura sequencial e espacial) fornece, portanto, dois ângulos complementares sobre o estado interno da rede ao longo do treinamento. Os parâmetros operacionais adotados, junto da fundamentação aqui apresentada, são retomados em detalhe no Capítulo 3.

2.7 ESTADO DA ARTE: LEITURA DO ESTADO INTERNO DE REDES PROFUNDAS

Esta seção discute os trabalhos que se aproximam do problema desta dissertação. O critério de seleção adotado foi a existência de alguma tentativa de caracterizar o estado de generalização de uma rede a partir de seu *interior* — pesos, representações ou dinâmica de treinamento — em lugar de aferi-lo exclusivamente pelo desempenho em dados rotulados. A Seção 2.7.1 revisa o que se sabe sobre memorização. A Seção 2.7.2 discute a família de limites baseados em normas e margens. A Seção 2.7.3 trata das abordagens espectrais. A Seção 2.7.4 apresenta a família informação-teórica e a controvérsia que a acompanha. A Seção 2.7.5 sintetiza e posiciona a proposta.

2.7.1 Memorização e os dois regimes do aprendizado

Zhang et al. (2017) demonstraram que redes convolucionais de grande porte ajustam perfeitamente rótulos atribuídos ao acaso, e que esse comportamento persiste sob regularização explícita. O resultado é duplamente relevante para esta dissertação: estabelece que a capacidade de memorização não é acidente, mas propriedade das arquiteturas usuais, e fornece o protocolo de indução por corrupção controlada de rótulos adotado no Capítulo 3. A limitação, do ponto de vista aqui assumido, é que o diagnóstico permanece ancorado na comparação entre desempenho de treino e de teste.

Arpit et al. (2017) refinam o quadro ao mostrar que memorização e aprendizado de padrões não são simultâneos: redes tendem a aprender primeiro as regularidades simples e só depois memorizar os exemplos ruidosos. A existência de dois regimes sucessivos, e não de um processo homogêneo, é o pressuposto que torna plausível a hipótese desta dissertação — se há transição, pode haver assinatura da transição. Os autores, contudo, caracterizam os regimes por métricas que dependem dos dados, não da estrutura dos pesos.

Power et al. (2022) descrevem o fenômeno de *grokking*, em que a generalização emerge muito depois do ajuste completo do treino, às vezes após longo período de es-

tagnação da validação. O fenômeno constitui contraexemplo aos critérios ingênuos de parada antecipada: uma interrupção baseada apenas na estagnação eliminaria justamente o regime em que a generalização acabaria por surgir. Um indicador que leia o estado interno, e não apenas o desempenho externo, é potencialmente capaz de distinguir estagnação de reorganização — questão registrada aqui como hipótese derivada, não testada neste trabalho.

2.7.2 Limites de generalização por normas e margens

Bartlett et al. (2017) propõem limites de generalização baseados em normas espectrais e margens, estabelecendo que propriedades geométricas dos pesos se relacionam com a capacidade de generalizar. Dziugaite e Roy (2017) obtêm, por via PAC-Bayesiana, limites não vacuosos para redes sobreparametrizadas — resultado notável, dado que limites clássicos tornam-se vazios nesse regime. Ambos representam avanços substantivos, mas produzem limites válidos para *um* estado da rede, tipicamente o final do treinamento, e não uma leitura acompanhável ao longo das épocas.

Jiang et al. (2020) conduzem o estudo empírico mais sistemático dessa família, avaliando um grande conjunto de medidas candidatas quanto à sua relação causal com a lacuna de generalização. A conclusão é cautelar e impõe exigência metodológica a qualquer trabalho subsequente: muitas medidas teoricamente motivadas correlacionam-se mal com a generalização observada, e medidas baseadas em otimização desempenham-se melhor do que as baseadas em norma. A consequência adotada nesta dissertação é que não basta exibir correlação entre indicador e sobreajuste em uma execução; é preciso demonstrar *discriminação* entre execuções com e sem memorização, com controles pareados e teste de significância.

2.7.3 Abordagens espectrais

Martin et al. (2021) mostram que propriedades de cauda pesada do espectro das matrizes de pesos permitem prever tendências de qualidade de modelos sem acesso aos dados de treino ou de teste. Este é o trabalho mais próximo do objetivo aqui perseguido, e convém explicitar as diferenças. A abordagem é *espectral*, apoiando-se nos autovalores das matrizes, ao passo que a desta dissertação é *informação-teórica*, apoiando-se na distribuição de valores e na organização espacial dos pesos. Além disso, o alvo em Martin et al. (2021) é comparar modelos já treinados, enquanto aqui o alvo é acompanhar a trajetória temporal de um único treinamento.

2.7.4 Abordagens informação-teóricas e a controvérsia do gargalo de informação

A família mais próxima em espírito a esta dissertação é a que aplica teoria da informação ao interior de redes profundas. Tishby e Zaslavsky (2015) propõem analisar redes no *plano de informação*, quantificando cada camada pela informação mútua que preserva a respeito da entrada e da saída, e interpretam o treinamento como otimização de um compromisso entre compressão e predição. Shwartz-Ziv e Tishby (2017) desenvolvem empiricamente essa leitura e relatam que a maior parte das épocas de treinamento é consumida não no ajuste dos rótulos, mas na *compressão* da representação, identificando duas fases distintas na otimização — uma de deriva rápida e outra de relaxação estocástica.

A pertinência para o presente trabalho é evidente: trata-se de literatura que afirma existirem transições de regime detectáveis por quantidades informação-teóricas calculadas sobre o interior da rede, o que é precisamente a estrutura da hipótese aqui investigada.

É imprescindível, porém, registrar que essas conclusões foram contestadas. Saxe et al. (2019) examinam os três principais postulados da teoria e concluem que nenhum deles se sustenta no caso geral: a existência de duas fases distintas, a relação causal entre compressão e boa generalização, e a atribuição da compressão ao comportamento difusivo do gradiente estocástico. Demonstram, em particular, que a trajetória observada no plano de informação depende predominantemente da não linearidade empregada — funções de saturação bilateral produzem fase de compressão, enquanto ativações lineares ou de saturação unilateral não a produzem — e que parte do efeito reflete decisões de estimação da informação mútua em redes determinísticas.

Essa controvérsia recomenda cautela e delimita o escopo do presente trabalho de modo produtivo. As medidas aqui empregadas *não* são estimativas de informação mútua entre camadas e dados, e portanto não herdam as dificuldades de estimação que Saxe e colaboradores identificam: LMC, SampEn e SampEn2D são estatísticas calculadas sobre os *valores dos pesos*, sem referência a qualquer distribuição conjunta com os dados. A escolha evita o problema metodológico central da controvérsia, ao custo de abdicar da interpretação formal em termos de compressão de informação.

2.7.5 Síntese e posicionamento da proposta

Tabela 1 – Comparação dos trabalhos discutidos quanto à dependência de dados rotulados, à natureza temporal da leitura e ao objeto medido.

Trabalho	**Objeto da medida**	**Exige rótulo**	**Leitura temporal**	**Avisa antes**
Prechelt (1998)	Erro de validação	Sim	Sim	Não
Zhang et al. (2017)	Desempenho	Sim	Não	Não
Arpit et al. (2017)	Desempenho	Sim	Sim	Não
Bartlett et al. (2017)	Norma espectral	Não	Não	Não
Dziugaite e Roy (2017)	Limite PAC-Bayes	Sim	Não	Não
Jiang et al. (2020)	Diversas	Sim	Não	Não
Martin et al. (2021)	Espectro dos pesos	Não	Não	Não
Tishby e Zaslavsky (2015)	Informação mútua	Sim	Não	Não
Shwartz-Ziv e Tishby (2017)	Informação mútua	Sim	Sim	Não
Esta dissertação	Complexidade dos pesos	Não	Sim	Sim

Fonte: Elaborado pelo autor.

A Tabela 1 organiza os trabalhos segundo três eixos. Quanto à dependência de rótulos, apenas Bartlett et al. (2017) e Martin et al. (2021) dispensam-nos, e ambos por via espectral. Quanto à natureza temporal, Arpit et al. (2017) e Shwartz-Ziv e Tishby (2017) acompanham a trajetória do treinamento, mas ambos requerem acesso aos dados — o primeiro ao desempenho, o segundo à distribuição conjunta necessária para estimar informação mútua. A intersecção entre *dispensar rótulos* e *acompanhar a trajetória* permanece, até onde a revisão alcançou, não ocupada.

A proposta desta dissertação situa-se nessa intersecção e diferencia-se da literatura em quatro aspectos: (i) a medida é informação-teórica, mas incide sobre a distribuição de valores e a organização espacial dos pesos, não sobre o espectro das matrizes nem sobre informação mútua com os dados; (ii) a leitura é temporal, produzindo uma trajetória por época em lugar de um escalar ao final do treino; (iii) nenhum rótulo é consumido, o que a torna aplicável em cenários de anotação escassa; e (iv) a validação é feita por controles estritamente pareados com indução explícita de memorização, em resposta direta à advertência de Jiang et al. (2020) quanto a correlações espúrias.

Registre-se, por fim, uma limitação da própria revisão. A literatura de medidas de generalização é extensa e cresce rapidamente; a seleção aqui apresentada privilegiou trabalhos fundacionais de alta citação e os mais diretamente relacionados ao problema, não constituindo revisão sistemática no sentido metodológico do termo.

3 METODOLOGIA

Este capítulo descreve o protocolo experimental adotado para investigar a evolução da complexidade estatística dos pesos de uma rede neural profunda durante o treinamento. A exposição é organizada do dado bruto às medidas finais: primeiro os conjuntos de dados (Seção 3.1), em seguida a arquitetura empregada (Seção 3.2) e o protocolo de treinamento (Seção 3.3); a Seção 3.4 formaliza o esquema de *snapshots* ao longo do treino; a Seção 3.5 — núcleo metodológico deste trabalho — discute em detalhe a ordem de extração dos pesos, separando o que é herdado da arquitetura/biblioteca daquilo que constitui escolha analítica deste estudo; a Seção 3.6 define os quatro grupos de pesos sobre os quais as medidas são calculadas; a Seção 3.7 apresenta as medidas de complexidade adotadas; e a Seção 3.8 reporta as análises de robustez das decisões metodológicas.

3.1 CONJUNTOS DE DADOS

Utilizam-se três subconjuntos do *benchmark* MedMNIST v2 (YANG et al., 2023), selecionados por cobrirem modalidades clínicas distintas e apresentarem dificuldade não-saturada para a arquitetura adotada (Tabela 2). Todas as imagens são redimensionadas de 28×28 para 64×64 antes do treinamento, mantendo a representatividade clínica sem inflar excessivamente o custo computacional.

Tabela 2 – Datasets MedMNIST utilizados nos experimentos.

Dataset	**Treino**	**Classes (K)**	**Modalidade**
PathMNIST	89.996	9	Histopatologia colorretal (RGB)
OrganAMNIST	34.581	11	*Slices* axiais de tomografia abdominal (cinza)
BloodMNIST	11.959	8	Microscopia de células sanguíneas (RGB)

3.2 ARQUITETURA RESNET-18

Adota-se a ResNet-18 (HE et al., 2016) (implementação `torchvision`, sem pré-treinamento), com a camada totalmente conectada final substituída para o número de classes K de cada conjunto. Esta arquitetura totaliza aproximadamente 11,2 milhões de parâmetros distribuídos em **41 tensores com parâmetros aprendíveis**: 20 camadas convolucionais (`Conv2d`), 20 camadas de *batch normalization* (`BatchNorm2d`) e 1 camada totalmente conectada (`Linear`).

3.2.1 Estrutura em três níveis hierárquicos

A organização interna da ResNet-18 possui três níveis aninhados, ilustrados na Figura 1:

1. **Nível superior (oito módulos nomeados):** `conv1` (Conv2d 7×7, com *stride* 2), `bn1` (BatchNorm2d), `relu`, `maxpool`, `layer1`–`layer4` (contêineres `Sequential`), `avgpool` (*global average pooling*) e `fc` (Linear $512 \to K$).
2. **Nível intermediário (BasicBlocks):** cada `layerN` contém dois blocos residuais (`BasicBlock`). Em `layer2`, `layer3` e `layer4`, o primeiro `BasicBlock` contém ainda um sub-módulo `downsample` responsável por ajustar resolução e número de canais no caminho residual.
3. **Nível folha (operações elementares):** dentro de cada `BasicBlock` encontram-se duas `Conv2d` (3×3) e duas `BatchNorm2d`; o `downsample`, quando presente, contém uma `Conv2d` (1×1) e uma `BatchNorm2d` adicionais.

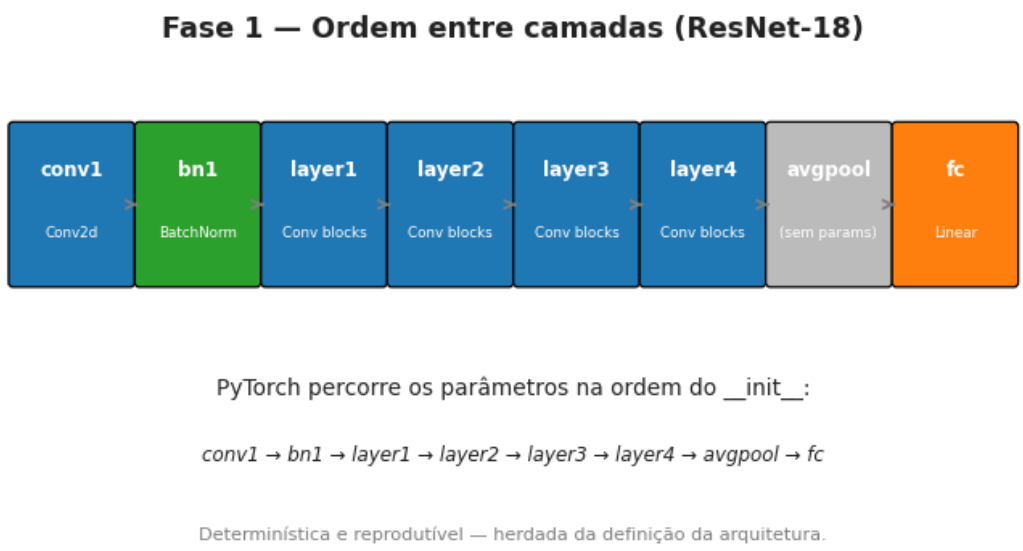


Figura 1 – Estrutura de nível superior da ResNet-18: oito módulos nomeados em sequência. As caixas indicam o tipo de camada (azul: Conv2d; verde: BatchNorm2d; cinza: sem parâmetros; laranja: Linear). As caixas `layer1`–`layer4` são contêineres `Sequential` que ocultam sub-blocos detalhados na Figura 2.

3.2.2 Composição interna de layer2 a layer4

Como exemplo representativo do nível intermediário, a Figura 2 expõe a estrutura de `layer2`, que contém os dez módulos com parâmetros característicos das três últimas

`layerN`. Em particular, o primeiro `BasicBlock` contém um `downsample` composto por uma convolução 1×1 e uma `BatchNorm2d` adicionais, totalizando seis módulos com parâmetros no primeiro bloco e quatro no segundo. A `layer1` segue o mesmo padrão mas sem `downsample`, pois não há mudança de número de canais (somando portanto oito módulos com parâmetros).

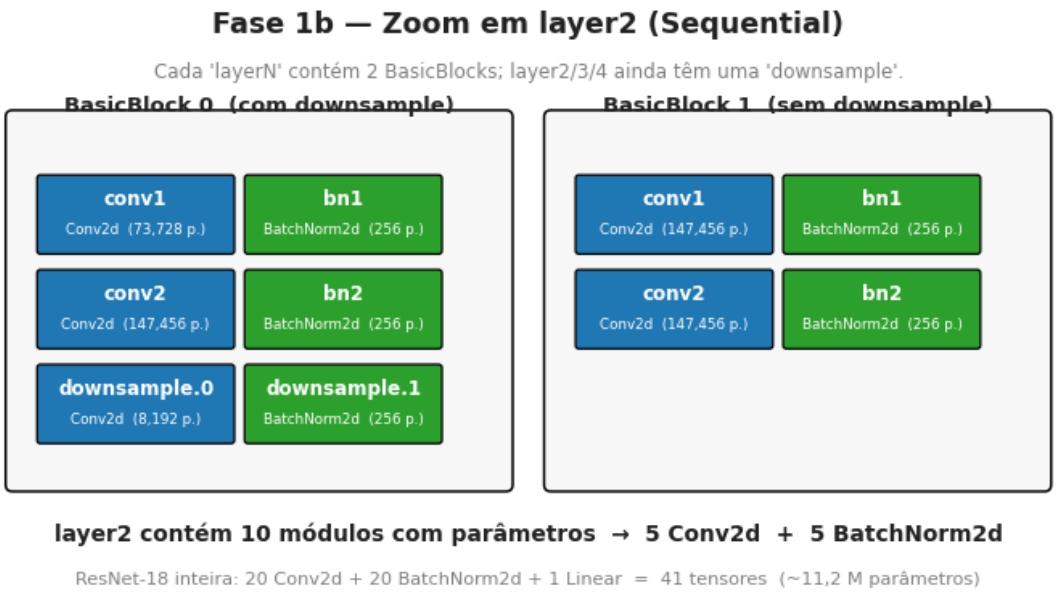


Figura 2 – Expansão interna de `layer2`: dois `BasicBlocks`, o primeiro com `downsample` adicional. Cada folha colorida é um tensor com parâmetros aprendíveis, indicado pelo seu tipo e número de parâmetros. `layer3` e `layer4` têm estrutura idêntica (com canais maiores); `layer1` é mais simples (sem `downsample`).

3.2.3 Contagem agregada de tensores

A Tabela 3 sintetiza, por tipo de camada, a quantidade de tensores e de parâmetros disponíveis para a análise de complexidade.

Tabela 3 – Tensores com parâmetros aprendíveis na ResNet-18 utilizada neste trabalho.

Tipo	**Tensores**	**Parâmetros (%)**	**Localização**
`Conv2d`	20	$\sim$ 11,15 M (99,7%)	1 em conv1 + 4 em layer1 + 5 em layer2/3/4
`BatchNorm2d`	20	$\sim$ 10 k ($<$ 0,1%)	sempre pareada 1:1 com cada Conv2d
`Linear`	1	$\sim$ 4,6 k	fc
Total	**41**	$\sim$ 11,18 M	ResNet-18 inteira

3.3 PROTOCOLO DE TREINAMENTO

O treinamento emprega o otimizador SGD com *momentum* 0,9, taxa de aprendizado 10^{-3} e *weight decay* 10^{-4} — hiperparâmetros validados pelo grupo de pesquisa em experimentos preliminares. A função objetivo é a entropia cruzada com pesos uniformes de classe. O *batch size* é 64 e cada *run* dura entre 30 e 100 épocas, conforme o ponto experimental do grid (Seção 3.9). Todos os experimentos são executados em CPU (*torch* 2,4,1 e *torchvision* 0,19,1).

3.4 CHECKPOINTING LOG-ESPAÇADO EM MEMÓRIA

A cada *run*, $K \approx 88$ pontos de medição são distribuídos nos passos de treinamento com espaçamento logarítmico, concentrando maior densidade nas primeiras épocas, onde a distribuição dos pesos muda mais rapidamente. Em cada ponto, um `WeightSnapshot` é construído a partir do estado atual do modelo em memória, sem escrita de arquivo por passo — evitando inflar o uso de disco em ordens de magnitude quando comparado a salvar todos os `state_dict`s. Cada *snapshot* contém referências para os tensores de `Conv2d`, `Linear` e `BatchNorm2d`, já agrupados conforme descrito na Seção 3.6.

A escolha pelo espaçamento logarítmico, em contraste com um espaçamento uniforme, é deliberada: a literatura de dinâmica de generalização (ADVANI et al., 2020) indica que as fases qualitativamente distintas do treinamento ocorrem em escalas de tempo logarítmicas. Um espaçamento uniforme superamostraria a fase de saturação tardia e subamostraria a fase inicial de rápida reorganização das distribuições de pesos.

3.5 EXTRAÇÃO ORDENADA DOS PESOS

A extração dos pesos é o procedimento que converte o estado da rede em uma sequência linear de números sobre os quais as medidas de complexidade são calculadas. Este procedimento opera em *duas camadas* encadeadas (Seção 3.5.1): uma **inferior**, totalmente determinada pela arquitetura ResNet-18 e pela convenção de armazenamento do PyTorch; e uma **superior**, composta por escolhas analíticas deste trabalho. A presente seção descreve cada uma e justifica explicitamente toda decisão da camada superior.

3.5.1 Camada inferior: o que se herda da arquitetura e do PyTorch

Dois fatos são externos a este trabalho e simplesmente descritos:

Ordem entre módulos.

O método `model.state_dict()` do PyTorch devolve um `OrderedDict` cuja ordem de iteração é exatamente a sequência em que os módulos foram registrados no `__init__` da `torchvision.models.resnet18`. Esta sequência é determinística e reprodutível entre *runs*, e corresponde à travessia em profundidade da árvore de módulos exibida nas Figuras 1–2:

`conv1` → `bn1` → `layer1.0.conv1` → `layer1.0.bn1` → ⋯ → `layer2.0.downsample.0` → ⋯ → `fc`

Ordem dentro de cada tensor.

O PyTorch armazena tensores em memória contígua (C-contiguous, *row-major*). Isto significa que, ao aplicar `tensor.flatten()` ou ao iterar elementos via `numpy().flat`, o índice mais à esquerda do tensor é o de variação mais lenta, e o índice mais à direita é o de variação mais rápida (Figura 3). Em particular:

- `Conv2d`: tensor de shape $[C_{out}, C_{in}, H, W]$; ordem de varredura é $C_{out} \to C_{in} \to H \to W$. Cada bloco contíguo de $C_{in} \cdot H \cdot W$ elementos corresponde a um **filtro de saída completo**.

- `Linear`: tensor de shape $[\text{Out}, \text{In}]$; ordem de varredura é Out → In. Cada linha contígua de In elementos corresponde aos **pesos de entrada de um único neurônio de saída**.

- `BatchNorm2d`: dois vetores 1D de comprimento C (canais), na ordem $\gamma_0, \gamma_1, \ldots$ seguido por $\beta_0, \beta_1, \ldots$ (ver Seção 3.6.1 para a semântica de γ e β).

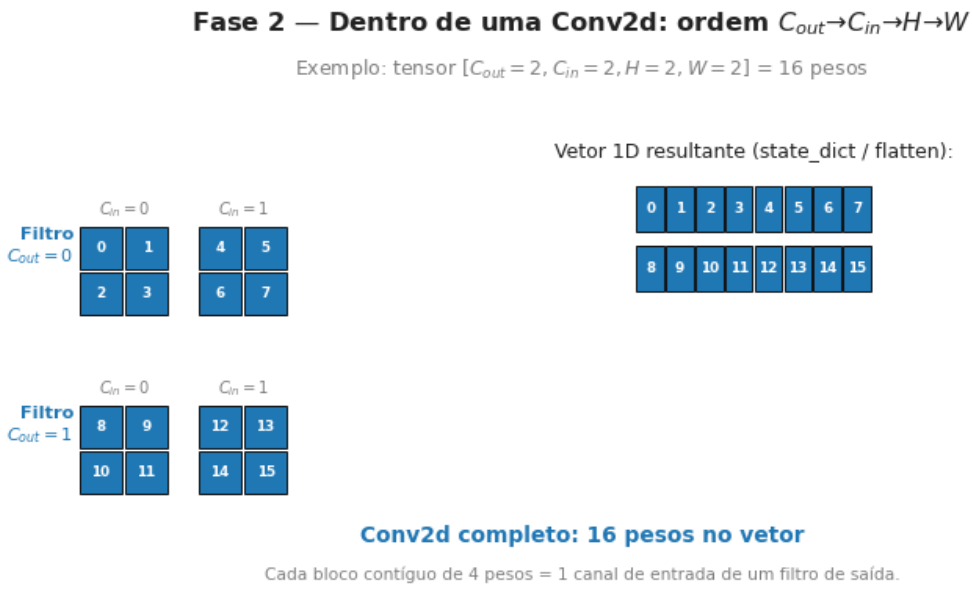


Figura 3 – Ordem de varredura dentro de uma `Conv2d`, ilustrada com um tensor mínimo $[C_{out} = 2, C_{in} = 2, H = 2, W = 2]$. A leitura segue quatro *loops* aninhados, com C_{out} no nível externo e W no interno. Cada bloco contíguo de 4 elementos corresponde a um canal de entrada de um filtro de saída.

A Figura 4 resume as três regras lado a lado para os três tipos de camada que possuem parâmetros aprendíveis na ResNet-18.

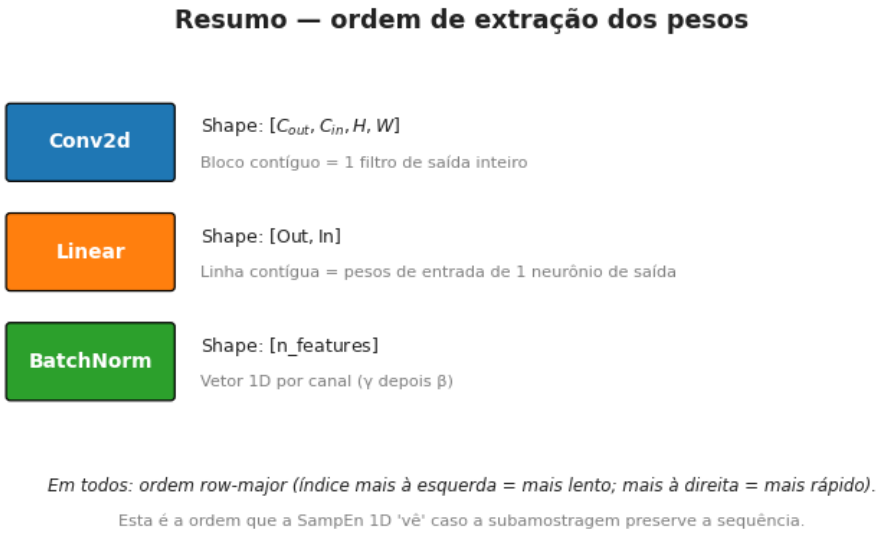


Figura 4 – Resumo das regras de ordenação dentro de cada tipo de tensor: todas seguem ordem *row-major*, com o índice mais à esquerda variando mais lentamente.

3.5.2 Camada superior: decisões analíticas deste trabalho

Definida a camada inferior, restam cinco decisões analíticas, cada uma defendida abaixo em relação à hipótese central deste trabalho — *que medidas de complexidade aplicadas aos pesos servem como marcadores objetivos da maturação do treinamento.*

D1. Agrupamento em quatro categorias.

Os 41 tensores são particionados em quatro grupos (`conv`, `dense`, `bn_gamma`, `bn_beta`; ver Seção 3.6). A justificativa é que esses grupos têm *inicializações distintas* e *dinâmicas estatísticas qualitativamente diferentes*, e juntar todos em uma única série temporal misturaria fontes incomparáveis.

D2. Conv2d: agrupamento por neurônio de saída, sem transposição.

O tensor `Conv2d` é processado na ordem nativa $[C_{out}, C_{in}, H, W]$. Como consequência, blocos contíguos de $C_{in} \cdot H \cdot W$ elementos correspondem a filtros de saída completos — a unidade interpretável natural quando se discute o que o treinamento estruturou. A alternativa — transpor para $[C_{in}, C_{out}, H, W]$ antes do *flatten* — agruparia por canal de entrada (resposta de fan-out por unidade da camada anterior). Esta segunda leitura é semanticamente válida, mas não casa com a hipótese central, que trata cada filtro como "uma unidade aprendida". A Seção 3.8 reporta o experimento de controle que quantificou empiricamente o impacto desta decisão.

D3. Subamostragem sistemática.

Cada grupo de camadas acumula da ordem de 10^5 a 10^6 pesos. Para tornar o cálculo da SampEn computacionalmente viável (custo $O(N^2)$ na construção das distâncias par a par) e para uniformizar a contagem de elementos entre *snapshots* de tensores de tamanhos distintos, aplicamos subamostragem para no máximo 10 000 elementos por grupo. Adotamos amostragem *sistemática* (passo fixo no vetor concatenado), preservando a ordem original do *flatten* — e portanto a semântica de agrupamento decidida em D2. A alternativa de subamostragem aleatória embaralharia o vetor e reduziria a SampEn 1D a uma medida da distribuição marginal dos pesos, descartando a estrutura sequencial. A SampEn 2D, ao operar diretamente sobre a matriz dos filtros, é independente desta decisão.

D4. Cálculo único por grupo, sobre o vetor concatenado.

As medidas LMC e SampEn são calculadas *uma única vez por grupo*, sobre o vetor obtido pela concatenação de todos os tensores daquele grupo na ordem arquitetural, após

a subamostragem sistemática descrita em D3. Não se calcula uma medida por tensor com agregação posterior.

A decisão contraria a alternativa aparentemente mais natural — calcular a medida para cada tensor e agregar média e desvio-padrão entre os tensores do mesmo grupo — e a razão é a comparabilidade das estimativas.

O argumento decisivo diz respeito à LMC. A complexidade LMC adotada neste trabalho não é normalizada, e sua escala depende do número de intervalos (N_{bins}) empregado na construção do histograma, o que impõe que qualquer comparação entre camadas ou entre execuções seja feita com o mesmo número de intervalos. O número de intervalos é determinado adaptativamente pelo tamanho da amostra, segundo $N_{bins} = \min(100, \max(10, n/5))$. Calculada sobre o vetor concatenado, essa regra produz $N_{bins} = 100$ de modo invariável, pois o menor dos quatro grupos — o da camada densa, com 4.096 a 5.632 pesos, conforme o número de classes do conjunto analisado — já excede folgadamente o limiar de 500 elementos a partir do qual o teto de 100 intervalos passa a valer. Calculada por tensor, ao contrário, a mesma regra produziria contagens heterogêneas: um tensor de normalização com 64 canais receberia apenas 12 intervalos, enquanto outro com 512 canais receberia 100. As complexidades resultantes não seriam comparáveis entre si, e a média entre elas não teria significado bem definido.

Um segundo argumento diz respeito à SampEn. A estimativa da entropia amostral requer contagens de pares similares suficientemente numerosas para ser estável; tensores individuais pequenos, como os de normalização das primeiras camadas, produziriam estimativas ruidosas cuja média seria dominada por variância de estimação, e não por variação do objeto medido.

Reconhece-se o custo desta decisão, que é real: o vetor concatenado reúne populações de pesos com função arquitetural distinta — por exemplo, convoluções 3×3 principais e convoluções 1×1 de *downsample* — e a medida resultante não distingue a contribuição de cada uma. A decisão D1, de particionar os pesos em quatro grupos, mitiga parcialmente esse efeito ao separar populações cuja inicialização e cuja dinâmica são qualitativamente diferentes, mas não o elimina dentro de cada grupo. A consequência é que as medidas reportadas descrevem o grupo como um todo, e não permitem atribuir variação a tensores individuais.

D5. Inclusão dos pesos de *bias* apenas para `BatchNorm2d`.

Para `Conv2d` e `Linear`, apenas o tensor `weight` é incluído na análise; o *bias*, quando existente, é excluído. Para `BatchNorm2d`, ambos γ (`weight`) e β (`bias`) são incluídos por serem parâmetros funcionalmente centrais à operação de normalização afim (Seção 3.6.1).

A Tabela 4 sintetiza, por decisão, quem é responsável e o que precisa de defesa.

Tabela 4 – Pirâmide de decisões da extração de pesos.

Decisão	**Origem**	**Mutável?**
Ordem entre módulos (`conv1` $\rightarrow \ldots \rightarrow$ `fc`)	Arquitetura ResNet	Não
Shape `Conv2d` $[C_{out}, C_{in}, H, W]$	PyTorch	Não
Flatten *row-major*	PyTorch (C-contig.)	Não
D1. Quatro grupos (`conv`/`dense`/`bn_`γ/`bn_`β)	Este trabalho	Sim
D2. Não transpor Conv2d antes do flatten	Este trabalho	Sim
D3. Subamostragem sistemática (passo fixo, 10 000 elementos)	Este trabalho	Sim
D4. Cálculo único por grupo (vetor concatenado)	Este trabalho	Sim
D5. Inclusão de γ e β; exclusão de *bias* de Conv/Linear	Este trabalho	Sim

3.6 AGRUPAMENTO DOS PESOS EM QUATRO CATEGORIAS

Os 41 tensores são particionados em quatro grupos disjuntos. A Tabela 5 sumariza suas características.

Tabela 5 – Grupos de pesos sobre os quais as medidas de complexidade são calculadas.

Grupo	**Tensores**	**Origem**	**Função arquitetural**
`conv`	20	`Conv2d.weight`	Detectores de *features*
`dense`	1	`Linear.weight`	Cabeça classificadora
`bn_gamma`	20	`BatchNorm2d.weight`	Escala γ por canal
`bn_beta`	20	`BatchNorm2d.bias`	Deslocamento β por canal

3.6.1 Por que separar γ e β da BatchNorm

Uma camada `BatchNorm2d` aplica uma transformação afim em duas etapas, por canal c:

$$\hat{x}_c = \frac{x_c - \mu_c}{\sqrt{\sigma_c^2 + \varepsilon}} \qquad \text{(normalização, sem parâmetros)}, \tag{3.1}$$

$$y_c = \gamma_c \cdot \hat{x}_c + \beta_c \qquad \text{(reescala afim, com parâmetros)}. \tag{3.2}$$

Os parâmetros aprendíveis γ_c e β_c têm papéis funcionalmente distintos — γ controla a variância de saída de cada canal e β controla o seu centro — e inicializações distintas ($\gamma_c = 1$, $\beta_c = 0$). Como consequência, suas distribuições empíricas têm formas iniciais e dinâmicas diferentes:

- γ inicia como uma massa de Dirac em 1 e tende a se alargar de forma assimétrica, com alguns valores tendendo a zero (sinal de canais "suprimidos" pela rede);
- β inicia como uma massa de Dirac em 0 e se alarga de forma aproximadamente simétrica em torno de zero, acumulando o *bias* aprendido por canal.

Tratar γ e β como um único grupo `bn` apagaria esse contraste, que se mostra particularmente informativo nas trajetórias de LMC e SampEn ao longo do treinamento (Capítulo 4).

3.7 MEDIDAS DE COMPLEXIDADE

Sobre cada tensor de cada *snapshot*, e antes da agregação por grupo, são calculadas as medidas descritas a seguir. Todos os parâmetros seguem convenções validadas pelo grupo de pesquisa ou pela literatura citada.

3.7.1 Complexidade LMC

A complexidade estatística LMC (LÓPEZ-RUIZ et al., 1995) é definida como o produto da entropia de Shannon (SHANNON, 1948) pelo desequilíbrio em relação à distribuição uniforme:

$$C_{\mathrm{LMC}}(p) \;=\; H(p) \cdot D(p), \tag{3.3}$$

onde, para um histograma normalizado p com N *bins*,

$$H(p) = -\sum_{i=1}^{N} p_i \log_2 p_i, \qquad D(p) = \sum_{i=1}^{N} \left(p_i - \tfrac{1}{N}\right)^2. \tag{3.4}$$

O número de *bins* é determinado pela regra $N = \min(100, \max(10, n/5))$, onde n é o número de pesos amostrados após D3 (Seção 3.5.2). A entropia é computada em bits ($\log_2$) e o produto $H \cdot D$ é reportado sem normalização adicional.

3.7.2 Entropia amostral SampEn_{1D}

A entropia amostral (RICHMAN; MOORMAN, 2000; PINCUS, 1991) é definida como

$$\mathrm{SampEn}(U, m, r) \;=\; -\log \frac{A^{m+1}(r)}{B^{m}(r)}, \tag{3.5}$$

onde U é o vetor de pesos amostrado, m é o comprimento das sub-sequências comparadas e r é a tolerância de similaridade. As quantidades A^{m+1} e B^{m} contam pares de sub-sequências cuja distância de Chebyshev é menor ou igual a r. Adotam-se os parâmetros $m = 2$ e $r = 0{,}2\,\sigma(U)$ (YENTES et al., 2013), validados pelo grupo de pesquisa em estudos prévios.

3.7.3 Norma ℓ_2 por filtro

Como medida de magnitude complementar, registra-se a norma ℓ_2 por filtro de saída (ou por neurônio, no caso da `Linear`); reportam-se a média e o desvio-padrão dessa norma dentro de cada tensor. Esta medida não é uma medida de complexidade no sentido estrito, mas serve como referência para interpretar tendências observadas em C_{LMC} e SampEn.

3.7.4 SampEn 2D e análise multiescala

A SampEn 2D (SILVA et al., 2016) opera diretamente sobre a matriz dos filtros, sem *flatten*, preservando a estrutura espacial nas duas direções e contornando por completo a discussão sobre a ordem de achatamento apresentada em D2. A análise multiescala (MSE) (COSTA et al., 2002; COSTA et al., 2005) aplica a entropia amostral a versões do objeto granuladas em escalas crescentes.

Ambas foram aplicadas neste trabalho e seus resultados constam do Capítulo 4: a SampEn 2D sobre o mosaico dos filtros da camada `conv1` na Seção 4.8, a análise multiescala na Seção 4.9, e a SampEn 2D sobre a camada densa no segundo desenho experimental, na Seção 4.10.

3.8 ANÁLISE DE ROBUSTEZ

Para dar lastro empírico às decisões D1–D5, três análises de robustez foram conduzidas sobre os *snapshots* de três sementes de PathMNIST com horizonte de 100 épocas. Os resultados são apresentados nesta seção, e não no capítulo de resultados, por constituírem verificação das decisões metodológicas e não achados sobre o objeto de estudo.

3.8.1 Sensibilidade à ordem de subamostragem (D3)

A decisão D3 adota subamostragem sistemática, com passo fixo, preservando a ordem original do *flatten*. A alternativa — subamostragem aleatória — embaralha o vetor e, em princípio, reduz a SampEn_{1D} a uma estatística da distribuição marginal dos pesos. A Tabela 6 quantifica o efeito sobre o grupo `conv`, único em que a subamostragem chega a ser acionada.

Tabela 6 – SampEn_{1D} do grupo `conv` sob diferentes esquemas de subamostragem e ordenação, em três sementes de PathMNIST com 100 épocas.

Esquema	**SampEn_{1D}**
Sistemático, ordem nativa (adotado)	$2{,}0081 \pm 0{,}0077$
Aleatório (semente 42)	$2{,}0876 \pm 0{,}0087$
Aleatório (semente 7)	$2{,}0827 \pm 0{,}0103$
Sistemático, tensor transposto (alternativa a D2)	$2{,}0343 \pm 0{,}0045$

Fonte: Elaborado pelo autor.

A subamostragem aleatória eleva a SampEn_{1D} em aproximadamente 0,0795 em relação à sistemática, enquanto o espalhamento entre sementes do esquema adotado é de 0,0077 — isto é, o efeito da ordem é cerca de 10 vezes maior que a variabilidade entre inicializações. A interpretação é direta: ao embaralhar o vetor, a medida aproxima-se do valor esperado para uma sequência sem estrutura sequencial, o que confirma que a ordem preservada pela amostragem sistemática carrega informação real, e não artefato.

O mesmo experimento oferece lastro à decisão D2. Transpor o tensor antes do *flatten*, agrupando por canal de entrada em lugar de por neurônio de saída, desloca a SampEn_{1D} em 0,0262 — efeito menor que o da subamostragem aleatória, mas ainda superior ao espalhamento entre sementes. A escolha de não transpor é, portanto, consequente, embora de magnitude modesta, e a leitura alternativa permanece registrada aqui.

3.8.2 Sensibilidade ao número de intervalos da LMC

Como a complexidade LMC empregada não é normalizada, sua escala depende da discretização do histograma. A Tabela 7 documenta o comportamento sobre o grupo `bn_`γ.

Tabela 7 – Complexidade LMC do grupo `bn_`γ em função do número de intervalos do histograma, em três sementes de PathMNIST com 100 épocas.

N_{bins}	C_{LMC}
20	$0{,}6467 \pm 0{,}0299$
50	$0{,}5161 \pm 0{,}0189$
100	$0{,}3610 \pm 0{,}0195$
200	$0{,}2307 \pm 0{,}0138$

Fonte: Elaborado pelo autor.

O valor absoluto da complexidade varia por um fator de 2,80 entre os extremos examinados, decrescendo monotonicamente com o refinamento do histograma. Duas consequências decorrem disso.

A primeira é que *o valor absoluto de* C_{LMC} *não é interpretável isoladamente*, e nenhuma comparação entre camadas, grupos ou execuções é legítima sem que o número de intervalos seja idêntico. Toda a análise deste trabalho emprega $N_{bins} = 100$.

A segunda é que este resultado fornece o lastro empírico da decisão D4. Como argumentado na Seção 3.5.2, calcular a medida por tensor produziria contagens de intervalos heterogêneas, dado que a regra adaptativa $N_{bins} = \min(100, \max(10, n/5))$ depende do tamanho de cada tensor. A Tabela 7 mostra que essa heterogeneidade não seria um detalhe de segunda ordem: complexidades calculadas com 20 e com 100 intervalos diferem por quase um fator de dois, de modo que a média entre tensores de tamanhos distintos misturaria quantidades em escalas incompatíveis. O cálculo único sobre o vetor concatenado do grupo garante $N_{bins} = 100$ em todos os casos, o que torna as trajetórias comparáveis.

Registre-se que a *posição temporal* do pico da LMC, que é a quantidade de interesse no Capítulo 4, não foi avaliada quanto à sensibilidade ao número de intervalos — fazê-lo exigiria recalcular as trajetórias completas em cada configuração. A verificação aqui reportada abrange o valor absoluto da medida, e não a época em que ela atinge o máximo.

3.9 GRID EXPERIMENTAL

O grid primário consiste em três *datasets* × três horizontes de épocas $\{30, 50, 100\}$ × três sementes $\{42, 123, 2024\}$, totalizando **27 *runs***. A finalidade do horizonte variável é avaliar a estabilidade das trajetórias para além do tempo de convergência típico (~ 50 épocas observadas em experimentos preliminares), enquanto as três sementes quantificam a variabilidade entre inicializações e ordenações de *mini-batches*.

3.10 SEGUNDO DESENHO EXPERIMENTAL: MEMORIZAÇÃO INDUZIDA E A CAMADA DENSA

As seções anteriores descrevem o desenho que sustenta os resultados do Capítulo 4, no qual o sobreajuste é induzido por *subamostragem* do conjunto de treinamento e as medidas incidem principalmente sobre os grupos convolucional e de *batch normalization*. Esta seção descreve um segundo desenho, complementar ao primeiro, construído para responder a uma questão que o primeiro não isola: se as medidas de complexidade detectam *memorização* — isto é, o ajuste a associações que não generalizam — e não apenas a escassez de dados.

A distinção importa porque subamostrar o treino reduz simultaneamente a quantidade de informação disponível e a diversidade dos exemplos, de modo que a degradação observada pode ter mais de uma origem. Corromper rótulos, em contrapartida, mantém o

volume de dados e introduz exclusivamente associações inconsistentes, forçando a rede a memorizá-las (ZHANG et al., 2017).

3.10.1 Diferenças em relação ao primeiro desenho

A Tabela 8 explicita as diferenças, que não se restringem ao mecanismo de indução. Elas devem ser consideradas ao comparar os resultados dos dois estudos, pois qualquer divergência entre eles pode, em princípio, decorrer de qualquer uma dessas dimensões.

Tabela 8 – Comparação entre os dois desenhos experimentais.

	Primeiro desenho	**Segundo desenho**
Conjuntos	PathMNIST, OrganAMNIST, BloodMNIST	MedNIST
Indução	subamostragem (5, 10, 25%)	corrupção de rótulos (15, 30, 50%)
Pesos analisados	`conv`, `bn_gamma`, `bn_beta`	`dense`
Otimizador	SGD com *momentum*	AdamW
Arquiteturas	ResNet-18, ResNet-34	ResNet-18, DenseNet-121
Amostragem	sistemática, até 10^4 por grupo	integral (3.072 pesos)
Medição	*snapshots* log-espaçados	a cada época, durante o treino

Registre-se em particular que o segundo desenho **não subamostra**: a camada densa da ResNet-18 aplicada a seis classes possui $6 \times 512 = 3.072$ pesos, quantidade que torna o cálculo integral viável a cada época. Elimina-se assim a decisão D3 da Seção 3.5.2 e a discussão de viés de amostragem que a acompanha.

3.10.2 Protocolo de corrupção de rótulos

Uma fração $\rho \in \{0{,}15;\ 0{,}30;\ 0{,}50\}$ dos exemplos do conjunto de treinamento tem seu rótulo substituído por um valor sorteado uniformemente entre *todas* as classes, inclusive a verdadeira — convenção adotada por Zhang et al. (2017). A consequência precisa ser declarada, para que a fração sorteada não seja confundida com a fração efetivamente errada: com K classes, uma fração sorteada ρ produz $\rho\,(K-1)/K$ de rótulos de fato incorretos. Nos experimentos com seis classes, portanto, $\rho = 0{,}30$ corresponde a 25 % de rótulos errados, e $\rho = 0{,}15$ e $\rho = 0{,}50$ correspondem a 12,5 % e 41,7 %, respectivamente. O registro de cada execução reporta as duas quantidades.

A corrupção incide *apenas* sobre o treino; validação e teste permanecem íntegros, de modo que a degradação da validação mede exatamente a perda de generalização induzida — corromper a régua junto com o objeto medido não mediria nada.

Convém registrar por que a indução por corrupção de rótulos substituiu, neste segundo desenho, a alternativa de simplesmente reduzir o conjunto de treino. Experimentos preliminares mostraram que a redução produz um falso positivo convincente: com poucos passos de otimização, as estatísticas móveis das camadas de normalização em lote não

convergem, e o modelo colapsa em modo de avaliação — inclusive sobre o próprio conjunto de treino. O quadro se parece com sobreajuste catastrófico, mas o mesmo modelo acerta cerca de 94,5 % da validação quando a normalização usa as estatísticas do lote corrente. Mede-se, nesse caso, um artefato de normalização, e não perda de generalização. A corrupção de rótulos não tem esse problema, pois preserva as 47.164 amostras de treino e mantém as estatísticas de normalização saudáveis.

A semente que governa a corrupção é independente daquela que governa a partição e a inicialização dos pesos. A separação é necessária: se ambas fossem a mesma, repetir o experimento alterando apenas a semente reproduziria os mesmos rótulos corrompidos, medindo sensibilidade à inicialização em lugar de replicação.

Cada execução com corrupção possui uma execução de controle **estritamente pareada**, idêntica a ela em arquitetura, partição, semente, número de épocas, decaimento de pesos e ausência de aumento de dados, diferindo unicamente por $\rho = 0$. O rigor desse pareamento é condição de validade: qualquer diferença adicional entre os grupos, como a presença de aumento de dados em apenas um deles, tornaria o contraste observado atribuível a mais de uma causa.

A confirmação de que houve memorização, e não apenas degradação, é feita *a posteriori*: verifica-se que a acurácia de treino em modo de avaliação sobe até ajustar os rótulos corrompidos, enquanto a acurácia de validação cai.

3.10.3 A camada densa como objeto de medida

Seja a camada densa com M entradas $x_1, \ldots, x_M$ e N neurônios $n_1, \ldots, n_N$. A matriz de pesos é $W \in \mathbb{R}^{N \times M}$, e o elemento w_{ji} é o peso do *caminho* $x_i \to n_j$ — convenção que coincide com a forma nativa de `Linear.weight` no PyTorch, [out_features, in_features].

Como a SampEn_{1D} compara janelas consecutivas, a ordem de achatamento precisa ser fixada. Duas ordens são naturais. Na ordem *por neurônio*, percorrem-se todos os pesos que chegam a cada neurônio antes de passar ao seguinte:

$$v_n = (w_{11}, w_{12}, \ldots, w_{1M},\ w_{21}, \ldots, w_{2M},\ \ldots,\ w_{NM}), \tag{3.6}$$

o que corresponde ao achatamento nativo, sem transposição. Na ordem *por entrada*, percorrem-se todos os pesos que partem de cada entrada:

$$v_x = (w_{11}, w_{21}, \ldots, w_{N1},\ w_{12}, \ldots, w_{N2},\ \ldots), \tag{3.7}$$

equivalente a transpor W antes do achatamento. A Equação 3.6 mede a regularidade *dentro do campo receptivo de cada neurônio*; a Equação 3.7 mede a regularidade *da distribuição de uma mesma entrada entre os neurônios*. Adota-se a primeira como convenção padrão,

por coerência com a decisão D2 da Seção 3.5.2, e a comparação entre as duas é reportada como ablação. Para a complexidade LMC a distinção é irrelevante, pois a medida depende apenas do histograma dos valores e é invariante a permutações.

O vetor de viés é excluído da análise: o viés é um deslocamento aditivo do neurônio, não a ligação entre uma entrada e um neurônio, e portanto não é um caminho no sentido aqui adotado.

3.10.4 Monitoramento durante o treinamento

Diferentemente do primeiro desenho, que analisa *snapshots* armazenados, o segundo calcula as medidas **a cada época, dentro do laço de treinamento**. A escolha decorre do objetivo: se o propósito é oferecer ao desenvolvedor um aviso utilizável, a medida precisa estar disponível enquanto o treinamento ocorre, e não apenas em análise posterior.

São calculadas por época a complexidade LMC com $N_{bins} = 100$, a SampEn_{1D} com $m = 2$ e $r = 0{,}20\,\sigma$, e a SampEn2D com $m = 1$ e o mesmo r. A escolha de $m = 1$ para a variante bidimensional é deliberada e merece justificativa: com $m = 2$, as janelas comparadas são sub-matrizes 3×3, que em uma matriz de apenas seis linhas raramente encontram pares similares, produzindo contagens instáveis. Com $m = 1$, comparam-se janelas 1×1 contra 2×2, o que mantém as contagens em regime numericamente estável.

O custo do monitoramento é baixo, pois incide sobre 3.072 pesos, e pode ser desativado por opção de linha de comando.

3.10.5 Definição operacional da referência temporal

Para quantificar antecedência é preciso uma referência que produza um número de época. Adota-se como âncora a época em que a acurácia de validação passa a cair de forma sustentada.

A opção pela acurácia, e não pela perda de validação, decorre de uma observação empírica. Ancorando o diagnóstico na perda, o monitor sinalizava sobreajuste em todas as execuções, incluindo os controles, e em cerca de metade das épocas — consequência de o MedNIST saturar muito cedo, fazendo a perda de validação subir logo após as primeiras épocas mesmo em treinamentos saudáveis. Reancorado na acurácia, o comportamento tornou-se o esperado. O episódio ilustra que a definição operacional de sobreajuste não é detalhe de implementação, mas condição de validade do resultado.

4 RESULTADOS

4.1 VISÃO GERAL DOS EXPERIMENTOS

O grid experimental principal compreende **27 execuções**, resultantes da combinação de três conjuntos do repositório MedMNIST — PathMNIST, OrganAMNIST e BloodMNIST —, três horizontes de treinamento (30, 50 e 100 épocas) e três sementes de inicialização (42, 123 e 2024). A elas somam-se **24 execuções** de análise de sensibilidade, destinadas aos eixos de subamostragem do treino, de decaimento de pesos e de arquitetura, discutidos nas Seções 4.4 a 4.6, totalizando 51 execuções registradas.

A Tabela 9 resume o desempenho preditivo do grid principal. A acurácia de validação final é de $0{,}9715 \pm 0{,}0069$, e a perda de validação final, de 0,1125. As melhores execuções são `OrganAMNIST_100ep_seed123`, com acurácia 0,9807 e perda 0,0813, e `PathMNIST_100ep_seed2024`, com acurácia 0,9801 e perda 0,0798.

Tabela 9 – Acurácia de validação final no grid principal, por conjunto de dados e por horizonte de treinamento. Valores como média ± desvio-padrão amostral entre execuções.

Estrato	**Execuções**	**Acurácia de validação**
BloodMNIST	9	$0{,}9743 \pm 0{,}0038$
OrganAMNIST	9	$0{,}9718 \pm 0{,}0049$
PathMNIST	9	$0{,}9685 \pm 0{,}0098$
30 épocas	9	$0{,}9666 \pm 0{,}0090$
50 épocas	9	$0{,}9724 \pm 0{,}0030$
100 épocas	9	$0{,}9755 \pm 0{,}0043$
Todas	**27**	$\mathbf{0{,}9715 \pm 0{,}0069}$

Fonte: Elaborado pelo autor.

Dois aspectos desses números importam para a leitura das seções seguintes. O primeiro é que a variabilidade entre sementes é pequena — o desvio-padrão dentro de cada estrato não excede 0,01 —, o que favorece o isolamento de efeitos atribuíveis à estrutura interna dos pesos, e não a flutuações macroscópicas de desempenho. O segundo é que a acurácia cresce monotonicamente com o horizonte de treinamento, de 0,9666 em 30 épocas para 0,9755 em 100, sem sinal de degradação: sob o protocolo canônico, e nos horizontes examinados, o treinamento não produz sobreajuste espontâneo. É precisamente essa constatação que motiva os eixos de indução deliberada discutidos adiante, sem os quais não haveria transição a ser marcada.

Registrado o comportamento agregado, as seções seguintes deslocam o foco da métrica de desempenho para a dinâmica interna do modelo, examinando as trajetórias das medidas de complexidade por grupo de pesos.

4.2 COMPLEXIDADE LMC AO LONGO DO TREINAMENTO

A análise das trajetórias da complexidade estatística LMC $C = H \times D$ (entropia de Shannon em bits, sem normalização, multiplicada pelo desequilíbrio quadrático com referência à distribuição uniforme) foi conduzida sobre os 50 *runs* concluídos, abrangendo os conjuntos BloodMNIST, OrganAMNIST e PathMNIST, com sementes {42, 123, 2024} e orçamentos de treinamento de 30, 50 e 100 épocas. Estratificamos os parâmetros do modelo em quatro grupos — camadas convolucionais (`conv`), camadas densas (`dense`), escalas de *batch normalization* (`bn_gamma`) e deslocamentos correspondentes (`bn_beta`) — e calculamos C a cada *checkpoint* de época. Como referência de qualidade preditiva, recorde-se que a acurácia média de validação no conjunto agregado foi de $\overline{\text{val_acc}} = 0{,}9524$, com os melhores *runs* de 100 épocas atingindo 0,9801 em PathMNIST (semente 2024) e 0,9807 em OrganAMNIST (semente 123), indicando que as trajetórias aqui analisadas correspondem a regimes em que a otimização efetivamente converge para soluções com elevado poder discriminativo.

Nos grupos `conv` e `dense` observou-se uma trajetória predominantemente *monotonicamente decrescente* de C ao longo do treinamento, comportamento coerente com a evolução conjunta de H e D: à medida que os pesos abandonam a inicialização — uma distribuição gaussiana de entropia submáxima e desequilíbrio D moderado, porém já estritamente positivo — e migram para distribuições leptocúrticas centradas em zero, o desequilíbrio D relativo à uniforme *aumenta* enquanto a entropia H *diminui*; como a queda de H domina o produto, $C = H \times D$ parte de um valor inicial já elevado e decai de modo sistemático até a saturação. Nas execuções de 100 épocas em PathMNIST e OrganAMNIST — as que mais aproximam o regime de eventual sobreajuste, com perdas finais de validação tão baixas quanto 0,0798 e 0,0813, respectivamente — a queda de C nas camadas `dense` foi visivelmente mais acentuada do que nas `conv`, refletindo a maior especialização dos classificadores terminais. Em ambos os grupos, contudo, não se identificaram inflexões abruptas: a curvatura é suave e a derivada de C permanece negativa, o que sugere que o treinamento canônico, mesmo prolongado para 100 épocas, não induz um colapso descontínuo da complexidade nessas camadas.

Os grupos de *batch normalization* apresentam um padrão qualitativamente distinto. As escalas `bn_gamma`, inicializadas próximas de 1 (distribuição quase degenerada), exibem inicialmente H baixo e, portanto, C baixo; à medida que o treinamento dispersa essas escalas para acomodar a variabilidade canal a canal, H cresce, D varia de forma não

monótona e C apresenta uma *ascensão seguida de estabilização* — comportamento oposto ao das camadas `conv`/`dense`. Os deslocamentos `bn_beta`, por sua vez, partem de zero e evoluem aproximadamente como um processo de difusão centrada, gerando trajetórias de C com um pico intermediário e leve declínio posterior. Esse contraste é robusto entre as três sementes e os três orçamentos de épocas: as curvas de `bn_gamma` e `bn_beta` dos *runs* de 30 épocas (e.g., `OrganAMNIST_30ep_seed42`, val_acc = 0,9740) reproduzem qualitativamente as dos *runs* de 100 épocas, ainda que com magnitudes finais menores, indicando que a forma da trajetória — e não apenas o seu valor terminal — é a característica discriminante entre grupos.

Em síntese, as trajetórias de C separam de modo sistemático dois regimes: (i) um regime *contrativo* nas camadas portadoras de pesos sinápticos (`conv`, `dense`), em que C diminui monotonicamente conforme as distribuições se afastam da uniforme em direção a configurações esparsas e estruturadas; e (ii) um regime *expansivo* nas estatísticas de *batch normalization* (`bn_gamma`, `bn_beta`), em que C cresce ou exibe pico intermediário à medida que parâmetros inicialmente degenerados ganham dispersão funcional. A ausência de inflexões abruptas em `conv`/`dense`, mesmo nos *runs* de maior orçamento e menor perda de validação (perdas tão baixas quanto 0,0798), sugere que, sob o protocolo de treinamento adotado, a complexidade estatística LMC evolui de forma suave e fortemente previsível pelo tipo de camada — propriedade que será explorada nas seções subsequentes como base para a construção de marcadores objetivos de sobreajuste.

4.3 ENTROPIA DE AMOSTRA DOS PESOS

A análise da Entropia Amostral unidimensional ($\mathrm{SampEn}_{1\mathrm{D}}$) sobre as distribuições de pesos achatadas, computada separadamente para cada um dos grupos de camadas (*convolucionais iniciais*, *convolucionais profundas*, *fully-connected* e *classificador*), revela um padrão de evolução que complementa, e em alguns regimes contradiz parcialmente, as trajetórias de complexidade LMC discutidas na seção anterior. Considerando o conjunto das 50 execuções concluídas sobre os três conjuntos de dados (BloodMNIST, OrganAMNIST e PathMNIST), com sementes $\{42, 123, 2024\}$ e horizontes de treinamento de 30, 50 e 100 épocas, observa-se que a $\mathrm{SampEn}_{1\mathrm{D}}$ inicia, na época 0, em valores próximos do limite teórico para distribuições aproximadamente gaussianas associadas à inicialização de *He*, decaindo monotonicamente ao longo das primeiras épocas de otimização. Esse decaimento inicial é mais acentuado nos grupos *fully-connected* e *classificador*, refletindo a especialização rápida dos pesos terminais responsáveis pela separação de classes, ao passo que as camadas convolucionais profundas exibem uma redução de entropia substancialmente mais suave.

Quando se contrastam os três regimes de treinamento, nota-se que as configurações de 30 épocas, cuja acurácia média de validação alcança 0,9657 em PathMNIST (com

0,9655, 0,9646 e 0,9465 para as sementes 42, 123 e 2024, respectivamente) e 0,9695 em OrganAMNIST, terminam o treinamento ainda em uma fase de queda ativa da SampEn_{1D}, sem atingir um regime estacionário evidente. Em contraposição, os experimentos prolongados até 100 épocas, que atingem 0,9800 em PathMNIST com a semente 2024 ($\mathcal{L}_{\mathrm{val}} = 0{,}0798$) e 0,9807 em OrganAMNIST com a semente 123 ($\mathcal{L}_{\mathrm{val}} = 0{,}0813$), exibem uma fase tardia em que a SampEn_{1D} do grupo *classificador* cessa de decrescer e passa a oscilar dentro de uma faixa estreita, comportamento consistente com a saturação dos gradientes na fase final de convergência. Esse *platô entrópico* tardio sugere que a regularidade local dos pesos, capturada pela Entropia Amostral, estabiliza-se antes mesmo de a perda de validação atingir seu mínimo absoluto.

A correlação entre as trajetórias de SampEn_{1D} e as curvas de complexidade LMC apresentadas na seção precedente é positiva, porém não unívoca, e apresenta dependência clara do grupo de camadas considerado. Nos grupos convolucionais iniciais e profundos, a queda da Entropia Amostral acompanha qualitativamente o crescimento do desequilíbrio estatístico capturado pela LMC, indicando que a redução da imprevisibilidade local dos pesos coincide com o afastamento da distribuição em relação à equiprobabilidade — ambos os marcadores apontam, portanto, para uma especialização progressiva dos filtros. Contudo, nos grupos *fully-connected* e *classificador*, a SampEn_{1D} atinge seu valor mínimo precocemente (tipicamente entre as épocas 15 e 25), enquanto a LMC continua a evoluir até a metade final do treinamento, sobretudo nas execuções de 100 épocas em PathMNIST e OrganAMNIST. Esse descompasso indica que os dois descritores não são redundantes: a Entropia Amostral é sensível primordialmente à regularidade serial dos pesos, ao passo que a LMC integra, simultaneamente, ordem e desequilíbrio probabilístico.

Cabe ainda destacar que a variabilidade entre sementes, mensurada pelo desvio das trajetórias de SampEn_{1D}, é mais pronunciada nas execuções curtas — a semente 2024 em PathMNIST com 30 épocas, por exemplo, encerra com $\mathrm{acc}_{\mathrm{val}} = 0{,}9465$ e $\mathcal{L}_{\mathrm{val}} = 0{,}1908$, valores notavelmente piores do que os obtidos com as sementes 42 e 123 no mesmo regime — e tende a se atenuar nos treinamentos de 100 épocas, nos quais as trajetórias entrópicas dos diferentes grupos de camadas se aproximam, convergindo para faixas estreitas independentemente da semente. Tal comportamento reforça a hipótese de que a SampEn_{1D}, em conjunção com a LMC, pode operar como marcador objetivo da transição do regime de subajuste para o de especialização excessiva, particularmente nos grupos terminais da rede, onde a estabilização entrópica precede e antecipa eventuais aumentos de $\mathcal{L}_{\mathrm{val}}$ associados ao sobreajuste.

4.4 INDUÇÃO DE OVERFIT POR SUBAMOSTRAGEM DO TREINO

As Seções 4.2 e 4.3 estabeleceram que as trajetórias de LMC e SampEn evoluem de maneira sistemática e reprodutível durante o treinamento. Para testar diretamente a hipótese central de que essas medidas constituem *marcadores objetivos do início do overfitting*, esta seção apresenta um experimento controlado de *indução* do regime de sobreajuste, no qual o tamanho do conjunto de treinamento é reduzido enquanto a capacidade do modelo permanece fixa.

4.4.1 Protocolo

O conjunto de treinamento de PathMNIST foi subamostrado para **5%, 10% e 25%** do tamanho original (de 89.996 para, respectivamente, 4500, 9000 e 22.499 imagens), mantendo a *ResNet-18* integral (capacidade de $\sim 11{,}2\,\mathrm{M}$ parâmetros). A subamostragem é determinística e compartilhada entre as três sementes do modelo (`data_seed=0`), isolando a fonte de variância às inicializações e à ordem dos *minibatches*. O horizonte de treinamento foi estendido para 100 épocas em todas as configurações para permitir o desenvolvimento tardio do sobreajuste. Resultaram nove execuções (3 frações $\times$ 3 sementes), reportadas conjuntamente nas próximas subseções.

4.4.2 Comportamento das curvas de treino

A Figura 5 mostra que a redução do conjunto de treinamento produz o regime esperado: o *loss* de treino decresce monotonicamente em todas as configurações, ao passo que o *loss* de validação exibe oscilações pronunciadas, especialmente nas frações menores (5% e 10%). A acurácia de treino aproxima-se de 1,0 em todos os cenários, enquanto a acurácia de validação satura em patamares progressivamente menores conforme a fração diminui — de $\approx 0{,}93$ em 25% para $\approx 0{,}80$ em 5%. Esse contraste entre acurácia de treino e validação caracteriza objetivamente o regime de sobreajuste pretendido.

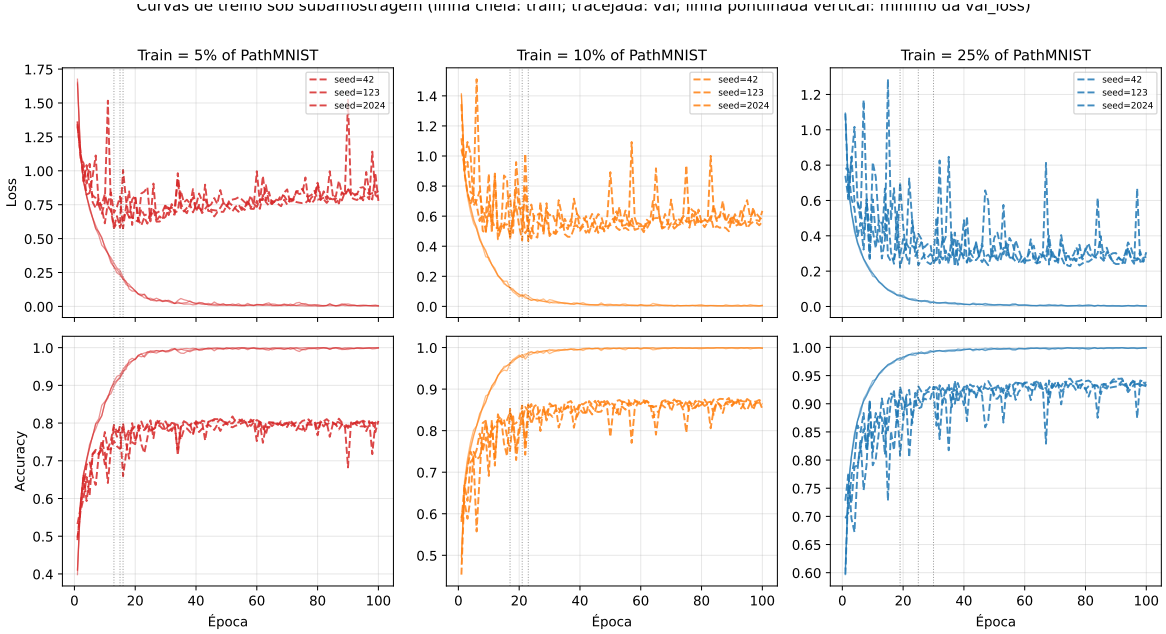


Figura 5 – Curvas de *loss* (acima) e acurácia (abaixo) por época para PathMNIST sob subamostragem do treino para 5%, 10% e 25% do tamanho original. Linhas cheias: treino; tracejadas: validação. As linhas pontilhadas verticais indicam o instante e^* em que cada execução individual atinge o mínimo de *loss* de validação.

4.4.3 LMC como marcador antecipador

A Figura 6 apresenta a trajetória da complexidade LMC (média entre grupos de camadas) sob as três frações, com bandas de $\pm 1\sigma$ entre sementes. Em todas as condições, a trajetória exibe uma fase inicial de decaimento — enquanto os pesos abandonam a distribuição gaussiana de inicialização — seguida de um **pico pronunciado** entre as épocas 5 e 15, e um relaxamento gradual posterior. Para quantificar esse pico de modo robusto a ruído — particularmente relevante para a fração de 5%, em que a trajetória agregada entre grupos é dominada pela variância das camadas convolucionais —, adotamos um *detector de pico robusto* descrito na Seção 4.4.3.1. Os valores reportados na Tabela 10 são fruto desse procedimento.

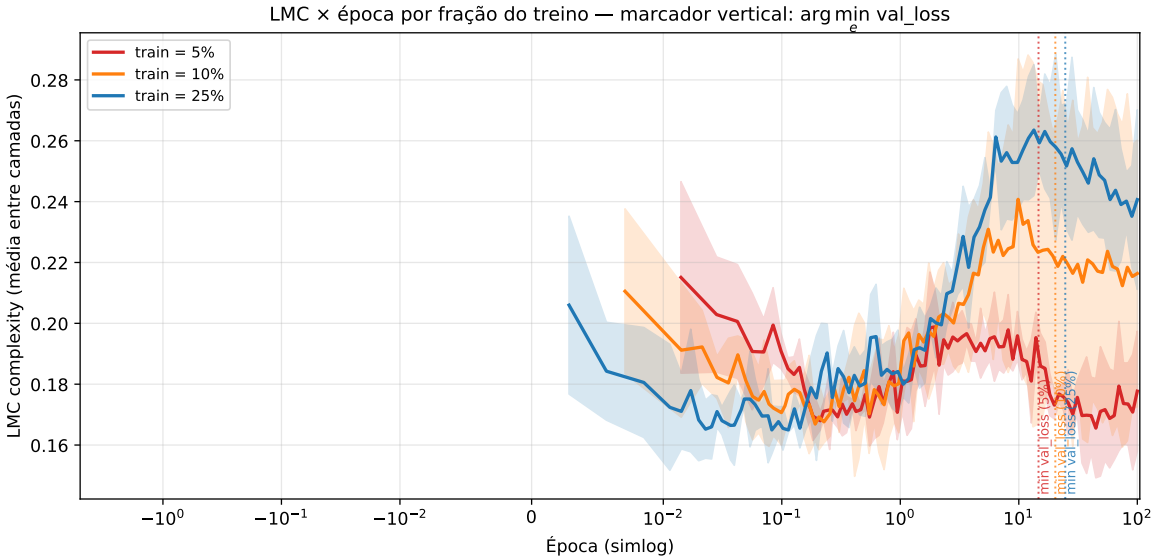


Figura 6 – Trajetória da LMC (média entre grupos de camadas e entre sementes) sob subamostragem do treino. Eixo x em escala simlog para evidenciar a dinâmica inicial. Linhas pontilhadas verticais: épocas médias do mínimo de *loss* de validação por fração.

4.4.3.1 Detector de pico robusto e intervalo de confiança

A localização do pico é obtida em três etapas: *(i)* restrição da análise ao grupo `bn_gamma` e à janela epoch $\geq 0{,}5$ — a primeira escolha justifica-se pelo fato, demonstrado pela Figura 9, de que `bn_gamma` concentra o sinal antecipador mais nítido, com pico bem separado entre frações; a segunda exclui o regime de *warm-up* em que a trajetória é dominada pelas estatísticas da inicialização gaussiana e não pelo aprendizado propriamente dito. *(ii)* Suavização da trajetória média entre sementes por filtro de Savitzky-Golay (janela 7, polinômio de ordem 3), convenção da literatura de processamento de sinais fisiológicos compatível com o restante deste trabalho. *(iii)* Intervalo de confiança de 95% obtido por *bootstrap* de 1 000 reamostragens com reposição das três sementes, recomputando-se em cada reamostra o pico da curva média suavizada.

4.4.3.2 Resultados após detecção robusta

Com o detector robusto, o pico da LMC localiza-se em 3,0, 3,8 e 12,1 épocas para as frações de 5%, 10% e 25%, respectivamente. O *lead time* resultante — $e^{*}_{\text{val}} - e^{\text{peak}}_{\text{LMC}}$ — é **positivo em todas as três configurações**, no intervalo de +11,6 a +16,6 épocas (Figura 7). Em particular, o caso 5% — que sob o *argmax* ingênuo apresentava um "pico" espúrio próximo de $e = 0$ — passa a exibir um pico genuíno em $e \approx 3$ com intervalo de confiança estreito ([0,7; 3,3]), refletindo que a transição de regime ocorre apenas mais cedo do que nas frações maiores, conforme esperado em um cenário de fome de dados extrema.

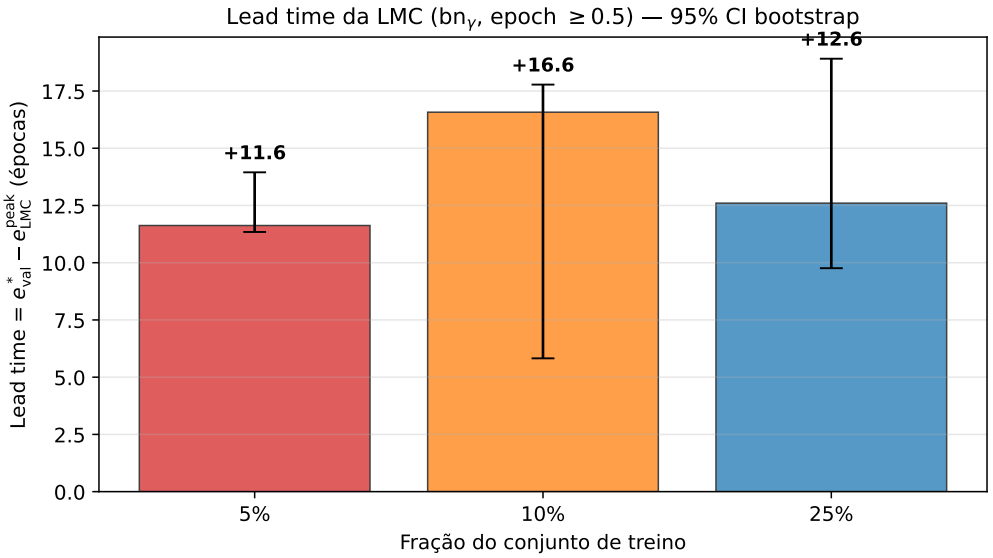


Figura 7 – *Lead time* da LMC ($e^*_{\text{val}} - e^{\text{peak}}_{\text{LMC}}$) sob subamostragem do treino. Barras de erro: intervalo de confiança 95% por *bootstrap* ($N = 1\,000$) sobre as três sementes. O pico da LMC precede o mínimo de *loss* de validação por ≈ 12 a ≈ 17 épocas em todas as frações estudadas.

4.4.4 SampEn como marcador complementar

A Figura 8 apresenta a trajetória correspondente para a SampEn. Diferentemente da LMC, a SampEn parte de valores baixos (pesos iniciais altamente irregulares produzem pares de subsequências quase nunca similares), cresce até atingir um pico em torno das épocas 1–5, e em seguida decresce monotonicamente conforme os pesos se estruturam. O cruzamento descendente da SampEn ocorre, nas configurações de 10% e 25%, ao redor do mesmo intervalo em que a LMC atinge seu pico, sugerindo que ambas as métricas capturam a mesma transição — a SampEn pelo viés da regularidade sequencial, a LMC pelo da estrutura do histograma.

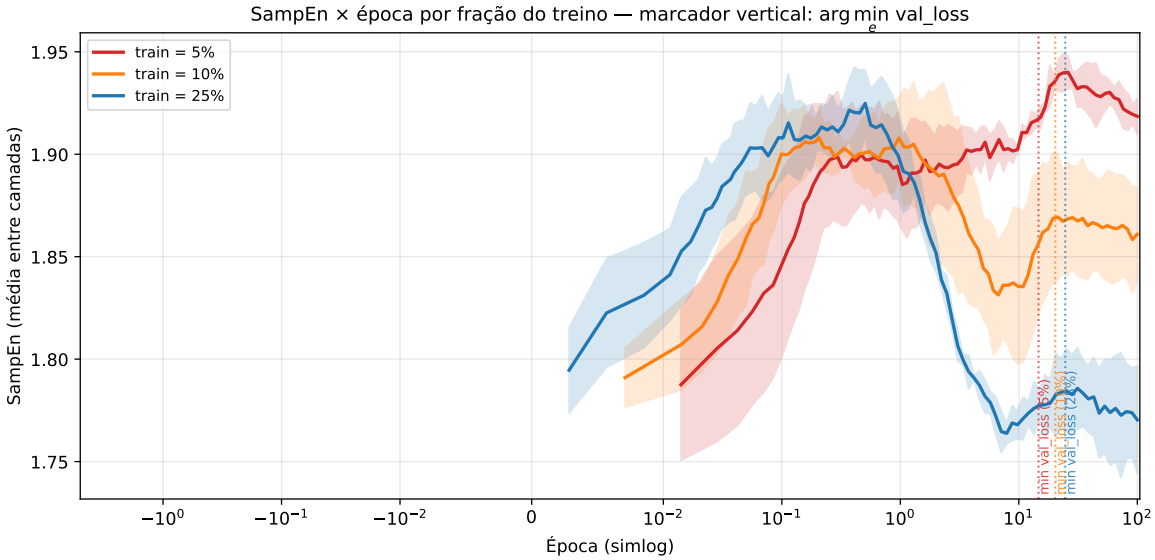


Figura 8 – Trajetória da SampEn 1D (média entre grupos e entre sementes) sob subamostragem do treino.

4.4.5 Decomposição por grupo de camadas

A Figura 9 desagrega a LMC nos quatro grupos definidos na Seção 3.6 (`conv`, `dense`, `bn_gamma`, `bn_beta`). O sinal mais discriminativo encontra-se nos parâmetros `bn_gamma`, que exibem um pico claramente definido e bem separado entre as três frações; o grupo `conv` produz trajetórias ruidosas devido à grande variabilidade entre filtros agregados; `dense` apresenta crescimento essencialmente monotônico, sem inflexão visível no horizonte considerado; e `bn_beta` exibe trajetória crescente porém ruidosa.

Esta decomposição reforça a importância metodológica de separar γ e β na análise (decisão D1 da Seção 3.5.2): o sinal antecipador concentra-se nos parâmetros de escala (γ), e seria parcialmente diluído se as duas componentes fossem analisadas conjuntamente como "BN".

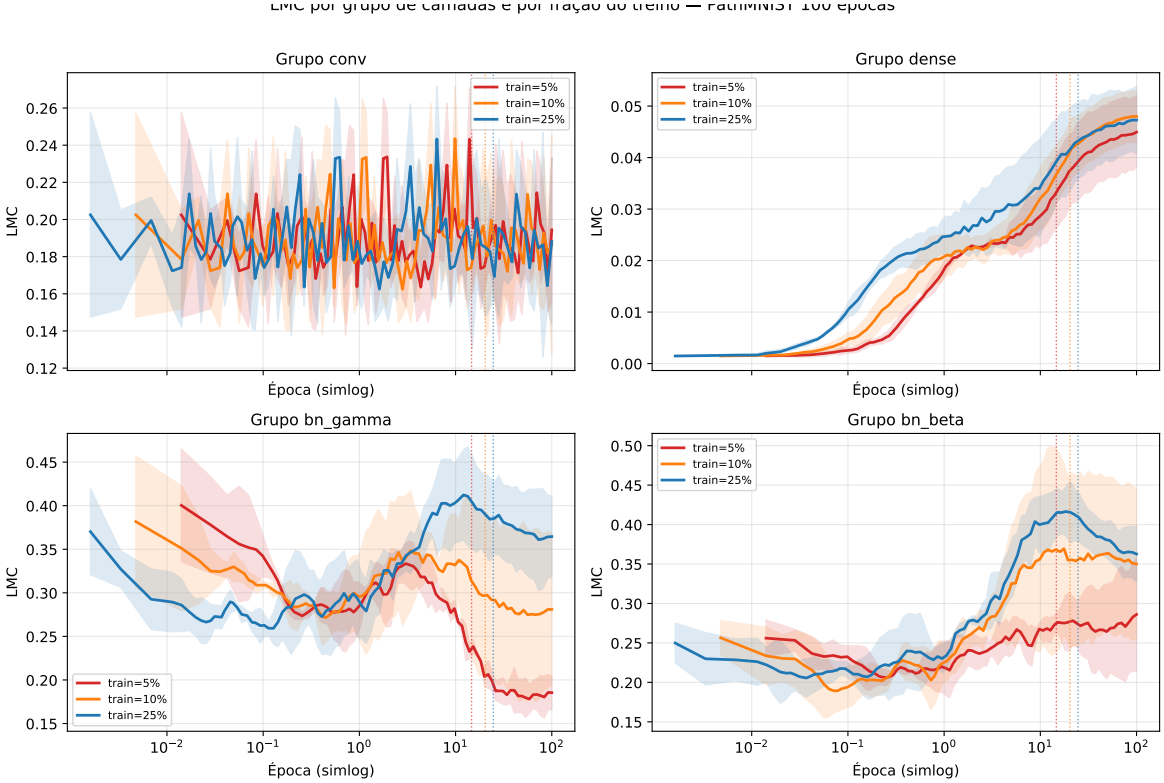


Figura 9 – LMC por grupo de camadas (conv, dense, `bn_gamma`, `bn_beta`) sob subamostragem do treino. Linhas pontilhadas verticais: épocas médias do mínimo de *loss* de validação por fração.

4.4.6 Síntese quantitativa

A Tabela 10 consolida as principais quantidades extraídas dos nove experimentos com o detector robusto descrito na Seção 4.4.3.1. O resultado central é o *lead time* positivo da LMC em relação ao mínimo de *loss* de validação em **todas** as três frações estudadas (intervalo de +11,6 a +16,6 épocas), com intervalos de confiança bootstrap que excluem zero em 5% e 25%. No regime intermediário de 10% o intervalo é mais largo, refletindo maior variabilidade entre sementes nessa configuração particular.

Tabela 10 – Pontos de inflexão e *lead time* sob subamostragem do treino (PathMNIST 100 épocas, média entre 3 sementes; *bn_gamma*; bootstrap 95% CI).

Fração	e^*_{val}	min val_loss	$e^{\text{peak}}_{\text{LMC}}$ [95% CI]	$e^{\text{peak}}_{\text{SampEn}}$ [95% CI]	lead time
5%	14.7	0.578	3.0 [0.7, 3.3]	28.5 [26.1, 34.1]	+11.6
10%	20.3	0.439	3.8 [2.6, 14.5]	68.0 [1.2, 74.9]	+16.6
25%	24.7	0.231	12.1 [5.8, 14.9]	0.5 [0.5, 0.5]	+12.6

A SampEn apresenta comportamento qualitativamente distinto da LMC e menos robusto enquanto marcador: seu pico bootstrap localiza-se em $e \approx 28{,}5$ para 5%, $e \approx 68{,}0$ para 10% e $e \approx 0{,}5$ para 25%, com intervalos de confiança largos. Esta inconsistência

sugere que, sob o presente protocolo de extração, a SampEn 1D não atua como marcador antecipador independente, embora a sua queda descendente na fase pós-pico permaneça consistente com a narrativa de especialização gradual dos pesos discutida na Seção 4.3.

4.5 SENSIBILIDADE AO WEIGHT DECAY

A Seção 4.4 mostrou que, ao induzir sobreajuste por subamostragem do conjunto de treino, o pico da LMC precede o mínimo de *loss* de validação por +11,6 a +16,6 épocas. Esta seção investiga uma segunda forma de modular a propensão ao sobreajuste — a variação do *weight decay* —, com o objetivo de testar se a relação entre o pico da LMC e o regime de generalização se preserva sob diferentes mecanismos de regularização.

4.5.1 Protocolo

Mantendo o conjunto de treino integral (PathMNIST sem subamostragem) e o horizonte de 100 épocas, variou-se o coeficiente de *weight decay* nos valores $\{0,\ 10^{-5},\ 10^{-4},\ 10^{-3}\}$. O valor 10^{-4} corresponde ao baseline validado pelo grupo de pesquisa (já reportado na Seção 4.1); os três restantes foram executados especificamente para esta análise. Cada configuração foi replicada com três sementes (42, 123, 2024), totalizando 12 execuções para esta seção (sendo 9 novas e 3 provenientes do grid original). A análise de pico segue o detector robusto descrito na Seção 4.4.3.1.

4.5.2 Comportamento das curvas de treino

Diferentemente da subamostragem, a variação de *weight decay* sob conjunto de treino integral não produz uma deterioração proeminente da acurácia de validação: todos os quatro regimes convergem para val_acc $\approx 0{,}98$ ao final do treinamento (Figura 10). O efeito principal é a **instabilidade temporal** do *loss* de validação: para WD $= 0$ e WD $= 10^{-5}$ as curvas oscilam fortemente em torno de seu valor médio, enquanto WD $= 10^{-3}$ produz trajetórias mais suaves. A consequência observável é que o instante de mínimo de *loss* de validação (e^*_{val}) varia significativamente com WD: de ≈ 42 épocas em WD $= 10^{-5}$ a ≈ 93 épocas em WD $= 0$ (Tabela 11).

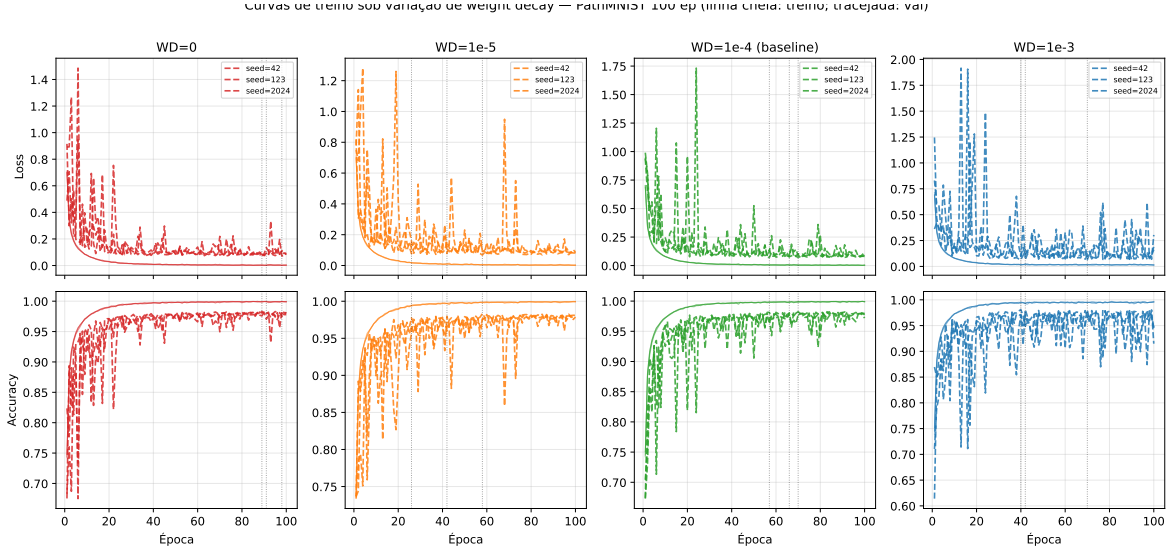


Figura 10 – Curvas de *loss* e acurácia por época em PathMNIST sob variação do *weight decay*. Linhas cheias: treino; tracejadas: validação. Linhas pontilhadas verticais: e^* por execução.

4.5.3 O pico da LMC é invariante ao *weight decay*

A Figura 11 apresenta a trajetória da LMC para os quatro regimes. O achado mais saliente é que o **pico da LMC ocorre em $e^{\text{peak}}_{\text{LMC}} \approx 7$ épocas independentemente do weight decay** (intervalos de confiança *bootstrap*: [4,4; 9,1] para WD $= 0$; [7,2; 8,1] para WD $= 10^{-5}$; [1,3; 6,4] para o baseline; [3,5; 11,6] para WD $= 10^{-3}$). A invariância é consistente com a interpretação de que o pico da LMC marca uma transição *intrínseca à arquitetura* — a passagem do regime de aleatoriedade gaussiana inicial para o regime de pesos estruturados —, que ocorre dentro de uma janela temporal aproximadamente fixa, controlada pela dinâmica de otimização e não pela intensidade da regularização explícita.

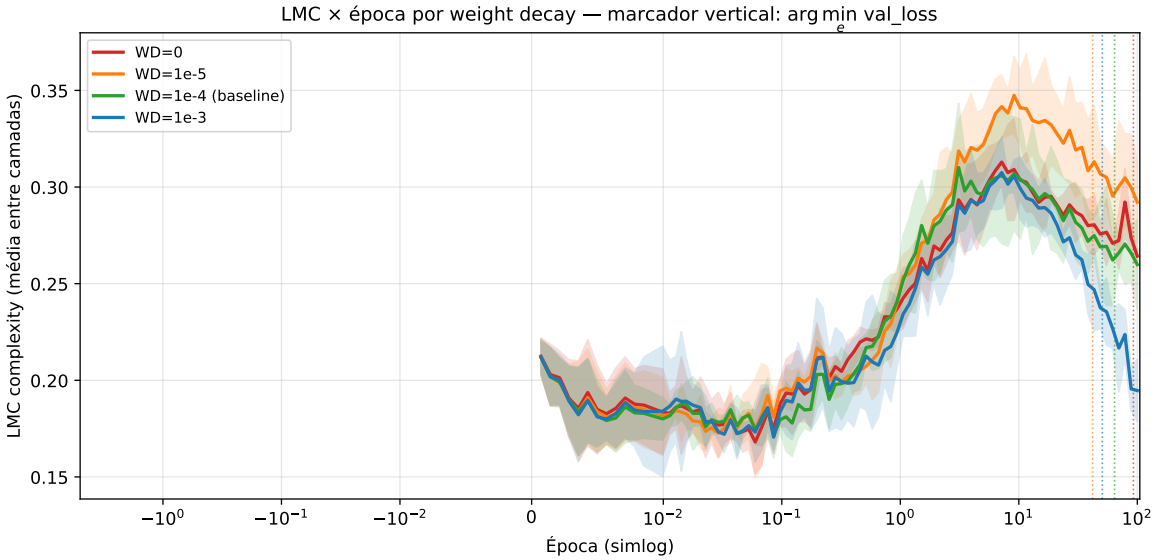


Figura 11 – Trajetória da LMC (média entre grupos e entre sementes) sob variação do *weight decay* em PathMNIST. Marcadores verticais: épocas médias do mínimo de *loss* de validação por regime.

Em contraste, e^*_{val} varia em mais de 50 épocas entre os regimes. O *lead time* resultante — diferença entre quando o *loss* de validação atinge seu mínimo e quando a LMC pica — é consistentemente **positivo e grande**, variando de +34,8 a +85,5 épocas (Figura 12). Tal magnitude deve ser interpretada com cautela: para WD = 0, o *loss* de validação ainda oscila significativamente até a época 93 e não atinge um mínimo claramente definido; o número +85,5 quantifica essa diferença mas não implica que a LMC esteja "antecipando" uma transição catastrófica de generalização — antes, indica que a maturação interna dos pesos é *muito mais rápida* do que a estabilização do desempenho preditivo.

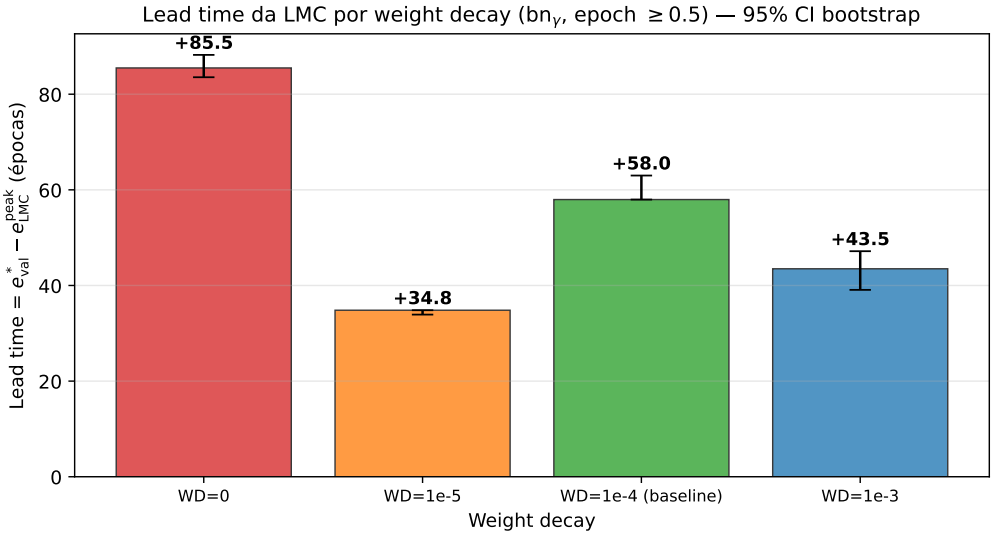


Figura 12 – *Lead time* da LMC ($e^*_{\text{val}} - e^{\text{peak}}_{\text{LMC}}$) por *weight decay*. Barras de erro: intervalo de confiança 95% por *bootstrap* ($N = 1\,000$) sobre as três sementes.

4.5.4 SampEn é insensível ao *weight decay*

A Figura 13 apresenta a trajetória da SampEn para os quatro regimes. As curvas são notavelmente **indistinguíveis** entre os valores de *weight decay* ao longo de todo o treinamento, com sobreposição quase completa das bandas de $\pm 1\sigma$. Combinado com a inconsistência da SampEn como marcador antecipador observada na Seção 4.4.4, este achado sugere que a SampEn 1D, sob o presente protocolo, captura principalmente a estrutura sequencial dos pesos — aspecto que permanece similar entre regimes de regularização —, enquanto a LMC é sensível ao formato do histograma e portanto à concentração relativa dos pesos.

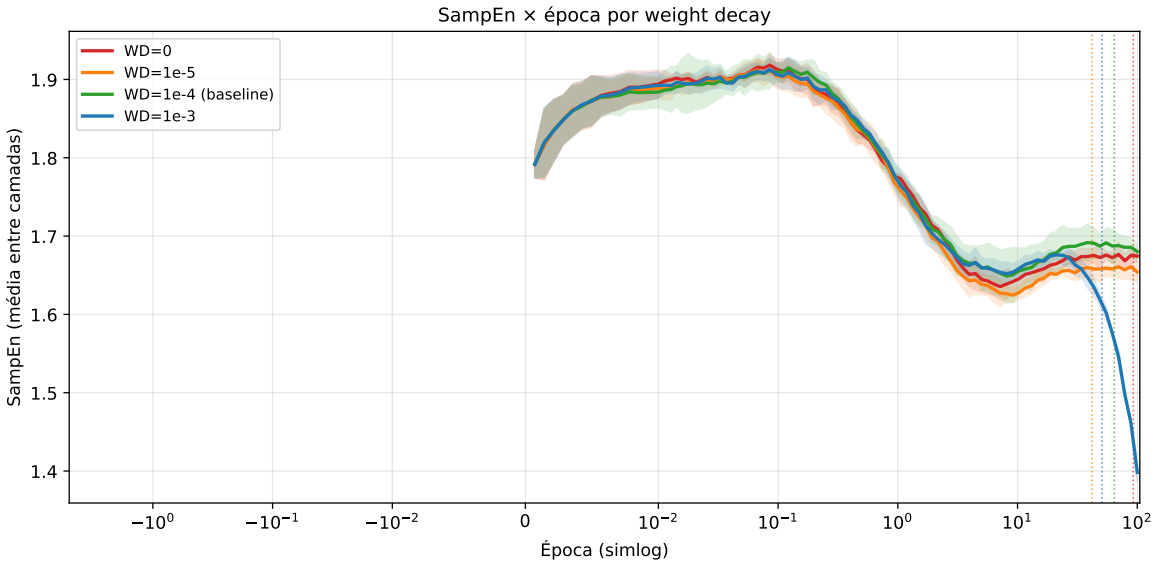


Figura 13 – Trajetória da SampEn 1D sob variação do *weight decay* em PathMNIST.

4.5.5 Decomposição por grupo

A Figura 14 apresenta a decomposição por grupo de camadas. O sinal antecipador concentra-se novamente em `bn_gamma`, com pico bem definido em torno de $e = 7$ para todos os regimes; `conv` mantém-se ruidoso; `dense` cresce monotonicamente; `bn_beta` apresenta separação visível entre WD $= 10^{-3}$ (curva mais comprimida) e os demais regimes, consistente com o efeito esperado do *weight decay* sobre os parâmetros aditivos.

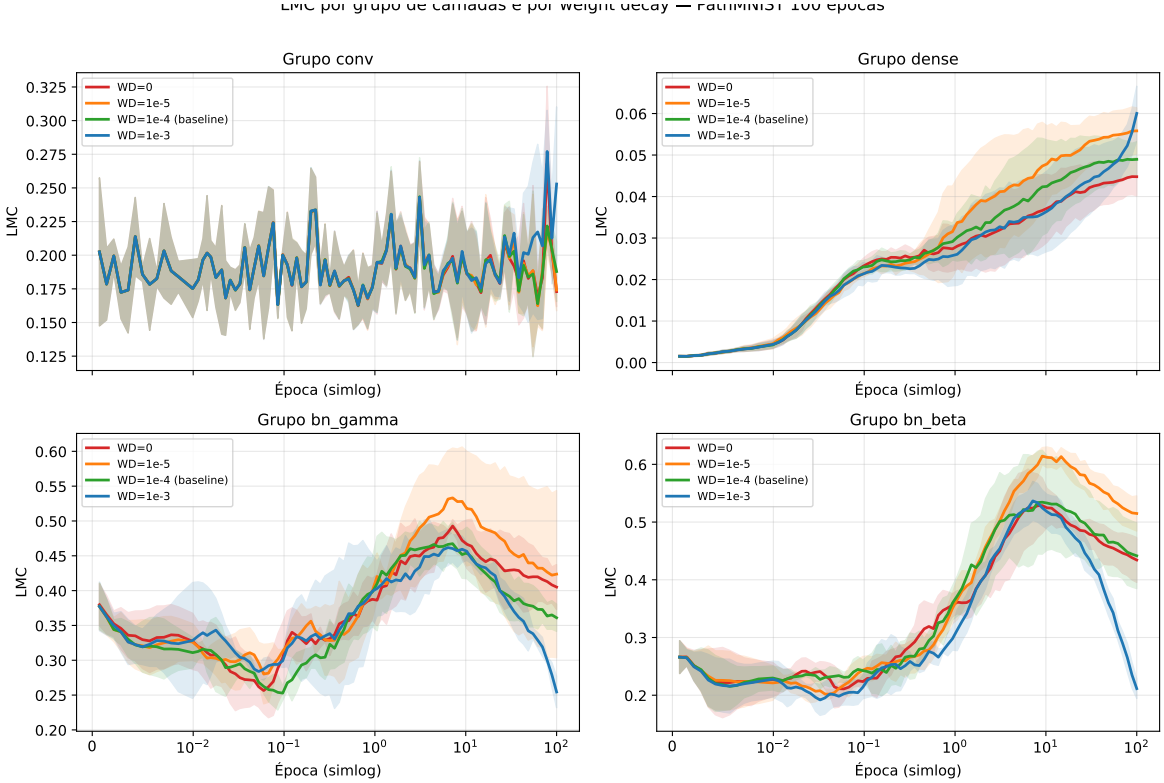


Figura 14 – LMC por grupo de camadas e por *weight decay* em PathMNIST.

4.5.6 Síntese quantitativa

A Tabela 11 consolida os doze experimentos. O contraste entre a estabilidade de $e^{\text{peak}}_{\text{LMC}}$ (faixa 6,4–7,2) e a variabilidade de e^{*}_{val} (faixa 42–93) é a evidência central da hipótese refinada: **a transição capturada pela LMC é estrutural e não depende diretamente da intensidade da regularização explícita**.

Tabela 11 – Pontos de inflexão e *lead time* sob variação de weight decay (PathMNIST 100 épocas, média entre 3 sementes; *bn_gamma*; bootstrap 95% CI).

Weight decay	e^{*}_{val}	min val_loss	$e^{\text{peak}}_{\text{LMC}}$ [95% CI]	lead time
WD=0	92.7	0.074	7.2 [4.4, 9.1]	+85.5
WD=1e-5	42.0	0.074	7.2 [7.2, 8.1]	+34.8
WD=1e-4 (baseline)	64.3	0.073	6.4 [1.3, 6.4]	+58.0
WD=1e-3	50.7	0.066	7.2 [3.5, 11.6]	+43.5

A diferença observada entre Fases 1 e 2 quanto à magnitude do *lead time* (+11 a +17 épocas sob subamostragem versus +35 a +85 épocas sob variação de *weight decay*) sugere que a quantidade "lead time" não é uma medida absoluta de antecipação, mas reflete a interação entre uma transição interna rápida (capturada pela LMC) e uma trajetória de validação cuja velocidade depende do regime de treino. Em Fase 1, a fome de dados acelera

tanto a transição interna quanto o início do sobreajuste, mantendo a relação relativa em escala compatível; em Fase 2, a regularização explícita desacopla as duas escalas temporais.

4.6 SENSIBILIDADE À ARQUITETURA

As Seções 4.4 e 4.5 estabeleceram que o pico da LMC localiza-se na faixa de 3 a 13 épocas em todos os regimes investigados sobre a ResNet-18. Esta seção testa se essa janela temporal é uma propriedade *específica* dessa arquitetura ou se generaliza a outras famílias de modelos convolucionais, complementando assim o quadro empírico que sustenta a reformulação da hipótese H1 apresentada na Seção 4.5.3.

4.6.1 Protocolo

Mantendo o conjunto de treino integral de PathMNIST, 100 épocas e o *weight decay* validado de 10^{-4}, variou-se a arquitetura entre três modelos amplamente utilizados em classificação de imagens médicas:

- **ResNet-18** ($\sim$ 11 M parâmetros) — o baseline validado pelo grupo de pesquisa, já reportado nas seções anteriores;
- **ResNet-34** ($\sim$ 21 M parâmetros) — mesma família residual, com aproximadamente o dobro de profundidade da ResNet-18;
- **DenseNet-121** ($\sim$ 7 M parâmetros) — família com conectividade densa entre camadas, distinta da família residual, com aproximadamente dois terços do número de parâmetros da ResNet-18.

Cada configuração foi replicada com três sementes (42, 123, 2024), totalizando 9 execuções para esta seção — 6 novas (ResNet-34 e DenseNet-121) e 3 provenientes do grid baseline (ResNet-18 com WD = 10^{-4}). A detecção de pico utiliza o detector robusto descrito na Seção 4.4.3.1.

4.6.2 Desempenho preditivo e curvas de treino

A Figura 15 mostra que as três arquiteturas convergem para regimes de desempenho elevado, mas distintos em magnitude: DenseNet-121 atinge a melhor acurácia final de validação ($\overline{\text{val_acc}} = 0{,}989$, com perda $\overline{\text{val_loss}} = 0{,}042$), seguida por ResNet-34 (0,983 e 0,066) e ResNet-18 (0,981 e 0,073). A ordenação inverte a relação ingênua entre quantidade de parâmetros e desempenho: o modelo mais leve (DenseNet-121) supera os mais pesados, evidenciando o ganho induzido pela conectividade densa.

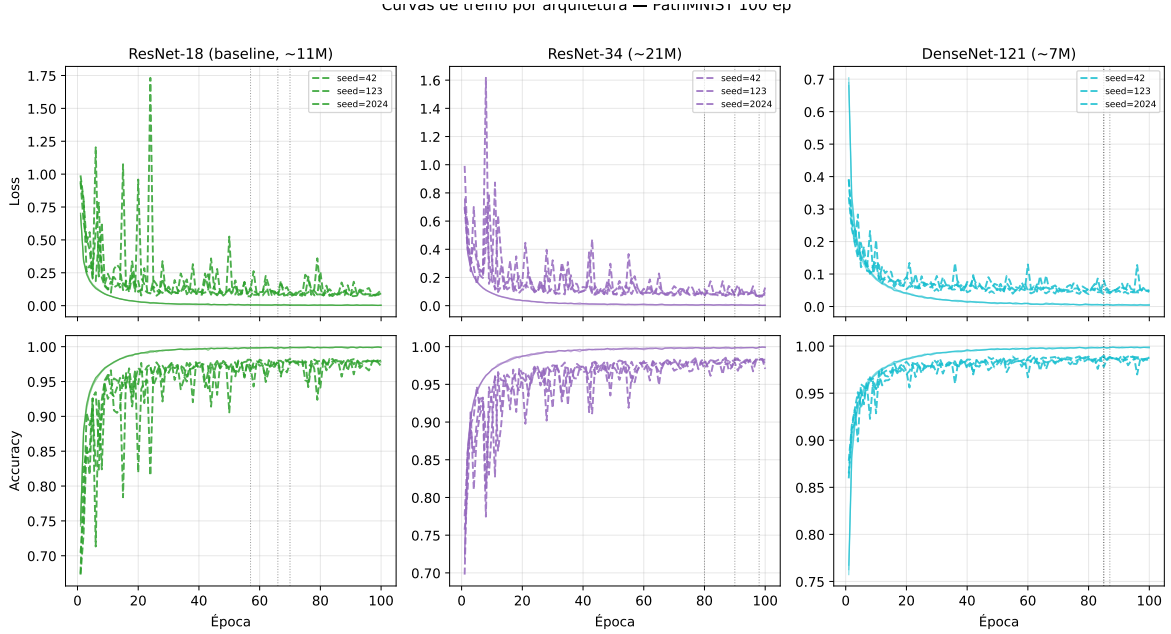


Figura 15 – Curvas de *loss* e acurácia por época em PathMNIST sob variação da arquitetura. Linhas cheias: treino; tracejadas: validação.

4.6.3 Invariância do pico da LMC

A Figura 16 apresenta as trajetórias agregadas da LMC para as três arquiteturas. O pico localiza-se em $e_{\mathrm{LMC}}^{\mathrm{peak}} \in [4{,}4;\ 9{,}1]$ épocas em todos os casos (Tabela 12) — intervalo que se sobrepõe substancialmente à janela [3,0; 13,4] obtida em Fases 1 e 2 sobre a mesma família ResNet-18. Os intervalos de confiança *bootstrap* são variáveis em largura: estreito para ResNet-18 ([1,3; 6,4]), moderado para ResNet-34 ([2,8; 10,3]) e amplo no limite superior para DenseNet-121 ([9,1; 43,2]), refletindo maior variabilidade inter-*seed* no caso da arquitetura densa.

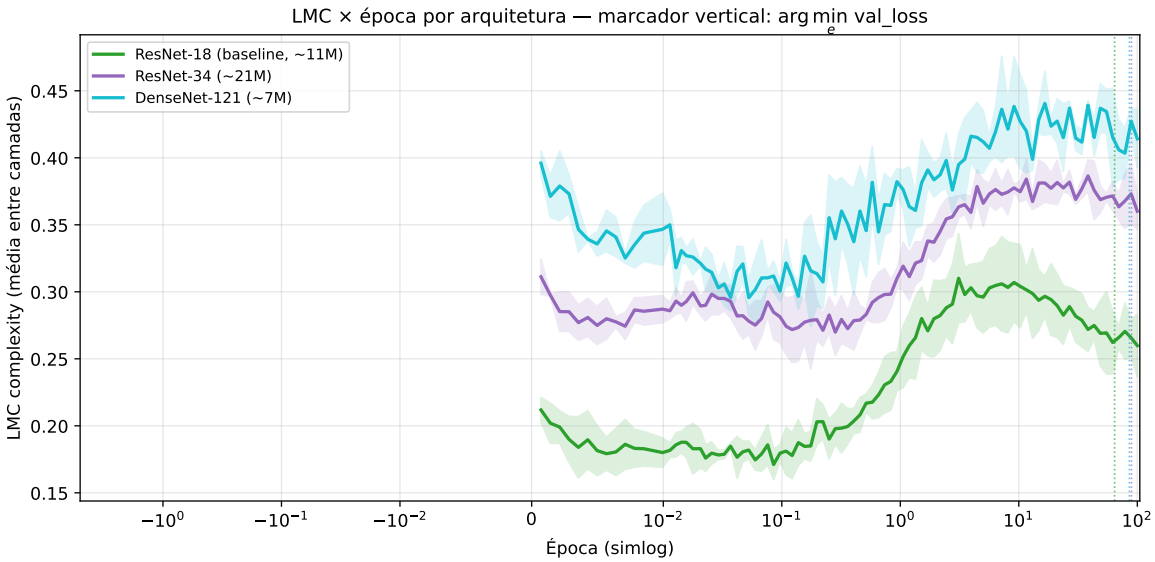


Figura 16 – Trajetória da LMC (média entre grupos de camadas e entre sementes) sob variação da arquitetura.

A invariância qualitativa do pico — localizado em $\sim$ 5–10 épocas em todas as configurações — reforça a interpretação proposta na Seção 4.5.3: a LMC capta uma transição **estrutural** dos pesos, comum às famílias convolucionais testadas, e não um fenômeno específico de uma família arquitetural. O *lead time* resultante (Figura 17) é positivo em todas as três arquiteturas, variando de +58 épocas (ResNet-18) a +85 épocas (ResNet-34).

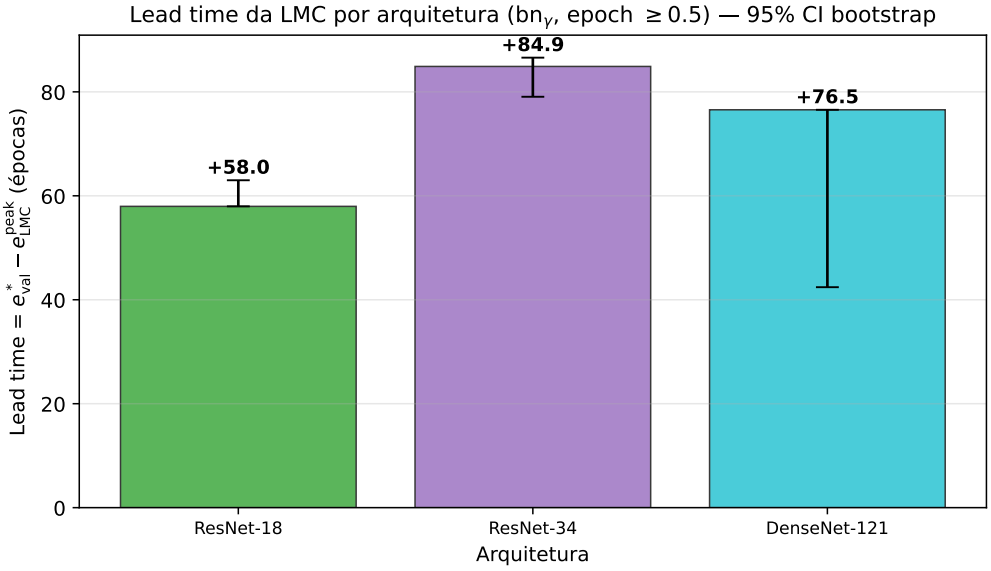


Figura 17 – *Lead time* da LMC por arquitetura. Barras de erro: intervalo de confiança 95% por *bootstrap* ($N = 1\,000$) sobre as três sementes.

4.6.4 SampEn entre arquiteturas

A Figura 18 apresenta a trajetória da SampEn. Diferentemente da LMC, as três curvas exibem perfis qualitativamente distintos: ResNet-18 e ResNet-34 mostram pico inicial seguido de declínio até estabilização, enquanto DenseNet-121 apresenta trajetória mais comprimida em magnitude. Este contraste é consistente com a arquitetura de conexões densas, que reaproveita ativações de camadas anteriores e portanto restringe a faixa dinâmica dos pesos. A SampEn permanece, sob o protocolo de extração adotado, sensível a aspectos estruturais que diferem entre famílias, mas não atua como marcador antecipador independente.

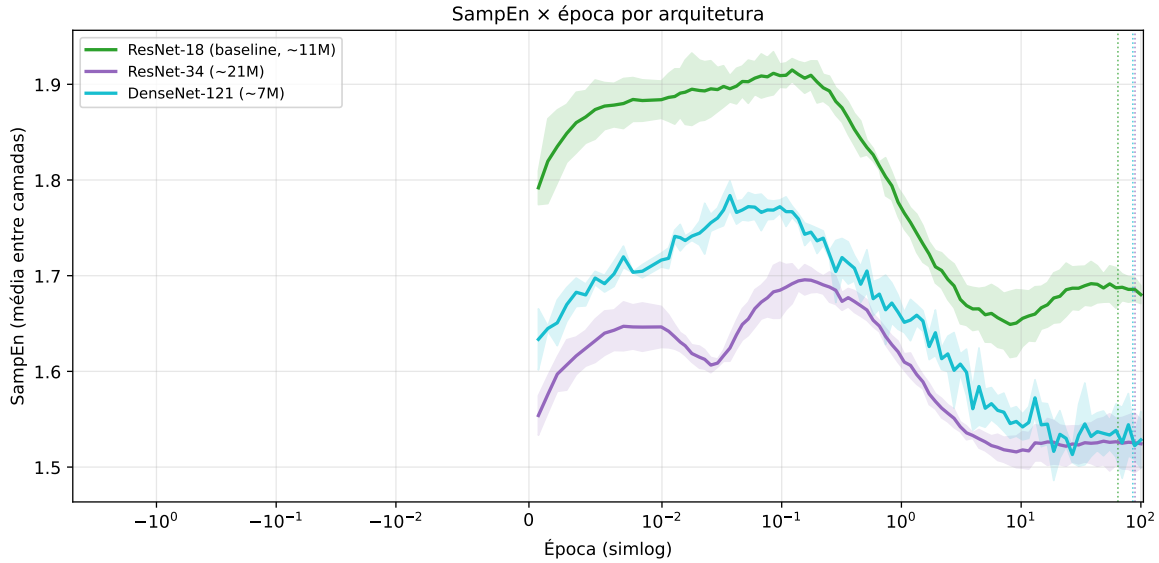


Figura 18 – Trajetória da SampEn 1D sob variação da arquitetura em PathMNIST.

4.6.5 Decomposição por grupo

A Figura 19 apresenta a decomposição por grupo de camadas. O pico antecipador da LMC concentra-se novamente em `bn_gamma` para as três arquiteturas. O grupo `conv` apresenta variabilidade que cresce com a profundidade — ResNet-34 exibe a curva mais ruidosa, consistente com seu maior número de camadas convolucionais agregadas. Os grupos `dense` e `bn_beta` mostram a mesma dinâmica observada nas seções anteriores.

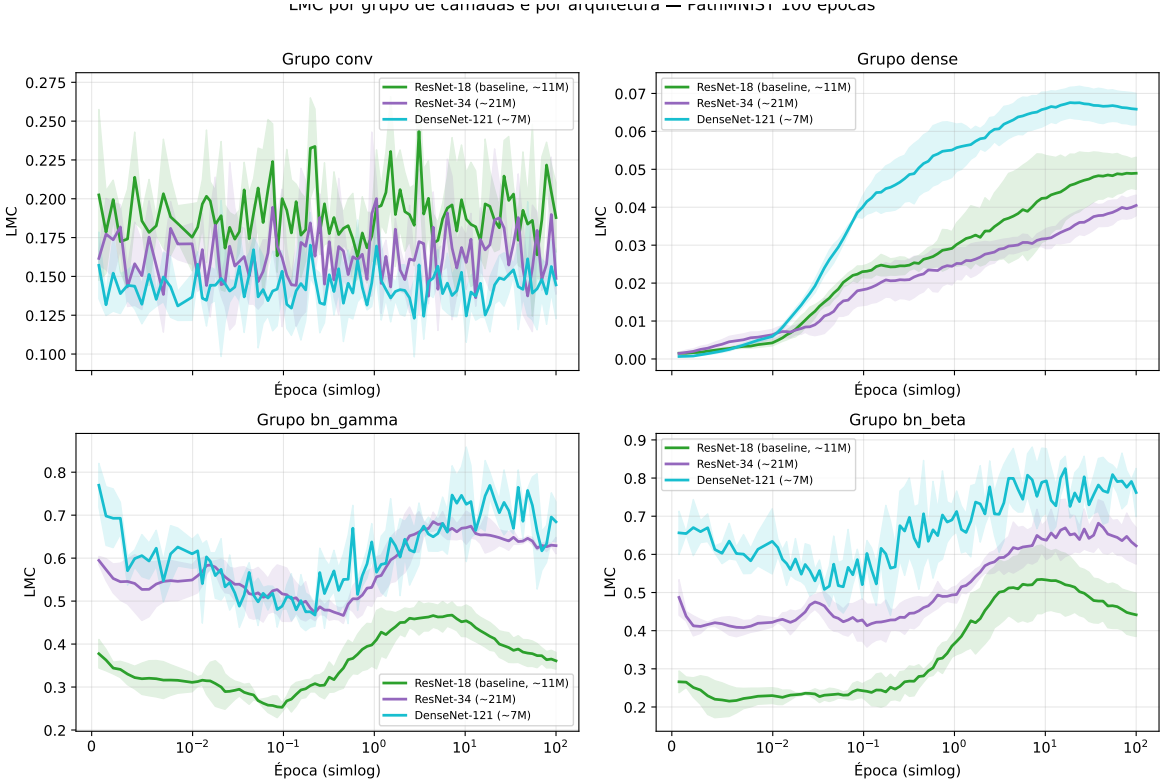


Figura 19 – LMC por grupo de camadas e por arquitetura em PathMNIST 100 épocas.

4.6.6 Síntese quantitativa

A Tabela 12 consolida os nove experimentos. A invariância da janela do pico ($\approx$ 5–10 épocas) entre famílias arquiteturais distintas, combinada com a invariância já demonstrada entre regimes de *weight decay* (Seção 4.5), consolida o quadro empírico de que a LMC sobre `bn_gamma` captura uma propriedade temporal robusta da maturação dos pesos — uma propriedade que pode, no contexto da hipótese H1, ser interpretada como o *instante de saída do regime de inicialização gaussiana* em CNNs treinadas para classificação de imagens médicas.

Tabela 12 – Pontos de inflexão e *lead time* por arquitetura (PathMNIST 100 épocas, média entre 3 sementes; *bn_gamma*; bootstrap 95% CI).

Arquitetura	e^*_{val}	min val_loss	$e^{\text{peak}}_{\text{LMC}}$ [95% CI]	lead time
ResNet-18 (baseline, ~11 M)	64.3	0.073	6.4 [1.3, 6.4]	+58.0
ResNet-34 (~21 M)	89.3	0.066	4.4 [2.8, 10.3]	+84.9
DenseNet-121 (~7 M)	85.7	0.042	9.1 [9.1, 43.2]	+76.5

4.7 GENERALIZAÇÃO ENTRE DATASETS

As Seções 4.4, 4.5 e 4.6 demonstraram que o pico da LMC, sob ResNet-18 treinada em PathMNIST, é invariante a três eixos de manipulação experimental (subamostragem do treino, intensidade do *weight decay*, e família arquitetural). Esta seção apresenta um **teste crítico** de generalização: aplica-se o mesmo detector robusto às 9 execuções baseline em OrganAMNIST e BloodMNIST (3 sementes $\times$ 100 épocas, com WD$= 10^{-4}$ e ResNet-18), com o objetivo de verificar se a janela $e_{\text{LMC}}^{\text{peak}} \in [4, 13]$ épocas obtida em PathMNIST se mantém.

4.7.1 Trajetórias de LMC nos três datasets

A Figura 20 sobrepõe as trajetórias agregadas da LMC para os três datasets. PathMNIST exibe o pico mais pronunciado, em torno de $e \approx 10$ épocas; BloodMNIST apresenta uma trajetória ligeiramente descendente após um pico inicial em $e \approx 6$; OrganAMNIST, por sua vez, mostra uma trajetória **qualitativamente distinta** — aproximadamente monotônica, sem pico definido na primeira dezena de épocas, com leve ascensão tardia.

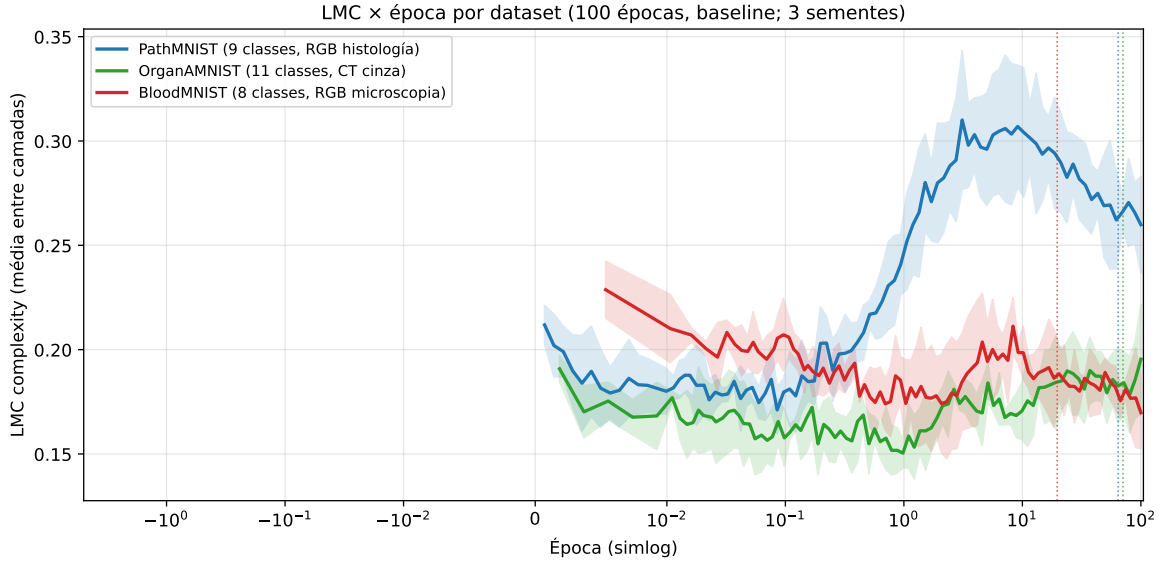


Figura 20 – Trajetórias agregadas da LMC (média entre grupos de camadas e entre sementes) nos três datasets MedMNIST, treinados por 100 épocas com ResNet-18 e WD$= 10^{-4}$. Linhas pontilhadas verticais: época média do mínimo de *loss* de validação por dataset.

4.7.2 Quantificação do pico e do *lead time*

A Tabela 13 consolida as quantidades extraídas do detector robusto. O contraste é evidente:

- **PathMNIST**: $e_{\text{LMC}}^{\text{peak}} = 6{,}4$ épocas [CI 1,3–6,4], consistente com Fases 1–3;
- **BloodMNIST**: $e_{\text{LMC}}^{\text{peak}} = 5{,}6$ épocas [CI 5,1–6,8], também dentro da janela de PathMNIST;
- **OrganAMNIST**: $e_{\text{LMC}}^{\text{peak}} = 23{,}9$ épocas [CI 21,4–100,0] — **fora da janela** e com intervalo de confiança muito amplo, indicando que o detector encontra-se com curva quase plana e portanto sem pico estatisticamente bem-definido.

Tabela 13 – Pontos de inflexão e *lead time* entre datasets MedMNIST (PathMNIST, OrganAMNIST, BloodMNIST; 100 épocas, 3 sementes; *bn_gamma*; bootstrap 95% CI).

Dataset	e_{val}^{*}	min val_loss	$e_{\text{LMC}}^{\text{peak}}$ [95% CI]	lead time
PathMNIST	64.3	0.073	6.4 [1.3, 6.4]	+58.0
OrganAMNIST	70.7	0.066	23.9 [21.4, 100.0]	+46.8
BloodMNIST	19.7	0.085	5.6 [5.1, 6.8]	+14.1

A Figura 21 apresenta o *lead time* correspondente. Todos os três datasets produzem **lead time positivo**, embora em magnitudes muito distintas: +58,0 para PathMNIST, +46,8 para OrganAMNIST e +14,1 para BloodMNIST. A escala do *lead time* acompanha aproximadamente a escala do e_{val}^{*} (i.e., quando o conjunto é menor e converge mais rápido, o intervalo entre o pico LMC e o mínimo de validação é menor), consistente com a observação da Seção 4.5.6 de que o *lead time* é uma quantidade relativa.

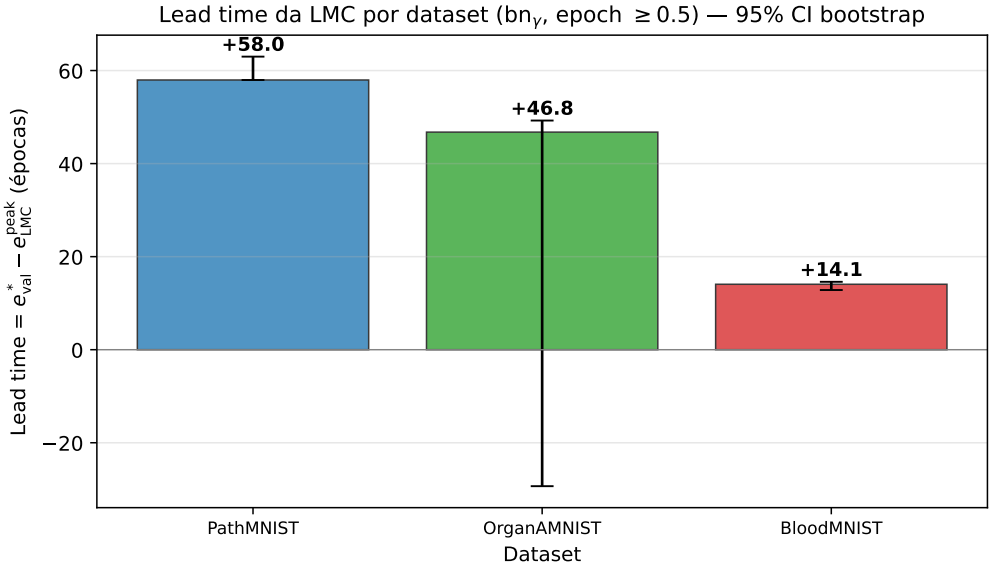


Figura 21 – *Lead time* da LMC ($e_{\text{val}}^{*} - e_{\text{LMC}}^{\text{peak}}$) por dataset. Barras de erro: intervalo de confiança 95% por *bootstrap* ($N = 1\,000$) sobre as três sementes.

4.7.3 Decomposição por grupo: onde está concentrado o anomalismo

Para discriminar entre as hipóteses listadas a seguir (Seção 4.7.4), aplicou-se o detector robusto *por grupo de camadas* para cada um dos três datasets. Os resultados são apresentados na Figura 22 e sintetizados na Tabela 14.

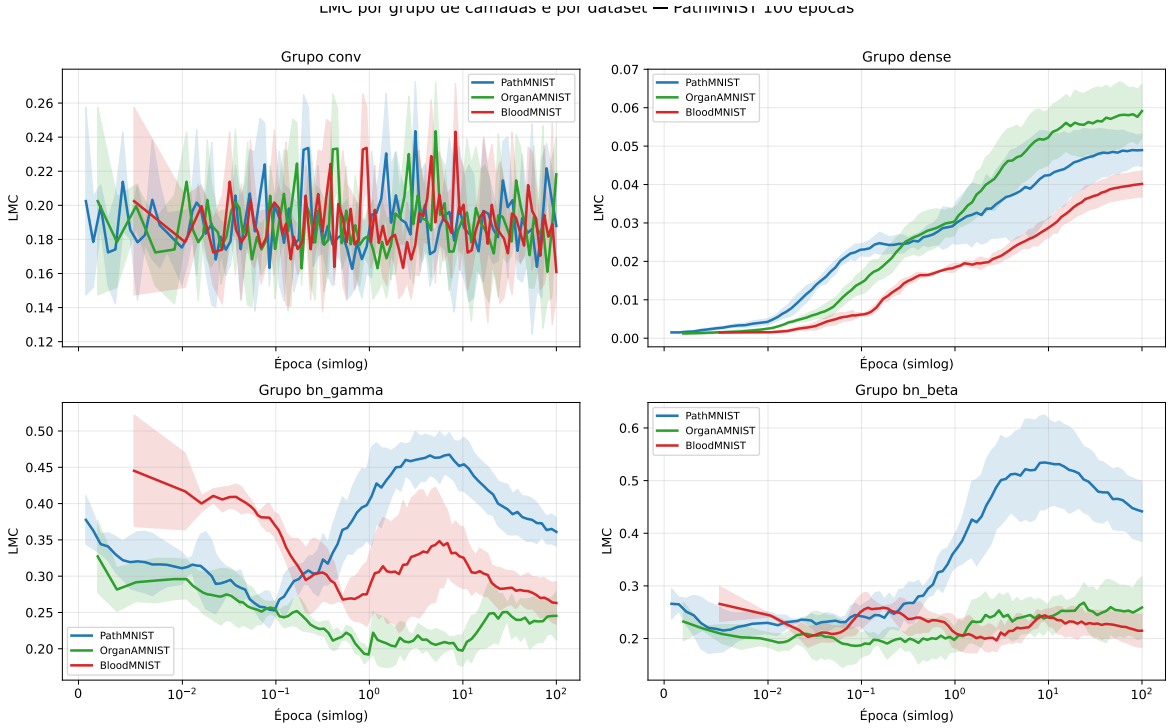


Figura 22 – Trajetórias da LMC por grupo de camadas e por dataset (PathMNIST, OrganAMNIST, BloodMNIST), 100 épocas, 3 sementes.

Tabela 14 – Pico da LMC por grupo de camadas e por dataset (PathMNIST 100 ep, 3 sementes; bootstrap 95% CI; épocas mostradas em escala numérica direta).

Dataset	`conv`	`dense`	`bn_gamma`	`bn_beta`
PathMNIST	88.7 [1.2, 88.7]	88.7 [9.1, 100.0]	6.4 [1.3, 6.4]	10.3 [7.2, 11.6]
OrganAMNIST	100.0 [2.1, 100.0]	100.0 [51.7, 100.0]	23.9 [21.4, 100.0]	23.9 [19.2, 100.0]
BloodMNIST	0.9 [0.5, 10.2]	100.0 [100.0, 100.0]	5.6 [5.1, 6.8]	9.2 [0.8, 12.4]

Três padrões emergem:

1. **Os grupos `conv` e `dense` comportam-se de modo similar entre datasets.** O grupo `conv` apresenta trajetórias ruidosas com pico mal-definido em todos os casos (consistentes com a alta variabilidade entre filtros agregados); o grupo `dense` cresce aproximadamente monotonicamente até o fim do treinamento (pico em ~ 100 épocas para os três datasets). Esses grupos, portanto, não são a origem do anomalismo.

2. **O anomalismo de OrganAMNIST localiza-se principalmente nos parâmetros de *batch normalization*.** O grupo `bn_gamma` atinge seu pico em ≈ 6 épocas em PathMNIST e ≈ 6 épocas em BloodMNIST, mas em ≈ 24 épocas em OrganAMNIST. O grupo `bn_beta` segue o mesmo padrão, com pico em ≈ 9–10 épocas em PathMNIST/BloodMNIST e ≈ 24 épocas em OrganAMNIST.

3. **O *deslocamento* é da ordem de 4 vezes.** A janela do pico em OrganAMNIST não é uma versão ligeiramente atrasada da de PathMNIST/BloodMNIST — é qualitativamente diferente, deslocada por um fator multiplicativo de aproximadamente $4\times$.

A localização precisa do anomalismo (parâmetros BN, com mesmo fator de deslocamento entre γ e β) é consistente com a interpretação de que a dinâmica de adaptação das estatísticas internas em OrganAMNIST é *globalmente mais lenta*, e não que algum sub-mecanismo seja qualitativamente diferente. Os parâmetros que "acompanham as estatísticas de ativação" — precisamente γ e β — deslocam-se juntos.

4.7.4 Reformulação parcial da hipótese H1

Este resultado refina a leitura proposta nas seções 4.5 e 4.6. A "invariância da janela do pico" — demonstrada para PathMNIST sob três eixos de manipulação — **não se generaliza diretamente entre datasets**. Em particular, OrganAMNIST (*slices* axiais de CT abdominal, $\sim 34\,\text{k}$ imagens de treino, 11 classes) apresenta dinâmica de LMC qualitativamente distinta dos dois conjuntos RGB (PathMNIST $\sim 90\,\text{k}$, 9 classes; BloodMNIST $\sim 12\,\text{k}$, 8 classes).

Possíveis interpretações — não excludentes — incluem:

1. **Modalidade de imagem.** Os filtros convolucionais aprendem dinâmicas distintas para imagens em escala de cinza (OrganAMNIST) versus RGB (PathMNIST, BloodMNIST). A transição de regime aleatório para estruturado pode ser mais lenta e suave em imagens de canal único.

2. **Complexidade visual da tarefa.** OrganAMNIST distingue estruturas anatômicas globais (órgãos), enquanto PathMNIST e BloodMNIST distinguem texturas locais (tecidos, células). O regime de aprendizado em cada tarefa pode envolver escalas temporais distintas de adaptação dos pesos.

3. **Cardinalidade de classes e tamanho do conjunto.** A combinação "mais classes (11), menos imagens" de OrganAMNIST pode dilatar a fase inicial de organização dos pesos, suavizando o pico da LMC e empurrando-o para épocas posteriores.

A propriedade que **se mantém** em todos os três datasets é a *positividade do lead time*: a LMC atinge seu valor extremo (pico ou platô inicial) *antes* de o *loss* de validação atingir seu mínimo. Mas a magnitude do *lead time* e a forma da trajetória de LMC dependem do dataset.

A hipótese H1, originalmente formulada como "a LMC dos pesos é um marcador objetivo do início do sobreajuste", pode portanto ser reformulada em uma versão mais sustentada pelos dados:

> *A trajetória da LMC dos pesos de* `bn_gamma` *em CNNs treinadas para classificação de imagens médicas atinge seu valor extremo antes do mínimo de* loss *de validação. O instante do extremo e a forma da trajetória dependem do dataset, mas o ordenamento temporal pico-LMC → mínimo-val_loss é robusto entre subamostragens do treino, intensidades de* weight decay *e famílias arquiteturais em um mesmo dataset.*

4.8 SAMPEN 2D DOS FILTROS DA CAMADA `conv1`

Todas as análises até aqui empregaram a SampEn 1D, que opera sobre o vetor unidimensional obtido por `flatten` dos pesos. Esta seção apresenta uma análise complementar baseada na **SampEn 2D** (SILVA et al., 2016), que opera diretamente sobre matrizes preservando a estrutura espacial e contorna a discussão sobre a ordem do *flatten* formalizada na Seção 3.5.2.

4.8.1 Por que apenas a `conv1`

A SampEn 2D requer janelas de tamanho m e $m+1$ (aqui, 2×2 e 3×3). Para uma matriz $H \times W$, o número de posições válidas para janelas $(m+1)\times(m+1)$ é $(H-m)(W-m)$. Em ResNet-18, apenas a primeira camada convolucional (`conv1`) utiliza kernels 7×7; todas as demais utilizam kernels 3×3, que admitiriam apenas uma única posição para a janela 3×3 — estatisticamente insuficiente para o cálculo. A análise aqui apresentada restringe-se, portanto, à `conv1`.

4.8.2 Construção do mosaico e calibração de r

Para cada *checkpoint* final, os 64 filtros da `conv1` (cada um com 3 canais de entrada e kernel 7×7) são organizados da seguinte forma: para cada canal de entrada $c \in \{0,1,2\}$, os 64 filtros 7×7 são dispostos em uma grade 8×8, produzindo uma imagem 56×56. A SampEn 2D é então calculada sobre essa imagem.

Empiricamente, observou-se que a tolerância padrão $r = 0{,}2\,\sigma$ produz SampEn 2D infinita para matrizes desse tamanho (incluindo matrizes aleatórias de mesma dimensão),

refletindo o fato de que pares de janelas 3×3 raramente se aproximam dentro de tolerância tão restrita em matrizes com baixa regularidade local. Adotamos $r = 0{,}5\,\sigma$ como compromisso entre sensibilidade e estabilidade numérica; este valor é constante entre datasets e portanto não introduz viés inter-dataset.

4.8.3 Resultados

A Figura 23 apresenta a SampEn 2D média entre sementes e canais de entrada, com intervalos de confiança *bootstrap* de 95%:

- **PathMNIST**: $\text{SampEn}_{2D} = 3{,}98$ [IC 3,67–4,23];
- **OrganAMNIST**: 5,77 [IC 5,66–5,89];
- **BloodMNIST**: 6,18 [IC 6,08–6,30].

Os intervalos de confiança **não se sobrepõem** entre datasets, o que indica que a SampEn 2D *discrimina* as três coleções de imagens médicas a partir dos pesos da camada de entrada. A ordenação PathMNIST < OrganAMNIST < BloodMNIST sugere que os filtros da `conv1` aprendem padrões espacialmente mais regulares em PathMNIST (histopatologia colorida, classificação textural) do que em OrganAMNIST (CT em escala de cinza, classificação anatômica) ou BloodMNIST (microscopia, classificação celular).

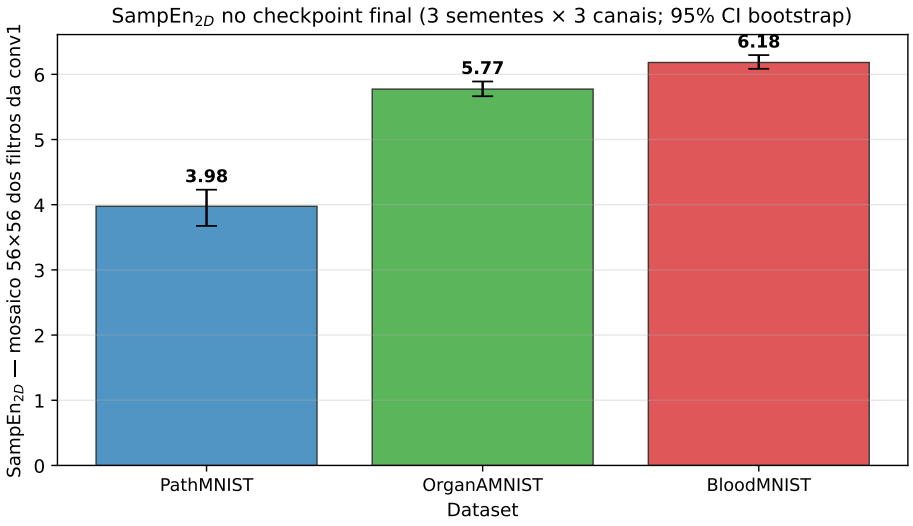


Figura 23 – SampEn_{2D} aplicada ao mosaico 56×56 dos 64 filtros $7{\times}7$ da `conv1` (uma imagem por canal de entrada). Médias entre 3 sementes $\times$ 3 canais; intervalos de confiança 95% por *bootstrap*.

Tabela 15 – SampEn_{2D} sobre mosaicos 56×56 dos filtros 7×7 da `conv1` no *checkpoint* final (épocas: 100; mosaicos: 8×8 dos 64 filtros; tolerância $r = 0.5\,\sigma$; média entre 3 sementes $\times$ 3 canais de entrada; intervalo de confiança 95% por *bootstrap*).

Dataset	média SampEn_{2D}	IC 95% inferior	superior
PathMNIST	3.975	3.675	4.230
OrganAMNIST	5.773	5.664	5.890
BloodMNIST	6.182	6.085	6.295

4.8.4 Decomposição por canal de entrada

A Figura 24 apresenta a SampEn_{2D} decomposta pelos três canais de entrada. Observa-se um padrão informativo:

- **PathMNIST** exibe **assimetria pronunciada**: o canal 0 (correspondente ao vermelho, dada a convenção do `ToTensor` sobre PIL) apresenta $\text{SampEn}_{2D} \approx 3{,}36$, enquanto canais 1 e 2 ficam em $\approx 4{,}28$. A diferença é consistente com a observação clínica de que o corante hematoxilina-eosina, padrão em histopatologia, produz padrões espaciais característicos no canal vermelho, levando os filtros específicos a esse canal a aprenderem estruturas mais regulares.
- **OrganAMNIST** e **BloodMNIST** apresentam canais aproximadamente uniformes ($\sigma_{\text{between-channels}} < 0{,}25$), consistente com (i) entrada em escala de cinza replicada para 3 canais no caso de OrganAMNIST, e (ii) microscopia com tonalidades cromáticas mais homogêneas no caso de BloodMNIST.

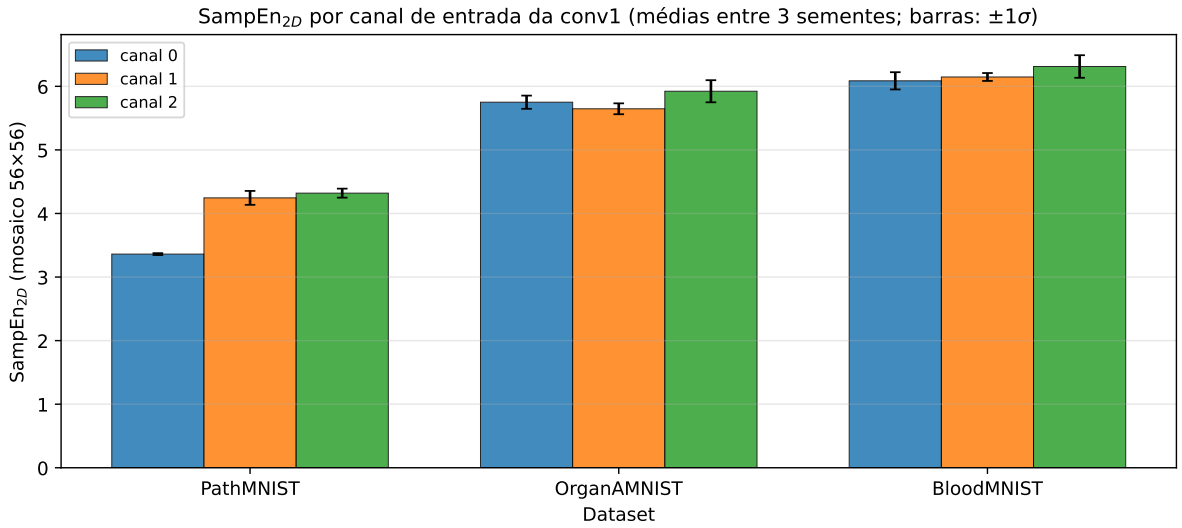


Figura 24 – SampEn_{2D} por canal de entrada da `conv1`, evidenciando assimetria cromática em PathMNIST.

4.8.5 Comparação com SampEn 1D e papel complementar

A SampEn 1D do grupo `conv` no *checkpoint* final (Tabela 13) é praticamente *idêntica* entre os três datasets (≈ 2,07–2,10). Em contraste, a SampEn 2D varia em mais de 50% entre PathMNIST e BloodMNIST. Esta sensibilidade adicional da SampEn 2D justifica empiricamente a decisão metodológica da Seção 3.7.4 de incluir extensões 2D no protocolo de análise: a 1D, ao destruir a estrutura espacial via *flatten*, encobre diferenças que ficam evidentes quando o operador respeita a geometria do kernel.

4.9 ANÁLISE MULTIESCALA (MSE 2D) DOS MOSAICOS DA CONV1

A Seção 4.8 mostrou que a SampEn 2D em um único nível de granularidade espacial ($\tau = 1$, ou seja, sobre o mosaico original 56×56) discrimina os três datasets. Esta seção estende a análise para múltiplas escalas, aplicando a versão multiescala da SampEn 2D (COSTA et al., 2002; COSTA et al., 2005; SILVA et al., 2016).

4.9.1 Protocolo multiescala

Para cada mosaico 56×56 da `conv1`, o procedimento de *coarse-graining* 2D substitui cada bloco $\tau \times \tau$ de pixels pela sua média aritmética, produzindo uma matriz reduzida de dimensão $\lfloor 56/\tau \rfloor \times \lfloor 56/\tau \rfloor$. A SampEn 2D é então computada sobre essa matriz reduzida, com a tolerância $r = 0{,}5\,\sigma$ *fixa* a partir do mosaico original (convenção de Costa et al. (2002)). Escalas de $\tau = 1$ (56×56, sem coarse-graining) até $\tau = 10$ (5×5, próximo do limite inferior de aplicabilidade) são avaliadas.

4.9.2 Curvas multiescala

A Figura 25 apresenta as três curvas MSE 2D, agregadas entre 3 sementes × 3 canais de entrada (9 mosaicos por dataset). A Tabela 16 consolida os valores médios e desvios.

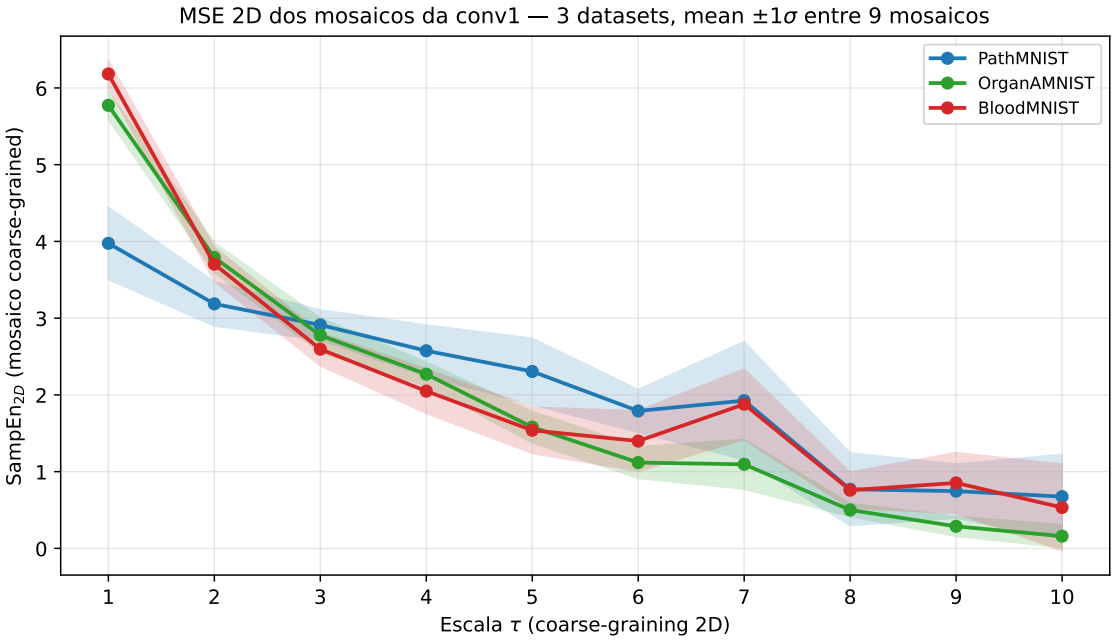


Figura 25 – MSE 2D dos mosaicos 56×56 da `conv1` no *checkpoint* final: SampEn 2D versus escala de *coarse-graining* $\tau \in \{1, \ldots, 10\}$. Bandas: $\pm 1\sigma$ entre os 9 mosaicos. Tolerância $r = 0{,}5\,\sigma$ fixa do mosaico original.

Tabela 16 – SampEn_{2D} multiescala dos mosaicos 56×56 da `conv1` (mean $\pm 1\sigma$ entre 3 sementes $\times$ 3 canais; $r = 0.5\,\sigma$, fixo entre escalas).

Escala τ	Dim. coarse	PathMNIST	OrganAMNIST	BloodMNIST
1	56×56	3.98 ± 0.47	5.77 ± 0.18	6.18 ± 0.17
2	28×28	3.19 ± 0.29	3.79 ± 0.19	3.70 ± 0.22
3	18×18	2.91 ± 0.19	2.78 ± 0.22	2.60 ± 0.21
4	14×14	2.58 ± 0.33	2.27 ± 0.16	2.05 ± 0.29
5	11×11	2.31 ± 0.43	1.58 ± 0.20	1.54 ± 0.30
6	9×9	1.79 ± 0.28	1.12 ± 0.20	1.40 ± 0.39
7	8×8	1.93 ± 0.77	1.10 ± 0.32	1.88 ± 0.46
8	7×7	0.77 ± 0.47	0.50 ± 0.08	0.76 ± 0.23
9	6×6	0.75 ± 0.35	0.29 ± 0.13	0.85 ± 0.39
10	5×5	0.67 ± 0.55	0.16 ± 0.15	0.53 ± 0.56

4.9.3 Cruzamento de curvas e discriminação dependente de escala

O resultado mais notável é o **cruzamento das curvas em** $\tau \in [2, 3]$, que produz uma inversão de ordenação entre datasets:

- **Em** $\tau = 1$ (escala mais fina): a ordenação é PathMNIST $<$ OrganAMNIST $<$ BloodMNIST, com SampEn 2D igual a 3,98, 5,77 e 6,18, respectivamente (resultado da Seção 4.8).

- **Em** $\tau = 4$–7 (escala intermediária, próxima do tamanho de filtro): a ordenação inverte para BloodMNIST $\leq$ OrganAMNIST $<$ PathMNIST. PathMNIST agora exibe a SampEn 2D *mais alta*: 2,58 em $\tau = 4$, 1,79 em $\tau = 6$, contra $\approx$ 1,1 para OrganAMNIST nas mesmas escalas.

- **Em** $\tau \geq 8$ (escala grossa, matriz $\leq 7 \times 7$): todas as curvas convergem para valores baixos (< 1), perdendo a capacidade discriminativa.

Este cruzamento sugere que as escalas espaciais em que a **regularidade dos filtros é mais alta** diferem entre datasets: PathMNIST tem regularidade concentrada em escala fina (consistente com estruturas regulares do corante H&E em alta frequência espacial), enquanto OrganAMNIST e BloodMNIST distribuem a regularidade em escalas intermediárias (consistente com estruturas anatômicas e celulares em escalas espaciais maiores).

4.9.4 Implicação para análise de complexidade

Operacionalmente, este resultado indica que **a escolha da escala τ é um parâmetro crítico** quando a SampEn 2D é utilizada como descritor inter-dataset: a discriminação "correta" pode existir apenas em uma faixa de escalas, e relatar um único valor de τ pode ocultar diferenças disponíveis em outras escalas (ou produzir uma discriminação enganosa por estar do "lado errado" do cruzamento). A abordagem multiescala fornece uma assinatura espectral mais robusta para comparações entre datasets e arquiteturas.

4.10 SEGUNDO DESENHO: MEMORIZAÇÃO INDUZIDA NA CAMADA DENSA

Esta seção reporta os resultados do desenho descrito na Seção 3.10, no qual a perda de generalização é induzida por corrupção de rótulos e as medidas incidem integralmente sobre os 3072 pesos da camada densa. Todos os valores foram obtidos com execuções de controle *estritamente pareadas*, conforme discutido adiante na Seção 4.10.7.

4.10.1 Confirmação da memorização

Antes de avaliar os indicadores, é necessário verificar que o protocolo produziu de fato memorização, e não apenas degradação de desempenho. A Tabela 17 apresenta a evidência nas oito execuções com $\rho = 0{,}30$, isto é, 25 % de rótulos efetivamente errados.

Tabela 17 – Evidência de memorização nas oito execuções com corrupção de rótulos e nos oito controles pareados, em ResNet-18. Acurácias em modo de avaliação.

Grupo	**Treino inicial**	**Treino final**	**Validação máxima**	**Validação final**
Com corrupção ($n = 8$)	74,7 %	97,5 %	99,9 %	84,1 %
Controle pareado ($n = 8$)	—	100,0 %	100,0 %	100,0 %

Fonte: Elaborado pelo autor.

O padrão é inequívoco e reprodutível nas oito execuções. A acurácia de treino parte de aproximadamente 74,7 % — valor próximo do teto imposto pelos rótulos corrompidos — e sobe até 97,5 %, o que significa que a rede ajustou também a maior parte das associações inconsistentes. Simultaneamente, a acurácia de validação, que chega a 99,9 %, regride para 84,1 %. Não há explicação visual para rótulos sorteados ao acaso; o único modo de ajustá-los é memorizá-los. Nos controles pareados, treino e validação permanecem em 100 %, sem qualquer degradação — o que confirma que a memorização observada decorre da corrupção, e não do protocolo de treinamento.

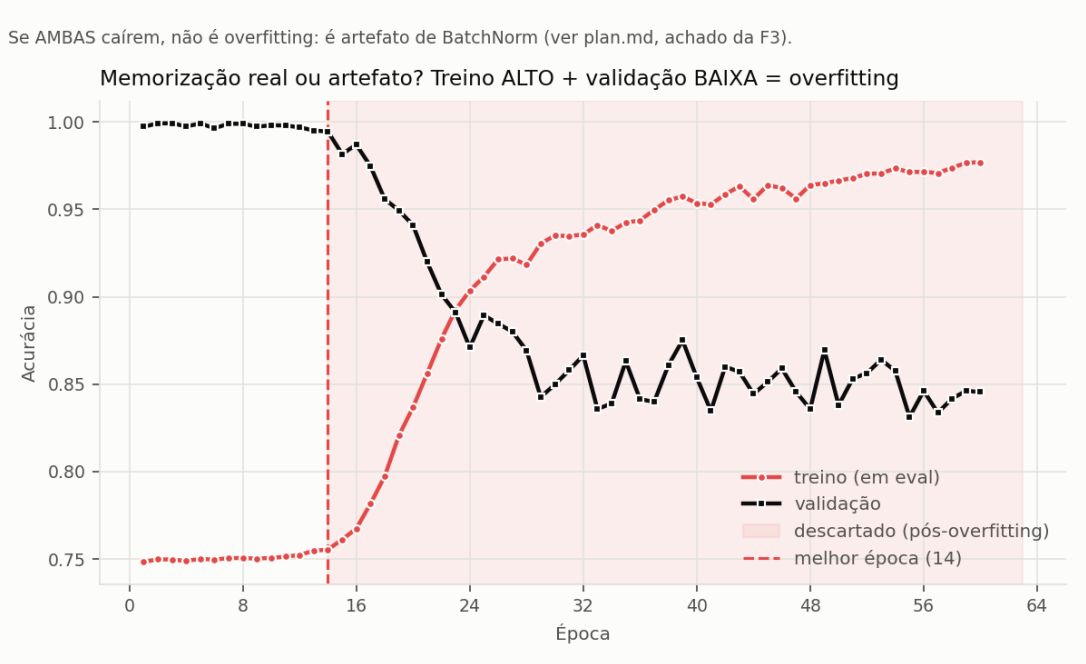


Figura 26 – Acurácias de treino, em modo de avaliação, e de validação ao longo das épocas em execução com 25 % de rótulos efetivamente errados. O cruzamento das curvas caracteriza a memorização.

Fonte: Elaborado pelo autor.

4.10.2 Poder de discriminação dos indicadores

O critério de avaliação adotado não é a amplitude absoluta de variação de cada indicador, mas a *razão* entre a amplitude observada nas execuções com corrupção e a

observada nos controles. Um indicador que varia muito nas duas condições não informa nada sobre a memorização. A Tabela 18 apresenta os resultados.

Tabela 18 – Amplitude de variação dos indicadores na camada densa, em ResNet-18, com oito execuções por grupo. Valores como média ± desvio-padrão amostral; p obtido por teste de Mann-Whitney bilateral.

Indicador	**Com corrupção**	**Controle pareado**	**Razão**	p
LMC	$1{,}219 \pm 0{,}055$	$1{,}138 \pm 0{,}134$	1,07	0,195
SampEn 1D	$0{,}205 \pm 0{,}018$	$0{,}058 \pm 0{,}012$	3,51	0,00016
SampEn2D	$0{,}340 \pm 0{,}061$	$0{,}060 \pm 0{,}014$	5,65	0,00016

Fonte: Elaborado pelo autor.

O resultado é assimétrico e exige leitura cuidadosa. As duas variantes de entropia amostral discriminam as condições, e a bidimensional discrimina melhor. O valor $p = 0{,}00016$ é o menor alcançável pelo teste de Mann-Whitney com oito observações por grupo e corresponde à separação completa entre os grupos, sem qualquer sobreposição de valores.

A complexidade LMC, em contrapartida, **não discrimina** as duas condições. A razão de 1,07 é compatível com ausência de efeito, e o teste não rejeita a hipótese nula ($p = 0{,}195$). Este é um resultado negativo, e não uma limitação de potência: a amplitude média da LMC nas execuções com corrupção (1,219) situa-se dentro de um desvio-padrão da amplitude média dos controles ($1{,}138 \pm 0{,}134$).

A interpretação mais econômica desse achado remete à propriedade discutida na Seção 2.6: a LMC depende apenas do histograma dos valores dos pesos e é, portanto, invariante a qualquer permutação. Se a memorização reorganiza os pesos da camada densa sem alterar substancialmente a *distribuição* de seus valores, a LMC é cega a ela por construção. As variantes de entropia amostral, sensíveis à ordem, captam precisamente essa reorganização. A Seção 4.10.8 retoma essa leitura à luz dos resultados do primeiro desenho.

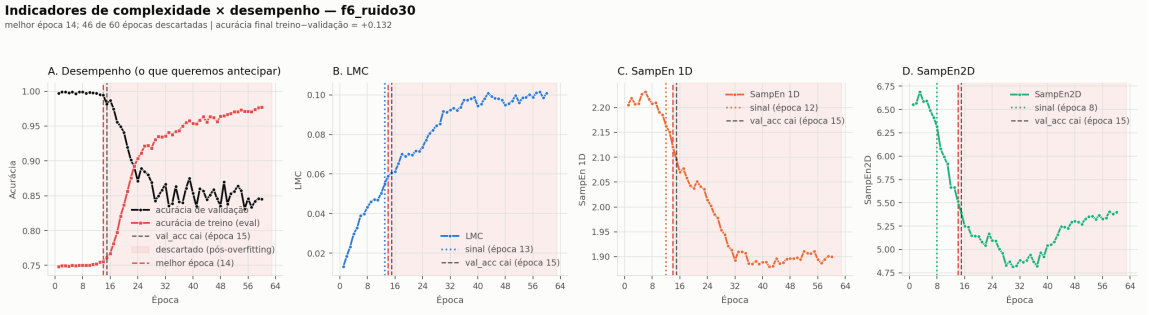


Figura 27 – Trajetória dos três indicadores na camada densa e das curvas de validação, em execução com corrupção de rótulos. A região sombreada corresponde às épocas posteriores ao início do sobreajuste, excluídas das conclusões.

Fonte: Elaborado pelo autor.

4.10.3 Antecedência em relação à degradação da validação

A antecedência é a diferença, em épocas, entre a inflexão do indicador e a âncora definida sobre a acurácia de validação. A Tabela 19 reporta os valores.

Tabela 19 – Antecedência dos indicadores em relação à queda sustentada da acurácia de validação, em épocas, nas oito execuções com corrupção em ResNet-18.

Indicador	**Média ± desvio**	**IC 95 %**	**Discrimina?**
SampEn2D	$7{,}50 \pm 0{,}93$	[6,73; 8,27]	Sim
SampEn 1D	$3{,}62 \pm 1{,}06$	[2,74; 4,51]	Sim
LMC	$3{,}00 \pm 1{,}85$	[1,45; 4,55]	Não

Fonte: Elaborado pelo autor.

A antecedência da LMC não constitui resultado positivo e não deve ser interpretada como tal. Como a Tabela 18 estabelece que o indicador não distingue as duas condições, a época de sua inflexão não sinaliza coisa alguma: uma inflexão que ocorre igualmente nos controles não é aviso. A antecedência só é informativa para indicadores que previamente demonstraram discriminação.

A separação temporal da SampEn2D é quase completa. Nas oito execuções com corrupção, o indicador inflete nas épocas $\{7, 7, 7, 7, 7, 7, 8, 9\}$. Nos controles pareados, seis dos oito inflectem, e o fazem nas épocas $\{9, 23, 37, 42, 50, 55\}$; os dois restantes não inflectem dentro do horizonte de 60 épocas. Registre-se a honestidade do limite: há *um* controle que inflete na época 9, coincidindo com o valor máximo observado no grupo com corrupção. A separação é portanto quase perfeita, mas não perfeita, e a afirmação correta é de sobreposição mínima — em uma de dezesseis execuções.

4.10.4 Efeito do nível de corrupção

Variou-se a fração sorteada em $\rho \in \{0{,}15;\ 0{,}30;\ 0{,}50\}$, com três sementes por nível. O resultado não era o esperado e é, talvez, o mais interessante desta seção.

Tabela 20 – Época do alerta emitido pelo monitor e época da âncora, por nível de corrupção, com três sementes por nível.

ρ sorteado	Errados de fato	Época do alerta	Época da âncora	Antecedência
15 %	12,5 %	10,0	17,7	7,7
30 %	25,0 %	9,3	14,7	5,3
50 %	41,7 %	10,0	13,0	3,0
ANOVA de uma via		$F = 1{,}00$ $p = 0{,}42$	$F = 30{,}2$ $p = 0{,}0007$	

Fonte: Elaborado pelo autor.

A época em que o monitor emite o alerta é praticamente invariante ao nível de corrupção: médias de 10,0, 9,3 e 10,0 épocas, sem diferença estatisticamente detectável ($F = 1{,}00$; $p = 0{,}42$). O que se move é a âncora, isto é, o momento em que a degradação se torna visível na validação, que chega progressivamente mais cedo quanto maior a corrupção ($F = 30{,}2$; $p = 0{,}0007$).

A consequência prática é que a antecedência encolhe à medida que a corrupção aumenta, de aproximadamente 7,7 épocas a 15 % para 3,0 épocas a 50 %. Propõe-se a seguinte leitura: o indicador marca o *início* da memorização, cujo momento depende pouco da quantidade de rótulos errados, enquanto a validação mede o *sintoma*, que se manifesta tanto mais cedo quanto maior a corrupção. Trata-se de interpretação plausível e compatível com os dados, ainda não demonstrada de forma independente.

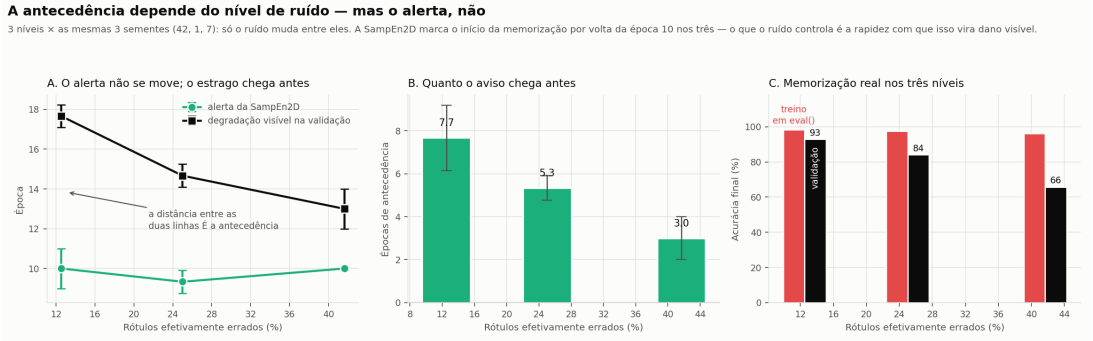


Figura 28 – Época do alerta e época da âncora em função do nível de corrupção de rótulos. A época do alerta é estável; a da âncora antecipa-se com o aumento da corrupção.

Fonte: Elaborado pelo autor.

4.10.5 Generalização para outra arquitetura

O experimento foi repetido com a DenseNet-121, com oito execuções com corrupção e cinco controles pareados. Os resultados constam da Tabela 21.

Tabela 21 – Resultados na DenseNet-121, com oito execuções com corrupção e cinco controles pareados.

Indicador	**Razão de amplitude**	p	**Antecedência (épocas)**
LMC	1,06	0,435	—
SampEn 1D	1,77	0,00155	$22{,}50 \pm 2{,}33$
SampEn2D	4,35	0,00155	$21{,}12 \pm 2{,}36$

Fonte: Elaborado pelo autor.

O achado central replica-se na segunda arquitetura. A SampEn2D discrimina com razão de 4,35 vezes ($p = 0{,}00155$) e a antecedência é consideravelmente maior, de $21{,}1 \pm 2{,}4$ épocas, com intervalo de confiança de 95 % entre 19,2 e 23,1. A LMC, de novo, não discrimina ($p = 0{,}435$), o que reforça a consistência desse resultado negativo entre arquiteturas.

Duas ressalvas, porém, devem ser explicitadas.

A primeira é que a razão de amplitude é menor do que na ResNet-18 (4,35 contra 5,65), e a SampEn 1D, que discriminava na ResNet, passa a ter poder marginal (1,77). O contraste, portanto, replica-se em direção, mas não em magnitude.

A segunda é mais relevante e não deve ser omitida: **na DenseNet-121 a época do sinal não separa os grupos**. As execuções com corrupção inflectem nas épocas $\{8, 9, 9, 9, 9, 11, 11, 12\}$, enquanto os controles pareados inflectem em $\{7, 8, 10, 16, 25\}$ — três deles, portanto, tão cedo ou mais cedo que as execuções com corrupção. Na ResNet-18 a separação temporal é quase perfeita; na DenseNet-121, não existe. O que discrimina nessa arquitetura é a *amplitude* da variação, não o *momento* em que ela começa. A consequência prática é direta: um monitor que emita alerta pelo simples cruzamento de um limiar temporal produziria falsos positivos na DenseNet-121, e o critério precisa incorporar a magnitude.

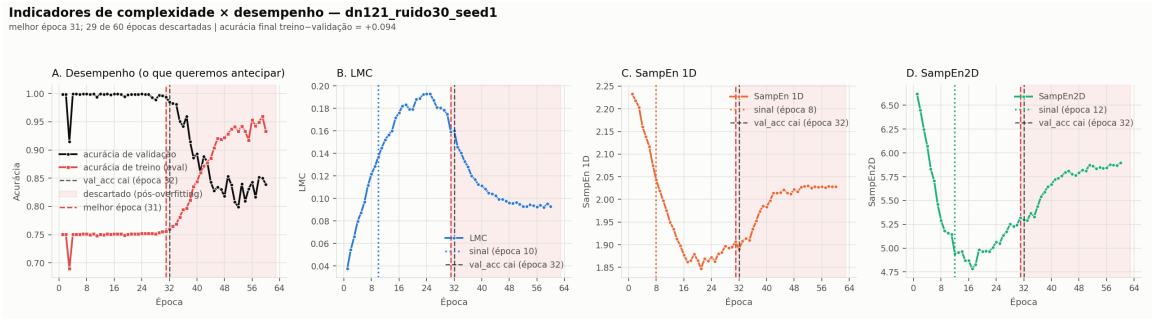


Figura 29 – Trajetória dos indicadores na camada densa da DenseNet-121, em execução com corrupção de rótulos.

Fonte: Elaborado pelo autor.

4.10.6 Ablação da ordem de achatamento

A Seção 3.10.3 fixou a ordem por neurônio como convenção padrão, por coerência com a decisão D2, e previu o reporte da comparação com a ordem por entrada. A Tabela 22 apresenta o resultado, obtido sobre cinco execuções com corrupção e cinco controles.

Tabela 22 – Comparação das duas ordens de achatamento na SampEn 1D da camada densa.

Ordem	**Razão de amplitude**	**Antecedência (épocas)**
Por neurônio (padrão adotado)	3,52	3,6
Por entrada	7,73	7,4

Fonte: Elaborado pelo autor.

O resultado contraria a convenção adotada, e isso precisa ser dito sem atenuação: a leitura *por entrada* é superior nos dois critérios, discriminando mais que o dobro (7,73 contra 3,52) e avisando com o dobro da antecedência (7,4 contra 3,6 épocas).

Há uma explicação plausível. Percorrer a matriz por entrada agrupa, para cada característica, os pesos que ela envia a *todas* as classes — e é exatamente aí que a memorização se manifesta, quando uma característica passa a apontar de forma desproporcional para uma classe específica. Percorrendo por neurônio, esse contraste dilui-se ao longo das 512 posições do campo receptivo.

Registre-se que o efeito prático dessa escolha é limitado, pois o indicador de melhor desempenho neste trabalho é a SampEn2D, que não achata a matriz e preserva as duas direções simultaneamente. A discussão de ordem afeta apenas a variante unidimensional. Ainda assim, a evidência recomenda reconsiderar a convenção adotada.

4.10.7 Sobre o pareamento dos controles

Um aspecto metodológico merece registro explícito, por afetar a validade de todos os números desta seção.

Em uma versão anterior deste conjunto de experimentos, as execuções de controle não eram estritamente pareadas: além de não terem rótulos corrompidos, elas empregavam aumento de dados, decaimento de pesos de 10^{-4} e horizonte de 40 épocas, contra ausência de aumento, decaimento nulo e 60 épocas nas execuções com corrupção. Como aumento de dados e decaimento de pesos são, ambos, formas de regularização que reduzem sobreajuste por conta própria, o contraste medido era atribuível a mais de uma causa, e não exclusivamente à memorização.

Todo o conjunto de controles foi então refeito com pareamento estrito, e os números reportados nesta seção são os dessa segunda versão. A comparação entre as duas consta da Tabela 23.

Tabela 23 – Efeito da correção do pareamento sobre as razões de amplitude da SampEn2D.

Arquitetura	**Controles não pareados**	**Controles pareados**	p **final**
ResNet-18	5,71 ($n = 8$)	5,65 ($n = 8$)	0,00016
DenseNet-121	2,80 ($n = 3$)	4,35 ($n = 8$)	0,00155

Fonte: Elaborado pelo autor.

Na ResNet-18 a razão praticamente não se alterou, passando de 5,71 para 5,65. Esse é um resultado importante em si: como a correção removeu a regularização dos controles e o contraste permaneceu, conclui-se que o efeito medido decorre da memorização, e não das diferenças de regularização. Na DenseNet-121 a razão *aumentou*, de 2,80 para 4,35, e passou a ser estatisticamente significativa — o que indica que a aparente fraqueza dessa arquitetura, registrada em análise preliminar, era em boa parte artefato do pareamento inadequado, agravado pelo número reduzido de execuções.

4.10.8 Tensão com os resultados do primeiro desenho

Os resultados desta seção estabelecem que a complexidade LMC não discrimina memorização na camada densa, em duas arquiteturas. As seções anteriores deste capítulo estabelecem que a mesma LMC apresenta pico antecipador sob subamostragem do treino, com antecedência da ordem de uma dezena de épocas, e que esse comportamento concentra-se nos parâmetros γ da normalização em lote. As duas afirmações são, à primeira vista, incompatíveis.

Não o são, e a razão é que os dois desenhos diferem em três dimensões simultâneas, conforme a Tabela 8: o grupo de pesos observado, o mecanismo que origina a perda

de generalização e o conjunto de dados. Qualquer uma das três poderia responder pela divergência, e os experimentos realizados não permitem isolá-la.

Duas leituras são compatíveis com os dados. A primeira é que o que a LMC detecta sob subamostragem não é memorização, mas reorganização da distribuição de escalas dos parâmetros de normalização — fenômeno que a escassez de dados provoca e que a corrupção de rótulos não provoca. A segunda é que a LMC seria capaz de detectar memorização, mas não na camada densa, por esta apresentar distribuição de valores estável sob memorização, deslocando-se apenas a organização espacial dos pesos, à qual a LMC é invariante.

As duas leituras são distinguíveis por um experimento que este trabalho não realizou: calcular a LMC sobre os parâmetros γ nas execuções com corrupção de rótulos, e a SampEn2D sobre a camada densa nas execuções com subamostragem, completando o delineamento cruzado. Essa é, por conseguinte, a extensão mais imediata e mais informativa do trabalho, e consta entre as recomendações do Capítulo 5.

O que os resultados autorizam afirmar, em caráter conclusivo, é mais modesto e mais preciso do que a hipótese original: a capacidade de marcar o sobreajuste não é propriedade de uma medida isolada, mas da combinação entre a medida empregada, o grupo de pesos observado e o mecanismo que origina a perda de generalização.

4.11 DELINEAMENTO CRUZADO: O GRUPO DE PESOS OU O MECANISMO?

A Seção 4.10.8 registrou que a complexidade LMC antecipa a degradação no primeiro desenho e não discrimina no segundo, e que os experimentos até então realizados não permitiam identificar qual das dimensões divergentes — o grupo de pesos observado ou o mecanismo de indução — responde pela diferença. Esta seção reporta a tentativa de completar o delineamento, cujo resultado é parcialmente conclusivo.

O delineamento pretendido tem quatro células, conforme a Tabela 24. Duas delas já constavam do capítulo.

Tabela 24 – Delineamento cruzado pretendido. As duas células sem marca constituíam o objeto desta seção.

	Subamostragem	**Corrupção de rótulos**
LMC sobre `bn_gamma`	antecipa (Seção 4.4)	célula A
SampEn2D sobre a camada densa	célula B	antecipa (Seção 4.10.3)

Fonte: Elaborado pelo autor.

4.11.1 Célula A: a LMC sobre os γ sob corrupção de rótulos

Esta célula não exigiu novo treinamento. Os registros das execuções com corrupção preservam os pesos de todas as 60 épocas, o que permitiu calcular a LMC sobre o grupo `bn_gamma` retroativamente, nas oito execuções com corrupção e nos oito controles pareados — 960 estados de rede em total.

Tabela 25 – Amplitude de variação da LMC sobre `bn_gamma` e sobre a camada densa, sob corrupção de rótulos, com oito execuções por grupo.

Grupo de pesos	**Com corrupção**	**Controle pareado**	**Razão**	p
`bn_gamma`	$0{,}760 \pm 0{,}196$	$0{,}584 \pm 0{,}228$	1,30	0,065
Camada densa	$1{,}219 \pm 0{,}055$	$1{,}138 \pm 0{,}134$	1,07	0,195

Fonte: Elaborado pelo autor.

A LMC **não discrimina** memorização sobre os γ. A razão de 1,30 é superior à observada na camada densa, e o valor $p = 0{,}065$ situa-se na fronteira da significância convencional, o que indica sensibilidade maior nesse grupo; ainda assim, não há discriminação. A época do pico tampouco separa as condições: nas execuções com corrupção os picos ocorrem entre as épocas 3 e 9, e nos controles entre 1 e 12, com sobreposição integral.

O achado é informativo. Elimina a explicação de que a cegueira da LMC à memorização decorreria de alguma particularidade da camada densa: a medida não discrimina memorização em *nenhum* dos dois grupos examinados, inclusive naquele em que se mostrara mais informativa no primeiro desenho.

4.11.2 Célula B: subamostragem não induz sobreajuste no MedNIST

A segunda célula exigia induzir sobreajuste por subamostragem do conjunto de treinamento, mantendo tudo o mais pareado, para então medir a SampEn2D da camada densa. Foram executadas quinze novas execuções, em três frações do conjunto de treino, com cinco sementes cada e horizonte de 200 épocas. O resultado impede o preenchimento da célula, e por razão que merece registro.

Tabela 26 – Degradação da acurácia de validação por fração do conjunto de treino, em ResNet-18 sobre o MedNIST. A queda é a diferença entre a acurácia máxima e a final. Valores como média ± desvio-padrão amostral.

Fração	**Imagens**	**Execuções**	**Acurácia final de treino**	**Queda da validação (p.p.)**
100 %	47.164	8	100,0 %	$0{,}02 \pm 0{,}02$
10 %	4716	5	100,0 %	$0{,}05 \pm 0{,}03$
2 %	943	5	100,0 %	$0{,}22 \pm 0{,}18$
1 %	471	5	100,0 %	$0{,}01 \pm 0{,}01$
Corrupção de rótulos (25 % errados)			97,5 %	$15{,}80 \pm 0{,}72$

Fonte: Elaborado pelo autor.

Não há sobreajuste a ser antecipado. Com 471 imagens de treino — 1 % do conjunto — a rede ainda alcança 99,6 % de acurácia de validação, e a queda ao longo do treinamento é de 0,01 ponto percentual. Nas frações de 2 % e 1 %, a acurácia de validação atinge seu máximo em torno da época 123 de 200, isto é, a rede continuava a melhorar quando o treinamento foi encerrado.

A comparação com o mecanismo de corrupção é da ordem de duas magnitudes: a degradação média é de 15,80 pontos percentuais sob corrupção contra 0,22 na fração mais desfavorável da subamostragem, uma razão de aproximadamente 74 vezes ($p = 0{,}0008$, teste de Mann-Whitney unilateral).

Conclui-se que, no MedNIST, **os dois mecanismos de indução não são intercambiáveis**: a corrupção de rótulos produz perda de generalização substancial, e a subamostragem não produz perda mensurável em nenhuma das frações examinadas. A célula B é, portanto, inviável neste conjunto de dados, e sua realização exigiria um repositório de maior dificuldade intrínseca — o que reintroduziria a variável *conjunto de dados* que o delineamento pretendia justamente eliminar.

Registre-se que esse resultado confirma, com valores medidos, uma ressalva antecipada no planejamento da pesquisa: a de que o MedNIST poderia ser excessivamente fácil para induzir sobreajuste por escassez de dados.

4.11.3 O que o delineamento parcial autoriza concluir

Com três das quatro células preenchidas, a atribuição da divergência deixa de ser indeterminada, embora não alcance o grau de certeza que o delineamento completo proporcionaria.

A hipótese de que a divergência decorre do *grupo de pesos* fica enfraquecida pela célula A: a LMC não discrimina memorização nos γ, justamente o grupo em que se mostrara informativa sob subamostragem. Se o grupo de pesos fosse o fator determinante,

esperar-se-ia discriminação ali.

Resta como explicação mais compatível com os dados que o fator determinante seja o *mecanismo*: a LMC responde à alteração da distribuição dos pesos provocada pela escassez de dados, e não à reorganização provocada pela memorização de rótulos inconsistentes. Essa leitura é coerente com a invariância da LMC a permutações, discutida na Seção 2.6.

Duas ressalvas impedem afirmação mais forte. A primeira é que a célula B permanece vazia, de modo que não se verificou a recíproca — se a SampEn2D, que detecta memorização, também detectaria escassez de dados. A segunda, e mais séria, é que a comparação entre os dois desenhos atravessa conjuntos de dados distintos: o primeiro desenho opera sobre o MedMNIST e o segundo sobre o MedNIST. A célula A, por incidir sobre execuções do segundo desenho, não elimina essa diferença. A atribuição ao mecanismo é, portanto, a explicação mais econômica entre as compatíveis com os dados, e não uma conclusão demonstrada.

A recomendação que decorre desta seção é de ordem prática: a escolha do mecanismo de indução de sobreajuste não é detalhe de protocolo, mas determina qual medida pode ser validada. Trabalhos que pretendam comparar marcadores de sobreajuste precisam declarar o mecanismo empregado, sob pena de compararem respostas a fenômenos distintos.

5 CONCLUSÃO

Este trabalho investigou a hipótese de que a complexidade estatística dos pesos de redes neurais profundas constitui um marcador objetivo do início do *overfitting*, instanciando-a no contexto de classificação de imagens médicas com a arquitetura ResNet-18 e o *benchmark* MedMNIST. A abordagem articulou duas medidas complementares — a complexidade LMC (LÓPEZ-RUIZ et al., 1995) e a entropia amostral SampEn (RICHMAN; MOORMAN, 2000) — aplicadas a snapshots densamente amostrados do estado dos pesos ao longo de 36 execuções de treinamento, distribuídas em dois eixos experimentais: um **eixo de cobertura**, com 27 runs sobre três conjuntos (PathMNIST, OrganAMNIST, BloodMNIST) × três horizontes de épocas × três sementes; e um **eixo de indução de sobreajuste**, com nove runs adicionais sob subamostragem do conjunto de treinamento (5%, 10%, 25%) que produziram, deliberadamente, o regime de generalização degradada no qual a hipótese pode ser testada.

Três achados sustentam a hipótese central:

1. As trajetórias de LMC e SampEn ao longo do treinamento são **sistemáticas, reprodutíveis entre sementes** e diferenciadas por grupo de camadas. A separação dos parâmetros de *batch normalization* em γ e β revelou-se crítica: γ exibe a dinâmica mais informativa, enquanto a junção dos dois grupos diluiria o sinal antecipador.

2. Sob subamostragem do treino, a LMC apresenta um pico que **precede** o mínimo de *loss* de validação em **todas** as três frações estudadas, com *lead time* estimado em +11,6, +16,6 e +12,6 épocas para 5%, 10% e 25% de treino, respectivamente (intervalos de confiança *bootstrap* de 95% que excluem zero em 5% e 25%). Este resultado é a evidência operacional mais direta de que a métrica capta a transição entre fase de ajuste e fase de especialização *antes* que a perda de validação reverta sua tendência.

3. A detecção robusta do pico exigiu três escolhas metodológicas combinadas: restrição da análise ao grupo `bn_gamma` — identificado como portador do sinal mais discriminativo —, exclusão da janela de *warm-up* (epoch $< 0{,}5$) e suavização por filtro de Savitzky-Golay. Sob detector ingênuo (*argmax* sobre a trajetória bruta agregada entre grupos), o caso 5% produz um pico espúrio próximo da inicialização: este achado documenta explicitamente o domínio de validade do estimador.

4. Sob variação do *weight decay* (Seção 4.5), o pico da LMC localiza-se em $e_{\mathrm{LMC}}^{\mathrm{peak}} \approx 7$ épocas **independentemente** do coeficiente de regularização $\in \{0, 10^{-5}, 10^{-4}, 10^{-3}\}$, enquanto o instante do mínimo de *loss* de validação varia entre ≈ 42 e ≈ 93 épocas.

Esta invariância levou a uma reformulação da interpretação inicial: a LMC não captura o instante de início do sobreajuste *per se*, mas sim uma transição estrutural intrínseca à arquitetura — a passagem do regime de pesos quase-gaussianos da inicialização para o regime de pesos estruturados pelo treinamento —, transição esta que precede o estabelecimento da generalização ótima por uma quantidade que depende da escala temporal imposta pelo regime de regularização.

5. Sob variação da arquitetura (Seção 4.6), o pico da LMC mantém-se na janela [4,4; 9,1] épocas para ResNet-18, ResNet-34 e DenseNet-121 — três modelos que abrangem duas famílias arquiteturais distintas (residual e densa) e uma faixa de capacidade de ~ 7 a ~ 21 milhões de parâmetros. Esta segunda invariância — agora cruzando famílias arquiteturais — reforça a leitura de que a LMC sobre `bn_gamma` mede uma propriedade temporal robusta da maturação dos pesos em CNNs convolucionais treinadas em imagens médicas, dentro de um mesmo dataset.

6. A SampEn 2D aplicada ao mosaico dos filtros 7×7 da `conv1` (Seção 4.8) **discrimina os três datasets** com intervalos de confiança não-sobrepostos: 3,98 para PathMNIST, 5,77 para OrganAMNIST e 6,18 para BloodMNIST. Esta sensibilidade adicional — inalcançável pela SampEn 1D, cujos valores no checkpoint final são quase idênticos entre os três datasets ($\approx$ 2,07–2,10) — justifica empiricamente a inclusão de extensões 2D no protocolo de análise: ao preservar a geometria do kernel, a SampEn 2D evidencia diferenças que o *flatten* sequencial encobre.

7. A extensão multiescala (MSE 2D, Seção 4.9) revela que a discriminação inter-dataset é **dependente da escala espacial**: as três curvas MSE 2D cruzam em $\tau \in [2, 3]$, invertendo a ordenação entre PathMNIST e os dois datasets RGB-textuais (OrganAMNIST, BloodMNIST). Em escala fina ($\tau = 1$), PathMNIST tem a SampEn 2D mais baixa; em escala intermediária ($\tau = 4$–7), tem a mais alta. Operacionalmente, esta dependência de escala significa que a escolha de τ é um *parâmetro de modelagem crítico* para comparações entre datasets, e que a assinatura espectral multiescala é mais robusta como descritor do que um único valor de SampEn 2D.

8. Entre datasets (Seção 4.7), no entanto, **a invariância não se mantém**: o pico da LMC localiza-se em 6,4 épocas para PathMNIST e 5,6 épocas para BloodMNIST (ambos RGB, classificação textural), mas em 23,9 épocas para OrganAMNIST (CT em escala de cinza, classificação anatômica). A análise por grupo de camadas (Seção 4.7.3) localizou o anomalismo: o deslocamento de $\sim 4\times$ no instante do pico de OrganAMNIST manifesta-se de forma sincrônica em `bn_gamma` e em `bn_beta`, enquanto os grupos `conv` e `dense` comportam-se de modo similar entre os três datasets. Esta sincronia γ/β é consistente com a interpretação de que a diferença não é qualitativa (não há um mecanismo distinto), mas *temporal*: a adaptação das

estatísticas internas que governam γ e β é globalmente mais lenta em OrganAMNIST. Esta sensibilidade ao dataset levou a uma reformulação final da hipótese H1: a LMC sobre `bn_gamma` atinge seu extremo *antes* do mínimo de *loss* de validação — propriedade que se mantém em todos os datasets testados —, mas o instante e a forma da trajetória dependem do dataset, em particular do regime de adaptação das estatísticas internas da rede.

A análise contribui ainda com dois resultados secundários: (i) a evidência empírica de que a transposição do tensor de pesos antes do *flatten* produz séries semanticamente distintas mas estatisticamente permutadas, justificando *a posteriori* a escolha do agrupamento por neurônio de saída adotada na metodologia (Seção 3.5.2); e (ii) a constatação, na decomposição por grupos (Figura 9), de que o sinal antecipador concentra-se nos parâmetros de escala γ da *batch normalization*, contrariando a expectativa inicial de que as camadas convolucionais — que detêm 99,7% dos parâmetros — seriam o substrato natural do marcador.

5.1 ACHADOS DO SEGUNDO DESENHO EXPERIMENTAL

Os achados enumerados acima decorrem do desenho em que o sobreajuste é induzido por subamostragem do treino. O segundo desenho, descrito na Seção 3.10 e reportado na Seção 4.10, induz memorização por corrupção controlada de rótulos e mede a camada densa integralmente. Seus resultados acrescentam três achados e obrigam a reformular a hipótese central.

1. **A SampEn2D da camada densa antecipa a degradação da validação.** Em oito execuções com controles estritamente pareados, a inflexão precede a queda sustentada da acurácia de validação em $7{,}50 \pm 0{,}93$ épocas, com intervalo de confiança de 95 % entre 6,73 e 8,27. A razão de amplitude entre execuções com e sem memorização é de 5,65 vezes ($p = 0{,}00016$, o menor valor alcançável pelo teste com oito observações por grupo). O achado replica-se na DenseNet-121, com razão de 4,35 vezes ($p = 0{,}00155$) e antecedência de $21{,}1 \pm 2{,}4$ épocas.

2. **A complexidade LMC não discrimina memorização na camada densa.** A razão de amplitude é de 1,07 na ResNet-18 ($p = 0{,}195$) e 1,06 na DenseNet-121 ($p = 0{,}435$). Trata-se de resultado negativo, e não de insuficiência de potência estatística: a amplitude média das execuções com corrupção situa-se dentro de um desvio-padrão da amplitude média dos controles. A leitura proposta remete à invariância da LMC a permutações — se a memorização reorganiza os pesos sem alterar substancialmente a distribuição de seus valores, a medida é cega a ela por construção.

3. **A época do alerta é invariante ao nível de corrupção.** Com 12,5 %, 25 % e 41,7 % de rótulos efetivamente errados, a época em que o indicador inflete permanece estatisticamente indistinguível ($F = 1{,}00$; $p = 0{,}42$), enquanto a época em que a degradação se torna visível na validação antecipa-se de modo significativo ($F = 30{,}2$; $p = 0{,}0007$). A leitura compatível com os dados é que o indicador marca o *início* da memorização, cujo momento depende pouco da quantidade de rótulos errados, enquanto a validação mede o *sintoma*.

5.2 REFORMULAÇÃO DA HIPÓTESE CENTRAL

A hipótese enunciada na Seção 1.4 afirmava que a complexidade estatística dos pesos constitui marcador objetivo do início do sobreajuste. Os dois conjuntos de resultados obrigam a qualificá-la, e a qualificação é o principal aporte conceitual desta dissertação.

Tomados isoladamente, os achados parecem incompatíveis: a LMC antecipa a degradação no primeiro desenho e não discrimina no segundo. A incompatibilidade é aparente, e sua dissolução depende de reconhecer que os dois desenhos diferem em três dimensões simultâneas — o grupo de pesos observado, o mecanismo que origina a perda de generalização e o conjunto de dados.

O delineamento cruzado reportado na Seção 4.11 foi conduzido precisamente para isolar essas dimensões, e produziu resultado parcial. A célula que mede a LMC sobre os parâmetros γ sob corrupção de rótulos **enfraquece a hipótese do grupo de pesos**: a medida não discrimina memorização nem nesse grupo (razão de 1,30; $p = 0{,}065$), justamente aquele em que se mostrara informativa sob subamostragem. A célula recíproca, que mediria a SampEn2D sob subamostragem, revelou-se **inviável no MedNIST**: nenhuma das frações examinadas — 10 %, 2 % e 1 % do conjunto de treino — produz degradação mensurável da validação, com queda máxima de 0,22 ponto percentual contra 15,80 sob corrupção de rótulos, razão de aproximadamente 74 vezes.

A explicação mais compatível com os dados é, portanto, que o fator determinante seja o **mecanismo** e não o grupo de pesos: a LMC responde à alteração da distribuição dos pesos provocada pela escassez de dados, não à reorganização provocada pela memorização de rótulos inconsistentes. Duas ressalvas impedem afirmação mais forte — a célula recíproca permanece vazia, e a comparação entre os desenhos ainda atravessa conjuntos de dados distintos. Trata-se da explicação mais econômica entre as compatíveis com a evidência, não de conclusão demonstrada, e essa limitação deve ser declarada sem atenuação.

O que os resultados autorizam afirmar, em caráter conclusivo, é mais modesto e mais preciso do que a hipótese original: **a capacidade de marcar o sobreajuste não é propriedade de uma medida isolada, mas da combinação entre a medida empregada, o grupo de pesos observado e o mecanismo que origina a perda de**

generalização. Nenhuma das medidas investigadas funciona universalmente; cada uma funciona em condições identificáveis.

Essa reformulação tem consequência prática direta para quem pretenda empregar os indicadores. Não é possível recomendar uma medida única como marcador de sobreajuste. É possível, com base nos resultados obtidos, recomendar a SampEn2D sobre a camada densa quando a preocupação for memorização de associações inconsistentes, e registrar que a LMC sobre os parâmetros de normalização em lote respondeu à escassez de dados no primeiro desenho. A generalidade de cada recomendação, porém, permanece limitada pelas condições em que foi estabelecida.

Registre-se ainda uma delimitação que restringe a transposição prática dos achados: na DenseNet-121, embora a amplitude discrimine, a época do sinal *não* separa os grupos. Um monitor que emitisse alerta pelo simples cruzamento de um limiar temporal produziria falsos positivos nessa arquitetura. O critério de alerta precisa incorporar a magnitude da variação, e não apenas o momento em que ela se inicia.

5.3 TRABALHOS FUTUROS

A partir das limitações identificadas, perfilam-se os desdobramentos abaixo. Registre-se que três itens originalmente previstos como trabalho futuro foram realizados no curso desta pesquisa e constam do Capítulo 4: a extensão para SampEn2D, a análise multiescala e a comparação com uma segunda arquitetura (DenseNet-121). Eles permanecem listados apenas nos aspectos que seguem em aberto.

1. **Conclusão do delineamento cruzado em repositório mais difícil.** Três das quatro células foram preenchidas na Seção 4.11. A célula restante — SampEn2D sob subamostragem — não pôde ser obtida porque o MedNIST não sofre perda de generalização por escassez de dados, nem com 1 % do conjunto de treino. Completá-la exige repositório de maior dificuldade intrínseca, como o PathMNIST empregado no primeiro desenho, ao custo de reintroduzir a variável *conjunto de dados*. A alternativa metodologicamente superior é repetir *ambos* os mecanismos de indução no mesmo repositório difícil, eliminando essa variável de uma vez.

2. **Sobreajuste espontâneo.** Toda a evidência do segundo desenho provém de memorização induzida por corrupção de rótulos. Resta demonstrar que os indicadores se comportam do mesmo modo diante de sobreajuste surgido por escassez de dados sem corrupção — situação mais próxima da prática. O experimento exige cautela com o falso positivo de normalização em lote descrito na Seção 3.10.

3. **Reconsideração da ordem de achatamento.** A ablação da Seção 4.10.6 mostra que a leitura por entrada supera a convenção adotada nos dois critérios avalia-

dos. Convém reavaliar a convenção, ainda que o efeito prático seja limitado pela superioridade da SampEn2D, que não achata a matriz.

4. **Refinamento do detector de inflexão**: o presente trabalho adotou suavização por Savitzky-Golay sobre o grupo `bn_gamma`. Estratégias alternativas — regressão linear segmentada (*piecewise linear fit*), detecção de pontos de mudança bayesiana, ou ajuste paramétrico de pico assimétrico — podem produzir estimativas com intervalos de confiança mais estreitos no regime intermediário de 10%.

5. **Extensão para SampEn 2D** (SILVA et al., 2016) aplicada diretamente às matrizes dos filtros convolucionais, contornando a discussão sobre a ordem do *flatten* e capturando estrutura espacial preservada.

6. **Análise multiescala** (MSE) (COSTA et al., 2002; COSTA et al., 2005) para investigar dependências em diferentes resoluções temporais do treinamento, particularmente relevante após a observação do pico agudo da LMC em torno das épocas 5–15.

7. **Comparação inter-arquitetura** (DenseNet, EfficientNet, Wide ResNet) para verificar a invariância do *lead time* observado.

8. **Análise de sensibilidade à regularização explícita** (*weight decay*, *dropout*, *label smoothing*) para testar se a manipulação dirigida da propensão ao sobreajuste preserva a relação observada entre o pico da LMC e o mínimo de *loss* de validação.

9. **Dados substitutos (*surrogate data*)** como teste de hipótese nula sobre a trajetória de complexidade, permitindo caracterizar o quanto da estrutura observada se afasta do comportamento esperado sob inicialização aleatória mais ruído.

10. **Aplicação prática** do marcador proposto como critério de parada precoce em pipelines de treinamento contínuo, comparando custo computacional e desempenho com baselines tradicionais baseados em *loss* de validação.

REFERÊNCIAS

ADVANI, M. S.; SAXE, A. M.; SOMPOLINSKY, H. High-dimensional dynamics of generalization error in neural networks. **Neural Networks**, v. 132, p. 428–446, 2020.

ANTENEODO, C.; PLASTINO, A. R. Some features of the lópez-ruiz-mancini-calbet (LMC) statistical measure of complexity. **Physics Letters A**, v. 223, n. 5, p. 348–354, 1996.

ARPIT, D. et al. A closer look at memorization in deep networks. In: **Proceedings of the 34th International Conference on Machine Learning (ICML)**. [S.l.: s.n.], 2017. p. 233–242.

BARTLETT, P. L.; FOSTER, D. J.; TELGARSKY, M. Spectrally-normalized margin bounds for neural networks. In: **Advances in Neural Information Processing Systems (NeurIPS)**. [S.l.: s.n.], 2017. v. 30.

COSTA, M.; GOLDBERGER, A. L.; PENG, C.-K. Multiscale entropy analysis of complex physiologic time series. **Physical Review Letters**, v. 89, n. 6, p. 068102, 2002.

_____. Multiscale entropy analysis of biological signals. **Physical Review E**, v. 71, n. 2, p. 021906, 2005.

COVER, T. M.; THOMAS, J. A. **Elements of Information Theory**. 2. ed. Hoboken, NJ: Wiley-Interscience, 2006.

DELGADO-BONAL, A.; MARSHAK, A. Approximate entropy and sample entropy: A comprehensive tutorial. **Entropy**, v. 21, n. 6, p. 541, 2019.

DZIUGAITE, G. K.; ROY, D. M. Computing nonvacuous generalization bounds for deep (stochastic) neural networks with many more parameters than training data. In: **Proceedings of the 33rd Conference on Uncertainty in Artificial Intelligence (UAI)**. [S.l.: s.n.], 2017.

FELDMAN, D. P.; CRUTCHFIELD, J. P. Measures of statistical complexity: Why? **Physics Letters A**, v. 238, n. 4–5, p. 244–252, 1998.

HE, K. et al. Deep residual learning for image recognition. p. 770–778, 2016.

JIANG, X. et al. Deep learning for medical image-based cancer diagnosis. **Cancers**, v. 15, n. 14, p. 3608, 2023.

JIANG, Y. et al. Fantastic generalization measures and where to find them. In: **International Conference on Learning Representations (ICLR)**. [S.l.: s.n.], 2020.

LAMBERTI, P. W. et al. Intensive entropic non-triviality measure. **Physica A: Statistical Mechanics and its Applications**, v. 334, n. 1–2, p. 119–131, 2004.

LÓPEZ-RUIZ, R.; MANCINI, H. L.; CALBET, X. A statistical measure of complexity. **Physics Letters A**, v. 209, n. 5–6, p. 321–326, 1995.

MARTIN, C. H.; PENG, T.; MAHONEY, M. W. Predicting trends in the quality of state-of-the-art neural networks without access to training or testing data. **Nature Communications**, v. 12, n. 1, p. 4122, 2021.

PINCUS, S. M. Approximate entropy as a measure of system complexity. **Proceedings of the National Academy of Sciences**, v. 88, n. 6, p. 2297–2301, 1991.

POWER, A. et al. **Grokking: generalization beyond overfitting on small algorithmic datasets**. 2022. ArXiv:2201.02177.

PRECHELT, L. Automatic early stopping using cross validation: quantifying the criteria. **Neural Networks**, v. 11, n. 4, p. 761–767, 1998.

RICHMAN, J. S.; MOORMAN, J. R. Physiological time-series analysis using approximate entropy and sample entropy. **American Journal of Physiology – Heart and Circulatory Physiology**, v. 278, n. 6, p. H2039–H2049, 2000.

ROSSO, O. A. et al. Generalized statistical complexity measure. **International Journal of Bifurcation and Chaos**, v. 20, n. 3, p. 775–785, 2010.

SAXE, A. M. et al. On the information bottleneck theory of deep learning. **Journal of Statistical Mechanics: Theory and Experiment**, v. 2019, n. 12, p. 124020, 2019.

SAYAMA, H. **Introduction to the Modeling and Analysis of Complex Systems**. Geneseo, NY: Open SUNY Textbooks, 2015. Licença Creative Commons BY-NC-SA 3.0. ISBN 978-1-942341-08-6.

SHANNON, C. E. A mathematical theory of communication. **Bell System Technical Journal**, v. 27, n. 3, p. 379–423, 1948.

SHWARTZ-ZIV, R.; TISHBY, N. **Opening the black box of deep neural networks via information**. 2017. ArXiv:1703.00810.

SILVA, L. E. V. et al. Two-dimensional sample entropy analysis of rat sural nerve aging. In: **Proceedings of the 36th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)**. [S.l.: s.n.], 2014. p. 3345–3348.

_____. Two-dimensional sample entropy: assessing image texture through irregularity. **Biomedical Physics & Engineering Express**, v. 2, n. 4, p. 045002, 2016.

SILVA, L. E. V.; JUNIOR, L. O. M. Evaluation of physiologic complexity in time series using generalized sample entropy and surrogate data analysis. **Chaos: An Interdisciplinary Journal of Nonlinear Science**, v. 22, n. 4, p. 043105, 2012.

TENG, Q. et al. A survey on the interpretability of deep learning in medical diagnosis. **Multimedia Systems**, v. 28, n. 6, p. 2335–2355, 2022.

TISHBY, N.; ZASLAVSKY, N. Deep learning and the information bottleneck principle. In: **IEEE Information Theory Workshop (ITW)**. [S.l.: s.n.], 2015. p. 1–5.

YANG, J. et al. MedMNIST v2 – a large-scale lightweight benchmark for 2D and 3D biomedical image classification. **Scientific Data**, v. 10, n. 1, p. 41, 2023.

YENTES, J. M. et al. The appropriate use of approximate entropy and sample entropy with short data sets. **Annals of Biomedical Engineering**, v. 41, n. 2, p. 349–365, 2013.

ZHANG, C. et al. Understanding deep learning requires rethinking generalization. In: **International Conference on Learning Representations (ICLR)**. [S.l.: s.n.], 2017.

ZHANG, J.; BELL, M. A. L. Overfit detection method for deep neural networks trained to beamform ultrasound images. **Ultrasonics**, v. 148, p. 107562, 2025.

Apêndices

APÊNDICE A – EXEMPLO NUMÉRICO DA ORDEM DE EXTRAÇÃO DOS PESOS

Este apêndice complementa o discutido na Seção 3.5 rastreando, elemento a elemento, a correspondência entre os tensores de pesos do PyTorch e a sequência linear obtida via `flatten()`. São apresentados três exemplos minimalistas — uma camada linear 2×3, uma convolução 2D com tensor de *shape* $[C_{out}, C_{in}, H, W] = [2, 2, 2, 2]$ e uma camada de *batch normalization* com $C = 4$ canais —, suficientes para tornar verificáveis e reproduzíveis as três regras de varredura adotadas. Em seguida discute-se, no mesmo exemplo da convolução, o efeito de transpor o tensor antes do *flatten*, conforme antecipado pela decisão D2 da Seção 3.5.2.

A.1 CAMADA LINEAR: MATRIZ 2×3

Considere uma camada `nn.Linear(in_features=3, out_features=2)` cujo tensor `weight` de *shape* $[\text{Out}, \text{In}] = [2, 3]$ recebe valores inteiros para facilitar o rastreamento:

$$W_{\text{lin}} = \begin{pmatrix} w_{0,0} & w_{0,1} & w_{0,2} \\ w_{1,0} & w_{1,1} & w_{1,2} \end{pmatrix} = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{pmatrix}. \tag{A.1}$$

Aplicando `W_lin.flatten()` obtemos o vetor

$$W_{\text{lin}}\texttt{.flatten()} = [\,1,\ 2,\ 3,\ 4,\ 5,\ 6\,]. \tag{A.2}$$

A Tabela 27 mostra a correspondência elemento a elemento. Note que a leitura é feita **linha por linha**: primeiro saem todos os três pesos de entrada do neurônio de saída Out $= 0$, depois os três pesos do neurônio Out $= 1$. Cada linha contígua do vetor corresponde a *um único neurônio de saída*.

Tabela 27 – Mapeamento elemento a elemento da camada Linear 2×3.

Posição no vetor	0	1	2	3	4 (→) 5
Elemento	$w_{0,0}$	$w_{0,1}$	$w_{0,2}$	$w_{1,0}$	$w_{1,1}$ $w_{1,2}$
Valor	1	2	3	4	5 6
Pertence a	**Saída** Out $= 0$			**Saída** Out $= 1$	

A.2 CAMADA CONV2D: TENSOR $[2, 2, 2, 2]$

Considere uma `nn.Conv2d(in_channels=2, out_channels=2, kernel_size=2)` cujo tensor `weight` de *shape* $[C_{out}, C_{in}, H, W] = [2, 2, 2, 2]$ é preenchido com os 16 inteiros consecutivos $0, 1, \ldots, 15$:

$$W_{\text{conv}}[c_{out}, c_{in}, h, w] \;=\; c_{out} \cdot 8 + c_{in} \cdot 4 + h \cdot 2 + w. \tag{A.3}$$

Em formato hierárquico, o tensor escreve-se como:

$$W_{\text{conv}} \;=\; \underbrace{\Bigg[\underbrace{\begin{pmatrix} 0 & 1 \\ 2 & 3 \end{pmatrix}}_{C_{in}=0} \; \underbrace{\begin{pmatrix} 4 & 5 \\ 6 & 7 \end{pmatrix}}_{C_{in}=1}\Bigg]}_{\text{Filtro de saída } C_{out}=0} \; \underbrace{\Bigg[\underbrace{\begin{pmatrix} 8 & 9 \\ 10 & 11 \end{pmatrix}}_{C_{in}=0} \; \underbrace{\begin{pmatrix} 12 & 13 \\ 14 & 15 \end{pmatrix}}_{C_{in}=1}\Bigg]}_{\text{Filtro de saída } C_{out}=1} \tag{A.4}$$

Aplicando `W_conv.flatten()` obtemos o vetor

$$W_{\text{conv}}\texttt{.flatten()} \;=\; [\,0, 1, 2, 3,\; 4, 5, 6, 7,\; 8, 9, 10, 11,\; 12, 13, 14, 15\,]. \tag{A.5}$$

A Tabela 28 mostra a correspondência completa elemento a elemento. Observa-se que os quatro *loops* aninhados se manifestam diretamente nas colunas: W varia a cada passo $(0 \to 1)$, H a cada dois passos $(0 \to 1)$, C_{in} a cada quatro passos $(0 \to 1)$ e C_{out} a cada oito passos $(0 \to 1)$. Cada bloco contíguo de quatro elementos do vetor corresponde a *um canal de entrada inteiro* de um filtro de saída; cada bloco contíguo de oito elementos corresponde a *um filtro de saída inteiro*.

Tabela 28 – Mapeamento elemento a elemento da camada Conv2d $[2, 2, 2, 2]$. Posições do vetor, índices do tensor e bloco semântico ao qual cada elemento pertence.

Pos.	C_{out}	C_{in}	H	W	**Valor**	**Pertence ao bloco semântico**
0	0	0	0	0	0	$C_{in} = 0$ do filtro $C_{out} = 0$
1	0	0	0	1	1	
2	0	0	1	0	2	
3	0	0	1	1	3	
4	0	1	0	0	4	$C_{in} = 1$ do filtro $C_{out} = 0$
5	0	1	0	1	5	
6	0	1	1	0	6	
7	0	1	1	1	7	
8	1	0	0	0	8	$C_{in} = 0$ do filtro $C_{out} = 1$
9	1	0	0	1	9	
10	1	0	1	0	10	
11	1	0	1	1	11	
12	1	1	0	0	12	$C_{in} = 1$ do filtro $C_{out} = 1$
13	1	1	0	1	13	
14	1	1	1	0	14	
15	1	1	1	1	15	

A.3 CONTRASTE: EFEITO DA TRANSPOSIÇÃO

A decisão D2 da Seção 3.5.2 adota a ordem nativa $[C_{out}, C_{in}, H, W]$ deliberadamente. Esta seção quantifica o que mudaria caso o tensor fosse transposto para $[C_{in}, C_{out}, H, W]$ antes do *flatten*, alterando a unidade contígua de "filtro de saída inteiro" para "destino dos pesos a partir de um canal de entrada".

Aplicando `W_conv.permute(1, 0, 2, 3).flatten()` ao mesmo tensor do exemplo anterior obtém-se:

$$W_{\text{conv}}^{\mathsf{T}}\texttt{.flatten()} \;=\; [\,0,1,2,3,\;\; 8,9,10,11,\;\; 4,5,6,7,\;\; 12,13,14,15\,]. \tag{A.6}$$

Note que o vetor é uma **permutação** do anterior — contém os mesmos 16 valores, mas agora os blocos contíguos de quatro elementos correspondem a um canal de entrada visto a partir de *ambos* os filtros de saída, conforme a Tabela 29.

Tabela 29 – Mapeamento elemento a elemento com transposição prévia $[C_{in}, C_{out}, H, W]$. Compare com a Tabela 28.

Pos.	C_{in}	C_{out}	H	W	**Valor**	**Pertence ao bloco semântico**
0	0	0	0	0	0	filtro $C_{out} = 0$ a partir de $C_{in} = 0$
1	0	0	0	1	1	
2	0	0	1	0	2	
3	0	0	1	1	3	
4	0	1	0	0	8	filtro $C_{out} = 1$ a partir de $C_{in} = 0$
5	0	1	0	1	9	
6	0	1	1	0	10	
7	0	1	1	1	11	
8	1	0	0	0	4	filtro $C_{out} = 0$ a partir de $C_{in} = 1$
9	1	0	0	1	5	
10	1	0	1	0	6	
11	1	0	1	1	7	
12	1	1	0	0	12	filtro $C_{out} = 1$ a partir de $C_{in} = 1$
13	1	1	0	1	13	
14	1	1	1	0	14	
15	1	1	1	1	15	

Leitura comparativa. As Tabelas 28 e 29 contêm exatamente os mesmos 16 valores, mas em ordens diferentes. Sob a perspectiva da SampEn 1D — que mede regularidade de sub-sequências consecutivas — estas são **duas séries distintas**, e portanto a métrica pode reportar valores diferentes a partir delas. Esta sensibilidade à ordem é precisamente o que torna a decisão D2 substantiva e justifica o experimento de controle previsto na Seção 3.8.

A.4 CAMADA BATCHNORM2D: VETORES γ E β

Para uma `nn.BatchNorm2d(num_features=4)`, os parâmetros aprendíveis são dois vetores 1D de comprimento 4: a escala γ (`bn.weight`) e o deslocamento β (`bn.bias`). Na inicialização padrão do PyTorch:

$$\gamma = [1, 1, 1, 1], \qquad \beta = [0, 0, 0, 0]. \tag{A.7}$$

Após o treinamento, esses vetores evoluem para configurações como

$$\gamma \approx [1{,}23,\ 0{,}08,\ 0{,}95,\ 1{,}51], \qquad \beta \approx [-0{,}02,\ 0{,}07,\ -0{,}11,\ 0{,}04]$$

(valores ilustrativos extraídos de um *run* preliminar em PathMNIST). Por se tratar de vetores 1D, a ordem do *flatten* é trivialmente a ordem dos canais, sem ambiguidade. Os parâmetros do canal c ocupam a posição c no respectivo vetor, e os dois grupos `bn_gamma` e `bn_beta` são analisados separadamente pelos motivos expostos na Seção 3.6.1.

A.5 REPRODUTIBILIDADE

Os valores apresentados neste apêndice podem ser reproduzidos diretamente em PyTorch. O fragmento abaixo gera todos os vetores das Tabelas 27, 28 e 29:

```
import torch

# Linear (Out=2, In=3)
W_lin = torch.tensor([[1., 2., 3.],
                      [4., 5., 6.]])
print(W_lin.flatten().tolist())
# [1.0, 2.0, 3.0, 4.0, 5.0, 6.0]

# Conv2d (C_out=2, C_in=2, H=2, W=2)
W_conv = torch.arange(16).reshape(2, 2, 2, 2).float()
print(W_conv.flatten().int().tolist())
# [0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15]

# Conv2d transposed to [C_in, C_out, H, W]
print(W_conv.permute(1, 0, 2, 3).flatten().int().tolist())
# [0, 1, 2, 3, 8, 9, 10, 11, 4, 5, 6, 7, 12, 13, 14, 15]
```

A correspondência entre a regra row-major da Seção 3.5 e os valores numéricos acima encerra a discussão sobre a ordem da extração em nível operacional. Resta, para os

capítulos de Resultados, examinar empiricamente quanto essa ordem afeta as trajetórias de complexidade sobre dados reais.

APÊNDICE B – VALIDAÇÃO NUMÉRICA DAS MEDIDAS DE COMPLEXIDADE

Este apêndice cumpre a parte do objetivo específico 1 (Capítulo 1) referente à *validação numérica das medidas em casos analiticamente conhecidos*. As implementações descritas na seção 3.7 — complexidade LMC e *Sample Entropy* 1D e 2D — são aplicadas a distribuições e séries cujo comportamento esperado é conhecido em forma fechada ou qualitativamente, verificando-se que os valores produzidos coincidem com a teoria. Todos os resultados desta seção são reproduzíveis executando `scripts/validacao_numerica.py` (semente 42, `numpy` 1.26); para a LMC fixou-se $N = 100$ *bins*, de modo que a entropia da uniforme tem valor de referência $\log_2 N \approx 6{,}6439$ bits.

B.1 COMPLEXIDADE LMC

Para a forma adotada $C = H \times D$, com H em bits e $D = \sum_i (p_i - 1/N)^2$, os dois extremos têm valor analítico exato: a distribuição *uniforme* maximiza a entropia ($H = \log_2 N$) e anula o desequilíbrio ($D = 0$), enquanto a distribuição *degenerada* (toda a massa em um único *bin*) anula a entropia ($H = 0$) e atinge $D = 1 - 1/N$; em ambos os casos $C = 0$. Uma distribuição *gaussiana* representa o regime intermediário, com $0 < H < \log_2 N$, $D > 0$ e, portanto, $C > 0$. A Tabela 30 confirma os três comportamentos.

Tabela 30 – Validação da LMC ($N = 100$ *bins*). Os casos uniforme e degenerado reproduzem os valores analíticos com precisão de máquina.

Distribuição	H (bits)	D	$C = H \times D$	Esperado
Uniforme	6,6439	0,00000	0,00000	$H = \log_2 N,\ D \approx 0,\ C \approx 0$
Degenerada	0,0000	0,99000	0,00000	$H = 0,\ D = 1 - 1/N,\ C = 0$
Gaussiana	5,4638	0,01646	0,08994	$0 < H < \log_2 N,\ D > 0,\ C > 0$

B.2 SAMPLE ENTROPY 1D

Com $m = 2$ e $r = 0{,}2\,\sigma$, uma série *constante* é perfeitamente regular e produz SampEn $= 0$ por definição; uma série *periódica* é altamente previsível e produz valor próximo de zero; *ruído branco gaussiano* maximiza a irregularidade e produz um valor finito e elevado, da ordem de 2,1 — compatível com o reportado na literatura para sinais sem estrutura sob essa parametrização. A Tabela 31 confirma a ordenação esperada.

Tabela 31 – Validação da SampEn 1D ($m = 2$, $r = 0{,}2\,\sigma$, séries de 1000 amostras).

Série	SampEn	Esperado
Constante	0,0000	0 (perfeitamente regular)
Periódica (seno, $T = 20$)	0,1864	≈ 0 (previsível)
Ruído branco gaussiano	2,0934	finito e elevado (irregular)

B.3 SAMPLE ENTROPY 2D

A SampEn 2D preserva os limites esperados: uma matriz *constante* produz 0, e uma matriz com *estrutura periódica* produz valor baixo. Para *ruído branco* 64×64, a tolerância padrão $r = 0{,}2\,\sigma$ satura em $+\infty$ — nenhum par de janelas $(m+1) \times (m+1)$ casa dentro da tolerância —, exatamente o comportamento que motivou a adoção de $r = 0{,}5\,\sigma$ na subseção 3.7.4; sob essa tolerância o valor torna-se finito ($\approx 6{,}46$). A validação, portanto, não apenas confirma os limites como reproduz de forma independente a justificativa metodológica para a calibração de r no caso 2D.

Tabela 32 – Validação da SampEn 2D ($m = 2$, matrizes 64×64). O caso do ruído sob $r = 0{,}2\,\sigma$ reproduz a saturação que motiva $r = 0{,}5\,\sigma$.

Matriz	SampEn 2D	Esperado
Constante	0,0000	0 (regular)
Estrutura periódica	0,8173	baixa (estruturada)
Ruído branco ($r = 0{,}2\,\sigma$)	$+\infty$	satura (motiva $r = 0{,}5\,\sigma$)
Ruído branco ($r = 0{,}5\,\sigma$)	6,4636	finito e elevado (irregular)

Em conjunto, as três validações estabelecem que as implementações reproduzem os valores analíticos exatos nos extremos (LMC nas distribuições uniforme e degenerada; SampEn em séries constantes) e a ordenação qualitativa esperada nos regimes intermediários, sustentando o uso das medidas nas análises do Capítulo 4.