Universidade de São Paulo
Faculdade de Filosofia, Ciências e Letras de Ribeirão Preto
Departamento de Computação e Matemática
Programa de Pós-Graduação em Computação Aplicada

Cássio Silva Takarada

Comportamento da Complexidade Estatística dos Pesos da Camada Densa durante o Treinamento de Redes Neurais Convolucionais em Imagens Médicas

Ribeirão Preto–SP
2026

Cássio Silva Takarada

Comportamento da Complexidade Estatística dos Pesos da Camada Densa durante o Treinamento de Redes Neurais Convolucionais em Imagens Médicas

Monografia apresentada à Faculdade de Filosofia, Ciências e Letras de Ribeirão Preto da Universidade de São Paulo, como parte das exigências para a obtenção do título de Mestre em Ciências.

Prof. Dr. Luiz Otávio Murta Junior

Ribeirão Preto–SP

2026

Takarada, Cássio Silva

Comportamento da complexidade estatística dos pesos da camada densa durante o treinamento de redes neurais convolucionais em imagens médicas / Cássio Silva Takarada; orientador Luiz Otávio Murta Junior. – Ribeirão Preto, 2026.

[PREENCHER: número de folhas] f. : il.

Dissertação (Mestrado – Programa de Pós-Graduação em Computação Aplicada) – Faculdade de Filosofia, Ciências e Letras de Ribeirão Preto, Universidade de São Paulo, 2026.

1. Aprendizado profundo. 2. Complexidade estatística. 3. Entropia amostral. 4. *Overfitting*. 5. Imagens médicas. I. Murta Junior, Luiz Otávio, orient. II. Título.

[PREENCHER: CDD]

[PREENCHER: Elaborada por ..., CRB-8/....]

Cássio Silva Takarada

Comportamento da Complexidade Estatística dos Pesos da Camada Densa durante o Treinamento de Redes Neurais Convolucionais em Imagens Médicas

Dissertação apresentada ao Programa de Pós-Graduação em Computação Aplicada da Faculdade de Filosofia, Ciências e Letras de Ribeirão Preto da Universidade de São Paulo, como parte das exigências para a obtenção do título de Mestre em Ciências.

Trabalho aprovado. Ribeirão Preto, [PREENCHER: dia] de [PREENCHER: mês] de [PREENCHER: ano].

Prof. Dr. Luiz Otávio Murta Junior
Orientador — FFCLRP/USP

[PREENCHER: Prof. Dr. Nome do 1º examinador]
[PREENCHER: instituição]

[PREENCHER: Prof. Dr. Nome do 2º examinador]
[PREENCHER: instituição]

AGRADECIMENTOS

Em primeiro lugar, agradeço a Deus pois sem Ele tudo o que sou seria em vão. Todas as oportunidades que tive e tenho de crescer e me aprimorar, tanto pessoalmente quanto profissionalmente, veio através Dele.

Subsequentemente, agradeço ao professor doutor Luiz Otávio Murta Júnior, por ter me acolhido e acreditado em mim para executar essa tão renomada pesquisa, bem como fazer parte de um grupo seleto de pessoas extremamente capacitadas.

Também, agradeço a minha família. Especialmente minha esposa e meu filho, pessoas as quais me dão força de vontade e determinação para continuar me aprimorando. Agradeço também aos meus pais, que são minha base e exemplo de pessoas e profissionais. Em adendo, agradeço ao meu irmão que me apoia em tudo que eu faço em minha vida, sempre dizendo “sim” quando preciso dele.

E por fim, agradeço aos meus amigos, que sem perceber, com seus pequenos atos, fazem minha vida mais fácil. Agradeço, especialmente, ao Alexandre Gomes da Silva, Matheus Rossato Silva e Airton Monte Serrat Borin Júnior. Os quais fizeram parte desse grupo seleto de pesquisadores que estenderam a mão sempre que precisei.

À todos, meu sincero agradecimento!

"Nada há encoberto que não haja de revelar-se,
nem oculto que não haja de saber-se."
Mateus 10:26

"Ego cogito ergo sum."
René Descartes

RESUMO

O acompanhamento do treinamento de redes neurais profundas depende, na prática corrente, de um conjunto de validação rotulado, representativo e suficientemente grande — condição frequentemente inviável em imagens médicas, nas quais a anotação é onerosa e exige especialista. Esta dissertação descreve como medidas de complexidade estatística calculadas exclusivamente sobre os pesos da rede, sem acesso a rótulo algum, se comportam ao longo do treinamento. São consideradas a complexidade Lopez-Ruiz–Mancini–Calbet (LMC), produto da entropia de Shannon pela distância estatística ao equilíbrio, e a entropia amostral (SampEn), calculadas a cada época sobre os pesos da camada densa de redes treinadas no conjunto MedNIST. As trajetórias são comparadas entre execuções de controle, execuções com subamostragem do conjunto de treino e execuções com ruído branco e rosa somado às imagens de treino. [**Pendente:** síntese dos resultados dos regimes que permanecem no trabalho.]

Palavras-chave: Complexidade estatística; Entropia amostral; Aprendizagem profunda; Imagens médicas; Complexidade LMC.

ABSTRACT

Monitoring the training of deep neural networks currently relies on a labelled validation set that is representative and sufficiently large — a condition often unattainable in medical imaging, where annotation is costly and requires expert knowledge. This dissertation describes how statistical complexity measures computed exclusively from network weights, without access to any label, behave throughout training. Two measures are considered: the Lopez-Ruiz–Mancini–Calbet (LMC) complexity, defined as the product of Shannon entropy and the statistical distance from equilibrium, and sample entropy (SampEn), computed at every epoch over the dense-layer weights of networks trained on the MedNIST dataset. The trajectories are compared across control runs, runs with a subsampled training set and runs with white and pink noise added to the training images. [**Pendente:** summary of the results of the remaining regimes.]

Keywords: Statistical complexity; Sample entropy; Deep learning; Medical imaging; LMC complexity.

LISTA DE ILUSTRAÇÕES

Figura 1 – Estrutura de nível superior da ResNet-18: oito módulos nomeados em sequência. As caixas indicam o tipo de camada (azul: Conv2d; verde: BatchNorm2d; cinza: sem parâmetros; laranja: Linear). As caixas `layer1`–`layer4` são contêineres `Sequential` de blocos residuais. 38

LISTA DE TABELAS

Tabela 1 – Comparação dos trabalhos discutidos quanto à dependência de dados rotulados, à natureza temporal da leitura e ao objeto medido. 34
Tabela 2 – Mapeamento elemento a elemento da camada Linear 2×3. 53
Tabela 3 – Validação da LMC ($N = 100$ *bins*). Os casos uniforme e degenerado reproduzem os valores analíticos com precisão de máquina. 55
Tabela 4 – Validação da SampEn 1D ($m = 2$, $r = 0{,}2\,\sigma$, séries de 1000 amostras). . 56

SUMÁRIO

1 INTRODUÇÃO 19
1.1 Contexto da análise de imagens médicas no diagnóstico clínico . . . 19
1.2 Avanços em aprendizado profundo aplicados à medicina 19
1.3 Justificativa do uso de medidas de complexidade 20
1.3.1 Justificativa prática: o ponto de vista de quem treina a rede 21
1.4 Hipótese, objetivos e escopo 22
1.5 Organização do trabalho 23

2 FUNDAMENTAÇÃO TEÓRICA 25
2.1 Sistemas complexos, auto-organização e emergência 25
2.1.1 A noção de sistema complexo 25
2.1.2 Emergência 26
2.1.3 Auto-organização 26
2.1.4 Delimitação: o que não se pretende afirmar 26
2.2 Entropia de Shannon e teoria da informação 27
2.3 Entropia Aproximada e Entropia de Amostra 28
2.4 Entropia Multiescala (MSE) 29
2.5 Complexidade Estatística LMC 30
2.6 Estado da arte: leitura do estado interno de redes profundas 32
2.6.1 Memorização e os dois regimes do aprendizado 32
2.6.2 Limites de generalização por normas e margens 33
2.6.3 Abordagens espectrais 33
2.6.4 Abordagens informação-teóricas e a controvérsia do gargalo de informação . 33
2.6.5 Síntese e posicionamento da proposta 34

3 METODOLOGIA 37
3.1 Conjunto de dados 37
3.2 Arquiteturas 37
3.3 Protocolo de treinamento 38
3.4 Regimes de treinamento 38
3.4.1 Controle 39
3.4.2 Subamostragem do conjunto de treino 39
3.4.3 Ruído nas imagens de treino 39
3.5 A camada densa como objeto de medida 40
3.6 Medidas de complexidade 41

3.6.1 Complexidade LMC 41
3.6.2 Entropia amostral SampEn_{1D} 41
3.7 Monitoramento durante o treinamento 41

4 RESULTADOS 43
4.1 Execuções de controle 43
4.2 Subamostragem do conjunto de treino 43
4.3 Ruído nas imagens de treino 43
4.4 Acerto por classe 43
4.5 Segunda arquitetura 43

5 CONCLUSÃO 45
5.1 Principais achados 45
5.2 Trabalhos Futuros 45

REFERÊNCIAS 47

APÊNDICES 51

APÊNDICE A – EXEMPLO NUMÉRICO DA ORDEM DE ACHATAMENTO DA CAMADA DENSA 53
A.1 Camada Linear: matriz 2×3 53
A.2 Contraste: ordem por entrada 54
A.3 Reprodutibilidade 54

APÊNDICE B – VALIDAÇÃO NUMÉRICA DAS MEDIDAS DE COMPLEXIDADE 55
B.1 Complexidade LMC 55
B.2 Sample Entropy 1D 55

1 INTRODUÇÃO

1.1 CONTEXTO DA ANÁLISE DE IMAGENS MÉDICAS NO DIAGNÓSTICO CLÍNICO

A imagem médica consolidou-se como um dos pilares do diagnóstico clínico contemporâneo. Modalidades como tomografia computadorizada, ressonância magnética, radiografia, ultrassonografia, tomografia por emissão de pósitrons e a histopatologia digital fornecem representações detalhadas de estruturas internas e teciduais que sustentam decisões de triagem, estadiamento e acompanhamento terapêutico em praticamente todas as especialidades médicas (JIANG et al., 2023). O volume de dados gerado por esses exames cresce de modo contínuo, ao mesmo tempo em que sua interpretação permanece uma tarefa que exige treinamento especializado e está sujeita a variabilidade inter e intraobservador. Esse cenário motiva o desenvolvimento de ferramentas computacionais capazes de oferecer suporte quantitativo à análise dessas imagens, notadamente em tarefas de classificação, segmentação e detecção de anomalias.

1.2 AVANÇOS EM APRENDIZADO PROFUNDO APLICADOS À MEDICINA

Nas últimas décadas o aprendizado profundo (*deep learning*, DL) emergiu como o paradigma dominante para o processamento de imagens médicas. Em particular, redes neurais convolucionais profundas, exemplificadas pela família de redes residuais introduzida por He et al. (2016), alcançaram desempenho próximo ou superior ao de especialistas humanos em diversas tarefas de classificação e detecção (JIANG et al., 2023). Esse progresso é sustentado, de um lado, pelo aumento sistemático do poder computacional e, de outro, pela disponibilização de coleções públicas padronizadas de imagens médicas que viabilizam treinamento, comparação e reprodutibilidade de modelos. Entre essas coleções destaca-se o *benchmark* MedMNIST v2 (YANG et al., 2023), que reúne dezoito conjuntos de classificação 2D e 3D oriundos de patologia, radiologia e oftalmologia, padronizados em baixa resolução para permitir prototipagem rápida sem perder representatividade das modalidades clínicas.

Apesar desses avanços, modelos profundos operam de modo essencialmente opaco do ponto de vista clínico: a relação entre os parâmetros aprendidos e as decisões de saída não é trivialmente legível, configurando o problema classicamente designado por *caixa-preta*. Levantamentos recentes apontam que essa limitação constitui hoje a principal

barreira à adoção de DL em fluxos diagnósticos sensíveis, mais relevante até que o ganho marginal de acurácia em métricas tradicionais (TENG et al., 2022). Nesse contexto, a interpretabilidade dos modelos depende não apenas de explicações *post hoc* sobre saídas individuais, mas também de instrumentos quantitativos que caracterizem o estado interno da rede durante o treinamento.

1.3 JUSTIFICATIVA DO USO DE MEDIDAS DE COMPLEXIDADE

Métricas tradicionais de avaliação — acurácia, perda de validação, área sob a curva ROC — capturam o comportamento do modelo sobre um conjunto de dados específico, mas não oferecem leitura direta sobre a organização estatística dos pesos aprendidos. Essa lacuna é particularmente visível no fenômeno do *overfitting*: redes com elevada capacidade podem memorizar o conjunto de treinamento de modo a atingir acurácia quase perfeita sobre ele, ao mesmo tempo em que generalizam mal para dados novos. Análises teóricas recentes da dinâmica de generalização em regimes de alta dimensionalidade indicam que os pesos atravessam fases qualitativamente distintas durante o treinamento, com implicações diretas sobre a capacidade preditiva do modelo (ADVANI et al., 2020), e métodos dedicados à detecção de *overfitting* em aplicações clínicas têm sido propostos como resposta prática a esse problema (ZHANG; BELL, 2025).

A presente dissertação parte da premissa de que medidas de complexidade aplicadas diretamente aos pesos da rede oferecem uma leitura quantitativa do treinamento que as métricas de desempenho não oferecem. Duas famílias de medidas dão sustentação a essa abordagem. A primeira é a Entropia de Amostra (*Sample Entropy*, SampEn) introduzida por Richman e Moorman (2000) como refinamento da Entropia Aproximada de Pincus (1991); SampEn quantifica, sem viés sistemático associado a contagens de auto-coincidência, a regularidade de uma sequência de valores e tem aplicação consolidada na análise de sinais fisiológicos. A análise multiescala (Multiscale Entropy, MSE) proposta por Costa et al. (2002) complementa SampEn ao revelar regularidades que se manifestam em diferentes resoluções da mesma sequência.

A segunda família é a complexidade estatística de López-Ruiz, Mancini e Calbet (LÓPEZ-RUIZ et al., 1995), definida pelo produto entre uma medida de incerteza, tipicamente a entropia de Shannon, e uma medida de desequilíbrio em relação à distribuição uniforme. Diferentemente de medidas puramente entrópicas, a complexidade LMC anula-se nos extremos de ordem perfeita e desordem perfeita, atingindo valores máximos em regimes intermediários de auto-organização (ANTENEODO; PLASTINO, 1996). Aplicada à distribuição dos pesos de uma rede neural, espera-se que ela descreva quantitativamente a transição entre o estado inicial aleatório e o estado treinado. A combinação entre Sam-

pEn (sensível à estrutura sequencial dos pesos) e LMC (sensível à forma da distribuição marginal) constitui o eixo metodológico desta investigação.

1.3.1 Justificativa prática: o ponto de vista de quem treina a rede

A justificativa apresentada até aqui é de natureza metodológica: as medidas de complexidade oferecem uma leitura dos pesos que as métricas de desempenho não oferecem. Há, porém, uma segunda justificativa, de natureza prática, que motiva este trabalho de modo mais imediato e é formulada deliberadamente do ponto de vista de quem desenvolve e treina a rede.

A dependência atual dos dados rotulados

Para saber se uma rede aprendeu ou apenas memorizou, o desenvolvedor depende hoje, integralmente, dos dados. É preciso construir conjuntos de treino, validação e teste bem particionados, corretamente rotulados e representativos da população de interesse. Cada um desses requisitos custa tempo e recursos, e em imagens médicas frequentemente esbarra na indisponibilidade de especialistas para a anotação. O diagnóstico do treinamento é, portanto, função do orçamento de anotação disponível — e não uma propriedade que se possa ler diretamente do modelo.

O procedimento padrão para decidir quando interromper o ajuste, a parada antecipada, monitora o erro em um conjunto de validação separado (PRECHELT, 1998). O procedimento é sólido, mas transfere ao conjunto de validação toda a responsabilidade pelo diagnóstico: se ele é pequeno, desbalanceado ou pouco representativo, a estimativa do momento de parada torna-se ruidosa, e o desenvolvedor não dispõe de sinal alternativo com que confrontá-la. Em outras palavras, justamente no regime de poucos dados — aquele em que o sobreajuste é mais provável — o instrumento de medida é o menos confiável.

O que muda com uma leitura calculada sobre os pesos

As medidas investigadas nesta dissertação são calculadas exclusivamente a partir dos pesos. Não consomem imagem, não consomem rótulo e não dependem de nenhuma partição. Descrever como elas se comportam em regimes de treinamento distintos é o passo que precede qualquer uso prático: só depois de saber o que cada medida registra — e o que ela não registra — é possível dizer se ela oferece ao desenvolvedor uma segunda leitura do treinamento, obtida por caminho independente daquele do conjunto de validação.

Delimite-se, por isso, o alcance deste trabalho: ele é *descritivo*. Não se propõe um detector de sobreajuste, nem limiares ou regras de parada; relata-se o comportamento das medidas em cada regime. Como subproduto, entrega-se um monitor implementado em PyTorch, acoplável ao laço de treinamento de terceiros, que calcula as medidas a cada

época (Seção 3.7), com custo computacional baixo por incidir apenas sobre a camada densa.

1.4 HIPÓTESE, OBJETIVOS E ESCOPO

A hipótese deste trabalho é que a complexidade estatística dos pesos da camada densa de uma rede neural profunda evolui de modo sistemático durante o treinamento, e que a trajetória das medidas LMC e SampEn difere entre regimes de treinamento distintos — treinamento com o conjunto completo, com subamostragem do conjunto de treino e com ruído somado às imagens de treino.

A pesquisa adota um **escopo deliberadamente restrito** a fim de permitir o controle das variáveis de interesse e a reprodutibilidade plena dos experimentos:

- **Arquitetura:** ResNet-18 (HE et al., 2016), escolhida por sua importância histórica, profundidade moderada e papel de *baseline* consagrado em classificação de imagens médicas; execuções de controle são repetidas com a DenseNet-121 para descrever o comportamento em uma segunda arquitetura.
- **Conjunto de dados:** MedNIST, com seis classes de imagens médicas de diferentes modalidades (Seção 3.1).
- **Pesos analisados:** apenas os da camada densa (classificadora), calculando-se as medidas sobre a camada inteira.
- **Tarefa única:** classificação multiclasse, excluindo-se explicitamente segmentação semântica, detecção e tarefas ordinais.

Arquiteturas alternativas como U-Net, conjuntos de dados de maior escala como NIH ChestX-ray14 e TCIA, e tarefas adicionais como segmentação — mencionados no projeto de qualificação — ficam relegados a trabalhos futuros (Capítulo 5).

Os objetivos específicos são:

1. Implementar a SampEn e a complexidade LMC com validação numérica em casos analiticamente conhecidos (distribuições uniforme, gaussiana e séries periódicas), conforme o Apêndice B.
2. Extrair os pesos da camada densa a cada época, durante o treinamento, excluindo o vetor de viés da análise.
3. Calcular a trajetória das medidas de complexidade em execuções de controle, com subamostragem do treino e com ruído nas imagens de treino, e confrontá-la com a evolução da perda e da acurácia de validação.

4. Descrever como a LMC e a SampEn se comportam em cada regime e comparar esses comportamentos entre regimes.

1.5 ORGANIZAÇÃO DO TRABALHO

O restante desta dissertação está organizado em quatro capítulos. O Capítulo 2 apresenta a fundamentação teórica das medidas de complexidade utilizadas (Entropia de Shannon, ApEn, SampEn, complexidade LMC) e situa-as no contexto da literatura de redes neurais profundas e análise de séries de pesos. O Capítulo 3 descreve o conjunto de dados, as arquiteturas, o protocolo de treinamento, os regimes de treinamento comparados, a camada densa como objeto de medida e os parâmetros adotados para cada medida (m, r, número de *bins*). O Capítulo 4 apresenta as trajetórias de complexidade da camada densa em cada regime e sua relação com a perda e a acurácia de validação. O Capítulo 5 sintetiza as evidências obtidas em relação à hipótese, discute as limitações do recorte adotado e indica direções para extensões futuras envolvendo arquiteturas, modalidades de imagem e tarefas adicionais.

2 FUNDAMENTAÇÃO TEÓRICA

Este capítulo apresenta o aparato conceitual e operacional sobre o qual se constrói a metodologia da dissertação. A seção 2.2 retoma a entropia de Shannon e seus desdobramentos em entropia diferencial e divergências, dando base formal às medidas que vêm a seguir. A seção 2.3 percorre a transição da Entropia Aproximada (ApEn) para a Entropia de Amostra (SampEn), explicitando os vieses que motivaram o refinamento e a interpretação probabilística de SampEn como log-verossimilhança condicional. A seção 2.4 estende SampEn ao plano multiescala. Por fim, a seção 2.5 apresenta a complexidade estatística de López-Ruiz, Mancini e Calbet (LMC), discute a controvérsia sobre normalização e intensividade que se seguiu à proposta original e justifica a convenção $C = H \times D$ adotada no restante do trabalho.

2.1 SISTEMAS COMPLEXOS, AUTO-ORGANIZAÇÃO E EMERGÊNCIA

Esta seção fixa o vocabulário conceitual sobre o qual as medidas das seções seguintes se apoiam. A justificativa para sua presença é direta: o restante desta dissertação afirma que os pesos de uma rede em treinamento apresentam regimes de *auto-organização*, e essa afirmação não tem conteúdo verificável enquanto o termo não for definido.

2.1.1 A noção de sistema complexo

Um sistema complexo pode ser informalmente caracterizado como uma rede de muitos componentes que interagem entre si e cujo comportamento coletivo surge e evolui por auto-organização (SAYAMA, 2015). A caracterização carrega duas exigências que não são triviais. A primeira é a *multiplicidade* de componentes interagentes. A segunda, mais restritiva, é que a informação relevante do sistema resida nas *relações* entre as partes, e não nas partes isoladamente; se o comportamento do todo for recuperável pela simples soma dos comportamentos individuais, o sistema é agregado, não complexo.

Uma rede neural profunda em treinamento satisfaz ambas as exigências. Os milhões de pesos constituem componentes que interagem indiretamente, pela retropropagação do gradiente, e nenhum peso isolado codifica a função aprendida — o conteúdo do modelo está na configuração conjunta. Essa observação não é retórica: é ela que autoriza aplicar ao treinamento o instrumental desenvolvido para sistemas complexos, em lugar de tratar a rede apenas como um problema de otimização de alta dimensão.

2.1.2 Emergência

Denomina-se *emergente* a propriedade que se manifesta no nível macroscópico do sistema e que não é redutível às propriedades dos componentes isolados (SAYAMA, 2015). O conceito exige, portanto, a distinção explícita de dois níveis de descrição: o microscópico, dos componentes, e o macroscópico, do comportamento observável.

Na presente dissertação essa distinção é operacional, e não apenas conceitual. O nível microscópico é o dos valores individuais dos pesos; o macroscópico é o da capacidade de generalização do modelo, aferida em dados não vistos. A hipótese central pode então ser reformulada nesses termos: pretende-se descrever como uma estatística calculada sobre o nível microscópico — a distribuição e a organização dos pesos — se comporta diante das mudanças de regime observadas no nível macroscópico.

2.1.3 Auto-organização

Chama-se *auto-organização* ao processo pelo qual um sistema desenvolve estrutura macroscópica sem que essa estrutura seja imposta por um controle externo ou por um plano centralizado (SAYAMA, 2015). Emergência e auto-organização são conceitos distintos, ainda que frequentemente tratados como sinônimos: a primeira descreve uma relação entre níveis de descrição em um instante, e a segunda descreve a evolução temporal do sistema.

O treinamento por descida de gradiente é, nessa acepção, um processo de auto-organização. Nenhum agente externo especifica o valor que cada peso deve assumir; os valores resultam da aplicação iterada de uma regra local de atualização, e a estrutura que se observa ao final — filtros que respondem a padrões visuais, camadas que se especializam — não foi projetada peso a peso.

Interessa particularmente a este trabalho a observação de que sistemas em auto-organização não evoluem de modo homogêneo: eles frequentemente apresentam *transições de regime*, nas quais o comportamento qualitativo muda em intervalos relativamente curtos (SAYAMA, 2015). É exatamente essa a estrutura que a hipótese desta dissertação pressupõe. Se o treinamento consistisse em um processo homogêneo de melhoria gradual, as trajetórias das medidas teriam pouco a registrar. A existência de dois regimes sucessivos no aprendizado — um em que a rede extrai regularidades generalizáveis e outro em que passa a memorizar exemplos — é documentada empiricamente por Arpit et al. (2017) e constitui o pressuposto factual da proposta.

2.1.4 Delimitação: o que não se pretende afirmar

Convém delimitar o alcance do enquadramento para evitar leitura excessiva. O aparato de sistemas complexos é empregado aqui em sentido *descritivo*, e não como apelo a um mecanismo explicativo. Não se afirma que o treinamento de uma rede neural seja

formalmente equivalente a algum dos modelos canônicos da área — autômatos celulares, sistemas de reação-difusão ou redes dinâmicas (SAYAMA, 2015) —, nem se pretende derivar as medidas empregadas a partir de primeiros princípios da teoria de sistemas complexos.

O que o enquadramento fornece é mais modesto e suficiente: a legitimidade de tratar a configuração dos pesos como estado de um sistema cuja organização macroscópica varia no tempo, e cujas transições podem, em princípio, ser detectadas por estatísticas calculadas sobre esse estado. As medidas específicas utilizadas provêm da teoria da informação e da análise de séries, apresentadas nas seções seguintes, e sua validade é estabelecida empiricamente no Capítulo 4, não por filiação teórica.

2.2 ENTROPIA DE SHANNON E TEORIA DA INFORMAÇÃO

A entropia de Shannon (SHANNON, 1948) é a pedra angular sobre a qual se assenta toda a discussão subsequente. Para uma variável aleatória discreta X que assume valores no alfabeto finito $\mathcal{X} = \{x_1, x_2, \ldots, x_N\}$ com distribuição de probabilidade $P = (p_1, p_2, \ldots, p_N)$, a entropia é definida por

$$H(X) = -\sum_{i=1}^{N} p_i \log_2 p_i, \tag{2.1}$$

adotando-se, por convenção, $0 \log_2 0 = 0$. A escolha do logaritmo na base 2 implica que H é medida em bits, interpretação diretamente associada ao número médio mínimo de dígitos binários necessário para codificar uma realização de X. A entropia satisfaz $0 \leq H(X) \leq \log_2 N$, com extremos alcançados, respectivamente, pela distribuição degenerada (existe i tal que $p_i = 1$) e pela distribuição uniforme ($p_i = 1/N$ para todo i). Caracterizações axiomáticas mostram que essas propriedades, junto da continuidade e da aditividade, determinam H a menos de um fator multiplicativo (COVER; THOMAS, 2006).

Quando X é uma variável contínua com função de densidade de probabilidade f, a generalização natural — a entropia diferencial — é dada por

$$h(X) = -\int_{\mathcal{X}} f(x) \log_2 f(x)\, dx, \tag{2.2}$$

sempre que a integral exista. Diferentemente da versão discreta, $h(X)$ pode assumir valores negativos e não é invariante sob mudança de escala, o que limita seu uso direto como índice de "incerteza". Em aplicações práticas com pesos de redes neurais, trabalha-se com a versão discretizada por meio de histogramas com N bins, recuperando a forma da Equação 2.1 a um custo controlado de viés e variância (COVER; THOMAS, 2006).

Uma medida de dissimilaridade entre duas distribuições P e Q sobre o mesmo alfabeto é a divergência de Kullback–Leibler

$$D_{\mathrm{KL}}(P \| Q) = \sum_{i=1}^{N} p_i \log_2 \frac{p_i}{q_i}, \tag{2.3}$$

que é não negativa e nula se, e somente se, $P = Q$. A Equação 2.3 é central nesta dissertação porque a noção de "desequilíbrio" subjacente à complexidade LMC pode ser interpretada como uma medida de afastamento entre P e a distribuição de referência (uniforme), tema retomado na seção 2.5.

2.3 ENTROPIA APROXIMADA E ENTROPIA DE AMOSTRA

O salto da teoria da informação para a análise de séries temporais finitas exige um estimador de regularidade que opere com poucos pontos e seja robusto a ruído moderado. A Entropia Aproximada (ApEn), introduzida por Pincus (1991), foi a primeira proposta a preencher esse papel para sinais fisiológicos. Dada uma série $\mathbf{u} = (u_1, u_2, \ldots, u_N)$, fixa-se um comprimento de embedding m e uma tolerância r e constroem-se os vetores $\mathbf{x}_i = (u_i, u_{i+1}, \ldots, u_{i+m-1})$ com $1 \leq i \leq N - m + 1$. Para cada i define-se

$$C_i^m(r) = \frac{\#\{j : d[\mathbf{x}_i, \mathbf{x}_j] \leq r\}}{N - m + 1}, \tag{2.4}$$

onde $d[\cdot, \cdot]$ é a distância de Chebyshev (máximo das diferenças absolutas componente a componente) e a contagem inclui o caso $j = i$ (*self-match*). A ApEn é então

$$\mathrm{ApEn}(m, r, N) = \Phi^m(r) - \Phi^{m+1}(r), \quad \Phi^m(r) = \frac{1}{N - m + 1} \sum_{i=1}^{N-m+1} \ln C_i^m(r). \tag{2.5}$$

A inclusão de *self-matches* em $C_i^m(r)$ é simultaneamente o recurso que viabiliza a definição (evita logaritmo de zero) e a fonte de seus dois principais defeitos: (i) ApEn é sistematicamente enviesada para valores menores em séries curtas, e (ii) sua consistência relativa — a propriedade de que, ao se comparar duas séries em um mesmo r, a ordem dos valores se preserva quando r varia — não é garantida (RICHMAN; MOORMAN, 2000; DELGADO-BONAL; MARSHAK, 2019). A literatura subsequente documenta cenários em que classificações fisiológicas baseadas em ApEn se invertem ao se mudar a tolerância, comprometendo seu uso como marcador objetivo (YENTES et al., 2013; DELGADO-BONAL; MARSHAK, 2019).

A Entropia de Amostra (SampEn), proposta por Richman e Moorman (2000), remove essas limitações por construção. Em vez de calcular o logaritmo médio de probabilidades locais, conta-se globalmente o número de pares de templates próximos. Sejam

$$B^m(r) = \#\{(i, j) : i < j,\ d[\mathbf{x}_i, \mathbf{x}_j] \leq r\}, \tag{2.6}$$

$$A^m(r) = \#\{(i, j) : i < j,\ d[\mathbf{x}_i, \mathbf{x}_j] \leq r,\ |u_{i+m} - u_{j+m}| \leq r\}, \tag{2.7}$$

isto é, $B^m(r)$ conta pares de janelas de comprimento m próximas e $A^m(r)$ conta os pares dessas janelas que permanecem próximas após um passo adicional. A SampEn é dada por

$$\mathrm{SampEn}(m, r, N) = -\ln \frac{A^m(r)}{B^m(r)}. \tag{2.8}$$

Pela construção, ambas as contagens excluem o par (i, i), eliminando o viés associado às auto-coincidências. A interpretação de Equação 2.8 é direta e instrutiva: SampEn é o negativo do logaritmo da probabilidade condicional de que duas janelas próximas em comprimento m permaneçam próximas em comprimento $m+1$. Valores baixos correspondem a séries muito regulares (a continuação é altamente previsível); valores altos, a séries irregulares (continuação imprevisível).

A Equação 2.8 herda independência tanto de N quanto da ordem dos pares por ser uma estatística baseada em razão de contagens globais. Demonstrou-se ainda que, em uma ampla família de processos estocásticos, SampEn possui consistência relativa entre tolerâncias, propriedade que ApEn não satisfaz (RICHMAN; MOORMAN, 2000). Por outro lado, a literatura recente registra cenários particulares de processos do tipo MIX contaminados por ruído em que mesmo SampEn pode falhar essa consistência, recomendando cautela ao se interpretar diferenças finas entre séries de naturezas distintas (DELGADO-BONAL; MARSHAK, 2019).

A escolha dos parâmetros m e r é prática consagrada na literatura. Pela análise sistemática de Yentes et al. (2013) sobre séries curtas, recomenda-se $m = 2$ e r entre 0,1 e 0,25 do desvio padrão da série, com $N \geq 200$ para evitar instabilidade estatística. Esta dissertação adota $m = 2$ e $r = 0{,}2 \times \sigma$, com σ tomado como desvio padrão populacional (`ddof`=0), em consonância com a convenção do grupo de pesquisa e com o intervalo recomendado pela literatura.

2.4 ENTROPIA MULTIESCALA (MSE)

A SampEn captura irregularidade em uma escala fixa. No entanto, sistemas com correlações de longo alcance — batimentos cardíacos saudáveis, ruído $1/f$, dinâmica de redes complexas — apresentam estrutura em múltiplas escalas temporais simultaneamente. A Entropia Multiescala (MSE), proposta por Costa et al. (2002) e sistematizada em Costa et al. (2005), lê esse fenômeno por meio de uma sequência de granulações grosseiras (*coarse-grainings*) da série original.

Dada uma série $\mathbf{u}$ e um fator de escala $\tau \in \mathbb{N}^*$, constrói-se a série granulosa

$$y_j^{(\tau)} = \frac{1}{\tau} \sum_{i=(j-1)\tau+1}^{j\tau} u_i, \quad 1 \leq j \leq \lfloor N/\tau \rfloor, \tag{2.9}$$

isto é, médias de blocos não sobrepostos de comprimento τ. A escala $\tau = 1$ recupera a série original. Para cada τ, calcula-se SampEn da série granulosa, formando o perfil multiescala $\{\mathrm{SampEn}(m, r, y^{(\tau)}) : \tau = 1, 2, \ldots, \tau_{\max}\}$.

Um detalhe metodológico crítico: a tolerância r é fixada uma única vez a partir do desvio padrão da série *original* e mantida constante em todas as escalas, conforme prescrição

de Costa et al. (2005). Recomputar r em cada escala invalidaria a comparação entre escalas, pois mudanças no perfil de complexidade ficariam confundidas com a renormalização local. A interpretação qualitativa da curva SampEn versus τ separa três classes principais: ruído branco (entropia decresce monotonicamente), ruído $1/f$ (entropia constante ao longo das escalas) e periódicos (entropia próxima de zero em todas as escalas). Sistemas fisiológicos saudáveis apresentam padrão similar ao $1/f$, enquanto patologias frequentemente colapsam para perfis monotonicamente decrescentes (COSTA et al., 2005).

2.5 COMPLEXIDADE ESTATÍSTICA LMC

A entropia, isoladamente, não é uma boa medida de complexidade. Distribuições uniformes (entropia máxima) são tão simples quanto distribuições degeneradas (entropia mínima), no sentido de que ambas são facilmente descritíveis e desprovidas de estrutura interna. López-Ruiz et al. (1995) — doravante LMC — propuseram, como remédio, uma medida que se anula em ambos os extremos e atinge valores máximos em regimes intermediários de auto-organização. Para uma distribuição $P = (p_1, \ldots, p_N)$, define-se o *desequilíbrio*

$$D(P) = \sum_{i=1}^{N} \left(p_i - \frac{1}{N} \right)^2 , \tag{2.10}$$

isto é, o quadrado da distância L_2 até a distribuição uniforme. A complexidade estatística LMC é o produto

$$C(P) = H(P) \times D(P), \tag{2.11}$$

em que H é a entropia de Shannon, dada pela Equação 2.1. Como H é máxima e D é nula sob a distribuição uniforme, e H é nula e D é máxima sob a distribuição degenerada, C se anula em ambos os extremos por construção. Para distribuições intermediárias, C assume valores estritamente positivos, refletindo simultaneamente incerteza e afastamento do equilíbrio (LÓPEZ-RUIZ et al., 1995).

A definição original gerou debate intenso. Anteneodo e Plastino (1996) demonstraram, no contexto de ensembles físicos, que C na forma Equação 2.11 *não* é uma quantidade intensiva: ao se duplicar o tamanho do sistema, C não satisfaz a relação de escala esperada de uma medida termodinâmica genuína. Esse fato limita a transferibilidade direta de C entre sistemas de tamanhos distintos e motivou a busca por refinamentos. Feldman e Crutchfield (1998), em uma revisão crítica das medidas de complexidade estatística disponíveis na época, articularam três desideratos: a medida deve (i) anular-se nos extremos de ordem e desordem perfeitas, (ii) ser intensiva, e (iii) capturar a presença de estrutura correlacional em escalas relevantes do sistema.

A resposta mais influente a essas críticas é a complexidade estatística generalizada (SCM, *Statistical Complexity Measure*), introduzida por Lamberti et al. (2004) e

desenvolvida por Rosso et al. (2010). Em vez do produto $H \times D$, define-se

$$C_{\mathrm{SCM}}(P) = Q_J(P, P_e) \cdot H(P)/H_{\max}, \tag{2.12}$$

em que $H_{\max} = \log_2 N$ normaliza a entropia, P_e é a distribuição de equilíbrio (tipicamente uniforme), e $Q_J(P, P_e)$ é o desequilíbrio em divergência de Jensen-Shannon, normalizado de modo que $0 \leq Q_J \leq 1$. A construção Equação 2.12 é intensiva, limitada ao intervalo $[0, 1]$ e aplicável a uma variedade de sistemas dinâmicos contínuos e discretos.

Apesar das vantagens formais da SCM, esta dissertação adota a forma original Equação 2.11 — $C = H \times D$ em bits, sem normalização — por três razões metodológicas que merecem explicitação:

1. **Comparação intra-modelo, não inter-sistema.** O objeto de análise são as trajetórias de complexidade dos pesos de *uma mesma rede* na *mesma camada* ao longo do treinamento. As comparações são pareadas por *checkpoint*, *seed* e dataset; o argumento de intensividade de Anteneodo e Plastino (1996), que diz respeito à escalonamento entre sistemas de tamanhos distintos, não é ativado nesse desenho experimental.

2. **Sensibilidade a transições intermediárias.** A forma $H \times D$ é sensível justamente ao regime que interessa à hipótese central — a transição entre o estado inicial aleatório e o estado treinado. Versões normalizadas saturam nas extremidades do intervalo $[0, 1]$, comprimindo as diferenças que se busca medir. A versão não normalizada preserva a granularidade necessária para detectar inflexões sutis na trajetória.

3. **Convenção do grupo de pesquisa.** Trabalhos anteriores do mesmo grupo (SILVA et al., 2016; SILVA; JUNIOR, 2012) adotam a convenção $H \times D$ em bits, sem normalização, com binarização adaptativa da forma $N = \min(100, \max(10, n/5))$, onde n é o número de amostras. Manter essa convenção preserva a comparabilidade direta entre os resultados desta dissertação e os da literatura imediata.

A normalização adaptativa do número de bins N é especialmente relevante para a aplicação a pesos de redes neurais, onde o número de parâmetros varia ordens de grandeza entre camadas: tipicamente poucas centenas em camadas iniciais e dezenas de milhares em camadas profundas. A regra $N = \min(100, \max(10, n/5))$ garante resolução suficiente para camadas pequenas sem incorrer em viés de subamostragem em camadas grandes.

A combinação entre LMC (sensível à forma da distribuição marginal dos pesos) e SampEn (sensível à estrutura sequencial) fornece, portanto, dois ângulos complementares sobre o estado interno da rede ao longo do treinamento. Os parâmetros operacionais adotados, junto da fundamentação aqui apresentada, são retomados em detalhe no Capítulo 3.

2.6 ESTADO DA ARTE: LEITURA DO ESTADO INTERNO DE REDES PROFUNDAS

Esta seção discute os trabalhos que se aproximam do problema desta dissertação. O critério de seleção adotado foi a existência de alguma tentativa de caracterizar o estado de generalização de uma rede a partir de seu *interior* — pesos, representações ou dinâmica de treinamento — em lugar de aferi-lo exclusivamente pelo desempenho em dados rotulados. A Seção 2.6.1 revisa o que se sabe sobre memorização. A Seção 2.6.2 discute a família de limites baseados em normas e margens. A Seção 2.6.3 trata das abordagens espectrais. A Seção 2.6.4 apresenta a família informação-teórica e a controvérsia que a acompanha. A Seção 2.6.5 sintetiza e posiciona a proposta.

2.6.1 Memorização e os dois regimes do aprendizado

Zhang et al. (2017) demonstraram que redes convolucionais de grande porte ajustam perfeitamente rótulos atribuídos ao acaso, e que esse comportamento persiste sob regularização explícita. O resultado é relevante para esta dissertação por estabelecer que a capacidade de memorização não é acidente, mas propriedade das arquiteturas usuais. A limitação, do ponto de vista aqui assumido, é que o diagnóstico permanece ancorado na comparação entre desempenho de treino e de teste.

Arpit et al. (2017) refinam o quadro ao mostrar que memorização e aprendizado de padrões não são simultâneos: redes tendem a aprender primeiro as regularidades simples e só depois memorizar os exemplos ruidosos. A existência de dois regimes sucessivos, e não de um processo homogêneo, é o pressuposto que torna plausível a hipótese desta dissertação — se há transição, as medidas calculadas sobre os pesos podem registrá-la. Os autores, contudo, caracterizam os regimes por métricas que dependem dos dados, não da estrutura dos pesos.

Power et al. (2022) descrevem o fenômeno de *grokking*, em que a generalização emerge muito depois do ajuste completo do treino, às vezes após longo período de estagnação da validação. O fenômeno constitui contraexemplo aos critérios ingênuos de parada antecipada: uma interrupção baseada apenas na estagnação eliminaria justamente o regime em que a generalização acabaria por surgir. Um indicador que leia o estado interno, e não apenas o desempenho externo, é potencialmente capaz de distinguir estagnação de reorganização — questão registrada aqui como hipótese derivada, não testada neste trabalho.

2.6.2 Limites de generalização por normas e margens

Bartlett et al. (2017) propõem limites de generalização baseados em normas espectrais e margens, estabelecendo que propriedades geométricas dos pesos se relacionam com a capacidade de generalizar. Dziugaite e Roy (2017) obtêm, por via PAC-Bayesiana, limites não vacuosos para redes sobreparametrizadas — resultado notável, dado que limites clássicos tornam-se vazios nesse regime. Ambos representam avanços substantivos, mas produzem limites válidos para *um* estado da rede, tipicamente o final do treinamento, e não uma leitura acompanhável ao longo das épocas.

Jiang et al. (2020) conduzem o estudo empírico mais sistemático dessa família, avaliando um grande conjunto de medidas candidatas quanto à sua relação causal com a lacuna de generalização. A conclusão é cautelar e impõe exigência metodológica a qualquer trabalho subsequente: muitas medidas teoricamente motivadas correlacionam-se mal com a generalização observada, e medidas baseadas em otimização desempenham-se melhor do que as baseadas em norma. A consequência adotada nesta dissertação é que não basta exibir o comportamento de uma medida em uma execução; é preciso compará-lo entre regimes, com várias sementes por regime e teste de significância.

2.6.3 Abordagens espectrais

Martin et al. (2021) mostram que propriedades de cauda pesada do espectro das matrizes de pesos permitem prever tendências de qualidade de modelos sem acesso aos dados de treino ou de teste. Este é o trabalho mais próximo do objetivo aqui perseguido, e convém explicitar as diferenças. A abordagem é *espectral*, apoiando-se nos autovalores das matrizes, ao passo que a desta dissertação é *informação-teórica*, apoiando-se na distribuição de valores e na organização espacial dos pesos. Além disso, o alvo em Martin et al. (2021) é comparar modelos já treinados, enquanto aqui o alvo é acompanhar a trajetória temporal de um único treinamento.

2.6.4 Abordagens informação-teóricas e a controvérsia do gargalo de informação

A família mais próxima em espírito a esta dissertação é a que aplica teoria da informação ao interior de redes profundas. Tishby e Zaslavsky (2015) propõem analisar redes no *plano de informação*, quantificando cada camada pela informação mútua que preserva a respeito da entrada e da saída, e interpretam o treinamento como otimização de um compromisso entre compressão e predição. Shwartz-Ziv e Tishby (2017) desenvolvem empiricamente essa leitura e relatam que a maior parte das épocas de treinamento é consumida não no ajuste dos rótulos, mas na *compressão* da representação, identificando duas fases distintas na otimização — uma de deriva rápida e outra de relaxação estocástica.

A pertinência para o presente trabalho é evidente: trata-se de literatura que afirma existirem transições de regime detectáveis por quantidades informação-teóricas calculadas sobre o interior da rede, o que é precisamente a estrutura da hipótese aqui investigada.

É imprescindível, porém, registrar que essas conclusões foram contestadas. Saxe et al. (2019) examinam os três principais postulados da teoria e concluem que nenhum deles se sustenta no caso geral: a existência de duas fases distintas, a relação causal entre compressão e boa generalização, e a atribuição da compressão ao comportamento difusivo do gradiente estocástico. Demonstram, em particular, que a trajetória observada no plano de informação depende predominantemente da não linearidade empregada — funções de saturação bilateral produzem fase de compressão, enquanto ativações lineares ou de saturação unilateral não a produzem — e que parte do efeito reflete decisões de estimação da informação mútua em redes determinísticas.

Essa controvérsia recomenda cautela e delimita o escopo do presente trabalho de modo produtivo. As medidas aqui empregadas *não* são estimativas de informação mútua entre camadas e dados, e portanto não herdam as dificuldades de estimação que Saxe e colaboradores identificam: LMC e SampEn são estatísticas calculadas sobre os *valores dos pesos*, sem referência a qualquer distribuição conjunta com os dados. A escolha evita o problema metodológico central da controvérsia, ao custo de abdicar da interpretação formal em termos de compressão de informação.

2.6.5 Síntese e posicionamento da proposta

Tabela 1 – Comparação dos trabalhos discutidos quanto à dependência de dados rotulados, à natureza temporal da leitura e ao objeto medido.

Trabalho	**Objeto da medida**	**Exige rótulo**	**Leitura temporal**
Prechelt (1998)	Erro de validação	Sim	Sim
Zhang et al. (2017)	Desempenho	Sim	Não
Arpit et al. (2017)	Desempenho	Sim	Sim
Bartlett et al. (2017)	Norma espectral	Não	Não
Dziugaite e Roy (2017)	Limite PAC-Bayes	Sim	Não
Jiang et al. (2020)	Diversas	Sim	Não
Martin et al. (2021)	Espectro dos pesos	Não	Não
Tishby e Zaslavsky (2015)	Informação mútua	Sim	Não
Shwartz-Ziv e Tishby (2017)	Informação mútua	Sim	Sim
Esta dissertação	Complexidade dos pesos	Não	Sim

Fonte: Elaborado pelo autor.

A Tabela 1 organiza os trabalhos segundo três eixos. Quanto à dependência de rótulos, apenas Bartlett et al. (2017) e Martin et al. (2021) dispensam-nos, e ambos por via espectral. Quanto à natureza temporal, Arpit et al. (2017) e Shwartz-Ziv e Tishby (2017) acompanham a trajetória do treinamento, mas ambos requerem acesso aos

dados — o primeiro ao desempenho, o segundo à distribuição conjunta necessária para estimar informação mútua. A intersecção entre *dispensar rótulos* e *acompanhar a trajetória* permanece, até onde a revisão alcançou, não ocupada.

A proposta desta dissertação situa-se nessa intersecção e diferencia-se da literatura em quatro aspectos: (i) a medida é informação-teórica, mas incide sobre a distribuição de valores e a organização espacial dos pesos, não sobre o espectro das matrizes nem sobre informação mútua com os dados; (ii) a leitura é temporal, produzindo uma trajetória por época em lugar de um escalar ao final do treino; (iii) nenhum rótulo é consumido, o que a torna aplicável em cenários de anotação escassa; e (iv) o comportamento das medidas é comparado entre regimes de treinamento, com várias sementes por regime, em resposta à advertência de Jiang et al. (2020) quanto a correlações espúrias.

Registre-se, por fim, uma limitação da própria revisão. A literatura de medidas de generalização é extensa e cresce rapidamente; a seleção aqui apresentada privilegiou trabalhos fundacionais de alta citação e os mais diretamente relacionados ao problema, não constituindo revisão sistemática no sentido metodológico do termo.

3 METODOLOGIA

Este capítulo descreve o protocolo experimental adotado para investigar a evolução da complexidade estatística dos pesos da camada densa de redes neurais profundas durante o treinamento. A exposição segue do dado bruto às medidas: o conjunto de dados (Seção 3.1), as arquiteturas (Seção 3.2) e o protocolo de treinamento (Seção 3.3); os regimes de treinamento comparados (Seção 3.4); a camada densa como objeto de medida e a ordem de achatamento dos seus pesos (Seção 3.5); as medidas de complexidade (Seção 3.6); e o monitoramento durante o treinamento (Seção 3.7).

3.1 CONJUNTO DE DADOS

Utiliza-se o MedNIST, conjunto de imagens médicas em escala de cinza, 64×64 pixels, distribuídas em seis classes: tomografia abdominal (*AbdomenCT*), ressonância de mama (*BreastMRI*), tomografia de tórax (*ChestCT*), radiografia de tórax (*CXR*), radiografia de mão (*Hand*) e tomografia de crânio (*HeadCT*). Emprega-se a partição oficial do conjunto em treinamento, validação e teste, com 47.164, 5895 e 5895 imagens, respectivamente. A semente que define a partição é fixa em todas as execuções e distinta da semente de inicialização dos pesos, de modo que todas as execuções compartilham exatamente os mesmos conjuntos de validação e de teste. O conjunto de teste é avaliado uma única vez por execução, ao final do treinamento.

3.2 ARQUITETURAS

Adota-se a ResNet-18 (HE et al., 2016) (implementação `torchvision`, sem pré-treinamento), com a camada totalmente conectada final substituída para as seis classes do MedNIST. Esta arquitetura totaliza aproximadamente 11,2 milhões de parâmetros distribuídos em **41 tensores com parâmetros aprendíveis**: 20 camadas convolucionais (`Conv2d`), 20 camadas de *batch normalization* (`BatchNorm2d`) e 1 camada totalmente conectada (`Linear`), que é o objeto das medidas deste trabalho (Figura 1).

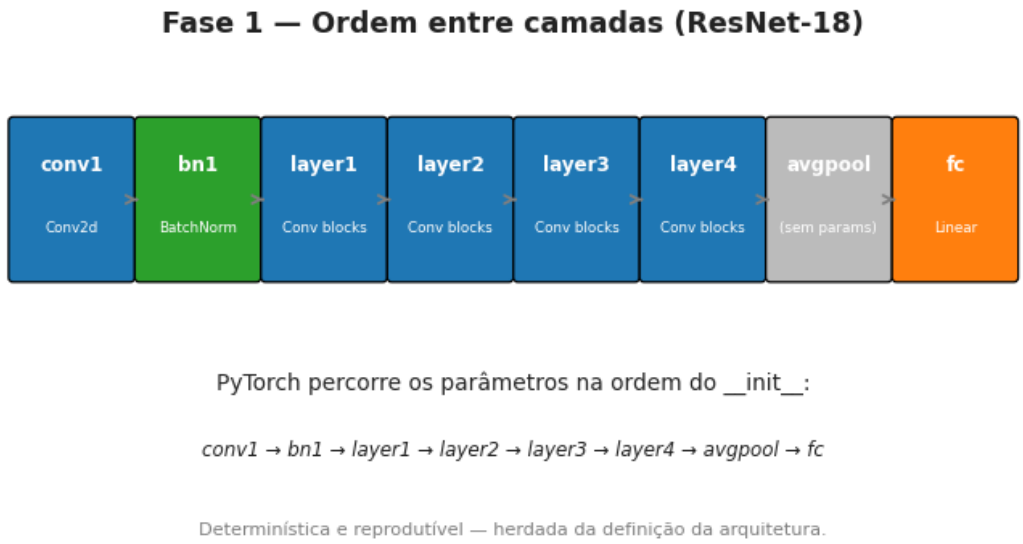


Figura 1 – Estrutura de nível superior da ResNet-18: oito módulos nomeados em sequência. As caixas indicam o tipo de camada (azul: Conv2d; verde: BatchNorm2d; cinza: sem parâmetros; laranja: Linear). As caixas `layer1`–`layer4` são contêineres `Sequential` de blocos residuais.

Para descrever o comportamento das medidas em uma segunda arquitetura, repetem-se as execuções de controle com a DenseNet-121 (implementação `torchvision`, sem pré-treinamento), com a camada classificadora igualmente substituída para seis classes.

3.3 PROTOCOLO DE TREINAMENTO

O treinamento emprega o otimizador AdamW com taxa de aprendizado 10^{-3} e *weight decay* nulo, entropia cruzada como função objetivo, lotes de 128 imagens e 60 épocas, sem aumento de dados, salvo quando o regime exige outro número de épocas (Seção 3.4.2). O *weight decay* e o aumento de dados são desligados deliberadamente: ambos são formas de regularização, e mantê-los atribuiria a diferença entre regimes a mais de uma causa. Todas as execuções compartilham essa configuração, de modo que cada regime difere do controle apenas pelo fator manipulado. Os experimentos foram executados em GPU (*torch* 2,4,1 e *torchvision* 0,19,1).

3.4 REGIMES DE TREINAMENTO

As trajetórias das medidas são comparadas entre três regimes, todos com a configuração da Seção 3.3. Em cada regime, a semente que governa a inicialização dos pesos varia entre as execuções, enquanto a partição permanece fixa. Validação e teste nunca são

alterados: o fator manipulado incide *apenas* sobre o treino, de modo que a validação mede o efeito desse fator sobre a generalização.

3.4.1 Controle

O controle usa o conjunto de treino completo (47.164 imagens), com rótulos e imagens intactos, por 60 épocas, o que corresponde a 22.140 passos de otimização (369 lotes por época). Na ResNet-18 há oito execuções de controle; na DenseNet-121, cinco.

3.4.2 Subamostragem do conjunto de treino

Treina-se com uma fração $f \in \{10\,\%;\ 2\,\%;\ 1\,\%\}$ do conjunto de treino, isto é, 4717, 944 e 471 imagens, com cinco sementes por fração. Reduzir o treino diminui simultaneamente a quantidade de informação e a diversidade dos exemplos, e torna o sobreajuste mais provável.

A subamostragem traz, porém, uma armadilha que precisa ser controlada. Experimentos preliminares mostraram que, com poucos passos de otimização, as estatísticas móveis das camadas de normalização em lote não convergem, e o modelo colapsa em modo de avaliação — inclusive sobre o próprio conjunto de treino. O quadro se parece com sobreajuste catastrófico, mas o mesmo modelo acerta cerca de 94,5 % da validação quando a normalização usa as estatísticas do lote corrente. Mede-se, nesse caso, um artefato de normalização, e não perda de generalização.

Por isso cada fração é treinada em duas versões. Na versão *curta*, o número de épocas é o usual para a fração (60 épocas a 10 % e 200 épocas a 2 % e 1 %, ou 2220, 1600 e 800 passos). Na versão de *passos igualados*, o número de épocas é ampliado até que o total de passos iguale o do controle (599, 2768 e 5535 épocas, cerca de 22.140 passos). A comparação entre as duas versões separa o efeito de ter poucos dados do efeito de ter poucos passos.

3.4.3 Ruído nas imagens de treino

Soma-se às imagens de treino um campo de ruído gerado no domínio da frequência. Sorteia-se ruído branco gaussiano do tamanho da imagem, aplica-se a transformada de Fourier bidimensional, multiplica-se o espectro pelo filtro radial $1/f^{\beta/2}$, com f a frequência espacial, e retorna-se ao domínio espacial. O espectro de potência resultante é proporcional a $1/f^{\beta}$: $\beta = 0$ produz ruído *branco*, de potência plana, e $\beta = 1$ produz ruído *rosa*, com mais potência nas baixas frequências. O componente de frequência nula é zerado, para que o ruído não desloque o brilho médio da imagem, e o campo é normalizado para desvio-padrão unitário. A imagem ruidosa é $\mathrm{clip}(x + \sigma z,\ 0,\ 1)$, com x a imagem em $[0, 1]$, z o campo de

ruído e $\sigma \in \{0{,}05;\ 0{,}1;\ 0{,}2\}$ a intensidade, na mesma escala do pixel. O mesmo campo é somado aos três canais, pois o MedNIST é escala de cinza replicada.

O ruído é *fixo por imagem*: cada imagem de treino recebe sempre o mesmo campo, em todas as épocas, de modo que a rede pode ajustá-lo. Os rótulos permanecem intactos. Há cinco sementes por combinação de cor e intensidade, totalizando 30 execuções.

3.5 A CAMADA DENSA COMO OBJETO DE MEDIDA

Seja a camada densa com M entradas $x_1, \ldots, x_M$ e N neurônios $n_1, \ldots, n_N$. A matriz de pesos é $W \in \mathbb{R}^{N \times M}$, e o elemento w_{ji} é o peso do *caminho* $x_i \to n_j$ — convenção que coincide com a forma nativa de `Linear.weight` no PyTorch, [out_features, in_features].

Como a SampEn_{1D} compara janelas consecutivas, a ordem de achatamento precisa ser fixada. Duas ordens são naturais. Na ordem *por neurônio*, percorrem-se todos os pesos que chegam a cada neurônio antes de passar ao seguinte:

$$v_n = (w_{11}, w_{12}, \ldots, w_{1M},\ w_{21}, \ldots, w_{2M},\ \ldots,\ w_{NM}), \tag{3.1}$$

o que corresponde ao achatamento nativo, sem transposição. Na ordem *por entrada*, percorrem-se todos os pesos que partem de cada entrada:

$$v_x = (w_{11}, w_{21}, \ldots, w_{N1},\ w_{12}, \ldots, w_{N2},\ \ldots), \tag{3.2}$$

equivalente a transpor W antes do achatamento. A Equação 3.1 mede a regularidade *dentro do campo receptivo de cada neurônio*; a Equação 3.2 mede a regularidade *da distribuição de uma mesma entrada entre os neurônios*. Adota-se a primeira como convenção padrão, por corresponder ao achatamento nativo do PyTorch. O Apêndice A ilustra as duas ordens com um exemplo numérico. Para a complexidade LMC a distinção é irrelevante, pois a medida depende apenas do histograma dos valores e é invariante a permutações.

O vetor de viés é excluído da análise: o viés é um deslocamento aditivo do neurônio, não a ligação entre uma entrada e um neurônio, e portanto não é um caminho no sentido aqui adotado.

Na ResNet-18 aplicada a seis classes, a camada densa (`fc`) possui $6 \times 512 = 3.072$ pesos; na DenseNet-121 (`classifier`), $6 \times 1.024 = 6.144$. São quantidades que permitem calcular as medidas sobre a camada inteira, sem subamostragem.

3.6 MEDIDAS DE COMPLEXIDADE

Sobre a camada densa de cada época são calculadas as medidas descritas a seguir. Os parâmetros seguem convenções da literatura citada.

3.6.1 Complexidade LMC

A complexidade estatística LMC (LÓPEZ-RUIZ et al., 1995) é definida como o produto da entropia de Shannon (SHANNON, 1948) pelo desequilíbrio em relação à distribuição uniforme:

$$C_{\mathrm{LMC}}(p) \;=\; H(p)\cdot D(p), \tag{3.3}$$

onde, para um histograma normalizado p com N *bins*,

$$H(p) = -\sum_{i=1}^{N} p_i \log_2 p_i, \qquad D(p) = \sum_{i=1}^{N} \left(p_i - \tfrac{1}{N}\right)^2. \tag{3.4}$$

Adota-se $N = 100$ *bins*. A entropia é computada em bits ($\log_2$) e o produto $H \cdot D$ é reportado sem normalização adicional. Como a medida não é normalizada, sua escala depende de N, e nenhuma comparação entre execuções é legítima sem que o número de intervalos seja idêntico.

3.6.2 Entropia amostral SampEn_{1D}

A entropia amostral (RICHMAN; MOORMAN, 2000; PINCUS, 1991) é definida como

$$\mathrm{SampEn}(U, m, r) \;=\; -\log \frac{A^{m+1}(r)}{B^{m}(r)}, \tag{3.5}$$

onde U é o vetor de pesos achatado, m é o comprimento das sub-sequências comparadas e r é a tolerância de similaridade. As quantidades A^{m+1} e B^{m} contam pares de sub-sequências cuja distância de Chebyshev é menor ou igual a r. Adotam-se os parâmetros $m = 2$ e $r = 0{,}2\,\sigma(U)$ (YENTES et al., 2013), validados pelo grupo de pesquisa em estudos prévios.

3.7 MONITORAMENTO DURANTE O TREINAMENTO

As medidas são calculadas **a cada época, dentro do laço de treinamento**, e não sobre *snapshots* analisados posteriormente. A escolha tem razão prática: nas execuções de passos igualados, com milhares de épocas, guardar os pesos de cada época seria inviável em disco, e o cálculo dentro do laço dispensa esse armazenamento.

São calculadas por época a complexidade LMC com $N_{bins} = 100$ e a SampEn_{1D} com $m = 2$ e $r = 0{,}20\,\sigma$.

O custo do monitoramento é baixo, pois incide apenas sobre a camada densa, e pode ser desativado por opção de linha de comando.

4 RESULTADOS

Este capítulo descreve o comportamento da complexidade LMC e da SampEn da camada densa das redes treinadas no MedNIST, segundo o protocolo descrito no Capítulo 3. Apresenta-se primeiro a trajetória das medidas nas execuções de controle; em seguida, como essa trajetória se altera sob subamostragem do conjunto de treino e sob ruído nas imagens de treino.

4.1 EXECUÇÕES DE CONTROLE

[**Pendente:** trajetórias de LMC e SampEn por época nas oito execuções de controle da ResNet-18 (média ± desvio entre sementes), com perda e acurácia de validação.]

4.2 SUBAMOSTRAGEM DO CONJUNTO DE TREINO

[**Pendente:** comparação com o controle das frações de 10 %, 2 % e 1 %, nas versões curta e de passos igualados; eixo em épocas e em passos de otimização.]

4.3 RUÍDO NAS IMAGENS DE TREINO

[**Pendente:** comparação com o controle do ruído branco e do ruído rosa, com $\sigma = 0{,}05$, 0,1 e 0,2, incluindo a figura de exemplo dos ruídos e de seus espectros.]

4.4 ACERTO POR CLASSE

[**Pendente:** acerto de cada classe na validação, por regime, na melhor época e na última época.]

4.5 SEGUNDA ARQUITETURA

[**Pendente:** trajetórias de LMC e SampEn nas cinco execuções de controle da DenseNet-121 — ou retirar a seção, caso a DenseNet não seja mantida.]

5 CONCLUSÃO

Este trabalho descreveu como a complexidade estatística dos pesos da camada densa de redes neurais profundas se comporta durante o treinamento, no contexto de classificação de imagens médicas com a arquitetura ResNet-18 e o conjunto MedNIST. A abordagem articulou duas medidas complementares — a complexidade LMC (LÓPEZ-RUIZ et al., 1995) e a entropia amostral SampEn (RICHMAN; MOORMAN, 2000) — calculadas a cada época sobre a camada densa, em execuções de controle, com subamostragem do conjunto de treino e com ruído branco e rosa nas imagens de treino.

5.1 PRINCIPAIS ACHADOS

[**Pendente:** síntese do comportamento da LMC e da SampEn em cada regime, a partir do Capítulo 4.]

5.2 TRABALHOS FUTUROS

A partir das limitações identificadas, perfilam-se os desdobramentos abaixo.

1. **Repositório de maior dificuldade.** Repetir os experimentos em um conjunto de dados menos saturável que o MedNIST, no qual a perda de generalização seja mais pronunciada, e comparar sobre a camada densa os mesmos regimes de treinamento.
2. **Ordem de achatamento.** A SampEn_{1D} depende da ordem em que a matriz da camada densa é achatada (Seção 3.5). Convém comparar a ordem por neurônio, adotada como padrão, com a ordem por entrada.
3. **Análise multiescala** (MSE) (COSTA et al., 2002; COSTA et al., 2005) dos pesos da camada densa, para investigar dependências em diferentes escalas.
4. **Comparação com outras arquiteturas** (EfficientNet, Wide ResNet) para verificar se o comportamento observado na ResNet-18 se mantém.
5. **Análise de sensibilidade à regularização explícita** (*weight decay*, *dropout*, *label smoothing*) para testar se a manipulação dirigida da propensão ao sobreajuste altera o comportamento das medidas na camada densa.
6. **Dados substitutos (*surrogate data*)** como teste de hipótese nula sobre a trajetória de complexidade, permitindo caracterizar o quanto da estrutura observada se afasta do comportamento esperado sob inicialização aleatória mais ruído.

7. **Uso prático.** Avaliar, a partir do comportamento descrito, se as medidas podem compor um critério auxiliar de parada em pipelines de treinamento, comparando custo computacional e desempenho com os critérios tradicionais baseados na perda de validação.

REFERÊNCIAS

ADVANI, M. S.; SAXE, A. M.; SOMPOLINSKY, H. High-dimensional dynamics of generalization error in neural networks. **Neural Networks**, v. 132, p. 428–446, 2020.

ANTENEODO, C.; PLASTINO, A. R. Some features of the lópez-ruiz-mancini-calbet (LMC) statistical measure of complexity. **Physics Letters A**, v. 223, n. 5, p. 348–354, 1996.

ARPIT, D. et al. A closer look at memorization in deep networks. In: **Proceedings of the 34th International Conference on Machine Learning (ICML)**. [S.l.: s.n.], 2017. p. 233–242.

BARTLETT, P. L.; FOSTER, D. J.; TELGARSKY, M. Spectrally-normalized margin bounds for neural networks. In: **Advances in Neural Information Processing Systems (NeurIPS)**. [S.l.: s.n.], 2017. v. 30.

COSTA, M.; GOLDBERGER, A. L.; PENG, C.-K. Multiscale entropy analysis of complex physiologic time series. **Physical Review Letters**, v. 89, n. 6, p. 068102, 2002.

_____. Multiscale entropy analysis of biological signals. **Physical Review E**, v. 71, n. 2, p. 021906, 2005.

COVER, T. M.; THOMAS, J. A. **Elements of Information Theory**. 2. ed. Hoboken, NJ: Wiley-Interscience, 2006.

DELGADO-BONAL, A.; MARSHAK, A. Approximate entropy and sample entropy: A comprehensive tutorial. **Entropy**, v. 21, n. 6, p. 541, 2019.

DZIUGAITE, G. K.; ROY, D. M. Computing nonvacuous generalization bounds for deep (stochastic) neural networks with many more parameters than training data. In: **Proceedings of the 33rd Conference on Uncertainty in Artificial Intelligence (UAI)**. [S.l.: s.n.], 2017.

FELDMAN, D. P.; CRUTCHFIELD, J. P. Measures of statistical complexity: Why? **Physics Letters A**, v. 238, n. 4–5, p. 244–252, 1998.

HE, K. et al. Deep residual learning for image recognition. p. 770–778, 2016.

JIANG, X. et al. Deep learning for medical image-based cancer diagnosis. **Cancers**, v. 15, n. 14, p. 3608, 2023.

JIANG, Y. et al. Fantastic generalization measures and where to find them. In: **International Conference on Learning Representations (ICLR)**. [S.l.: s.n.], 2020.

LAMBERTI, P. W. et al. Intensive entropic non-triviality measure. **Physica A: Statistical Mechanics and its Applications**, v. 334, n. 1–2, p. 119–131, 2004.

LÓPEZ-RUIZ, R.; MANCINI, H. L.; CALBET, X. A statistical measure of complexity. **Physics Letters A**, v. 209, n. 5–6, p. 321–326, 1995.

MARTIN, C. H.; PENG, T.; MAHONEY, M. W. Predicting trends in the quality of state-of-the-art neural networks without access to training or testing data. **Nature Communications**, v. 12, n. 1, p. 4122, 2021.

PINCUS, S. M. Approximate entropy as a measure of system complexity. **Proceedings of the National Academy of Sciences**, v. 88, n. 6, p. 2297–2301, 1991.

POWER, A. et al. **Grokking: generalization beyond overfitting on small algorithmic datasets**. 2022. ArXiv:2201.02177.

PRECHELT, L. Automatic early stopping using cross validation: quantifying the criteria. **Neural Networks**, v. 11, n. 4, p. 761–767, 1998.

RICHMAN, J. S.; MOORMAN, J. R. Physiological time-series analysis using approximate entropy and sample entropy. **American Journal of Physiology – Heart and Circulatory Physiology**, v. 278, n. 6, p. H2039–H2049, 2000.

ROSSO, O. A. et al. Generalized statistical complexity measure. **International Journal of Bifurcation and Chaos**, v. 20, n. 3, p. 775–785, 2010.

SAXE, A. M. et al. On the information bottleneck theory of deep learning. **Journal of Statistical Mechanics: Theory and Experiment**, v. 2019, n. 12, p. 124020, 2019.

SAYAMA, H. **Introduction to the Modeling and Analysis of Complex Systems**. Geneseo, NY: Open SUNY Textbooks, 2015. Licença Creative Commons BY-NC-SA 3.0. ISBN 978-1-942341-08-6.

SHANNON, C. E. A mathematical theory of communication. **Bell System Technical Journal**, v. 27, n. 3, p. 379–423, 1948.

SHWARTZ-ZIV, R.; TISHBY, N. **Opening the black box of deep neural networks via information**. 2017. ArXiv:1703.00810.

SILVA, L. E. V. et al. Two-dimensional sample entropy: assessing image texture through irregularity. **Biomedical Physics & Engineering Express**, v. 2, n. 4, p. 045002, 2016.

SILVA, L. E. V.; JUNIOR, L. O. M. Evaluation of physiologic complexity in time series using generalized sample entropy and surrogate data analysis. **Chaos: An Interdisciplinary Journal of Nonlinear Science**, v. 22, n. 4, p. 043105, 2012.

TENG, Q. et al. A survey on the interpretability of deep learning in medical diagnosis. **Multimedia Systems**, v. 28, n. 6, p. 2335–2355, 2022.

TISHBY, N.; ZASLAVSKY, N. Deep learning and the information bottleneck principle. In: **IEEE Information Theory Workshop (ITW)**. [S.l.: s.n.], 2015. p. 1–5.

YANG, J. et al. MedMNIST v2 – a large-scale lightweight benchmark for 2D and 3D biomedical image classification. **Scientific Data**, v. 10, n. 1, p. 41, 2023.

YENTES, J. M. et al. The appropriate use of approximate entropy and sample entropy with short data sets. **Annals of Biomedical Engineering**, v. 41, n. 2, p. 349–365, 2013.

ZHANG, C. et al. Understanding deep learning requires rethinking generalization. In: **International Conference on Learning Representations (ICLR)**. [S.l.: s.n.], 2017.

ZHANG, J.; BELL, M. A. L. Overfit detection method for deep neural networks trained to beamform ultrasound images. **Ultrasonics**, v. 148, p. 107562, 2025.

Apêndices

APÊNDICE A – EXEMPLO NUMÉRICO DA ORDEM DE ACHATAMENTO DA CAMADA DENSA

Este apêndice complementa a Seção 3.5, rastreando, elemento a elemento, a correspondência entre a matriz de pesos de uma camada `Linear` do PyTorch e a sequência linear sobre a qual a SampEn_{1D} é calculada. Usa-se uma camada mínima, 2×3, primeiro na ordem por neurônio (Equação 3.1) e em seguida na ordem por entrada (Equação 3.2).

A.1 CAMADA LINEAR: MATRIZ 2×3

Considere uma camada `nn.Linear(in_features=3, out_features=2)` cujo tensor `weight` de *shape* $[\mathrm{Out}, \mathrm{In}] = [2, 3]$ recebe valores inteiros para facilitar o rastreamento:

$$W_{\mathrm{lin}} = \begin{pmatrix} w_{0,0} & w_{0,1} & w_{0,2} \\ w_{1,0} & w_{1,1} & w_{1,2} \end{pmatrix} = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{pmatrix}. \tag{A.1}$$

Aplicando `W_lin.flatten()` obtemos o vetor

$$W_{\mathrm{lin}}\texttt{.flatten()} = [\,1,\ 2,\ 3,\ 4,\ 5,\ 6\,]. \tag{A.2}$$

A Tabela 2 mostra a correspondência elemento a elemento. Note que a leitura é feita **linha por linha**: primeiro saem todos os três pesos de entrada do neurônio de saída $\mathrm{Out} = 0$, depois os três pesos do neurônio $\mathrm{Out} = 1$. Cada linha contígua do vetor corresponde a *um único neurônio de saída*.

Tabela 2 – Mapeamento elemento a elemento da camada Linear 2×3.

Posição no vetor	0 (→) 5	1	2	3	4
Elemento	$w_{0,0}$ $w_{1,2}$	$w_{0,1}$	$w_{0,2}$	$w_{1,0}$	$w_{1,1}$
Valor	1 6	2	3	4	5
Pertence a	**Saída** $\mathrm{Out} = 0$			**Saída** $\mathrm{Out} = 1$	

A.2 CONTRASTE: ORDEM POR ENTRADA

Transpondo a mesma matriz antes do achatamento, percorrem-se primeiro todos os pesos que partem da entrada In = 0, depois os da entrada In = 1, e assim por diante:

$$W_{\text{lin}}^{\top}.\texttt{flatten()} \;=\; [\,1,\; 4,\; 2,\; 5,\; 3,\; 6\,]. \tag{A.3}$$

Os dois vetores contêm exatamente os mesmos seis valores, e portanto o mesmo histograma: a complexidade LMC é idêntica nas duas ordens. O que muda é a vizinhança de cada valor, à qual a SampEn_{1D} é sensível.

A.3 REPRODUTIBILIDADE

Os vetores apresentados neste apêndice podem ser reproduzidos diretamente em PyTorch:

```
import torch

# Linear (Out=2, In=3)
W_lin = torch.tensor([[1., 2., 3.],
                      [4., 5., 6.]])
print(W_lin.flatten().tolist())      # ordem por neuronio
# [1.0, 2.0, 3.0, 4.0, 5.0, 6.0]
print(W_lin.t().flatten().tolist())  # ordem por entrada
# [1.0, 4.0, 2.0, 5.0, 3.0, 6.0]
```

APÊNDICE B – VALIDAÇÃO NUMÉRICA DAS MEDIDAS DE COMPLEXIDADE

Este apêndice cumpre a parte do objetivo específico 1 (Capítulo 1) referente à *validação numérica das medidas em casos analiticamente conhecidos*. As implementações descritas na seção 3.6 — complexidade LMC e *Sample Entropy* — são aplicadas a distribuições e séries cujo comportamento esperado é conhecido em forma fechada ou qualitativamente, verificando-se que os valores produzidos coincidem com a teoria. Todos os resultados desta seção são reproduzíveis executando `scripts/validacao_numerica.py` (semente 42, `numpy` 1.26); para a LMC fixou-se $N = 100$ *bins*, de modo que a entropia da uniforme tem valor de referência $\log_2 N \approx 6{,}6439$ bits.

B.1 COMPLEXIDADE LMC

Para a forma adotada $C = H \times D$, com H em bits e $D = \sum_i (p_i - 1/N)^2$, os dois extremos têm valor analítico exato: a distribuição *uniforme* maximiza a entropia ($H = \log_2 N$) e anula o desequilíbrio ($D = 0$), enquanto a distribuição *degenerada* (toda a massa em um único *bin*) anula a entropia ($H = 0$) e atinge $D = 1 - 1/N$; em ambos os casos $C = 0$. Uma distribuição *gaussiana* representa o regime intermediário, com $0 < H < \log_2 N$, $D > 0$ e, portanto, $C > 0$. A Tabela 3 confirma os três comportamentos.

Tabela 3 – Validação da LMC ($N = 100$ *bins*). Os casos uniforme e degenerado reproduzem os valores analíticos com precisão de máquina.

Distribuição	H (bits)	D	$C = H \times D$	Esperado
Uniforme	6,6439	0,00000	0,00000	$H = \log_2 N,\ D \approx 0,\ C \approx 0$
Degenerada	0,0000	0,99000	0,00000	$H = 0,\ D = 1 - 1/N,\ C = 0$
Gaussiana	5,4638	0,01646	0,08994	$0 < H < \log_2 N,\ D > 0,\ C > 0$

B.2 SAMPLE ENTROPY 1D

Com $m = 2$ e $r = 0{,}2\,\sigma$, uma série *constante* é perfeitamente regular e produz SampEn $= 0$ por definição; uma série *periódica* é altamente previsível e produz valor próximo de zero; *ruído branco gaussiano* maximiza a irregularidade e produz um valor finito e elevado, da ordem de 2,1 — compatível com o reportado na literatura para sinais sem estrutura sob essa parametrização. A Tabela 4 confirma a ordenação esperada.

Tabela 4 – Validação da SampEn 1D ($m = 2$, $r = 0{,}2\,\sigma$, séries de 1000 amostras).

Série	SampEn	Esperado
Constante	0,0000	0 (perfeitamente regular)
Periódica (seno, $T = 20$)	0,1864	≈ 0 (previsível)
Ruído branco gaussiano	2,0934	finito e elevado (irregular)

Em conjunto, as duas validações estabelecem que as implementações reproduzem os valores analíticos exatos nos extremos (LMC nas distribuições uniforme e degenerada; SampEn em séries constantes) e a ordenação qualitativa esperada nos regimes intermediários, sustentando o uso das medidas nas análises do Capítulo 4.